

Esercizio

Supponiamo di aver il seguente training set (ogni riga è un esempio di training).

Id	Frase
1	Udine is a city and one and two and three
2	Venezia is a city and just one and two

Ipotizziamo di aver definito il seguente vocabolario:

Parola	<i>Index</i>
Udine	1
is	2
a	3
city	4
and	5
one	6
two	7
three	8
Venezia	9
just	10

Scrivere la *rappresentazione Bag-of-Word* (BOW) corretta dei dati di Training. In particolare, si richiede di calcolare il valore BoW della parola all'indice 5 (and) per la frase con id=1

Risposta: 3

(vedi esercizio visto a lezione)

Esercizio

Supponiamo di voler costruire un Regressore Lineare e di aver il seguente training set (ogni riga è un esempio di training).

Id	x_1	x_2	x_3	x_4	x_5	y
1	1	1	1	1	0	0
2	0	1	1	1	1	5

Determinare il valore della funzione di costo J per la seguente ipotesi:

$$\theta_0 = 1.2; \theta_1 = 0.4; \theta_2 = 1.2; \theta_3 = 0.4; \theta_4 = 1; \theta_5 = 2$$

Approssimare il risultato alla seconda cifra decimale.

Risposta: 4.57

Cenni di soluzione:

The Cost Function:

$$J = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

.....

Nota, possibile variante: Calcolare la funzione di Costo di un Linear Regression in presenza di un *regularization term*; Calcolare la funzione di costo di un Logistic Regression; Calcolare la funzione di costo di un Logist Regression con *regularization term*; Calcolare la funzione di Costo di un SVM; Dato un punto calcolare la distanza euclidea dal Decision Boundary di un Logistic Regression/SVM.

Esercizio:

Supponiamo di volere addestrare un Regressore Lineare. Abbiamo a disposizione il seguente training set:

X_1	X_2	Y
3.1	7.5	5.96
4.2	2	8.2
7	5.5	9

Data la grandezza del training set decidiamo di utilizzare solo una delle due feature disponibili. Supponendo di aver già calcolato il Coefficiente di Correlazione $\rho_{X_2,Y}$ si determini il Coefficiente di Correlazione $\rho_{X_1,Y}$

Approssimare il risultato alla seconda cifra decimale.

Risposta: __0.87__

Cenni di soluzione:

$$\rho_{x,y} = \frac{1}{M-1} \sum_{i=1}^M \left(\frac{X_i - \mu_X}{\sigma_X} \right) \left(\frac{Y_i - \mu_Y}{\sigma_Y} \right)$$

dove μ_X and σ_X sono la media e la deviazione standard di X rispettivamente, e μ_Y and σ_Y sono la media e la deviazione standard di Y

Mean

- $\mu_X = \frac{1}{M} \sum_{i=1}^M X_i$

Standard Deviation

- $\sigma_X = \sqrt{\frac{1}{M-1} \sum_{i=1}^M |X_i - \mu_X|^2}$

$$\mu_{x_1} = 4.7667 \quad \sigma_{x_1} = 2.0108$$

$$\mu_y = 7.72 \quad \sigma_y = 1.5758$$

$$\rho_{x,y} = 0.8710$$

Esercizio

Supponiamo di aver collezionato un piccolo dataset composto da informazioni derivanti da 3 studenti che hanno frequentato un corso universitario:

Studente	Primo Parziale	Secondo Parziale	Totale minuti di presenza	Voto finale
1	30	30	3500	30
2	22	20	2800	24
3	19	25	1800	23

Supponiamo, inoltre, di voler utilizzare tale dataset per costruire un Regressore che permetta di stimare il voto finale utilizzando come *feature* i voti delle prove intermedie e il totale di minuti di presenza a lezione.

Per migliorare l'accuratezza del Regressore decidiamo, inoltre, di effettuare una *Mean Normalization* dei dati.

Completare la seguente tabella con i valori normalizzati:

Studente	Primo Parziale	Secondo Parziale	Totale minuti di presenza	Voto finale
1	1.113	1	0.936	1.144
2	-0.293	-1	0.117	-0.440
3	-0.820	0	-1.053	-0.704

Nota, possibile variante: Calcolare un singolo valore della tabella; utilizzare la funzione di normalizzazione *MinMax Normalization*.

Nota aggiuntiva *MinMax Normalization*:

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Esercizio

Supponiamo di aver addestrare un Logistic Regression, al fine di identificare automaticamente dei volti all'interno di immagini, e di voler calcolare le performance su un piccolo *test set* (vedi sotto):

Id	Input	Actual Class	Prediction
1	Immagine1	Face	Face
2	Immagine2	Face	Face
3	Immagine3	Face	No-Face
4	Immagine4	Face	Face
5	Immagine5	No-Face	No-Face
6	Immagine6	No-Face	No-Face
7	Immagine7	No-Face	No-Face
8	Immagine8	No-Face	No-Face

Calcolare la matrice di confusione corrispondente, Precision, Recall e F-score.

Cenni di soluzione:

		Predicted class	
		<i>P</i>	<i>N</i>
Actual Class	<i>P</i>	True Positives (TP)	False Negatives (FN)
	<i>N</i>	False Positives (FP)	True Negatives (TN)

3	1
0	4

$$P = \frac{TP}{TP + FP} = \frac{3}{3} = 1$$

$$R = \frac{TP}{FN + TP} = \frac{3}{4} = 0.75$$

$$F - Score = 2 \frac{P * R}{P + R} = \frac{3}{4} = 0.86$$
