

14 - FormularioML

In riferimento a *14 - FormularioML.pdf*

Linear Regression

Ipotesi

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

Funzione di costo

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

 Nota

Nella funzione di costo viene calcolato l'errore quadratico medio.

Polynomial Regression

Si utilizzano le stesse formule della **Linear Regression**, ma si considerano termini $x^2, x^3, \dots$

Gradient Descent

Ipotesi

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1$$

Formula generica

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

Aggiornamento per θ_0 :

$$\theta_{0_{\text{new}}} := \theta_0 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)$$

Aggiornamento per θ_1 :

$$\theta_{1_{\text{new}}} := \theta_1 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) \cdot x^{(i)}$$

Media e Deviazione Standard

Media

$$\mu_x = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$

Deviazione standard

$$\sigma = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (x^{(i)} - \mu_x)^2}$$

Normalization

Mean Normalization

(per ogni valore della tabella!)

$$x'_i = \frac{x_i - \mu_x}{\sigma}$$

Min-Max Normalization

(per ogni valore della tabella!)

$$x'_i = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

 Importante

Calcolare sempre i parametri (media, min, max, deviazione standard) **solo sul training set** e usarli anche per normalizzare il test set.

Coefficiente di Pearson

$$\rho_{X,Y} = \frac{1}{m-1} \sum_{i=1}^m \left(\frac{X_i - \mu_X}{\sigma_X} \cdot \frac{Y_i - \mu_Y}{\sigma_Y} \right)$$

Logistic Regression

Ipotesi

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Sigmoid function

$$g(z) = \frac{1}{1 + e^{-z}}$$

Funzione di costo

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

 **Nota**

- $-\theta^T x$ equivale a $-(\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n)$
- $\text{Cost} = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$

Metrics

Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Precision

$$P = \frac{TP}{TP + FP}$$

Recall

$$R = \frac{TP}{TP + FN}$$

F-score

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Bag of Words (BoW)

Si contano le occorrenze di ogni parola in una frase (o *documento*).

TF-IDF

Formula

$$tfidf(w, d) = tf \cdot \left(\ln \left(\frac{N+1}{N_w+1} \right) + 1 \right)$$

Dove:

- N = numero totale di documenti
- N_w = numero di documenti in cui compare w
- tf = frequenza del termine w nel documento d

Normalizzazione vettoriale (*L2 normalization*)

$$v_{norm} = \frac{v}{\|v\|_2} = \frac{v}{\sqrt{v_1^2 + v_2^2 + \dots + v_n^2}}$$

Esempio

$v = [3, 2, 1]$

$$\|v\|_2 = \sqrt{3^2 + 2^2 + 1^2} = \sqrt{14}$$

$$v_{norm} = \left[\frac{3}{\sqrt{14}}, \frac{2}{\sqrt{14}}, \frac{1}{\sqrt{14}} \right]$$

Ridge Regularization

Funzione di costo regolarizzata

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

Neural Network

Layer 1

$$z^{[1]} = W^{[1]}x + b^{[1]} \quad ; \quad a^{[1]} = g(z^{[1]})$$

Layer 2

$$z^{[2]} = W^{[2]}a^{[1]} + b^{[2]} \quad ; \quad a^{[2]} = g(z^{[2]})$$

Ultimo livello

Dipende dalla funzione di attivazione.

ReLU

Sia z il valore di input:

- Se $z \leq 0$, ritorna 0
- Se $z > 0$, ritorna z

Loss Functions

Binary Cross-Entropy

$$L(W, b) = \frac{1}{m} \sum_{i=1}^m \left[-y^{(i)} \log \left(h_{W,b}(x^{(i)}) \right) - \left(1 - y^{(i)} \right) \log \left(1 - h_{W,b}(x^{(i)}) \right) \right]$$

m = numero di esempi contenuti nel training set.

Mean Squared Error (MSE)

$$L(W, b) = \frac{1}{m} \sum_{i=1}^m \left(h_{W,b}(x^{(i)}) - y^{(i)} \right)^2$$

m = numero di esempi contenuti nel training set.

Softmax

$$a^{[i]} = \frac{e^{z^{[i]}}}{\sum_{j=1}^N e^{z_j^{[i]}}} \quad \text{dove } N \text{ è il numero di classi}$$

Esempio

$$z^{[i]} = \begin{bmatrix} 5 \\ 2 \\ -1 \\ 3 \end{bmatrix} \Rightarrow a^{[i]} = \frac{1}{\tau} \begin{bmatrix} e^5 \\ e^2 \\ e^{-1} \\ e^3 \end{bmatrix} \quad \text{con } \tau = e^5 + e^2 + e^{-1} + e^3$$

$$\Rightarrow a^{[i]} = \begin{bmatrix} 0.842 \\ 0.042 \\ 0.002 \\ 0.114 \end{bmatrix}$$

Cross-Entropy Loss (Multi-class)

$$L(W, b) = - \sum_{i=1}^m y^{(i)} \log \left(h_{W,b}(x^{(i)}) \right)$$

Dove:

- m è il numero di esempi nel dataset
- $y^{(i)}$ è la distribuzione vera (one-hot) per l'esempio i
- $h_{W,b}(x^{(i)})$ è la distribuzione predetta dalla rete per l'input $x^{(i)}$

SVM

Funzione di costo

$$\min_{W,b} \frac{W^T W}{2}$$

soggetta al seguente vincolo:

$$y_i(W^T x_i + b) \geq 1 \quad \text{per ogni } x_i$$

Margine

$$x_2 = x_1 + \lambda W$$
$$\lambda = \frac{2}{W^T W} = \frac{2}{\|W\|^2}$$

Distanza fra x_1 e x_2 (distanza tra margini)

$$\|\lambda W\| = \lambda \|W\| = \frac{2}{\|W\|^2} \cdot \|W\| = \frac{2}{\|W\|} = \frac{2}{\sqrt{W^T W}}$$

Distanza punto retta

$$d(p, R) = \frac{|ax_p + by_p + c|}{\sqrt{a^2 + b^2}}$$

Kernel Gaussiano

$$f_1 = \text{similarity}(x, l^{(1)}) = \exp\left(\frac{-\sum_{j=1}^n (x_j - l_j^{(1)})^2}{2\sigma^2}\right)$$

Clustering

K-Means

Nuovo centroide di un cluster (cluster Cl_i)

$$\text{Nuovo Centroide}_{Cl_i} = \left(\frac{1}{n} \sum_{j=1}^n x_j \in Cl_i, \frac{1}{n} \sum_{j=1}^n y_j \in Cl_i \right)$$

Distanza euclidea

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

DBSCAN

Parametri:

- ϵ : raggio
- minPts: min. punti in ϵ -vicinato

Tipi di punti:

- **Core**: $|N_\epsilon(p)| \geq \text{minPts}$
- **Border**: $|N_\epsilon(p)| < \text{minPts}$ ma vicino a un core
- **Rumore**: né core né border

Hierarchical Agglomerative Clustering

Single link: prendo, tra cluster diversi, le distanze tra i punti più **vicini**, poi scelgo la distanza **minima** tra quelle trovate.

Complete link: prendo, tra cluster diversi, le distanze tra i punti più **lontani**, poi scelgo la distanza **minima** tra quelle trovate.

Average: prendo tutte le distanze tra i punti di due cluster diversi, calcolo la **media** di queste distanze, poi scelgo la **media minima** tra quelle trovate.

PCA

Calcolo della matrice di covarianza

$$\Sigma = \frac{1}{m} \sum_{i=1}^m x^{(i)} (x^{(i)})^T$$

Decomposizione ai valori singolari (SVD)

$$[U, S, V] = \text{svd}(\Sigma)$$

Matrice U (autovettori)

$$U = \begin{bmatrix} | & | & & | \\ u^{(1)} & u^{(2)} & \dots & u^{(n)} \\ | & | & & | \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Proiezione nei primi k autovettori

$$U_{\text{reduce}} = U(:, 1:k)$$

Proiezione del dato nel nuovo spazio (z)

$$z = U_{\text{reduce}}^T x$$

Ricostruzione approssimata del dato originale

$$x_{\text{approx}} = U_{\text{reduce}} z$$

Anomaly Detection

Media e varianza per feature (feature j)

$$\mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)} \quad \sigma_j^2 = \frac{1}{m} \sum_{i=1}^m \left(x_j^{(i)} - \mu_j \right)^2$$

Distribuzione gaussiana univariata

$$p(x) = \frac{1}{\sigma \cdot \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Multivariata (assumendo indipendenza tra feature)

$$p(\vec{x}) = \prod_{j=1}^n p(x_j; \mu_j, \sigma_j^2)$$