

Statistica descrittiva

Gianluca Fava

Settembre 2022

Indice

1	Cos'è la statistica?	1
2	Passi principali di una analisi statistica	2
3	Dati	2
3.1	Unità statistiche e popolazione	2
4	Statistica descrittiva	2
4.1	Variabili	3
4.2	Frequenze	3
4.2.1	Frequenza assoluta	3
4.2.2	Frequenza relativa	4
4.2.3	Frequenza cumulata	4
4.3	Grafici	4
4.4	Indici sintetici	6
4.4.1	Indici di posizione	6
4.4.2	Indici di variabilità	8
4.4.3	Simmetria e curtosi	9
5	Analisi multivariate	10
5.1	Distribuzioni di frequenza	10
5.2	Grafici	10
5.3	Dipendenze	10
5.3.1	Studio della dipendenza	10
5.3.2	Analisi dipendenze	10
5.3.3	Indice di connessione	11
5.3.4	Dipendenza in media	11
5.4	Analisi di correlazione	11
5.4.1	Covarianza	11
5.4.2	Coefficiente di correlazione lineare	12
5.5	Analisi di regressione	12
5.5.1	Regressione lineare semplice	12
5.6	Minimi quadrati	12
5.6.1	Coefficiente di determinazione	13

1 Cos'è la statistica?

"Statistics is the science of learning from data, and of measuring, controlling, and communicating uncertainty"

- Per studiare un fenomeno spesso serve un'analisi di informazioni espresse in **forma quantitativa: dati**;
- La statistica è **di supporto** per molte discipline: economia, finanza, medicina, biologia...
- La statistica **fornisce strumenti** per evidenziare aspetti rilevanti nascosti nei dati e per quantificare la forza delle conclusioni che si possono dedurre dalle analisi.

2 Passi principali di una analisi statistica

- **Formulazione del problema:** studiare il contesto, specificare gli obbiettivi dell'analisi, tradurre il problema in termini matematico-statistici.
- **Raccogliere e organizzare i dati:** dati osservazionali o sperimentali, unità statistiche, dati mancanti, codifica e organizzazione dei dati.
- **Analisi iniziale dei dati:** sintesi numeriche e grafiche per iniziare a esplorare i dati.
- **Analisi completa dei dati.**
- **Presentazione dei risultati.**

3 Dati

I dati si possono ottenere tramite **osservazione** o **sperimentazione**:

- **Dati osservazionali:** dati già **esistenti in natura** e se ne osservano le caratteristiche (visite a un sito web in un determinato periodo, età-statura-genere dei residenti di un comune).
- **Dati sperimentali:** dati inesistenti, vengono **creati con esperimenti** (scientifici, medici, indagini di mercato).

3.1 Unità statistiche e popolazione


Una **popolazione** è una collezione di **unità statistiche** (es. classe = popolazione, studente = unità statistica).

- **Popolazione reale:** unità statistiche con **esistenza fisica**, possono essere rilevate con un **censimento** (completa) o con un **campione** (parziale).
- **Popolazione virtuale:** unità che hanno un **esistenza concettuale**, di solito riferito all'ambito sperimentale, sono potenzialmente **infinite** ed estimabili solo in modo parziale (**campionamento**).

Con il **censimento** si esaminano tutte le unità di una *popolazione reale*, con determinate caratteristiche.

Con il **campionamento** si esamina un sottoinsieme finito di unità statistiche di *popolazione reale* o *virtuale* con determinate caratteristiche.

La scelta dei campioni è casuale: ci sono più esiti possibili e prima dell'esperimento non si può individuare con certezza quale campione verrà selezionato (**variabilità campionaria**).



- **La statistica descrittiva:** (analisi esplorativa dei fatti) fornisce metodi per descrivere e presentare i dati disponibili per individuare la struttura essenziale.
- **La statistica inferenziale:** fornisce metodi per ricavare dai dati campionari delle informazioni sulla popolazione di riferimento e per quantificare la fiducia da dare a quelle informazioni: si possono trarre delle conclusioni non vere, quindi tramite il calcolo delle probabilità si valuta il grado di **incertezza**.

4 Statistica descrittiva

La statistica descrittiva ha l'obbiettivo di descrivere e sintetizzare i dati.

- Può essere un'analisi **univariata** (singola variabile) o **multivariata** (più variabili).
- Molte volte viene usata per un **analisi preliminare**: come sono i dati raccolti, ripulire il data-set, sistemare i dati in una forma migliore per l'analisi, ricavare informazioni preliminari con grafici.

4.1 Variabili

Una **variabile** è una caratteristica d'interesse.

Le **modalità** sono valori che una variabile può assumere (Numeri, caratteri,...).

- Y = generica variabile
- y = generica modalità
- Y = insieme delle possibili modalità

Ci sono 2 tipi di variabili:

- **Variabili qualitative** (categoriali): espresse in forma verbale
 - sconnesse: non ordinabili (colore degli occhi, genere);
 - ordinali: ordinabili (età, livello di istruzione).
- **Variabili quantitative** (numeriche): espresse in forma numerica
 - discrete: Y è un insieme finito o numerabile (età, numero di figli);
 - continue: Y è un insieme continuo (distanza, altezza).

Possono essere su:

- scale di intervalli: non esiste uno zero naturale (temperature)
- scale di rapporti: esiste uno zero naturale con tali caratteristiche (Reddito)

La **variabile statistica** è la rilevazione $(y_1, \dots, y_i, \dots, y_n)$ di una certa caratteristica (variabile) Y su una determinata popolazione (campione), n rappresenta il numero di unità.

Il **supporto di una variabile statistica** Y (S_Y), è l'insieme delle modalità di Y osservate nella popolazione (campione): $S_Y = \{y_1, \dots, y_j, \dots, y_J\}$ (con $J \leq n$).

4.2 Frequenze

Le frequenze servono per sintetizzare i dati raccolti per avere risultati più semplici da confrontare e capire.

4.2.1 Frequenza assoluta

Se una delle modalità osservate di Y è: $y_j \in S_Y$, con $j = 1, \dots, J$; la **frequenza assoluta** di y_j è il numero di volte che y_j risulta osservata e si indica con f_i .

Quindi si avrà che: $f_i > 0$, $j = 1, \dots, J$, $\sum_{j=1}^J f_i = n$.

La **distribuzione di frequenza assoluta** è la lista delle modalità osservate accompagnate dalle rispettive frequenze assolute, viene rappresentata in una **tabella di frequenza** come:

Modalità	y_1	$\dots$	y_j	$\dots$	y_J	Totale
Frequenza	f_1	$\dots$	f_j	$\dots$	f_J	$\sum_{j=1}^J f_j$

Quando una tabella di frequenza è riferita ad una variabile statistica qualitativa è detta **serie statistica**, per non dover avere troppe modalità distinte si usano le **classi di modalità**: degli *intervalli* di una modalità di un carattere quantitativo.

Le classi possono avere *ampiezza diversa* (anche infinita), devono coprire tutti i dati osservati e non devono sovrapporsi. In questo modo si può ottenere una tabella di frequenza assoluta con modalità raggruppate in classi (**seriazione statistica**):

Classi	$y_0 \dashv y_1$	$\dots$	$y_{j-1} \dashv y_j$	$\dots$	$y_{J-1} \dashv y_J$	Totale
Freq.	f_1	$\dots$	f_j	$\dots$	f_J	$\sum_{j=1}^J f_j$

4.2.2 Frequenza relativa

La **frequenza relativa** di una modalità y_j , o di una classe di modalità $y_{j1} \vdash y_j$, è la proporzione p_j di unità statistiche portatrici di quella modalità o classe di modalità:

$$p_j = \frac{f_i}{\sum_{j=1}^J f_i} = \frac{f_i}{n}, \quad j = 1, \dots, J$$

Quindi si avrà: $p_j > 0$, $j = 1, \dots, J$, $\sum_{j=1}^J p_j = 1$.
 $p_j * 100 =$ **frequenze relative percentuali**.

Le frequenze relative sono utili per capire il **peso delle varie modalità** e fare **confronti tra diverse popolazioni**: si ha una rappresentazione immediata sul totale.

Se $S_Y = \{y1\}$, allora $J = 1$, $f_1 = n$, $p_1 = 1$ e la variabile statistica Y è detta **degenere** (la distribuzione di probabilità è concentrata in un unico valore).

4.2.3 Frequenza cumulata

Le **frequenze cumulate** sono utilizzabili solo con modalità ordinabili, vengono usate per elaborazioni su frequenze con una certa utilità o per **impostare una quota di osservazione** (numero di persone/percentuale inferiore alla quota X).

- **Frequenza assoluta cumulata** (F_j): frequenza assoluta di modalità o classi di modalità non superiori alla j-esima:

$$F_j = \sum_{i=1}^j f_i \quad \text{con } j = 1, \dots, J$$

- **Frequenza relativa cumulata** (P_j): frequenza relativa di modalità o classi di modalità non superiori alla j-esima:

$$P_j = \sum_{i=1}^j p_i \quad \text{con } j = 1, \dots, J$$

Quindi si avrà: $F_1 = f_1$, $F_J = n$, $P_1 = p_1$, $P_J = 1$.


Serie storica: quando si misura un fenomeno nel **tempo**, si ottiene una distribuzione di frequenza: **serie storica** (temporale).

Serie spaziale: quando si misura un fenomeno nello **spazio**, si ottiene una distribuzione di frequenza: **serie spaziale** (territoriale).

4.3 Grafici


1. Variabili non numeriche:

A- Diagramma a torta:



Per serie statistiche sconnesse (su dati quantitativi o ordinali)
L'area del cerchio è proporzionale alle frequenze delle modalità


B- Bar plot:



Utile per serie statistiche sconnesse
Le altezze dei rettangoli sono proporzionali alle frequenze delle modalità; le basi hanno la stessa dimensione e sono separate.


2. Variabili numeriche:

A- Diagrammi a bastoncini:



Per rappresentare distribuzioni di frequenza assoluta o relativa. L'altezza dei bastoncini è proporzionale o pari alla frequenza, assoluta o relativa, della modalità.


B- Istogrammi:



Per rappresentare distribuzioni di frequenza assoluta o relativa con modalità raggruppate in classi.

La base coincide con la classe e l'area è proporzionale alla frequenza: $h = \frac{\text{Frequenza}}{\text{Classe}} = \frac{\text{Area}}{\text{Base}}$ (se le classi sono tutte uguali, posso usare l'altezza effettiva dal grafico).

- Poligoni di frequenza:



Tentativo di lisciare / smussare i dati dell'istogramma per tornare alla forma continua dei dati originali.

Il poligono si ottiene unendo i punti di mezzo dei lati superiori dei rettangoli dell'istogramma con una linea spezzata.

- Stima della densità:


Stima della distribuzione delle frequenze tramite una curva più smussata.

La funzione che rappresenta la stima della densità con il metodo del nucleo è:


$$f_n(y) = \frac{1}{nb} \sum_{i=1}^n K\left(\frac{y-y_1}{b}\right), \quad y \in R$$

Dove:

- **K** = nucleo (Kernel): ce ne sono molteplici, ma devono soddisfare $K(u) \leq 0$ e $\int u^2 K(u) du = 1$;
- **b** > 0 = banda: **b** troppo grande = grafico appiattito, **b** troppo piccolo = grafico che si avvicina ad uno a bastoncini.



- Funzione di ripartizione empirica:




Si usa per rappresentazioni grafiche di dati quantitativi, utile per rappresentare frequenze relative cumulate, il valore della funzione nel punto $y \in R$ è:

$$F_n(y) = \frac{n^\circ \text{ osservazioni} \leq y}{n^\circ \text{ totale osservazioni}}, \quad y \in R$$

Al variare di y fornisce la proporzione cumulata di unità statistiche che presentano valori minori o uguali a y (è una funzione a gradini).

C- Diagrammi di dispersione (scatterplot):



Per rappresentare due variabili quantitative; il diagramma si ottiene rappresentando i punti di x e y in un piano cartesiano. Per più di due variabili, si possono ottenere i diagrammi di dispersione per ogni coppia di variabili.

4.4 Indici sintetici

Gli indici statistici servono per descrivere particolari aspetti del dataset.

Per farlo si indaga sulla **posizione**, sulla **variabilità** e la **distribuzione di frequenza** (la simmetria e la curtosi).

4.4.1 Indici di posizione

1. **Media aritmetica** - $E(Y)$: si può calcolare per una *variabile quantitativa* Y e non si calcola per dati categoriali. Si indica anche con μ_Y o μ .

La media è un **indice non robusto** perchè se ci sono dati errati viene sballata di molto.

A- **Calcolo**: in base ai dati che si hanno:

- **dati grezzi**:

$$E(Y) = \frac{1}{n} \sum_{i=1}^n y_i = \frac{y_1 + y_2 + \dots + y_n}{n}$$

- **tabella di frequenza assoluta o relativa**:

$$E(Y) = \frac{1}{n} \sum_{i=1}^J y_i f_i = \sum_{i=1}^J y_i p_i = y_1 p_1 + y_2 p_2 + \dots + y_n p_n$$

- **tabella di frequenza assoluta o relativa con modalità raggruppate in classi**: si calcola il punto centrale $y_i^c = (y_{j-1} + y_j)/2$, $j = 1, \dots, J$ delle singole classi (per ogni modalità) e:

$$E(Y) = \frac{1}{n} \sum_{i=1}^J y_i^c f_i = \sum_{i=1}^J y_i^c p_i = (y_1^c p_1) + (y_2^c p_2) + \dots + (y_n^c p_n)$$

B- **Proprietà**:

- **Cauchy**: la media è un valore che sta sempre tra il più piccolo e il più grande dei valori osservati.

$$\text{Se: } S_Y = y_1, \dots, y_J \text{ con } y_1 < \dots < y_J \Rightarrow y_1 < E(Y) < y_J$$

- **Baricentro**: i dati shiftati hanno media zero. Sia $Y - E(Y)$ la variabile di scarto di Y dalla sua media $E(Y)$, allora:

$$E(Y - E(Y)) = 0$$

- **Linearità:** la media è un operatore lineare. Sia $aY + b : a, b \in R$, una trasformata lineare della variabile Y , allora:

$$E(aY + b) = aE(Y) + b$$

2. **Mediana** - $y_{0.5}$: si può calcolare per una *variabile qualitativa ordinale* o *quantitativa* Y . Si indica anche con Y_α .

La mediana è un **indice robusto** perchè i valori sballati vanno a finire alla fine della "rampa" e quindi la mediana cambia al più di 1 posizione.

A- **Calcolo:** è il valore centrale preso ordinando i valori dal minimo al massimo (due parti uguali a destra e sinistra). In base ai dati che si hanno:

- **dati grezzi:** con $y_1, \dots, y_n$ ordinati in modo crescente,
 - * se n è dispari: posizione $\frac{(n+1)}{2}$;
 - * se n è pari: posizioni $\frac{n}{2}$ e $\frac{n}{2} + 1$; (se i valori sono diversi, si possono avere 2 mediane)
- **frequenze assolute** f_i : con $j = 1, \dots, J$
 - * se n è dispari: alla modalità y_j con la frequenza assoluta cumulata $F_j \geq \frac{(n+1)}{2}$;
 - * se n è pari: alle modalità y_j con la frequenza assoluta cumulata più piccola tale che $F_j \geq (\frac{n}{2})$ e $F_j \geq (\frac{n}{2}) + 1$; (se i valori sono diversi, si possono avere 2 mediane)
- **frequenze relative** p_j : con $j = 1, \dots, J$ corrisponde alla modalità y_j con frequenza relativa cumulata $P_j \geq 0.5$. Se c'è una modalità tale che $P_j = 0.5$ allora si prende y_j e y_{j+1} .

3. **Quantili** - α : si può calcolare per una *variabile qualitativa ordinale* o *quantitativa* Y .

A- **Tipologie:** il valore $y_\alpha \in (0, 1)$, rispetto all'ordinamento crescente delle osservazioni sarà preceduta da $\alpha 100\%$ osservazioni e sarà seguita da $(1 - \alpha) 100\%$ osservazioni:

- **Mediana:** $\alpha = 0.5$ divide le osservazioni in 2 parti uguali.
- **Quartile:** $\alpha = 0.25, 0.5, 0.75$ dividono le osservazioni in 4 parti uguali.
- **Decile:** $\alpha = 0.10, 0.20, \dots, 0.90$ dividono le osservazioni in 10 parti uguali.
- **Percentile:** $\alpha = 0.01, 0.02, \dots, 0.99$ dividono le osservazioni in 100 parti uguali.


B- **Calcolo:** in base ai dati che si hanno:

- **dati grezzi:** $y_1, \dots, y_n$ ordinati in modo crescente, $y_\alpha = \alpha(n + 1)$
 - * se si ottiene un valore intero, y_α è la modalità in posizione $\alpha(n + 1)$.
 - * se si ottiene un valore non intero, y_α sono le modalità corrispondenti a valori interi che seguono e precedono $\alpha(n + 1)$.
- **frequenze assolute** f_i : con $j = 1, \dots, J$
 - * se n è dispari: alla modalità y_j con la frequenza assoluta cumulata $F_j \geq \frac{(n+1)}{2}$
 - * se n è pari: alle modalità y_j con la frequenza assoluta cumulata $F_j \geq (\frac{n}{2})$ & $(\frac{n}{2} + 1)$
- **frequenze relative** p_j : con $j = 1, \dots, J$ corrisponde alla modalità y_j con frequenza relativa cumulata $P_j \geq \alpha$. Se c'è una modalità tale che $P_j = \alpha$ allora si prende y_j e y_{j+1} .

4. **Moda** - y_{mo} : si può calcolare per una *variabile qualitativa* o *quantitativa* Y .

Corrisponde alla modalità che si ripete più volte, è un **indice molto grezzo**.

Boxplot:



Serve per rappresentare graficamente l'insieme di dati basato sui quantili. È formato da:

- **scatola:** contiene il 50% dei dati, sta tra il primo quartile $y_{0.25}$ e il terzo quartile $y_{0.75}$.
- **linea dentro la scatola:** mediana ($y_{0.5}$)
- **baffi:** inferiore $y_{0.01}$ e superiore $y_{0.99}$, indicano il valore minimo e massimo dei dati osservati (outliers); serve per evidenziare i valori anomali.

4.4.2 Indici di variabilità

La **variabilità** riferita a una variabile statistica indica la **diversificazione** delle modalità osservate e la **distanza** tra loro. Per misurarla ci sono gli *indici di variabilità*:

1. **campo di variazione (range)** - R_Y : è la **differenza tra l'osservazione più grande e la più piccola**, è un metodo **grezzo**. Se Y è degenere, $R_Y = 0$; altrimenti $R_Y > 0$.

$$R_Y = y_{(n)} - y_{(1)}$$

2. **scarto tra quantili** - SI_Y : è la **differenza tra il terzo e il primo quartile** (la dimensione della scatola nel boxplot), è un metodo **grezzo**. SI_Y può essere nullo anche per variabili non degeneri.

$$SI_Y = y_{0.75} - y_{0.25}$$

3. **varianza** - $V(Y)$: è la media aritmetica della variabile scarto $Y - E(Y)$ elevata al quadrato, misura la **dispersione dei dati attorno alla media**. Se i valori sono tutti uguali la varianza è 0.

$$V(Y) = E[(Y - E(Y))^2]$$

Si può indicare anche con σ_Y^2 oppure σ^2 .

Lo **scarto quadratico medio** di Y (σ_Y oppure σ), è la radice quadrata (positiva) della varianza:

$$\sigma_Y = \sqrt{E[(Y - E(Y))^2]} = \sqrt{V(Y)}$$

A- **Calcolo:** in base ai dati che si hanno:

- **Dati grezzi:** $Y = (y_1, \dots, y_n)$, si calcola $E(Y)$ e

$$V(Y) = \frac{1}{n} \sum_{i=1}^n (y_i - E(Y))^2$$

- **Frequenza assoluta/relativa:**

$$V(Y) = \frac{1}{n} \sum_{j=1}^J (y_j - E(Y))^2 f_j = \sum_{j=1}^J (y_j - E(Y))^2 p_j$$

- **Frequenza assoluta o relativa con modalità raggruppate in classi:** si calcola il punto centrale $y_j^c = (y_{j-1} + y_j)/2, j = 1, \dots, J$ delle singole classi (per ogni modalità) e:

$$V(Y) = \frac{1}{n} \sum_{j=1}^J (y_j^c - E(Y))^2 f_j = \sum_{j=1}^J (y_j^c - E(Y))^2 p_j$$

B- Proprietà:

- **non negatività:** la varianza non è mai negativa ed è nulla solo se Y è degenere:

$$V(Y) \geq 0, \text{ con } V(Y) = 0 \Leftrightarrow Y \text{ è degenere}$$

- **formula per il calcolo:**

$$V(Y) = E(Y^2) - (E(Y))^2$$

- **invarianza per traslazioni:** la varianza rimane uguale anche shiftando il dataset

$$V(Y + b) = V(Y), \text{ con } b \in R$$

- **omogeneità di secondo grado:**

$$V(aY) = a^2 V(Y), \text{ con } a \in R$$

Quindi se:

$$E(Y) = 0 \Rightarrow V(Y) = E(Y^2)$$

$$V(aY + b) = a^2 V(Y)$$

4. **coefficiente di variazione** - CV_Y : è un numero puro (**scarto quadratico medio / media aritmetica**) che serve per misurare la **variabilità** riferita a 2 fenomeni molto diversi tra loro (unità di misura diverse o con valori medi molto distanti):

$$CV_Y = \frac{\sigma_Y}{\mu_Y}$$

A- **standardizzazione:** una variabile statistica con $E(Y) = 0$ e $V(Y) = 1$ è standardizzata (con grandi quantità di dati è utile standardizzare):

- la media: $E\left(\frac{Y-\mu}{\sigma}\right) = \frac{1}{\sigma} E(Y - \mu) = 0$

- la varianza: $V\left(\frac{Y-\mu}{\sigma}\right) = \frac{1}{\sigma^2} V(Y) = 1$

La standardizzazione dei dati serve per **far emergere più chiaramente** ulteriori caratteristiche della distribuzione di frequenza, oltre la posizione e la variabilità.

4.4.3 Simmetria e curtosi

1. **Simmetria e asimmetria:** una distribuzione di frequenza è **simmetrica** se la sua metà di destra si sovrappone alla sua metà di sinistra.

Una distribuzione di frequenza **asimmetrica** avrà una coda più lunga dell'altra; può essere sia positiva che negativa: coda destra più lunga = *asimmetria positiva*, coda sinistra più lunga = *asimmetria negativa*.

Per calcolarle:

A- confronto media/mediana:

- simmetria: media $\approx$ mediana
- asimmetria positiva: media $>$ mediana
- asimmetria negativa: media $<$ mediana
- a distribuzione di frequenza unimodale e simmetrica: media $\approx$ mediana $\approx$ moda

B indice di simmetria:

$$\gamma_Y = \frac{E[(Y - E(Y))^3]}{\sigma_Y^3} = \frac{\frac{1}{n} \sum_{i=1}^n (y_i - E(Y))^3}{\sigma_Y^3}$$

- simmetria: $\gamma_Y \approx 0$
- asimmetria positiva: $\gamma_Y > 0$
- asimmetria negativa: $\gamma_Y < 0$

2. **Curtosi: pesantezza delle code:** allontanamento dalla distribuzione di frequenza normale, gaussiana.

Distribuzione platicurtica (ipornormale): code leggere (la curva nelle code tende ad appiattirsi).

Distribuzione leptocurtica (ipernormale): code pesanti (la curva nelle code tende ad allungarsi).

Per il calcolo:

A- indice di curtosi:

$$\beta_Y = \frac{E[(Y - E(Y))^4]}{\sigma_Y^4} = \frac{\frac{1}{n} \sum_{i=1}^n (y_i - E(Y))^4}{\sigma_Y^4}$$

- normocurtica: $\beta_Y \approx 3$
- leptocurtica: $\beta_Y > 3$
- platicurtica: $\beta_Y < 3$

5 Analisi multivariate

Serve a fare uno **studio congiunto** di più variabili e a mettere insieme due o più fenomeni per confrontarli; è importante lo studio delle **potenziali relazioni esistenti** tra le due variabili in esame.

5.1 Distribuzioni di frequenza

Con 2 variabili X e Y che forniscono i dati grezzi (x_i, y_i) , si possono fare operazioni con:

- **distribuzione congiunta**: considerando le frequenze delle unità che presentano congiuntamente la modalità x_r , $r = 1, \dots, m$ di X e la modalità y_s , $s = 1, \dots, k$, di Y ;
- **distribuzione marginale**: considerando la distribuzione di frequenza relativa ad una sola variabile;
- **distribuzione condizionata**: considerando una sola condizione (modalità) della distribuzione di frequenza relativa ad una singola variabile.

5.2 Grafici

Si possono usare i grafici dell'analisi univariata o loro estensioni tridimensionali:

- **Dati grezzi**: scatterplot.
- **Distribuzione di frequenza congiunta**: istogrammi o diagrammi a bastoncini, disegnati in uno spazio tridimensionale.
- **Distribuzione di frequenza marginale o condizionata**: tutte i grafici visti nell'analisi univariata.

5.3 Dipendenze

5.3.1 Studio della dipendenza

Ci sono tre situazioni tipiche:

- le due variabili sono **qualitative**: *analisi di dipendenza* (o connessione);
- una variabile è **qualitativa** e l'altra **quantitativa**: *analisi di dipendenza in media*;
- le due variabili sono **quantitative**: *analisi di correlazione* e *analisi di regressione*.

Se si hanno più di 2 variabili si possono analizzare a coppie e poi usare i metodi più generali della statistica multivariata per un'analisi complessiva.

5.3.2 Analisi dipendenze

Date 2 variabili X, Y *qualitative categoriali*, si indaga sull'esistenza di associazione (**dipendenza**) tra le modalità corrispondenti.

La **tabella di contingenza** descrive la frequenza delle modalità (categorie) di due variabili quantitative X, Y vengono osservate assieme:

	y_1	y_2	$\dots$	y_k		frequenza assoluta :
x_1	n_{11}	n_{12}	$\dots$	n_{1k}	n_{1+}	● congiunta
x_2	n_{21}	n_{22}	$\dots$	n_{2k}	n_{2+}	● marginale
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	
x_m	n_{m1}	n_{m2}	$\dots$	n_{mk}	n_{m+}	
	n_{+1}	n_{+2}	$\dots$	n_{+k}	n	

Da questa tabella si ottengono le distribuzioni di frequenza assoluta:

- **congiunta:** $(x_r, y_s), n_{rs}, r = 1, \dots, m, s = 1, \dots, k$
- **marginale di X:** $x_r, n_{r+}, r = 1, \dots, m$
- **marginale di Y:** $y_s, n_{+s}, s = 1, \dots, k$
- **condizionata di X dato Y = y_s:** $n_{rs}, r = 1, \dots, m$
- **condizionata di Y dato X = x_r:** $n_{rs}, s = 1, \dots, k$

Le **frequenze marginali** di X e di Y corrispondono, rispettivamente, alla somma delle righe e delle colonne. Le **frequenze condizionate** di X e di Y corrispondono, rispettivamente, ai valori di colonna e di riga individuati dalle condizioni $Y = y_s$ e $X = x_r$; (isolando la riga/colonna di quella modalità). Le **distribuzioni di frequenza relativa** si ottengono dividendo per i corrispondenti totali (*congiunte* e *marginali*: diviso n ; *condizionate*: diviso i totali di riga o di colonna corrispondenti alla condizione).

5.3.3 Indice di connessione

Si dice **indipendenza statistica** se tutte le distribuzioni condizionate di Y dato $X = x_r$, sono uguali, e quindi uguali alla distribuzione marginale di Y.

Per misurare come sono legate le 2 variabili:

$$n_{rs} = \frac{n_{r+}n_{+s}}{n} \quad r = 1, \dots, m \quad s = 1, \dots, k$$

$$\frac{n_{rs}}{n} = \frac{n_{r+}}{n} \frac{n_{+s}}{n}, \quad r = 1, \dots, m \quad s = 1, \dots, k$$

L'**indice di connessione** misura la distanza tra le frequenze osservate in una tabella di contingenza (n_{rs}) e le frequenze attese nel caso di indipendenza (n_{rs}^*):

$$\chi^2 = \sum_{r=1}^m \sum_{s=1}^k \frac{(n_{rs} - n_{rs}^*)^2}{n_{rs}^*}, \quad n_{rs}^* = \frac{n_{r+}n_{+s}}{n}$$

Se le due tabelle sono uguali (**indipendenza fra le due variabili**) l'indice vale 0.

Il massimo che si può avere è $n * \min(m-1, k-1)$ (dove m, k sono le dimensioni delle righe e colonne della tabella di contingenza).

Per valutare la **forza dell'eventuale dipendenza** tra X e Y si normalizza χ^2 dividendo il suo valore assoluto per il suo massimo: $\chi_{norm}^2 = \frac{|\chi^2|}{n * \min(m-1, k-1)}$

5.3.4 Dipendenza in media

L'**indipendenza in media** è una forma debole di indipendenza nella quale si considera solo la media della Y e non la sua distribuzione di frequenza.

Due variabili Y ed X sono **indipendenti in media** se la media condizionata di Y dato X è la stessa per ogni valore assunto da X:

$$E(Y|X = x_r) = E(Y) \quad \forall x_r, r = 1, \dots, m$$

Se le varie medie condizionate sono diverse, allora le due variabili si diranno **dipendenti in media**.

Se due variabili sono indipendenti allora saranno anche indipendenti in media.

5.4 Analisi di correlazione

5.4.1 Covarianza

La **covarianza** è il simbolo della **crescenza/decrescenza** del legame lineare tra *variabili quantitative*.

Non importa se X influenzi Y o il contrario, si analizza la loro relazione senza il verso di dipendenza.

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - E(X))(y_i - E(Y)) = E(XY) - E(X)E(Y)$$

Se $(x_i - E(X))$ e $(y_i - E(Y))$ sono di segno uguale, si avrà covarianza positiva (**relazione lineare crescente**), se sono diversi sarà negativa (**relazione lineare decrescente**).

La covarianza si indica anche con σ_{XY} perchè $V(X) = \sigma_X^2 = \sigma_{XX}$.

La covarianza è sempre compresa tra $-\sigma_X\sigma_Y$ e $\sigma_X\sigma_Y$.

5.4.2 Coefficiente di correlazione lineare

Il **coefficiente di correlazione lineare** aiuta ad **analizzare la dipendenza lineare**, è molto sensibile a dati anomali, va da -1 a $+1$:

$$\rho_{XY} = \text{Cor}(X, Y) = \frac{\sigma_{XY}}{\sigma_X\sigma_Y} = \frac{\text{Cov}(X, Y)}{\sqrt{V(X)}\sqrt{V(Y)}}$$

- Se $\rho_{XY} > 0 \Rightarrow$ **relazione lineare crescente** fra X e Y ;
- Se $\rho_{XY} < 0 \Rightarrow$ **relazione lineare decrescente** fra X e Y ;
- Se $\rho_{XY} = 1 \Rightarrow (x_i, y_i)$ sono **allineati su una retta con pendenza positiva**;
- Se $\rho_{XY} = -1 \Rightarrow (x_i, y_i)$ sono **allineati su una retta con pendenza negativa**;
- Se $\rho_{XY} = 0 \Rightarrow$ non c'è legame lineare tra X e Y : **incorrelate**.

$|\rho_{XY}|$ indica la **forza del legame lineare**.

5.5 Analisi di regressione

Si analizzano 2 o più *variabili quantitative*, in genere si studia la **media condizionata** di una **variabile risposta** Y in funzione di una (regressione semplice) o più (regressione multipla) **variabili esplicative** $X_1, \dots, X_k$.

Questo tipo di analisi è utile per raccogliere informazioni sulla Y e per fare **analisi predittive** usando la **retta di regressione lineare** (vedendo il valore corrispondente sulla X , ma non in contesti inesplorati).

5.5.1 Regressione lineare semplice

La **regressione lineare semplice** considera una **variabile risposta** Y e una **variabile esplicativa** X :

$$y_i = \underbrace{a + bx_i}_{\text{parte deterministica}} + \underbrace{\epsilon_i}_{\text{errore}}, \quad i = 1, \dots, n$$

Dove a, b sono i **coefficienti di regressione**, a *l'intercetta* e b *il coefficiente angolare* della **retta di regressione** $y = a + bx$.

5.6 Minimi quadrati

Con il metodo dei minimi quadrati si **stimano**, sulla base dei dati osservati, i **coefficienti di regressione**; è metodo di adattamento per il calcolo della retta tra i punti osservati.

$$\epsilon_i = y_i - (a + bx_i), \quad i = 1, \dots, n$$

Dove ϵ_i sono i **residui di regressione**: rappresentano gli *scostamenti* fra le osservazioni e il modello teorico.

Per il calcolo di a, b si cercano dei valori che minimizzano la somma dei quadrati dei residui, **il metodo dei minimi quadrati**:

$$Q(a, b) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (y_i - a - bx_i)^2$$

Le soluzioni possibili sono:

$$\left. \begin{aligned} \hat{a} &= E(Y) - \hat{b}E(X) \\ \hat{b} &= \text{Cov}(X, Y)/V(X) \end{aligned} \right\} \text{Retta di regressione stimata } y = \hat{a} + \hat{b}x.$$

$\hat{b}$ è il coefficiente angolare della retta di regressione stimata; il suo segno dipende dalla covarianza in:

$$\hat{b} = \frac{Cov(X, Y)}{V(X)} = \rho_{XY} \frac{\sigma_Y}{\sigma_X}.$$

Dopo aver calcolato $\hat{a}$ e $\hat{b}$, si possono trovare i **valori stimati dal modello** cioè i valori della variabile risposta Y per ogni valore osservato x_i :

$$\hat{y} = \hat{a} + \hat{b}x_i, \quad i = 1, \dots, n$$

Considerando valori di X che non sono tra gli osservati, si otterranno valori previsti dal modello (**previsioni**).

I **residui stimati** sono le stime degli errori residui basati sulle osservazioni:

$$\hat{\epsilon}_i = y_i - \hat{a} - \hat{b}x_i = y_i - \hat{y}_i, \quad i = 1, \dots, n$$

5.6.1 Coefficiente di determinazione

Il **coefficiente di determinazione** (R^2) è una procedura per **valutare la bontà di un modello** di regressione lineare.

$$\underbrace{V(Y)}_{\text{varianza totale}} = \underbrace{V(\hat{Y})}_{\text{varianza spiegata}} + \underbrace{V(\hat{\epsilon})}_{\text{varianza residua}}$$

Dove:

- Y = variabile d'interesse;
- $\hat{Y}$ = valori stimati dal modello;
- $\hat{\epsilon}$ = residui stimati.

Se il modello è perfetto: $V(Y) = V(\hat{Y}) \Rightarrow V(\hat{\epsilon}) = 0$.

Il **coefficiente di determinazione** R^2 è la **proporzione di varianza di Y** spiegata dal modello di regressione; è compreso tra 0 e 1, più si avvicina a 1 e migliore sarà l'adattamento del modello ai dati:

$$R^2 = \frac{\text{varianza spiegata}}{\text{varianza totale}} = \frac{\sum_i (\hat{y}_i - E(\hat{Y}))^2 / n}{\sum_i (y_i - E(Y))^2 / n} = \frac{V(\hat{Y})}{V(Y)}$$

$$R^2 = 1 - \frac{\text{varianza residua}}{\text{varianza totale}} = 1 - \frac{\sum_i (\hat{\epsilon}_i - E(\hat{\epsilon}))^2 / n}{\sum_i (y_i - E(Y))^2 / n} = 1 - \frac{V(\hat{\epsilon})}{V(Y)}$$

Proprietà:

- $E(Y) = E(\hat{Y}) \Rightarrow$ media dei valori stimati dal modello ;
- $E(\hat{\epsilon}) = 0 \Rightarrow$ media dei residui stimati;
- $R^2 = \rho_{XY}^2$
- $V(\hat{\epsilon}) = E(\hat{\epsilon}^2), \quad E(\epsilon) = 0$

PROBABILITÀ

Gianluca Fava

Novembre 2022

Indice

1	Cos'è il calcolo delle probabilità?	2
2	Probabilità elementare	2
2.1	Esperimenti aleatori	2
2.1.1	Spazio fondamentale	2
2.2	Assioni di Kolmogorov	3
2.2.1	Conseguenze degli assiomi	3
2.3	Probabilità condizionata	3
2.3.1	Eventi condizionati	3
2.4	Eventi indipendenti	4
2.5	Teorema di Bayes	4
3	Variabili casuali	4
3.1	Funzione di ripartizione	4
3.2	Funzione di probabilità	5
3.2.1	Variabili casuali discrete	5
3.2.2	Variabili casuali continue	5
3.2.3	Variabile casuale esponenziale	6
3.2.4	Variabile casuale uniforme	6
3.3	Indici sintetici per variabili casuali	6
3.3.1	Valore atteso - Media	6
3.3.2	Mediana	7
3.3.3	Moda	7
3.3.4	Quantili	7
3.3.5	Varianza	7
3.3.6	Coefficiente di variazione	8
3.3.7	Scarti	8
3.3.8	Simmetria e curtosi	8
4	Variabili casuali bivariate	8
4.0.1	Funzione di ripartizione congiunta	8
4.0.2	Funzione di ripartizione marginale	8
4.0.3	Funzione di probabilità congiunta	8
4.0.4	Funzione di probabilità marginale	9
4.1	Condizionamento e indipendenza	9
4.1.1	Valore atteso condizionato	9
4.1.2	Varianza condizionata	9
4.2	Covarianza e correlazione	9
5	Modelli probabilistici	10
5.1	Modelli per variabili discrete	10
5.1.1	Modello uniforme discreto	10
5.1.2	Modello binomiale	10
5.1.3	Modello Poisson	11
5.1.4	Modello geometrico	11
5.2	Modelli per variabili continue	11
5.2.1	Modello uniforme continuo	11

5.2.2	Modello esponenziale	12
5.2.3	Modello normale	12
5.2.4	Verifica di normalità	13
5.2.5	Modello chi-quadrato	13
5.2.6	Modello t-Student	13
5.2.7	Modello F di Fisher	14
6	Statistica inferenziale	14
6.1	Campionamento	14
6.1.1	Campioni casuali semplici	14
6.2	Modelli statistici parametrici	14
6.2.1	Scelta del modello	14
6.2.2	Verifica del modello	15
7	Procedure inferenziali	15
7.1	Statistiche campionarie	15
7.1.1	Somma e media campionaria	15
7.1.2	Varianza campionaria	16

1 Cos'è il calcolo delle probabilità?

Definizione classica: a probabilità di un evento è il rapporto tra il numero di casi ad esso favorevoli e il numero di casi possibili, supposti tutti egualmente probabili.

Approccio assiomatico: (pragmatico) la probabilità è una misura che serve a dire la possibilità che un evento si realizzi.

2 Probabilità elementare

2.1 Esperimenti aleatori

Negli esperimenti aleatori **non si hanno risultati prevedibili con certezza**, anche se si conoscono tutti gli esiti possibili (es. lancio di un dado, rendimento di un titolo azionario ...); quando si parla di esperimenti aleatori si è nel campo della **statistica sperimentale**.

2.1.1 Spazio fondamentale

Lo **spazio fondamentale** (spazio degli eventi elementari) è l'insieme di tutti i possibili risultati di un esperimento aleatorio (Ω) che può essere:

- **discreto:** se costituito da un *numero finito* o da un *infinità numerabile* (lancio di un dado);
- **continuo:** se costituito da un *insieme continuo di punti* (rendimento di un titolo azionario).

I singoli risultati sono detti **eventi elementari**.

Un **evento** è un sottoinsieme dello spazio fondamentale Ω (l'insieme di tutti i sottoinsiemi) cioè **l'insieme delle parti di Ω** : $P(\Omega)$.

Un evento si dice **realizzato** solo se realizza uno degli eventi elementari che lo definiscono.

Operazioni logiche sugli eventi dati due eventi $A, B \subset \Omega$:

- A^c è l'**evento complementare ad A**, contiene tutti gli eventi elementari non in A;
- $A \cup B$ è l'**evento unione tra A e B**, contiene tutti gli eventi elementari in A o in B;
- $A \cap B$ è l'**evento intersezione tra A e B**, contiene tutti gli eventi elementari sia in A che in B;
- $A \setminus B$ è l'**evento differenza tra A e B**, contiene tutti gli eventi elementari in A e non in B;
- Ω è l'**evento certo**;
- $\emptyset$ è l'**evento impossibile**;

- $A \cap B = \emptyset$ significa che **A e B sono incompatibili (disgiunti)**: non hanno eventi elementari in comune e quindi non si realizzano contemporaneamente;
- $A \subseteq B$ significa che **A implica B**: tutti gli eventi elementari di A cadono anche in B, la realizzazione di A implica la realizzazione di B;
- $A \subseteq B$ e $B \subseteq A$ significa che gli eventi **A e B sono equivalenti**.

2.2 Assioni di Kolmogorov

La probabilità è una **misura** che associa ad ogni evento $A \subseteq \Omega$ un numero reale, che indica la sua possibilità di realizzazione; una misura di probabilità P deve essere:

1. dato un evento A , la sua probabilità $P(A) \geq 0$: **assioma di non negatività**;
2. la probabilità dell'evento certo $P(\Omega) = 1$: **assioma di normalizzazione**;
3. la probabilità dell'unione di una collezione finita o infinita ma numerabile di eventi disgiunti ($A_i, i \in I \subseteq N$ tali che $A_i \cap A_j = \emptyset, i \neq j$) è la somma delle corrispondenti probabilità ($P(\bigcup_{i \in I} A_i) = \sum_{i \in I} P(A_i)$): **assioma di σ -additività**.

Se $A \cup B = \emptyset$ allora $P(A \cup B) = P(A) + P(B)$.

Un evento di probabilità nulla è "trascurabile", un evento di probabilità 1 è "quasi certo".

Il **criterio costruttivo per definire misure di probabilità** che soddisfano ai tre assiomi in esperimenti dove Ω è finito o numerabile è:

$$\left. \begin{array}{ccc} \Omega = \{\omega_1, \omega_2, \dots, \omega_n\} \\ \downarrow \quad \downarrow \quad \downarrow \\ p_1 \quad p_2 \quad p_n \end{array} \right\} \text{ con: } p_i > 0, \sum_{i=1}^n p_i = 1 \left\{ \text{Se: } A \subseteq \Omega \text{ allora, } P(A) = \sum_{i: \omega_i \in A} p_i \right.$$

Quindi se Ω è costituito da n eventi elementari equiprobabili e $A = \{\omega_i, i \in I\}$, con $I \subseteq \{1, \dots, n\}$,

$$P(A) = \sum_{i \in I} \frac{1}{n} = \frac{\text{numero casi favorevoli ad A}}{\text{numero casi possibili}}$$

2.2.1 Conseguenze degli assiomi

1. La probabilità dell'evento impossibile è zero: $P(\emptyset) = 0$
2. Preso l'evento complementare A^c di A , la sua probabilità sarà: $P(A^c) = 1 - P(A)$
3. Se $A \subseteq B$ allora $P(A) \leq P(B)$ e $P(B) \setminus P(A) = P(B) - P(A)$
4. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
5. $P(B) = \sum_{i \in I} P(B \cap A_i)$ dove A_i è una partizione di Ω (formula di addizione)

2.3 Probabilità condizionata

2.3.1 Eventi condizionati

Dati due eventi A e B , con $P(A) > 0$, l'**evento condizionato** $B|A$ è la probabilità di B nel caso sia noto il realizzarsi di A e $P(B|A)$ sarà la **probabilità condizionata** di B dato A ; ($P(A)$ è detto evento condizionante, permette la normalizzazione):

$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$

Proprietà:

1. **Formula di moltiplicazione**: usabile anche con 3 o più elementi

$$P(A \cap B) = P(A)P(B|A)$$

2. **Formula di addizione + moltiplicazione** (formula della probabilità totale):

$$P(B) = \sum_{i \in I} P(A_i)P(B|A_i)$$

2.4 Eventi indipendenti

Due eventi sono **indipendenti** se il realizzarsi o meno di uno dei due non modifica la probabilità di realizzazione dell'altro:

- Se $P(A \cap B) = P(A)P(B) \Rightarrow A, B$ **indipendenti**
- Se $P(A \cap B) \neq P(A)P(B) \Rightarrow A, B$ **dipendenti**.

$$P(B|A) = \frac{P(B \cap A)}{P(A)} \xrightarrow{\text{Se indipendenti}} \frac{\cancel{P(A)}P(B)}{\cancel{P(A)}} = P(B)$$

Proprietà:

1. Con A, B non trascurabili: $P(A|B) = P(B)$ oppure $P(A|B) = P(A)$
2. Se A, B sono indipendenti, lo sono anche A e B^c , B e A^c , A^c e B^c
3. Ω , $\emptyset$ ed ogni evento trascurabile, sono indipendenti da qualsiasi evento.

(Queste proprietà valgono anche con 3 o più elementi).

2.5 Teorema di Bayes

Questo teorema permette di aggiornare la probabilità di un evento con nuove informazioni: dato un evento B non trascurabile e una partizione A_i , $i \in I \subseteq N$, di Ω costituita da eventi non trascurabili:

$$P(A_i|B) = \frac{P(B \cap A_i)}{P(B)} = \underbrace{\frac{P(A_i)P(B|A_i)}{P(B)}}_{\text{probabilità iniziale}}; \quad P(B) = \underbrace{\sum_{j \in J} P(A_j)P(B|A_j)}_{\text{formula della probabilità totale}}$$

Proprietà:

- le probabilità $P(A_i)$, $i \in I$, vengono chiamate **probabilità a priori (iniziali)** della condizione sperimentale i -esima, sono le conoscenze disponibili prima della realizzazione dell'esperimento;
- le probabilità $P(A_i|B)$, $i \in I$, vengono chiamate **probabilità a posteriori (finali)**, tengono conto del fatto che l'esperimento si è concluso e l'evento B si è realizzato;
- $P(A_i|B)$ è proporzionale a $P(A_i)P(B|A_i)$, mentre $P(B)$ (al denominatore) serve a normalizzare;
- $P(B|A_i)$ è la verosimiglianza di A_i .

3 Variabili casuali

Le **variabili casuali** servono per descrivere fenomeni o esperimenti **aleatori**, permettono di operare in insiemi numerici.

Una **variabile aleatoria** è una funzione che lega l'insieme degli esiti dell'esperimento ad $\mathbb{R}$ o un insieme di $\mathbb{R}$ (con $\mathbb{R}$ misurabile).

3.1 Funzione di ripartizione

Serve per probabilizzare tutti gli eventi riferiti a X , questa funzione soddisfa gli assiomi di Kolmogorov.

Due variabili casuali sono **identicamente distribuite** se probabilizzano un evento con lo stesso numero (stessa distribuzione di probabilità).

$$F_X : \mathbb{R} \rightarrow [0, 1] \quad F_X(x) = P(X \leq x), \quad X \in (-\infty, x), \quad x \in \mathbb{R}$$

Proprietà:

1. intervallo: $P(a < X \leq b) = F_X(b) - F_X(a)$
2. > valore: $P(X > a) = 1 - F_X(a)$

3. = valore: $P(X = b) = F_X(b) - \lim_{x \rightarrow b^-} F_X(x)$

Conseguenze delle proprietà:

- F_X è **monotona non decrescente**: se l'evento cresce, la proprietà non può diminuire (se $x_1 < x_2$ allora $F(x_1) \leq F(x_2)$)
- I punti di salto sono dove c'è la continuità da destra: F_X è **continua da destra**
- F_X sta tra 0,1 e non è decrescente: $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$

Il supporto di X è l'insieme dei possibili valori $x \in R$: $S_X = (x \in R : \forall \varepsilon > 0, P(x - \varepsilon < X < x + \varepsilon) > 0)$

3.2 Funzione di probabilità

3.2.1 Variabili casuali discrete

Le **variabili casuali discrete** descrivono un esperimento che ha **esiti numerabili/finiti**:

$\{x_i\}_{i \in I}$ è finito o numerabile tale che $P(X = x_i) = p_i > 0$ e $\sum_{i \in I} p_i = 1$:

$$f(x) = \begin{cases} P(X = x_i) = p_i & \text{se } x = x_i, \quad \forall i \in I \\ 0 & \text{altrimenti} \end{cases}$$

Se si conosce f_X si può ricavare a F_X e viceversa:

$$F_X(x) = P(X \leq x) = \sum_{i: x_i \leq x} p_i, \quad p_i = f_X(x_i) = F_X(x_i) - F_X(x_{i-1})$$

????????? altre formule qua, che è sta roba (pag.13)?????????

- Caso degenere: unico esito con probabilità 1;
- Caso variabile casuale Bernoulli: probabilità $\{0, 1\}$.

3.2.2 Variabili casuali continue

Le **variabili casuali continue** descrivono un esperimento che ha **esiti continui** (senza salti):



X è continua se la sua funzione di ripartizione F_X è continua ed esiste $f_X \in R$ tale per cui:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \quad \forall x \in R$$

f_x è la **funzione di densità di probabilità** che deposita ("spalmando") la probabilità agli intervalli.

Proprietà:

- $f_X(x) \geq 0, \quad \forall x \in R \rightarrow$ densità > 0
- $\int_{-\infty}^{+\infty} f_X(x) dx = 1 \rightarrow$ l'integrale = 1
- $f_X(x) = \frac{d}{dx} F_X(x), \quad \forall x \in R$ in cui $f_X(x)$ è continua
- $P(X = x) = 0 \quad \forall x \in R$





$\forall a \in R$ vale:

$$P(X > a) = 1 - P(X \leq a) = 1 - F_X(a)$$

che corrisponde all'area sottesa dalla funzione di densità in $(\infty, a]$.

$\forall a, b \in R, a < b$ vale:



$$P(a < X \leq b) = F_X(b) - F_X(a) = \int_a^b f_X(x) dx$$

che corrisponde all'area sottesa dalla funzione di densità nell'intervallo $[a, b]$.

In generale la probabilità associata all'evento $X \in B$ corrisponde a: $P(X \in B) = \int_B f_X(x) dx$

3.2.3 Variabile casuale esponenziale

La **variabile casuale esponenziale** viene utilizzata per rappresentare *durate e tempi di vita o di funzionamento*, nel caso in cui si ipotizza *assenza di memoria o di usura*.

X è esponenziale e continua ($X \sim \text{Esp}(\lambda)$, $\lambda > 0$) se $S_X = [0, +\infty]$ e :

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \in S_X \\ 0 & \text{altrimenti} \end{cases} \Rightarrow F_X(x) = \int_{-\infty}^x \lambda e^{-\lambda t} dt = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}$$

Se $x \notin S_X$, allora $F_X(x) = 0$,

Minore è λ e più sarà probabile avere osservazioni grandi e viceversa.

3.2.4 Variabile casuale uniforme

La **variabile casuale uniforme** continua viene utilizzata per *esperienze aleatorie* che possono essere rappresentati come un'*estrazione casuale di un numero da un certo intervallo di R* (è un modello che descrive l'equiprobabilità nel continuo).

X è uniforme e continua in $[0, 1]$ ($X \sim U(0, 1)$) se $S_X = [0, 1]$ e :

$$f_X(x) = \begin{cases} 1 & \text{se } x \in S_X \\ 0 & \text{altrimenti} \end{cases} \Rightarrow F_X(x) = \begin{cases} 0 & \text{se } x < 0 \\ x & \text{se } 0 \leq x < 1 \\ 1 & \text{se } \geq 1 \end{cases}$$

Se $[a, b]$ e $[c, d]$ con $a < b$ e $c < d$ hanno la stessa ampiezza (h) allora:

$$P(a \leq X \leq b) = P(c \leq X \leq d) = h \cdot 1 = h$$

3.3 Indici sintetici per variabili casuali

Indagano sulla **posizione**, sulla **variabilità** e la forma della distribuzione di probabilità (**la simmetria e la curtosi**).

3.3.1 Valore atteso - Media

Il **valore atteso** (μ) di una variabile casuale discreta o continua X è la **media** dei suoi possibili valori ponderati con le relative probabilità:

1. Calcolo:

- Nel caso in cui la serie o l'integrale siano convergenti:

$$E(X) = \sum_{x \in S_X} x f_X(x) = \sum_{x \in S_X} x P(X = x), \quad \text{se } X \text{ è discreta}$$

$$E(x) = \int_{-\infty}^{+\infty} x f_X(x) dx, \quad \text{se } X \text{ è continua}$$

- Nel caso in cui X sia una variabile casuale e $Y = g(X)$ sia una variabile casuale ottenuta come trasformata di X tramite $g(X) \Rightarrow E(Y) = E(g(X))$ e:

$$E(Y) = \sum_{x \in S_X} g(x) f_X(x), \quad \text{se } X, Y \text{ sono discrete}$$

$$E(x) = \int_{-\infty}^{+\infty} g(x) f_X(x) dx, \quad \text{se } X, Y \text{ sono continue}$$

2. Proprietà:

- **Cauchy**: la media sta tra il valore min e max: $\inf\{x \in S_X\} \leq E(X) \leq \sup\{x \in S_X\}$
- **Baricentro**: i dati shiftati hanno media zero: $E(X - E(X)) = 0$
- **Linearità**: la media è un operatore lineare: $E(aX + b) = aE(X) + b \forall a, b \in R$
Un'estensione della linearità è: $E(aX + bY) = aE(X) + bE(Y)$

3.3.2 Mediana

La **mediana** ($x_{0.5}$) della distribuzione di probabilità di X , è quel valore che ripartisce la massa unitaria di probabilità, in modo che $X \leq x_{0.5}$ e $X \geq x_{0.5}$ abbiano probabilità pari a $\frac{1}{2}$:

- Se X è continua: $F_X(x_{0.5}) = \frac{1}{2}$
- Se X è discreta: è quel valore/valori dove la funzione di ripartizione raggiunge o supera per la prima volta $\frac{1}{2}$.

3.3.3 Moda

La **moda** (x_{mo}) della distribuzione di probabilità di X è quel valore per cui è massima la funzione di densità di probabilità; ci può essere anche più di un valore moda e può anche non esistere.

Se $F_X(x)$ ha un **unico massimo** la distribuzione di probabilità di X è **unimodale**; se ha **2 o più punti di massimo** sarà una distribuzione bimodale o multi modale.

3.3.4 Quantili

Con $\alpha \in (0, 1)$, il **quantile** (x_α) di livello α della distribuzione di probabilità di X è quel valore che ripartisce la massa unitaria di probabilità lasciando una proporzione pari a α alla propria sinistra e $1 - \alpha$ alla propria destra.

- Se X è continua: $F_X(x_\alpha) = \alpha$
- Se X è discreta: è quel valore/valori dove la funzione di ripartizione raggiunge o supera per la prima volta α .

3.3.5 Varianza

La varianza ($V(X)$) di una variabile casuale discreta o continua X , con supporto S_X e funzione di densità di probabilità f_X , è la quantità $V(X) = E((X - E(X))^2)$, misura la dispersione distribuzione di probabilità attorno alla media:

1. Calcolo:

- Nel caso in cui la serie o l'integrale siano convergenti:

$$E(X) = \sum_{x \in S_X} (x - E(X))^2 f_X(x), \quad \text{se } X \text{ è discreta}$$

$$E(x) = \int_{-\infty}^{+\infty} (x - E(X))^2 f_X(x) dx, \quad \text{se } X \text{ è continua}$$

Lo **scarto quadratico medio** di X è: $\sigma = \sqrt{V(X)}$

2. Proprietà:

- **non negatività**: $V(X) \geq 0$, con $V(X) = 0 \Leftrightarrow X$ è degenera
- **formula per il calcolo**: $V(X) = E(X^2) - (E(X))^2$
- **invarianza per traslazioni**: $V(X + b) = V(X)$, con $b \in R$
- **omogeneità di secondo grado**: $V(aX) = a^2 V(X)$, con $a \in R$

Quindi se:

- $V(aX + b) = a^2 V(X)$
- Se si ha una variabile casuale X la sua trasformata $Y = \frac{X - \mu}{\sigma}$ è tale per cui $E(Y) = 0$ e $V(Y) = 1$ si ha una **variabile casuale standardizzata**.

3.3.6 Coefficiente di variazione

Se X è positiva e $P(X > 0) = 1$, il **coefficiente di variazione** sarà $\frac{\sigma}{|\mu|}$; è utile per confrontare la dispersione di 2 o più variabili casuali.

3.3.7 Scarti

- Lo **scarto medio assoluto dalla mediana**, definito come $E(|X - x_{0.5}|)$, se esiste finito, è la distanza attesa tra i valori di X e la mediana $x_{0.5}$.
- Lo **scarto interquartile** $SI = x_{3/4} - x_{1/4}$, è la differenza tra il terzo e il primo quartile.
- Il **campo di variazione** (range) $R = \sup\{x \in S_X\} - \inf\{x \in S_X\}$, è la differenza tra il valore più grande e più piccolo del supporto.

3.3.8 Simmetria e curtosi

Per il calcolo della **simmetria** e della **curtosi** della funzione di densità (probabilità) di una variabile casuale X si usa:

- l'indice di simmetria:

$$\gamma = \frac{E[(X - E(X))^3]}{\sigma^3}$$

- se la funzione di densità (probabilità) è **simmetrica**: $\gamma = 0$;
- se c'è **asimmetria negativa**: $\gamma < 0$;
- se c'è **asimmetria positiva**: $\gamma > 0$.

- l'indice di curtosi:

$$\beta = \frac{E[(X - E(X))^4]}{\sigma^4}$$

- Se la funzione di densità (probabilità) è **normocurtica**: $\beta = 3$;
- se è **leptocurtica** (code pesanti): $\beta > 3$;
- se è **platicurtica** (code leggere): $\beta < 3$.

4 Variabili casuali bivariate

Serve a fare uno studio congiunto di più variabili e a mettere insieme due o più fenomeni per confrontarli.

Vettore aleatorio (variabile casuale multivariata): è un vettore i cui elementi sono variabili casuali.

Una **variabile casuale bivariata** è formata da 2 variabili casuali.

4.0.1 Funzione di ripartizione congiunta

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y), \quad (x, y) \in R^2$$

Il **supporto congiunto** $S_{X,Y}$ è dato dall'insieme dei punti $(x, y) \in R^2$ nei cui intorno si possono osservare valori per (X, Y) con probabilità strettamente positiva.

4.0.2 Funzione di ripartizione marginale

$$F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y), \quad (x) \in R$$

Il **caso discreto** (caso più facile): consiste nell'estensione al caso continuo.

La **variabile casuale bivariata è discreta** se esiste un insieme di coppie di reali $\{(x_i, y_i)\}_{(i,j) \in I \times J}$, finito o numerabile, tale che $P(X = x_i, Y = y_i) = p_{ij} > 0$ e $\sum_{i,j} p_{ij} = 1 \Rightarrow (S_{X,Y} = \{(x_i, y_i), (i, j) \in I \times J\})$

4.0.3 Funzione di probabilità congiunta

$$f_{X,Y}(x, y) = \begin{cases} p_{ij} & \text{se } (x, y) = (x_i, y_i), \quad \forall (i, j) \in I \times J, \\ 0 & \text{altrimenti} \end{cases}$$

4.0.4 Funzione di probabilità marginale

$$P(X = x_i) = \sum_{j \in J} P(X = x_i, Y = y_j) = \sum_{j \in J} p_{ij} = p_{i+}, \quad x_i \in S_X$$

	y_1	y_2	$\dots$	y_k	
x_1	p_{11}	p_{12}	$\dots$	p_{1k}	p_{1+}
x_2	p_{21}	p_{22}	$\dots$	p_{2k}	p_{2+}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_m	p_{m1}	p_{m2}	$\dots$	p_{mk}	p_{m+}
	p_{+1}	p_{+2}	$\dots$	p_{+k}	1

4.1 Condizionamento e indipendenza

Due eventi (X, Y) sono **indipendenti** se $P(A \cap B) = P(A)P(B)$ cioè se:

$$F_{X,Y}(x, y) = F_X(x)F_Y(y)$$

Se (X, Y) è discreta allora saranno indipendenti se $f_{X,Y}(x_i, y_i) = f_X(x_i)f_Y(y_i)$

Se (X, Y) è discreta, la **funzione di probabilità** della variabile casuale X **condizionata** a Y è:

$$f_{X|Y=y_i}(x_i) = P(X = x_i, Y = y_i) = \frac{p_{ij}}{p_{+j}} = \frac{\text{Riga/Colonna data dal condizionamento}}{\text{totale riga/colonna}}$$

Se (X, Y) sono **indipendenti** tutte le distribuzioni **condizionate** di $X|Y = y_i$ al variare di y_i sono uguali e coincidono con la distribuzione marginale di X .

4.1.1 Valore atteso condizionato

$$E(X|Y = y_i) = \sum_{x_i} x_i f_{X|Y=y_i}(x_i)$$

Se (X, Y) sono **indipendenti** il valore atteso condizionato è costante e coincide con $E(X)$.

4.1.2 Varianza condizionata

$$V(X|Y = y_i) = \sum_{x_i} (x_i - E(X|Y = y_i))^2 f_{X|Y=y_i}(x_i)$$

Se (X, Y) sono **indipendenti** la varianza condizionata è costante e coincide con $V(X)$.

4.2 Covarianza e correlazione

La misura della dipendenza lineare tra due variabili X e Y è la **covarianza**:

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

Nel caso di variabili casuali **discrete**:

$$\text{Cov}(X, Y) = \sum_{x_i} \sum_{y_i} (x_i - E(X))(y_i - E(Y)) f_{X,Y}(x_i, y_i)$$

Il **coefficiente di correlazione lineare** descrive la dipendenza tra le due variabili:

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}, \quad -1 \leq \rho \leq 1$$

- Se $\rho_{XY} > 0 \Rightarrow$ **relazione lineare crescente** fra X e Y ;
- Se $\rho_{XY} < 0 \Rightarrow$ **relazione lineare decrescente** fra X e Y ;
- Se $\rho_{XY} = 1 \Rightarrow$ **relazione lineare crescente con probabilità 1**;

- Se $\rho_{XY} = -1 \Rightarrow$ **relazione lineare decrescente con probabilità 1**;
- Se $\rho_{XY} = 0 \Rightarrow X$ e Y **sono indipendenti: incorrelate**.

Siccome:

$$E(aX + bY) = aE(X) + bE(Y) \quad \text{e} \quad V(aX + bY) = a^2V(X) + b^2V(Y) + 2ab \operatorname{Cov}(X, Y)$$

ci sono dei casi particolari in cui la $\operatorname{Cov}(X, Y) = 0$ implica indipendenza:

- (X, Y) dove $X \sim \operatorname{Ber}(p), Y \sim \operatorname{Ber}(p)$
- (X, Y) dove $X \sim N(\mu_X, \sigma_X^2), Y \sim N(\mu_Y, \sigma_Y^2)$
- $V(X+Y) = V(X) + V(Y) + 2\operatorname{Cov}(X, Y) = V(X+Y) = V(X) + V(Y) - 2\operatorname{Cov}(X, Y)$

5 Modelli probabilistici

Un **modello probabilistico** è una famiglia di distribuzioni di probabilità, i modelli sono delle variabili casuali "tipiche".

Data X la sua famiglia di funzioni di densità sarà $f_X(x; \theta), \theta \in \Theta \subseteq \mathbb{R}^n$, dove θ è il parametro che individua le distribuzioni di probabilità appartenenti a quella famiglia.

5.1 Modelli per variabili discrete

5.1.1 Modello uniforme discreto

Il **modello uniforme discreto** descrive esperimenti con un **numero finito di esiti equiprobabili**.

Una variabile casuale X ha **distribuzione uniforme discreta**: $X \sim \operatorname{Ud}(x_1, \dots, x_n)$ se $S_X = \{x_1, \dots, x_n\}$ e:

$$f_X(x; x_1, \dots, x_n) = \begin{cases} \frac{1}{n} & \text{se } x = x_1, \dots, x_n \\ 0 & \text{altrimenti} \end{cases}$$

- $E(X) = \sum_{i=1}^n x_i / n$
- $V(X) = \sum_{i=1}^n (x_i - E(X))^2 / n$

Se $x_i = i, i = 1, \dots, n$ allora $X \sim \operatorname{Ud}(n)$ e: $E(X) = \frac{n+1}{2}; \quad V(X) = \frac{n^2-1}{12}$.

Se $n = 1$ si ha una distribuzione degenera in x_i quindi $X \sim D(x_1)$ e: $E(X) = x_1; \quad V(X) = 0$.

5.1.2 Modello binomiale

Il **modello binomiale** rappresenta estrazioni con reinserimento da un'urna di composizione nota dove ogni estrazione sarà classificata come **successo** (1) o **insuccesso** (0) e avrà la stessa probabilità di uscita; è una generalizzazione del modello bernoulliano.

Una variabile casuale X ha **distribuzione binomiale** di parametri $n \geq 1$ (numero di prove indipendenti); $p \in (0, 1)$ (probabilità di successo): $X \sim \operatorname{Bi}(n, p)$ se $S_X = \{0, \dots, n\}$ e:

$$f_X(x; x_1, \dots, x_n) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & \text{se } x \in S_X \\ 0 & \text{altrimenti} \end{cases}$$

Se $n = 1$ si ha una variabile casuale **bernoulliana**, o **binomiale elementare**.

Se la variabile casuale somma $X = \sum_{i=1}^n X_i \sim \operatorname{Bi}(n, p)$ allora:

$$E(X_i) = 1 \cdot p + 0 \cdot (1-p) = p \quad \text{e} \quad V(X_i) = E(X_i^2) - (E(X_i))^2 = p(1-p)$$

$$E(X) = E\left(\sum_{i=1}^n X_i\right) = np \quad \text{e} \quad V(X) = V\left(\sum_{i=1}^n X_i\right) = np(1-p)$$

Più sarà alto n e più la varianza si riduce.

5.1.3 Modello Poisson

Il **modello Poisson** è utile per descrivere **problemi di conteggio** (non c'è un limite massimo di numeri contabili, si vuole contare il numero di volte che un fenomeno si verifica).

Una variabile casuale X ha **distribuzione poisson** con parametro $\lambda > 0$: $\mathbf{X} \sim \mathbf{P}(\lambda)$ se $S_X = N$ e:

$$f_X(x; \lambda) = \begin{cases} \lambda^x e^{-\lambda} / x! & \text{se } x \in S_X \\ 0 & \text{altrimenti} \end{cases}$$

$$\text{Dove: } E(X) = \lambda; \quad E(X^2) = \lambda^2 + \lambda \Rightarrow V(X) = E(X^2) - (E(X))^2 = \lambda \Rightarrow \mathbf{E}(\mathbf{X}) = \mathbf{V}(\mathbf{X})$$

Il numero di successi in un unità di tempo è v , la variabile casuale che rappresenta il numero di successi in un intervallo di tempo è t , e $P(\lambda)$ con $\lambda = vt$; la scelta di λ aiuta a calibrare il tipo di modello da descrivere.

Se n è elevato e p è piccola, la distribuzione $Bi(n, p)$ viene approssimata ad una $P(\lambda)$ con $\lambda = np$, in questo caso la Poisson e la binomiale sono molto simili (l'approssimazione è efficace se $n \geq 50$ e $p \leq 1/25$)

Se $Y_1 \sim P(\lambda_1)$ e $Y_2 \sim P(\lambda_2)$ sono indipendenti, la loro somma $Y_1 + Y_2 \sim P(\lambda_1 + \lambda_2)$

5.1.4 Modello geometrico

Il **modello geometrico** descrive un tempo d'attesa misurato come numero di tentativi di un esperimento bernoulliano fino ad osservare per la prima volta il **successo**.

Una variabile casuale X ha **distribuzione geometrica** con parametro $p \in (0, 1)$: $\mathbf{X} \sim \mathbf{Ge}(p)$ se $S_X = N^+$ e:

$$f_X(x; \lambda) = \begin{cases} (1-p)^{x-1} & \text{se } x \in S_X \\ 0 & \text{altrimenti} \end{cases}$$

- $E(X) = 1/p$
- $V(X) = (1-p)/p^2$

Questo modello ha la proprietà di **assenza di memoria**:

$$P(\underbrace{X}_{\text{successo}} > \underbrace{s+t}_{\text{tentativi}} \mid \underbrace{X > s}_{\substack{\text{sapendo che il successo} \\ \text{non è avvenuto nei precedenti} \\ \text{s tentativi}}}) = P(X > t), \quad \forall s, t \in S_X$$

Quindi la probabilità che il successo avvenga dopo $s+t$ prove bernoulliane (se non è avvenuto nelle prime s prove) è uguale alla probabilità che avvenga dopo t prove.

5.2 Modelli per variabili continue

5.2.1 Modello uniforme continuo

Il **modello uniforme continuo** descrive l'**equiprobabilità** nel continuo (cioè tutti i sotto-intervalli del supporto hanno la stessa probabilità di successo).

Una variabile casuale X ha **distribuzione uniforme continua** con parametri $a, b \in R$, $a < b$: $\mathbf{X} \sim \mathbf{U}(a, b)$ se $S_X = [a, b]$ e:

$$f_X(x; a, b) = \begin{cases} 1/(b-a) & \text{se } a \leq x \leq b \\ 0 & \text{altrimenti} \end{cases} \quad F_X(x; a, b) = \begin{cases} 0 & \text{se } x < a \\ (x-a)/(b-a) & \text{se } a \leq x < b \\ 1 & \text{se } x \geq b \end{cases}$$

$$E(X) = \int_a^b x \frac{1}{b-a} dx = \frac{b+a}{2}$$
$$V(X) = \int_a^b x^2 \frac{1}{b-a} dx - \left(\frac{b+a}{2} \right)^2 = \frac{(b-a)^2}{12}$$

La trasformata lineare di una variabile uniforme continua rimane uniforme:
se $X \sim U(a, b) \Rightarrow Y = \alpha + \beta X \sim U(\alpha + \beta a, \alpha + \beta b)$.

5.2.2 Modello esponenziale

Il **modello esponenziale** descrive **tempi di vita / durate / tempi d'attesa** nel caso in cui c'è assenza di memoria; è la versione nel continuo del modello geometrico.

Una variabile casuale X ha **distribuzione esponenziale** con parametro $\lambda > 0$ (tasso di guasto): $X \sim \text{Esp}(\lambda)$ se $S_X = [0, +\infty)$ e:

$$f_X(x; \lambda) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \in S_X \\ 0 & \text{altrimenti} \end{cases} \quad F_X(x; \lambda) = \begin{cases} 1 - e^{-\lambda x} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

In alcuni casi si usa il parametro $\theta = 1/\lambda = E(X)$.

Nel caso in cui $\lambda = 1$:

- $E(X) = 1/\lambda$
- $V(X) = 1/\lambda^2$

Se $X \sim \text{Esp}(\lambda) \Rightarrow aX \sim \text{Esp}(\lambda/a), \quad \forall a > 0$.

Questo modello ha la proprietà di **assenza di memoria**: $P(X > t+s | X > t) = P(X > s), \quad \forall s, t > 0$

5.2.3 Modello normale

Il **modello normale o gaussiano** è il più utilizzato, descrive la presenza di caratteri antropometrici o fenomeni sociali / naturali.

Una variabile casuale X ha **distribuzione normale o gaussiana** con parametri $\mu \in R; \sigma^2 > 0$: $X \sim N(\mu, \sigma^2)$ se $S_X = R$ e:

$$f_X(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad \forall x \in R$$

f_X ha un andamento a campana centrata in μ e con massimo in μ e con i punti di flesso in $\mu - \sigma, \mu + \sigma$. F_X viene definita usando la definizione di funzione di ripartizione.

- $x_{0,5} = \mu$
- $x_{mo} = \mu$
- $E(X) = \mu$
- $V(X) = \sigma^2$


Se $\mu = 0, \sigma^2 = 1$ si ha una **distribuzione normale standard**: $N(0, 1)$.

Una variabile casuale gaussiana se trasformata linearmente rimane gaussiana: se $X \sim N(\mu, \sigma^2)$ e $Y = aX + b$ con $a, b \in R, a \neq 0 \Rightarrow Y \sim N(a\mu + b, a^2\sigma^2)$.

Se $X \sim N(\mu, \sigma^2)$ un caso particolare è quello che permette di **standardizzare**: $Z \sim N(0, 1)$ dove $Z = \frac{(X-\mu)}{\sigma}$ se invece si ha $Z \sim N(0, 1)$ allora $X = \sigma Z + \mu \sim N(\mu, \sigma^2)$.

Nel caso di $Z \sim N(0, 1)$:

- $\Phi(z)$ è la funzione di ripartizione: gaussiana standard
- $\phi(z)$ è la funzione di densità: gaussiana standard



$\phi(x)$ è simmetrica $\Rightarrow \Phi(-z) = 1 - \Phi(z), \quad \forall z \geq 0$

- $P(|Z| < z) = \Phi(z) - \Phi(-z)$
- $P(|Z| > z) = 2(1 - \Phi(z))$
- $P(a \leq X \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$
- $P(X \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right)$

La maggior parte della massa di probabilità si trova entro i limiti definiti dalla media più o meno 3σ .

Per rendere una gaussiana qualsiasi, una gaussiana standardizzata si usano le [tavole statistiche](#).

Per le applicazioni statistiche si forniscono i **valori critici** di una $N(0, 1)$ cioè i valori z_α tali che $P(Z > z_\alpha)$ con $\alpha \in (0, 0.5)$ dove z_α indica una coda destra della distribuzione di probabilità di peso α e $z_{-\alpha}$ indica la coda di sinistra.

α	0.10	0.05	0.025	0.01	0.005	0.001	0.0005
z_α	1.28	1.65	1.96	2.33	2.58	3.09	3.29

5.2.4 Verifica di normalità

La **verifica di normalità** è un'analisi preliminare per vedere se il fenomeno in esame **può essere descritto da un modello normale**, la verifica avviene con tre metodi grafici:

- confronto tra l'**istogramma** basato su dati e la **funzione di densità di una normale** con media e varianza calcolate sui dati ($\hat{\mu} = \sum_{i=1}^n x_i/n$, $\hat{\sigma} = \sqrt{\sum_{i=1}^n (x_i - \hat{\mu})^2/n}$).
- confronto tra la **stima della densità** basata sui dati e la **funzione di densità di una normale** con media e varianza calcolate sui dati ($\hat{\mu} = \sum_{i=1}^n x_i/n$, $\hat{\sigma} = \sqrt{\sum_{i=1}^n (x_i - \hat{\mu})^2/n}$).
- **q-q plot**: confronto tra i **quantili** calcolati sui dati (in ordinata) e i quantili della **distribuzione normale** (in ascissa), se il modello normale è corretto i punti si trovano allineati su una linea retta).

5.2.5 Modello chi-quadrato

Il **modello chi-quadrato**, date le variabili $Z_1, \dots, Z_n$ indipendenti con distribuzione $N(0, 1)$ allora la variabile casuale Y ha distribuzione **chi-quadrato** con n gradi di libertà e $S_X = [0, +\infty)$: $Y \sim \chi^2(n)$

$$Y = \sum_{i=1}^n Z_i^2$$

Più è grande n e più il modello assomiglia ad un modello gaussiano (con $n > 80$ tendenzialmente).

- $E(Y) = n$
- $V(Y) = 2n$

Se $Y_1 \sim \chi^2(n_1)$, $Y_2 \sim \chi^2(n_2)$ sono indipendenti, allora $Y_1 + Y_2 \sim \chi^2(n_1 + n_2)$.

Con le [tavole statistiche](#) i **valori critici** di una $Y \sim \chi^2(n)$ cioè i valori $\chi_{\alpha,n}^2$ tali che $P(Y > \chi_{\alpha,n}^2) = \alpha$ con $\alpha \in (0, 1)$, $n \leq 1$

5.2.6 Modello t-Student

Il **modello t-Student** è simile al modello gaussiano ma con le code più pesanti; date le variabili casuali $Z \sim N(0, 1)$ e $Y \sim \chi^2(n)$ indipendenti, la variabile casuale T ha **distribuzione t-Student** con n gradi di libertà e supporto $S_T = \mathbb{R}$: $T \sim t(n)$

$$T = \frac{Z}{\sqrt{Y/n}}$$

Più è grande n e più il modello assomiglia ad un modello gaussiano (con $n > 30$ tendenzialmente).

- $E(T) = 0$ se $n > 1$
- $V(T) = n/(n-2)$ se $n > 2$

Con le [tavole statistiche](#) i **valori critici** di una $T \sim t(n)$ cioè i valori $t_{\alpha,n}$ tali che $P(T > t_{\alpha,n}) = \alpha$ con $\alpha \in (0, 0.5)$, $n \geq 1$.

per la simmetria $t_{1-\alpha,n} = -t_{\alpha,n}$

5.2.7 Modello F di Fisher

Il **modello F di Fisher**, date le variabili casuali $X \sim \chi^2(n)$ e $Y \sim \chi^2(m)$ con $n, m \geq 1$ indipendenti e la variabile casuale F ha **distribuzione F di Fisher** con n, m gradi di libertà e supporto $S_F = [0, +\infty)$: $F \sim F(n, m)$

$$F = \frac{X/n}{Y/n}$$

- $E(F) = m/(m-2)$ se $m > 2$

Se $F \sim F(n, m)$, allora $F^{-1} \sim F(m, n)$

Se $T \sim t(n)$, allora $T^2 \sim F(1, n)$.

Con le [tavole statistiche](#) i **valori critici** di una $F \sim F(n, m)$ cioè i valori $F_{\alpha, n, m}$ tali che $P(F > F_{\alpha, n, m}) = \alpha$ con $\alpha \in (0, 1)$, $n, m \geq 1$.

6 Statistica inferenziale

La **statistica inferenziale** ha l'obiettivo di studiare esperimenti e dati campionari (generati da esperimenti aleatori).

Le conclusioni che si traggono sono sempre soggette ad errori (per questo si deve controllare la probabilità d'errore).

6.1 Campionamento

Indagine campionaria ...

????????? motivazioni indagini ??????????????

6.1.1 Campioni casuali semplici

Si considereranno **campioni casuali semplici** di dimensione $n \geq 1$, interpretabili come n realizzazioni indipendenti di un esperimento di base (aleatorio), nelle stesse condizioni.

L'**ipotesi fondamentale** su cui poggia l'inferenza statistica è che le osservazioni dei dati sperimentali $X = (X_1, \dots, X_n)$ e che i dati derivano dall'esperimento, quindi sono interpretati come osservazioni di variabili casuali.

Nel **campionamento casuale semplice**, le variabili casuali $X = (X_1, \dots, X_n)$ sono indipendenti e identicamente distribuite (**IID**), cioè con lo stesso modello probabilistico e tali da non influenzarsi a vicenda.

6.2 Modelli statistici parametrici

Si ha un **modello statistico parametrico** per i dati di un campione casuale semplice se:

- le variabili sono indipendenti
- le variabili hanno la stessa distribuzione di probabilità
- una volta scelto il modello, si stimano i valori che non si conoscono

Lo **spazio parametrico** (Θ) è l'insieme dei valori che un parametro θ può assumere.

Lo **spazio campionario** (Θ) è il supporto dei possibili valori osservabili (le variabili casuali $x_1, \dots, x_n$).

6.2.1 Scelta del modello

Quando si sceglie il modello si devono considerare:

- la natura dei dati (qualitativi o quantitativi, discreti o continui, ...);
- gli aspetti notevoli presenti nei dati (posizione, variabilità, simmetria, ...);
- tutte le informazioni sul meccanismo generatore dei dati.

Non sempre esiste un modello che rappresenta i dati osservati.

6.2.2 Verifica del modello

Per verificare che la scelta del modello statistico parametrico sia corretta, si fa un **controllo empirico del modello**:

- confronto tra l'**istogramma delle frequenze relative** e la **stima della densità**.
- **q-q plot**.

7 Procedure inferenziali

Con le procedure inferenziali si ha l'obiettivo di fare:

- **stima puntuale**: ottenere, sulla base dell'osservazione x , una congettura puntuale su Θ ;
- **stima intervallare o regione di confidenza**: dare un range di valori, sottoinsieme di Θ dove è incluso θ ;
- **verifica di ipotesi**: verificare sulla base dell'osservazione x , se una data ipotesi su Θ , è accettabile (cioè in accordo con i dati x).

7.1 Statistiche campionarie

Le analisi statistiche inferenziali hanno sempre un grado di incertezza siccome i dati campionari x sono interpretati come realizzazione di un vettore casuale $\bar{X}$, quindi ripetendo un esperimento 2 volte si dovrebbero ottenere risultati diversi.

La **statistica campionaria** è ogni trasformata $T = t(X_1, \dots, X_n)$ che sintetizza opportunamente il campione casuale $X_1, \dots, X_n$, dove T (**distribuzione campionaria**) è una variabile casuale con una determinata distribuzione di probabilità.

Con i dati:

- $x_1, \dots, x_n$ (osservazioni di variabili casuali) :

$$\frac{\sum_{i=1}^n x_i}{n} = \text{media dei dati (i dati vengono usati per avere dei valori di sintesi campionaria)}$$

- $X_1, \dots, X_n$ (variabili casuali)

$$\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} = \text{media campionaria}$$

Delle sintesi campionarie sono:

- **somma campionaria**: $S_n = \sum_{i=1}^n X_i$
- **media campionaria**: $\bar{X}_n = S_n/n$
- **varianza campionaria**: $S^2 = \sum_{i=1}^n (\bar{X}_i - \bar{X}_n)^2/n$; S_c^2 è la versione corretta.

7.1.1 Somma e media campionaria

La **somma e la media campionaria** sono variabili casuali (quindi avranno a loro volta una media, varianza e distribuzione campionaria).

$$S_n = \sum_{i=1}^n X_i, \quad \bar{X}_n = \frac{S_n}{n}$$

$$\text{Valori: } E(S_n) = \sum_{i=1}^n E(X_i) = n\mu, \quad V(S_n) = \sum_{i=1}^n V(X_i) = n\sigma^2$$

$$\text{Campionaria: } E(\bar{X}_n) = \frac{E(S_n)}{n} = \mu, \quad V(\bar{X}_n) = \frac{V(S_n)}{n^2} = \frac{\sigma^2}{n}$$

- Se le variabili del campione sono **gaussiane**: somma campionaria e media campionaria sono gaussiane

- Se le variabili del campione sono **binomiali**: la somma campionaria è binomiale
- Se le variabili del campione sono **poisson**: la somma campionaria è poisson
- Se le variabili del campione sono χ^2 : la somma campionaria è χ^2

X_n è uno **stimatore** per μ e il suo corrispondente valore osservato $\bar{x}_n$ è usato come **stima** di μ .

Al crescere di n la media campionaria converge a μ (target) ed è sempre più probabile avere valori vicini a μ (e la varianza diminuisce); è la **legge debole dei grandi numeri**:

$$n \rightarrow +\infty, \quad \bar{X}_n \xrightarrow{p} \mu$$

Dove $\xrightarrow{p}$ è la convergenza in probabilità.

Il **teorema limite centrale** afferma che presa una sequenza di variabili casuali IID di qualsiasi tipo, se vengono standardizzate la media campionaria e la somma, queste coincidono e quando n cresce, queste convergono in distribuzione ad una variabile casuale Z :

$$\frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}} = \frac{S_n - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{d} Z \sim N(0, 1)$$

Se $n > 30$: $\bar{X}_n \sim N(\mu, \sigma^2/n)$, $S_n \sim N(n\mu, n\sigma^2)$ (dove $\sim$ indica la distribuzione approssimata).

Sapendo che, se delle variabili casuali hanno **distribuzione gaussiana**, S_n e $\bar{X}_n$ rimangono gaussiane e, sapendo dal teorema limite centrale che con un n elevato si possono ricondurre a delle gaussiane anche delle variabili che non hanno distribuzione gaussiana, allora:

$$P(a < \bar{X}_n \leq b) \doteq \Phi\left(\frac{b - \mu}{\sigma/\sqrt{n}}\right) - \Phi\left(\frac{a - \mu}{\sigma/\sqrt{n}}\right); \quad P(a < S_n \leq b) \doteq \Phi\left(\frac{b - n\mu}{\sigma/\sqrt{n}}\right) - \Phi\left(\frac{a - n\mu}{\sigma/\sqrt{n}}\right)$$

- Se $X_i \sim \text{Ber}(p)$ allora $S_n \sim N(np, np(1-p))$, $\bar{X}_n \sim N(p, np(1-p)/n)$ (buone approssimazioni per: $np \geq 5$, $n(1-p) \geq 5$)
- Se $X_i \sim P(\lambda)$ allora $S_n \sim N(n\lambda, n\lambda)$, $\bar{X}_n \sim N(\lambda, \lambda/n)$ (buone approssimazioni per: $n\lambda > 10$)

7.1.2 Varianza campionaria

La **varianza campionaria** è la variabile casuale:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$$

$$E(S^2) = \frac{n-1}{n} \sigma^2 = \sigma^2 - \frac{1}{n} \sigma^2$$

Il **valore osservato** di S^2 è s^2 (che è la varianza calcolata sul campione effettivamente osservato) ed è usato come **stima** per σ^2 .

La varianza campionaria (S^2) si avvicina alla varianza reale (σ^2) al crescere dei dati osservati, per questo si considera la **varianza campionaria corretta** (S_c^2):

$$S_c^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad \text{quindi:} \quad E(S_c^2) = \frac{n}{n-1} E(S^2) = \frac{n}{n-1} \frac{n-1}{n} \sigma^2 = \sigma^2$$

$$n \rightarrow +\infty, \quad S^2 \xrightarrow{p} \sigma^2, \quad S_c^2 \xrightarrow{p} \sigma^2$$

Quindi S_c^2 è uno stimatore alternativo di S^2 che ha come valore atteso σ^2 .

Se si considerano delle variabili casuali gaussiane, la **varianza campionaria** (S^2) e la **varianza campionaria corretta** (S_c^2) hanno una distribuzione di probabilità legata al modello χ^2 :

$$\frac{n}{\sigma^2} S^2 = \frac{n-1}{\sigma^2} S_c^2 = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{\sigma^2} \sim \chi^2(n-1)$$

La media campionaria e la varianza campionaria sono indipendenti.

Nel caso di variabili casuali indipendenti con distribuzione normale, se si standardizza la variabile casuale media campionaria si ottiene la **media campionaria standardizzata**:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Se al posto di σ si considera $S_c = \sqrt{S_c^2}$ si ha la **media campionaria studentizzata**:

$$\frac{\bar{X}_n - \mu}{S_c/\sqrt{n}} \sim t(n - 1)$$

Nel caso di variabili casuali con distribuzione normale $N(\mu_X, \sigma_X^2)$, $N(\mu_Y, \sigma_Y^2)$, tutte indipendenti, anche le associate varianze campionarie saranno indipendenti:


$$S_X^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad S_Y^2 = m^{-1} \sum_{i=1}^m (Y_i - \bar{Y}_m)^2$$

quindi $nS_X^2/\sigma_X^2 \sim \chi^2(n - 1)$, e, $mS_Y^2/\sigma_Y^2 \sim \chi^2(m - 1)$; quindi:

$$\frac{[nS_X^2/\sigma_X^2]/(n - 1)}{[mS_Y^2/\sigma_Y^2]/(m - 1)} \sim F(n - 1, m - 1)$$

Tavola 1: Funzione di ripartizione della Variabile Casuale Normale Standardizzata

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz$$




z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
-3.4	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0002
-3.3	0.0005	0.0005	0.0005	0.0004	0.0004	0.0004	0.0004	0.0004	0.0004	0.0003
-3.2	0.0007	0.0007	0.0006	0.0006	0.0006	0.0006	0.0006	0.0005	0.0005	0.0005
-3.1	0.0010	0.0009	0.0009	0.0009	0.0008	0.0008	0.0008	0.0008	0.0007	0.0007
-3.0	0.0013	0.0013	0.0013	0.0012	0.0012	0.0011	0.0011	0.0011	0.0010	0.0010
-2.9	0.0019	0.0018	0.0018	0.0017	0.0016	0.0016	0.0015	0.0015	0.0014	0.0014
-2.8	0.0026	0.0025	0.0024	0.0023	0.0023	0.0022	0.0021	0.0021	0.0020	0.0019
-2.7	0.0035	0.0034	0.0033	0.0032	0.0031	0.0030	0.0029	0.0028	0.0027	0.0026
-2.6	0.0047	0.0045	0.0044	0.0043	0.0041	0.0040	0.0039	0.0038	0.0037	0.0036
-2.5	0.0062	0.0060	0.0059	0.0057	0.0055	0.0054	0.0052	0.0051	0.0049	0.0048
-2.4	0.0082	0.0080	0.0078	0.0075	0.0073	0.0071	0.0069	0.0068	0.0066	0.0064
-2.3	0.0107	0.0104	0.0102	0.0099	0.0096	0.0094	0.0091	0.0089	0.0087	0.0084
-2.2	0.0139	0.0136	0.0132	0.0129	0.0125	0.0122	0.0119	0.0116	0.0113	0.0110
-2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823
-1.2	0.1151	0.1131	0.1112	0.1093	0.1075	0.1056	0.1038	0.1020	0.1003	0.0985
-1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
-1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
-0.9	0.1841	0.1814	0.1788	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611
-0.8	0.2119	0.2090	0.2061	0.2033	0.2005	0.1977	0.1949	0.1922	0.1894	0.1867
-0.7	0.2420	0.2389	0.2358	0.2327	0.2296	0.2266	0.2236	0.2206	0.2177	0.2148
-0.6	0.2743	0.2709	0.2676	0.2643	0.2611	0.2578	0.2546	0.2514	0.2483	0.2451
-0.5	0.3085	0.3050	0.3015	0.2981	0.2946	0.2912	0.2877	0.2843	0.2810	0.2776
-0.4	0.3446	0.3409	0.3372	0.3336	0.3300	0.3264	0.3228	0.3192	0.3156	0.3121
-0.3	0.3821	0.3783	0.3745	0.3707	0.3669	0.3632	0.3594	0.3557	0.3520	0.3483
-0.2	0.4207	0.4168	0.4129	0.4090	0.4052	0.4013	0.3974	0.3936	0.3897	0.3859
-0.1	0.4602	0.4562	0.4522	0.4483	0.4443	0.4404	0.4364	0.4325	0.4286	0.4247
-0.0	0.5000	0.4960	0.4920	0.4880	0.4840	0.4801	0.4761	0.4721	0.4681	0.4641

Tavola 1 (segue): Funzione di ripartizione della Variabile Casuale Normale Standardizzata

[illegible]


Tavola 1a: Valori critici della Variabile Casuale Normale Standardizzata. $P(Z \geq z_\alpha) = \alpha$.

α	0.10	0.05	0.025	0.01	0.005	0.001	0.0005	0.0001	
z_α	1.2816	1.6449	1.9600	2.3263	2.5758	3.0902	3.2905	3.7190	
α	0.00009	0.00008	0.00007	0.00006	0.00005	0.00004	0.00003	0.00002	0.00001
z_α	3.7455	3.7750	3.8082	3.8461	3.8906	3.9444	4.0128	4.1075	4.2649

Tavola 2: Valori critici della Distribuzione t 

ν	α								
	0.20	0.10	0.05	0.025	0.01	0.005	0.001	0.0005	0.0001
1	1.3764	3.0777	6.3137	12.7062	31.8210	63.6559	318.2888	636.5776	3185.2722
2	1.0607	1.8856	2.9200	4.3027	6.9645	9.9250	22.3285	31.5998	70.7060
3	0.9785	1.6377	2.3534	3.1824	4.5407	5.8408	10.2143	12.9244	22.2027
4	0.9410	1.5332	2.1318	2.7765	3.7469	4.6041	7.1729	8.6101	13.0385
5	0.9195	1.4759	2.0150	2.5706	3.3649	4.0321	5.8935	6.8685	9.6764
6	0.9057	1.4398	1.9432	2.4469	3.1427	3.7074	5.2075	5.9587	8.0233
7	0.8960	1.4149	1.8946	2.3646	2.9979	3.4995	4.7853	5.4081	7.0641
8	0.8889	1.3968	1.8595	2.3060	2.8965	3.3554	4.5008	5.0414	6.4424
9	0.8834	1.3830	1.8331	2.2622	2.8214	3.2498	4.2969	4.7809	6.0094
10	0.8791	1.3722	1.8125	2.2281	2.7638	3.1693	4.1437	4.5868	5.6939
11	0.8755	1.3634	1.7959	2.2010	2.7181	3.1058	4.0248	4.4369	5.4529
12	0.8726	1.3562	1.7823	2.1788	2.6810	3.0545	3.9296	4.3178	5.2631
13	0.8702	1.3502	1.7709	2.1604	2.6503	3.0123	3.8520	4.2209	5.1106
14	0.8681	1.3450	1.7613	2.1448	2.6245	2.9768	3.7874	4.1403	4.9849
15	0.8662	1.3406	1.7531	2.1315	2.6025	2.9467	3.7329	4.0728	4.8801
16	0.8647	1.3368	1.7459	2.1199	2.5835	2.9208	3.6861	4.0149	4.7905
17	0.8633	1.3334	1.7396	2.1098	2.5669	2.8982	3.6458	3.9651	4.7148
18	0.8620	1.3304	1.7341	2.1009	2.5524	2.8784	3.6105	3.9217	4.6485
19	0.8610	1.3277	1.7291	2.0930	2.5395	2.8609	3.5793	3.8833	4.5903
20	0.8600	1.3253	1.7247	2.0860	2.5280	2.8453	3.5518	3.8496	4.5390
21	0.8591	1.3232	1.7207	2.0796	2.5176	2.8314	3.5271	3.8193	4.4925
22	0.8583	1.3212	1.7171	2.0739	2.5083	2.8188	3.5050	3.7922	4.4517
23	0.8575	1.3195	1.7139	2.0687	2.4999	2.8073	3.4850	3.7676	4.4156
24	0.8569	1.3178	1.7109	2.0639	2.4922	2.7970	3.4668	3.7454	4.3819
25	0.8562	1.3163	1.7081	2.0595	2.4851	2.7874	3.4502	3.7251	4.3516
26	0.8557	1.3150	1.7056	2.0555	2.4786	2.7787	3.4350	3.7067	4.3237
27	0.8551	1.3137	1.7033	2.0518	2.4727	2.7707	3.4210	3.6895	4.2992
28	0.8546	1.3125	1.7011	2.0484	2.4671	2.7633	3.4082	3.6739	4.2759
29	0.8542	1.3114	1.6991	2.0452	2.4620	2.7564	3.3963	3.6595	4.2538
30	0.8538	1.3104	1.6973	2.0423	2.4573	2.7500	3.3852	3.6460	4.2340
35	0.8520	1.3062	1.6896	2.0301	2.4377	2.7238	3.3400	3.5911	4.1531
40	0.8507	1.3031	1.6839	2.0211	2.4233	2.7045	3.3069	3.5510	4.0943
45	0.8497	1.3007	1.6794	2.0141	2.4121	2.6896	3.2815	3.5203	4.0489
50	0.8489	1.2987	1.6759	2.0086	2.4033	2.6778	3.2614	3.4960	4.0140
55	0.8482	1.2971	1.6730	2.0040	2.3961	2.6682	3.2451	3.4765	3.9855
60	0.8477	1.2958	1.6706	2.0003	2.3901	2.6603	3.2317	3.4602	3.9622
70	0.8468	1.2938	1.6669	1.9944	2.3808	2.6479	3.2108	3.4350	3.9255
80	0.8461	1.2922	1.6641	1.9901	2.3739	2.6387	3.1952	3.4164	3.8987
90	0.8456	1.2910	1.6620	1.9867	2.3685	2.6316	3.1832	3.4019	3.8778
100	0.8452	1.2901	1.6602	1.9840	2.3642	2.6259	3.1738	3.3905	3.8615
120	0.8446	1.2886	1.6576	1.9799	2.3578	2.6174	3.1595	3.3734	3.8370
∞	0.8416	1.2816	1.6449	1.9600	2.3264	2.5758	3.0902	3.2905	3.7189

Tavola 3: Valori critici della Distribuzione Chi-Quadrato



ν	0.9999	0.9995	0.999	0.995	α 0.99	0.975	0.95	0.90	0.80
1	1.57E-8	3.93E-7	1.57E-6	3.93E-5	0.0002	0.0010	0.0039	0.0158	0.0642
2	0.0002	0.0010	0.0020	0.0100	0.0201	0.0506	0.1026	0.2107	0.4463
3	0.0052	0.0153	0.0243	0.0717	0.1148	0.2158	0.3518	0.5844	1.0052
4	0.0284	0.0639	0.0908	0.2070	0.2971	0.4844	0.7107	1.0636	1.6488
5	0.0821	0.1581	0.2102	0.4118	0.5543	0.8312	1.1455	1.6103	2.3425
6	0.1723	0.2994	0.3810	0.6757	0.8721	1.2373	1.6354	2.2041	3.0701
7	0.2998	0.4849	0.5985	0.9893	1.2390	1.6899	2.1673	2.8331	3.8223
8	0.4634	0.7104	0.8571	1.3444	1.6465	2.1797	2.7326	3.4895	4.5936
9	0.6611	0.9718	1.1519	1.7349	2.0879	2.7004	3.3251	4.1682	5.3801
10	0.8890	1.2651	1.4787	2.1558	2.5582	3.2470	3.9403	4.8652	6.1791
11	1.1449	1.5870	1.8338	2.6032	3.0535	3.8157	4.5748	5.5778	6.9887
12	1.4281	1.9345	2.2141	3.0738	3.5706	4.4038	5.2260	6.3038	7.8073
13	1.7341	2.3049	2.6172	3.5650	4.1069	5.0087	5.8919	7.0415	8.6339
14	2.0601	2.6966	3.0407	4.0747	4.6604	5.6287	6.5706	7.7895	9.4673
15	2.4084	3.1073	3.4825	4.6009	5.2294	6.2621	7.2609	8.5468	10.3070
16	2.7736	3.5357	3.9417	5.1422	5.8122	6.9077	7.9616	9.3122	11.1521
17	3.1561	3.9800	4.4162	5.6973	6.4077	7.5642	8.6718	10.0852	12.0023
18	3.5559	4.4391	4.9048	6.2648	7.0149	8.2307	9.3904	10.8649	12.8570
19	3.9687	4.9125	5.4067	6.8439	7.6327	8.9065	10.1170	11.6509	13.7158
20	4.3950	5.3978	5.9210	7.4338	8.2604	9.5908	10.8508	12.4426	14.5784
21	4.8342	5.8954	6.4467	8.0336	8.8972	10.2829	11.5913	13.2396	15.4446
22	5.2862	6.4041	6.9829	8.6427	9.5425	10.9823	12.3380	14.0415	16.3140
23	5.7482	6.9240	7.5291	9.2604	10.1957	11.6885	13.0905	14.8480	17.1865
24	6.2231	7.4528	8.0847	9.8862	10.8563	12.4011	13.8484	15.6587	18.0618
25	6.7087	7.9905	8.6494	10.5196	11.5240	13.1197	14.6114	16.4734	18.9397
26	7.1980	8.5374	9.2222	11.1602	12.1982	13.8439	15.3792	17.2919	19.8202
27	7.6997	9.0929	9.8029	11.8077	12.8785	14.5734	16.1514	18.1139	20.7030
28	8.2115	9.6558	10.3907	12.4613	13.5647	15.3079	16.9279	18.9392	21.5880
29	8.7303	10.2266	10.9861	13.1211	14.2564	16.0471	17.7084	19.7677	22.4751
30	9.2559	10.8040	11.5876	13.7867	14.9535	16.7908	18.4927	20.5992	23.3641
35	11.9929	13.7879	14.6881	17.1917	18.5089	20.5694	22.4650	24.7966	27.8359
40	14.8820	16.9058	17.9166	20.7066	22.1642	24.4331	26.5093	29.0505	32.3449
45	17.8922	20.1361	21.2509	24.3110	25.9012	28.3662	30.6123	33.3504	36.8844
50	21.0077	23.4611	24.6736	27.9908	29.7067	32.3574	34.7642	37.6886	41.4492
55	24.2133	26.8650	28.1731	31.7349	33.5705	36.3981	38.9581	42.0596	46.0356
60	27.5006	30.3393	31.7381	35.5344	37.4848	40.4817	43.1880	46.4589	50.6406
70	34.2581	37.4671	39.0358	43.2753	45.4417	48.7575	51.7393	55.3289	59.8978
80	41.2407	44.7917	46.5197	51.1719	53.5400	57.1532	60.3915	64.2778	69.2070
90	48.4095	52.2768	54.1559	59.1963	61.7540	65.6466	69.1260	73.2911	78.5584
100	55.7202	59.8946	61.9182	67.3275	70.0650	74.2219	77.9294	82.3581	87.9453
150	93.9492	99.4617	102.1127	109.1423	112.6676	117.9846	122.6918	128.2750	135.2625
200	134.0154	140.6591	143.8420	152.2408	156.4321	162.7280	168.2785	174.8353	183.0028

STATISTICA INFERENZIALE

Gianluca Fava

Dicembre 2022

Indice

1	Stime e stimatori	1
1.1	Metodi di stima	2
1.1.1	Standard error	2
1.2	Intervalli di confidenza	3
1.2.1	Intervallo di confidenza per la media di una popolazione normale	3
1.2.2	Intervallo di confidenza per la media di una popolazione qualsiasi	4
1.2.3	Intervallo di confidenza per la varianza di una popolazione normale	4
2	Verifica delle ipotesi	5
2.1	Test statistici	5
2.1.1	Statistica test	5
2.1.2	Livello di significatività e regione di rifiuto	6
2.1.3	P-value	7
2.2	Test su media e varianza	8
2.2.1	Verifica di ipotesi per la media di una popolazione normale	8
2.2.2	Verifica di ipotesi per la media di una popolazione qualsiasi	9
2.2.3	Verifica di ipotesi per la varianza di una popolazione normale	9
2.2.4	Test di confronto tra medie di popolazione normali	10
2.2.5	Test di confronto tra varianze di popolazione normali	11
2.3	Test su popolazioni	11
2.3.1	Test per il confronto tra popolazioni	12
2.3.2	Test chi-quadrato di indipendenza	12
2.3.3	Test chi-quadrato di adattamento	13
3	Modello di regressione lineare	13
3.1	Analisi di correlazione	13
3.1.1	Test di correlazione	13
3.2	Analisi di regressione	14
3.2.1	Modello di regressione lineare semplice	14
3.2.2	Inferenza e verifica di ipotesi nel modello regressione lineare	14
3.2.3	Valutazioni sul modello di regressione	15
3.3	Diagnostiche	16

1 Stime e stimatori

Le procedure di **stima puntuale** assegnano un valore plausibile al parametro ignoto θ (tenendo conto delle informazioni contenute nel campione e delle assunzioni sul modello generatore dei dati).

Le procedure di **stima intervallare** definiscono un intervallo di valori plausibili per θ .

Dati n dati campionari riferiti ad un campione casuale semplice $X_1, \dots, X_n$:

- la **stima** per θ (parametro ignoto) sarà il **valore** $\hat{\theta} = \hat{\theta}(\mathbf{x}_1, \dots, \mathbf{x}_n)$, ottenuto dai dati osservati nel campione;
- lo **stimatore** per θ (parametro ignoto) sarà la **variabile casuale** $\hat{\theta} = \hat{\theta}(\mathbf{X}_1, \dots, \mathbf{X}_n)$, ottenuta come funzione delle variabili casuali che generano i dati osservati.

Quindi lo **stimatore** è una **statistica campionaria** usata per stimare θ e la **stima** è il **valore osservato** in corrispondenza ai dati campionari.

Se si ripete l'esperimento, il campione sarà diverso da quelli osservati precedentemente quindi anche la stima cambierà in base all'osservazione.

Per definire le procedure inferenziali per la stima puntuale si deve costruire:

- un opportuno **metodo per definire stimatori** (riferiti ad un parametro d'interesse);
- l'analisi delle **proprietà di uno stimatore** (valutare la sua bontà ed efficacia nel definire i valori di stima).

1.1 Metodi di stima

Se le quantità a cui si applica sono momenti (varianza, valore medio...) si usa il **metodo dei momenti**.

Con il **metodo dell'analogia**, per stimare un parametro della popolazione, si utilizza la corrispondente quantità campionaria. Insieme al metodo dell'analogia di solito si usa il **metodo di sostituzione (plug-in)**: per stima di $\tau = g(\theta)$, se esiste uno stimatore $\hat{\theta}$ di θ , uno stimatore per τ sarà $\hat{\tau} = g(\hat{\theta})$.

1.1.1 Standard error

Con θ è unidimensionale, come misura della precisione di uno stimatore $\hat{\theta}$ si può prendere l'**errore quadratico medio di stima** sotto θ (in media l'errore dello stimatore):


$$EQM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Lo **standard error** (più è piccolo e meglio è): $se(\hat{\theta}) = \sqrt{EQM(\hat{\theta})}$.

L'**estimated standard error**: $\hat{se}(\hat{\theta}) = \sqrt{E(\hat{\theta} - \theta)^2|_{\theta=\hat{\theta}}}$

L'errore quadratico medio di stima, e lo standard error, tengono conto della **variabilità** e della sua **distorsione** di uno stimatore.

$$EQM(\hat{\theta}) = \underbrace{V(\hat{\theta})}_{\text{variabilità}} + \underbrace{E[E(\hat{\theta}) - \theta]^2}_{\text{distorsione}}$$



- Calibrazione non ottimale, varianza bassa (*migliore*)
- Calibrazione ottimale (*non buono*)
- Varianza alta (*non buono*)

Proprietà degli stimatori: uno stimatore $\hat{\theta}$

- **non distorsione** (o buona calibrazione): il valor medio coincide con il vero valore del parametro

$$E(\hat{\theta}) = \theta \quad \forall \theta \in \Theta$$

- **asintoticamente non distorto**: al crescere della dimensione n del campione tende alla non distorsione

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta \quad \forall \theta \in \Theta$$

- **consistenza**: al crescere della dimensione n del campione lo stimatore si avvicina a θ

$$\hat{\theta}_n \xrightarrow{p} \theta \quad \text{per } n \rightarrow \infty$$

Nel caso in cui lo stimatore è (almeno) asintoticamente non distorto e tale che $\lim_{n \rightarrow \infty} V(\hat{\theta}_n) = 0$, in questo caso anche $EQM(\hat{\theta})$ tende a zero.

Come stimatori per σ^2 si usano la varianza campionaria (S^2) e la varianza campionaria corretta (S_c^2).

Caso genrale	$N(0, \sigma^2)$	$Ber(p)$	$Bi(m, p)$	$P(\lambda)$	$Esp(\lambda)$
$\theta = \mu$	μ	p	$p \ (\neq \mu)$	λ	$\mu = \frac{1}{\lambda}$
$\hat{\theta} = \bar{X}_n$	$\bar{X}_n$	$\hat{p} = \bar{X}_n$	$\hat{p} = \frac{\bar{X}_n}{m}$	$\hat{\lambda} = \bar{X}_n$	$\hat{\mu} = \bar{X}_n$
$V(\theta) = V(\bar{X}_n) = \frac{\sigma^2}{n}$	$\frac{\sigma^2}{n}$	$\frac{p(1-p)}{n}$	$V(\hat{p}) = \frac{p(1-p)}{nm}$	$\frac{\lambda}{n}$	$\frac{\sigma^2}{n} = \frac{\mu^2}{n}$
$se(\bar{X}_n) = \sqrt{\frac{\sigma^2}{n}}$	$\sqrt{\frac{\sigma^2}{n}}$	$\sqrt{\frac{p(1-p)}{n}}$	$\sqrt{\frac{p(1-p)}{nm}}$	$\sqrt{\frac{\lambda}{n}}$	$\sqrt{\frac{\mu^2}{n}}$

1.2 Intervalli di confidenza

Gli **intervalli di confidenza** sono tentativi di dire la percentuale stimata entro quali range sta.

Definisce un range (intervallo) di valori di stima, l'intervallo è un informazione sull'affidabilità della stima (più stretto = più preciso).

Dato il campione casuale $X_1, \dots, X_n$, un intervallo di confidenza per θ sarà dato da:

- **livello di confidenza** $1 - \alpha$
- **limite inferiore e limite superiore di confidenza** $[L, U]$ per far sì che il valore stia in quel range.

$$P(L \leq \theta \leq U) = 1 - \alpha$$

$L - U$ sarà la **lunghezza** dell'intervallo e $(U - L)/2$ sarà l'**accuratezza**

La procedura usata per definire intervalli di confidenza per θ è:


- cercare uno **stimatore** per il parametro d'interesse;
- partendo dalla statistica campionaria scelta, trovare una **variabile pivot**.

1.2.1 Intervallo di confidenza per la media di una popolazione normale

L'**intervallo di confidenza** per μ con livello di confidenza $1 - \alpha$, di un campione casuale semplice $X_1, \dots, X_n$ da una popolazione $N(\mu, \sigma^2)$ sarà:

- con **varianza nota**: si considera la media campionaria $\bar{X}_n$ e la media campionaria standardizzata $\sqrt{n}(\bar{X}_n - \mu)/\sigma \sim N(0, 1)$ (come quantità pivotale).
Si cercano a, b tali che per ogni $\mu \in R$:

$$P\left(a < \frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}} < b\right) = 1 - \alpha \Rightarrow P\left(\bar{X}_n - b\frac{\sigma}{\sqrt{n}} < \mu < \bar{X}_n - a\frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$




La scelta più conveniente è porre $a = -z_{\alpha/2}$, $b = z_{\alpha/2}$ dove $z_{\alpha/2}$ è il valore critico tale che $P(Z \geq z_{\alpha/2}) = \alpha/2$

L'intervallo di confidenza per μ con livello $\alpha - 1$:

$$\left[\bar{X}_n - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right] = [\hat{\mu} - z_{\alpha/2} se(\hat{\mu}), \hat{\mu} + z_{\alpha/2} se(\hat{\mu})]$$

L'**accuratezza** dell'intervallo di confidenza è tanto migliore quanto più n è elevata e σ è piccola cioè più α diminuisce. L'ampiezza dell'intervallo dipende da: dati, variabilità, quanto è elevata la confidenza.

- con **varianza ignota**: si usa al suo posto la varianza campionaria corretta S_c^2 e la media campionaria studentizzata $\sqrt{n}(\bar{X}_n - \mu)/S_c \sim t(n-1)$ (come quantità pivotale).



$t_{\alpha/2}$ è il valore critico tale che $P(T \geq z_{\alpha/2}) = \alpha/2$ con $T \sim t(n-1)$.
Con un campione di dimensione n elevata si può stimare $t_{\alpha/2}$ con $z_{\alpha/2}$.

L'intervallo di confidenza per μ con livello $1 - \alpha$:

$$\left[\bar{X}_n - t_{\alpha/2} \frac{S_c}{\sqrt{n}}, \bar{X}_n + t_{\alpha/2} \frac{S_c}{\sqrt{n}} \right] = [\hat{\mu} - t_{\alpha/2} \hat{se}(\hat{\mu}), \hat{\mu} + t_{\alpha/2} \hat{se}(\hat{\mu})]$$

Siccome una t di student ha code più pesanti della $N(0, 1)$ l'intervallo di confidenza tende a essere più ampio (quindi meno preciso, dato che si stima σ con S_c).

L'accuratezza dell'intervallo di confidenza è tanto migliore quanto più n è elevata e S_c è piccola cioè più α diminuisce.

1.2.2 Intervallo di confidenza per la media di una popolazione qualsiasi

L'**intervallo di confidenza** di un campione casuale semplice $X_1, \dots, X_n$ da una popolazione non normale con μ ignota e livello di confidenza $1 - \alpha$, sarà:

- con **n elevato**: si considera la media campionaria $\bar{X}_n$ e la media campionaria standardizzata $\sqrt{n}(\bar{X}_n - \mu)/\sigma \sim N(0, 1)$ (come quantità pivotale).

Siccome non si conosce σ lo si sostituisce con il suo stimatore $\hat{\sigma}$ ottenendo l'intervallo di confidenza:

$$\left[\bar{X}_n - z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}, \bar{X}_n + z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}} \right]$$

- se $X_i \sim \text{Ber}(p)$ allora l'intervallo di confidenza per $\mu = p$ sarà: $\hat{p} = \bar{X}_n$ e $\hat{\sigma} = \sqrt{\hat{p}(1 - \hat{p})}$
- se $X_i \sim P(\lambda)$ allora l'intervallo di confidenza per $\mu = \lambda$ sarà: $\hat{\lambda} = \bar{X}_n$ e $\hat{\sigma} = \sqrt{\hat{\lambda}}$


- con **n non elevato**, bisogna vedere caso per caso.

1.2.3 Intervallo di confidenza per la varianza di una popolazione normale

L'**intervallo di confidenza** per σ^2 con livello di confidenza $1 - \alpha$, di un campione casuale semplice $X_1, \dots, X_n$ da una popolazione $N(\mu, \sigma^2)$ sarà, sempre nel caso di media incognita:

- se si usa la varianza campionaria S^2 e la trasformata della varianza campionaria $nS^2/\sigma^2 \sim \chi^2(n-1)$ (come quantità pivotale).

$$P\left(\chi_{1-\alpha/2}^2 \leq \frac{nS^2}{\sigma^2} \leq \chi_{\alpha/2}^2\right) = P\left(\frac{nS^2}{\chi_{\alpha/2}^2} \leq \sigma^2 \leq \frac{nS^2}{\chi_{1-\alpha/2}^2}\right) = 1 - \alpha$$



Dove $\chi^2_{1-\alpha/2}$ e $\chi^2_{\alpha/2}$ sono i valori critici tali che rispettivamente $P(Y \geq \chi^2_{1-\alpha/2}) = 1 - \alpha/2$ e $P(Y \geq \chi^2_{\alpha/2}) = \alpha/2$ siccome $Y \sim \chi^2(n-1)$

L'intervallo di confidenza è:

$$\left[\underbrace{\frac{nS^2}{\chi^2_{\alpha/2}}}_{\text{estremo inferiore}}, \underbrace{\frac{nS^2}{\chi^2_{1-\alpha/2}}}_{\text{estremo superiore}} \right]$$

- se si usa la varianza campionaria corretta S_c^2 e la trasformata della varianza campionaria corretta $(n-1)S_c^2/\sigma^2 \sim \chi^2(n-1)$ (come quantità pivotale).

L'intervallo di confidenza sarà:

$$\left[\frac{(n-1)S_c^2}{\chi^2_{\alpha/2}}, \frac{(n-1)S_c^2}{\chi^2_{1-\alpha/2}} \right]$$

2 Verifica delle ipotesi

Ha l'obiettivo di verificare, sulla base dell'osservazioni ottenute, se un'ipotesi sulla popolazione oggetto di indagine è accettabile; di solito si è propensi ad accettare se l'osservazione è in accordo con i dati osservati.

L'ipotesi è un'affermazione (basata sul fenomeno in oggetto di studio) su un parametro d'interesse (θ).

Si può avere:

- **ipotesi semplice:** specifica in modo completo la popolazione (come vengono generati i dati, es. $\theta = 3$).
- **ipotesi composta:** non specifica in modo completo la popolazione (come vengono generati i dati, es. $\theta < 3, \theta \neq 3$).

Un **test statistico** è un procedimento per accettare/rifiutare un'ipotesi (sulla base dei dati raccolti).

- **Ipotesi nulla** (H_0): l'ipotesi di partenza (sottoposta a verifica); $H_0 : \theta = \theta_0$
- **Ipotesi alternativa** (H_1): nega l'ipotesi nulla:
 - $H_1 : \theta > \theta_0 \rightarrow$ alternativa unilaterale destra;
 - $H_1 : \theta < \theta_0 \rightarrow$ alternativa unilaterale sinistra;
 - $H_1 : \theta \neq \theta_0 \rightarrow$ alternativa bilaterale;

Un **test significativo** è un test che rifiuta H_0 , è contro l'ipotesi nulla.

2.1 Test statistici

2.1.1 Statistica test

La **statistica test**, dato un campione casuale (semplice) $X_1, \dots, X_n$ e le ipotesi H_0 e H_1 riferite al parametro ignoto θ , sarà una trasformata opportuna dello stimatore per θ del quale si conosce la distribuzione di probabilità (almeno sotto H_0); serve a capire se ha più senso rifiutare H_0 o H_1 .

Ci sono 2 tipi di errore:

	H_0 vera	H_1 vera
Rifiuto H_0	Errore I tipo	OK
Accetto H_0	OK	Errore II tipo

- rifiutare H_0 quando è vera: errore di I tipo.
- accettare H_0 quando è falsa: errore II tipo.

Le probabilità di errore sono:

- $\alpha = P(\text{errore di I tipo}) = P(\text{rifiutare } H_0 \text{ quando è vera}).$
- $\beta = P(\text{errore di II tipo}) = P(\text{accettare } H_0 \text{ quando è falsa}).$

Il **livello di protezione del test** è la probabilità $1 - \alpha$ di accettare H_0 quando è vera e la **potenza** è la probabilità $1 - \beta$ di rifiutare H_0 quando è falsa.

2.1.2 Livello di significatività e regione di rifiuto

L'obiettivo è una strategia di testing con α, β minimizzate (probabilità di errore minimizzate); ma α, β sono indipendenti quindi non possono essere minimizzate insieme.

L'errore più problematico e rilevante è α quindi si fissa il livello di significatività (probabilità di errore $\alpha = 0.1, 0.05, 0.01, 0.001$) e si cerca il test con la potenza $1 - \beta$ più alta.


Procedura per definire un test statistico per $H_0 : \theta = \theta_0$:

- trovare una statistica test T della quale si conosce la distribuzione di probabilità sotto H_0 ;
- fissare il livello di significatività α ;
- trovare le regioni di rifiuto R_α e di accettazione A_α per H_0 ;
- se il valore osservato (t^{oss}) di T :
 - è in R_α si rifiuta H_0 ;
 - è in A_α si accetta H_0 .

Se si rifiuta H_0 il test è detto significativo al $100\alpha\%$

Casi possibili:

1. $H_1 : \theta > \theta_0$ (**alternativa unilaterale destra**)
 θ grande $\Rightarrow$ ci si allontana dall'ipotesi nulla e si va verso l'ipotesi alternativa:



$$\alpha = P(\text{rifiutare } H_0 | H_0 \text{ vera}) = P(T \geq c_\alpha | H_0 \text{ vera}) = P_0(T \geq c_\alpha)$$


c_α : valore critico di livello α supponendo H_0 vera.

P_0 : probabilità calcolata supponendo vera H_0 (sotto H_0).

La regione di rifiuto sarà:

$$R_\alpha = \{t \in S_T : t \geq c_\alpha\} \quad \text{con } c_\alpha \text{ tale che } P_0(T \geq c_\alpha) = \alpha$$

2. $H_1 : \theta < \theta_0$ (**alternativa unilaterale sinistra**)
 θ piccolo $\Rightarrow$ ci si allontana dall'ipotesi nulla e si va verso l'ipotesi alternativa:



$$\alpha = P(\text{rifiutare } H_0 | H_0 \text{ vera}) = P(T \leq d_\alpha | H_0 \text{ vera}) = P_0(T \leq d_\alpha)$$


d_α : valore critico di livello α supponendo H_0 vera.

La regione di rifiuto sarà:

$$R_\alpha = \{t \in S_T : t \leq d_\alpha\} \quad \text{con } d_\alpha \text{ tale che } P_0(T \leq d_\alpha) = \alpha$$

3. $H_1 : \theta \neq \theta_0$ (**alternativa bilaterale**)

θ piccolo e θ grande $\Rightarrow$ ci si allontana dall'ipotesi nulla e si va verso l'ipotesi alternativa:



$$\alpha = P(\text{rifiutare } H_0 | H_0 \text{ vera}) = P(T \leq d_{\alpha/2} \text{ oppure } T \geq c_{\alpha/2})$$

La regione di rifiuto sarà:

$$R_\alpha = \{t \in S_T : t \leq d_\alpha \text{ oppure } t \geq c_{\alpha/2}\}$$

con : $d_{\alpha/2}$ tale che $P_0(T \leq d_{\alpha/2}) = \alpha/2$, e $c_{\alpha/2}$ tale che $P_0(T \geq c_{\alpha/2}) = \alpha/2$

R_α e A_α danno una partizione del supporto S_T della statistica test T e individuano la soglia o le soglie critiche, oltre le quali si rifiuta H_0 .

2.1.3 P-value

Il **livello di significatività osservato (P-value)** è una probabilità che misura il livello di sintonia tra i dati campionari e l'ipotesi nulla, è il più piccolo livello di significatività (α^{oss}) che porta a rifiutare H_0 .

Più è elevato il p-value e più c'è un buon accordo tra dati e H_0 quindi si è propensi ad accettare H_0 .

Calcolo:

1. $H_1 : \theta > \theta_0 \rightarrow \alpha^{oss} = P_0(T \geq t^{oss})$
2. $H_1 : \theta < \theta_0 \rightarrow \alpha^{oss} = P_0(T \leq t^{oss})$
3. $H_1 : \theta \neq \theta_0 \rightarrow \alpha^{oss} = 2\min\{P_0(T \leq t^{oss}), P_0(T \geq t^{oss})\}$

α^{oss} è la probabilità che si verifichi un evento uguale a quello osservato, $\alpha^{oss} \in [0, 1]$:

- se $\alpha^{oss} \leq 0.01 \rightarrow$ rifiutare H_0 con sicurezza;
- se $0,01 < \alpha^{oss} \leq 0.05 \rightarrow$ rifiutare H_0 con riserva;
- se $0,05 < \alpha^{oss} \leq 0.10 \rightarrow$ incertezza nella decisione;
- se $\alpha^{oss} > 0.10 \rightarrow$ non si rifiuta H_0 ;
- se n è elevato H_0 si rifiuta se $\alpha^{oss} \leq 0.01$.

Quindi:

- se $\alpha^{oss} \leq \alpha \rightarrow t^{oss} \in R_\alpha$ e si **rifiuta** H_0 ;
- se $\alpha^{oss} > \alpha \rightarrow t^{oss} \in A_\alpha$ e si **accetta** H_0 .

2.2 Test su media e varianza

2.2.1 Verifica di ipotesi per la media di una popolazione normale

Dato un campione casuale semplice $X_1, \dots, X_n$ da una popolazione $N(\mu, \sigma^2)$ e un valore μ_0 per la media, si vuole verificare l'ipotesi nulla ($H_0 : \mu = \mu_0$) ad un livello α fissato.

- Se la varianza è nota si ha il test **z**:

$$Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$$

La **statistica test** è la **media campionaria standardizzata** che sotto H_0 ha distribuzione $N(0, 1)$ (è utile per vedere la vicinanza tra i dati e H_0).

Per la regione di rifiuto R_α si considerano valori per Z che si allontanano dall'ipotesi nulla vanno verso l'ipotesi alternativa:

1. $H_1 : \mu > \mu_0$ (**alternativa unilaterale destra**)

Valori grandi per Z non possono esserci con H_0 andando verso H_1 , quindi la regione di rifiuto sarà:

$$R_\alpha = \{z \in R : z \geq z_\alpha\} \quad \text{con } z_\alpha \text{ tale che } P_0(Z \geq z_\alpha) = \alpha$$

Dove: z_α : valore critico di livello α supponendo H_0 vera.

2. $H_1 : \mu < \mu_0$ (**alternativa unilaterale sinistra**)

Valori piccoli per Z non possono esserci con H_0 andando verso H_1 , quindi la regione di rifiuto sarà:

$$R_\alpha = \{z \in R : z \leq -z_\alpha\} \quad \text{con } z_\alpha \text{ tale che } P_0(Z \geq z_\alpha) = \alpha$$

3. $H_1 : \mu \neq \mu_0$ (**alternativa bilaterale**)

Valori grandi e piccoli per Z non possono esserci con H_0 andando verso H_1 , quindi la regione di rifiuto sarà:

$$R_\alpha = \{z \in R : z \leq -z_{\alpha/2} \vee z \geq z_{\alpha/2}\} = \{z \in R : |z| \geq z_{\alpha/2}\} \quad \text{con } z_{\alpha/2} \text{ tale che } P_0(Z \geq z_{\alpha/2}) = \alpha/2$$

In ogni caso:

- $\alpha = P(\text{rifiutare } H_0 | H_0 \text{ vera})$
- R_α = valori riferiti alla/e coda/e della distribuzione di probabilità di Z sotto H_0

Il **P-value** sarà:

1. $H_1 : \mu > \mu_0 \rightarrow \alpha^{oss} = P_0(Z \geq z^{oss}) = 1 - \Phi(z^{oss})$
2. $H_1 : \mu < \mu_0 \rightarrow \alpha^{oss} = P_0(Z \leq z^{oss}) = \Phi(z^{oss})$
3. $H_1 : \mu \neq \mu_0 \rightarrow \alpha^{oss} = 2\min\{\Phi(z^{oss}), 1 - \Phi(z^{oss})\}$

- Se la varianza è ignota: si usa al suo posto la varianza campionaria corretta (S_c^2) e si ha il test **t**:

$$T = \frac{\bar{X}_n - \mu_0}{S_c/\sqrt{n}}$$

La **statistica test** è la **media campionaria studentizzata** che sotto H_0 ha distribuzione $t(n-1)$.

Per la regione di rifiuto R_α si fissa un livello di significatività α e t un generico valore per T :

1. $H_1 : \mu > \mu_0, R_\alpha = \{t \in R : t \geq t_\alpha\}$
2. $H_1 : \mu < \mu_0, R_\alpha = \{t \in R : t \leq -t_\alpha\}$

$$3. H_1 : \mu \neq \mu_0, R_\alpha = \{t \in R : |t| \geq t_{\alpha/2}\}$$

Dove: t_α e $t_{\alpha/2}$ sono valori critici associati alla distribuzione $t(n-1)$.

I **P-value** si ottengono sostituendo $\Phi(\cdot)$ con la funzione di ripartizione di una $t(n-1)$.

2.2.2 Verifica di ipotesi per la media di una popolazione qualsiasi

Dato un campione casuale semplice $X_1, \dots, X_n$ da una popolazione non normale con media μ , si vuole verificare l'ipotesi nulla ($H_0 : \mu = \mu_0$) ad un livello α fissato.

- Se n è grande:

$$Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$$

La **statistica test** è la **media campionaria** standardizzata che sotto H_0 ha distribuzione $N(0,1)$, se σ non è noto si può usare il suo stimatore $\hat{\sigma}$.

La regione di rifiuto e il livello di significatività si definiscono come nel caso del **test z**.

Proprietà:

- Se $X_i \sim Ber(p) \rightarrow H_0 : p = p_0$ e la statistica test per la media p è $p_0 = \mu_0$, $\hat{p} = \bar{X}_n$, $\sigma = \sqrt{p_0(1-p_0)}$.
- Se $X_i \sim P(\lambda) \rightarrow H_0 : \lambda = \lambda_0$ e la statistica test per la media λ è $\lambda_0 = \mu_0$, $\hat{\lambda} = \bar{X}_n$, $\sigma = \sqrt{\lambda_0}$.
- Se $X_i \sim Ber(p)$ & H_1 è bilaterale si può usare Z^2 come statistica test che sotto H_0 ha circa distribuzione $\chi^2(1)$.

- Se n è piccolo: si vede caso per caso.

2.2.3 Verifica di ipotesi per la varianza di una popolazione normale

Dato un campione casuale semplice $X_1, \dots, X_n$ da una popolazione $N(\mu, \sigma^2)$ e dato σ_0^2 per la varianza, si vuole verificare l'ipotesi nulla ($H_0 : \sigma^2 = \sigma_0^2$) ad un livello α fissato.

La **statistica test** è la **varianza campionaria** S^2 modificata (K) che sotto H_0 ha distribuzione $\chi^2(n-1)$:

$$K = \frac{nS^2}{\sigma_0^2}$$

La **regione di rifiuto** R_α si considerano valori per K che si allontanano dall'ipotesi nulla vanno verso l'ipotesi alternativa:

1. $H_1 : \sigma^2 > \sigma_0^2$ (**alternativa unilaterale destra**)

Valori grandi per K non possono esserci con H_0 andando verso H_1 , quindi la regione di rifiuto sarà:

$$R_\alpha = \{k \in R^+ : k \geq \chi_\alpha^2\} \quad \text{con } \chi_\alpha^2 \text{ tale che } P_0(K \geq \chi_\alpha^2) = \alpha$$

2. $H_1 : \sigma^2 < \sigma_0^2$ (**alternativa unilaterale sinistra**)

Valori piccoli per K non possono esserci con H_0 andando verso H_1 , quindi la regione di rifiuto sarà:

$$R_\alpha = \{k \in R^+ : K \leq \chi_{1-\alpha}^2\} \quad \text{con } \chi_{1-\alpha}^2 \text{ tale che } P_0(K \leq \chi_{1-\alpha}^2) = 1 - \alpha$$

3. $H_1 : \sigma^2 \neq \sigma_0^2$ (**alternativa bilaterale**)

Valori grandi e piccoli per K non possono esserci con H_0 andando verso H_1 , quindi la regione di rifiuto sarà:

$$R_\alpha = \{k \in R^+ : k \leq \chi_{1-\alpha/2}^2 \vee k \geq \chi_{\alpha/2}^2\} \quad \text{con } \chi_{\alpha/2}^2 \text{ e } \chi_{1-\alpha/2}^2 \text{ tale che } P_0(K \geq \chi_{1-\alpha/2}^2) = 1 - \alpha/2$$

Con la statistica test pari alla varianza campionaria corretta:

$$K = \frac{(n-1)S_c^2}{\sigma_0^2}$$

Il **P-value** sarà:

1. $H_1 : \sigma^2 > \sigma_0^2 \rightarrow \alpha^{oss} = P_0(K \geq k^{oss}) = 1 - F_K(k^{oss})$
2. $H_1 : \sigma^2 < \sigma_0^2 \rightarrow \alpha^{oss} = P_0(k \leq k^{oss}) = F_K(k^{oss})$
3. $H_1 : \sigma^2 \neq \sigma_0^2 \rightarrow \alpha^{oss} = 2\min\{F_K(k^{oss}), 1 - F_K(k^{oss})\}$

Dove $F_K(\cdot)$ è la funzione di ripartizione di una $\chi^2(n-1)$.

2.2.4 Test di confronto tra medie di popolazione normali

Nel caso in cui si abbiano 2 o più campioni, si possono confrontarne dei valori di sintesi come la media o per confrontare 2 metodiche di analisi (confronto tra medie, varianze, proporzioni).

Date due popolazioni $N(\mu_1, \sigma_1^2)$ e $N(\mu_2, \sigma_2^2)$ con varianze note ed estratti due campioni casuali semplici n_1 e n_2 dalle rispettive popolazioni, si vuole vedere se le popolazioni hanno la stessa media ($H_0 : \mu_1 = \mu_2$) ad un livello α fissato:

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} = \frac{\bar{X}_1 - \bar{X}_2 - \overbrace{E(\bar{X}_1 - \bar{X}_2)}^{\text{se } H_0 \text{ vera: } \mu_1 = \mu_2}}{\sqrt{V(\bar{X}_1 - \bar{X}_2)}}$$

La **statistica test** è la **differenza tra le medie campionarie** $\bar{X}_1$ e $\bar{X}_2$ calcolate su campioni standardizzati.

- **Se le varianze sono ignote e uguali** (omoschedasticità): la **statistica test** è la **differenza tra le medie campionarie studentizzata** che sotto H_0 ha distribuzione $t(n_1 + n_2 - 2)$:

$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

La varianza comune: $\sigma^2 = \sigma_1^2 = \sigma_2^2$ è lo stimatore combinato:

$$S_p^2 = \frac{(n_1 - 1)S_{c_1}^2 + (n_2 - 1)S_{c_2}^2}{n_1 + n_2 - 2}$$

Questo è il **test t a due campioni**: dove la regione di rifiuto R_α e il P-value definiscono come nel caso del **test t**.

- **Se le varianze sono ignote e diverse** (eteroschedasticità): si usa il **test di Welch**, con statistica test T (che sotto H_0 è possibile calcolarla solo con R):

$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_{c_1}^2}{n_1} + \frac{S_{c_2}^2}{n_2}}}$$

Si possono usare metodi grafici per un confronti più immediato (boxplot, istogrammi, qqplot, test di normalità).

Nel caso del **confronto tra medie di popolazioni non normali**, n è abbastanza elevata, si possono utilizzare le statistiche test che, sotto H_0 , hanno circa distribuzione $N(0, 1)$.

Si possono confrontare le medie di due popolazioni anche quando non sono indipendenti.

Date due popolazioni normali dipendenti, con distribuzione $N(\mu_1, \sigma_1^2)$ e $N(\mu_2, \sigma_2^2)$ per estrarre due campioni casuali semplici appaiati, di dimensione n dalle due popolazioni, si calcolano le differenze tra osservazioni

corrispondenti ottenendo un campione casuale semplice di variabili casuali differenza: $D_i = X_{1i} - X_{2i}$ con media $E(D_i) = \mu_1 - \mu_2 = \mu_d$. Quindi verificando l'ipotesi che $H_0 : \mu_d = 0$ con un livello α fissato, ci si riconduce ad un problema di verifica di ipotesi sulla media di una popolazione normale (**test t**) per il campione differenza.

2.2.5 Test di confronto tra varianze di popolazione normali

Nel caso in cui si abbiano 2 o più campioni, si possono confrontarne per vedere se provengono dallo stesso campione (cioè se vale l'ipotesi di omoschedasticità); questo test è utile anche come verifica preliminare tra il confronto tra medie.

Date due popolazioni $N(\mu_1, \sigma_1^2)$ e $N(\mu_2, \sigma_2^2)$ indipendenti, con parametri ignoti ed estratti due campioni casuali semplici n_1 e n_2 dalle rispettive popolazioni, si vuole vedere se le popolazioni hanno la stessa varianza ($H_0 : \sigma_1^2 = \sigma_2^2 \Rightarrow \sigma_1^2/\sigma_2^2 = 1$) ad un livello α fissato.

La **statistica test** è il **rapporto tra le varianze campionarie corrette** S_{c1}^2 e S_{c2}^2 calcolate nei rispettivi campioni, che sotto H_0 ha distribuzione $F(n_1 - 1, n_2 - 2)$ ottenendo il **test F**:

$$F = \frac{S_{c1}^2}{S_{c2}^2}$$

Se il risultato del test F è circa 1 si accetta H_0 se è lontano da 1 si rifiuta H_0 .

La **regione di rifiuto** R_α si ottiene considerando valori per F che si allontanano dall'ipotesi nulla vanno verso l'ipotesi alternativa:

1. $H_1 : \sigma_1^2 > \sigma_2^2$ ($\sigma_1^2/\sigma_2^2 > 1$) (**alternativa unilaterale destra**)

Valori molto maggiori di 1 per F non possono esserci con H_0 andando verso H_1 , la regione di rifiuto sarà:

$$R_\alpha = \{f \in R^+ : f \geq F_\alpha\} \quad \text{con } F_\alpha \text{ tale che } P_0(F \geq F_\alpha) = \alpha$$

2. $H_1 : \sigma_1^2 < \sigma_2^2$ ($\sigma_1^2/\sigma_2^2 < 1$) (**alternativa unilaterale sinistra**)

Valori molto minori di 1 per F non possono esserci con H_0 andando verso H_1 , la regione di rifiuto sarà:

$$R_\alpha = \{f \in R^+ : f \leq F_{1-\alpha}\} \quad \text{con } F_{1-\alpha} \text{ tale che } P_0(F \geq F_{1-\alpha}) = 1 - \alpha$$

3. $H_1 : \sigma^2 \neq \sigma_0^2$ ($\sigma_1^2/\sigma_2^2 \neq 1$) (**alternativa bilaterale**)

Valori molto maggiori o minori di 1 per F non possono esserci con H_0 andando verso H_1 , la regione di rifiuto sarà:

$$R_\alpha = \{f \in R^+ : f \leq F_{1-\alpha/2} \vee f \geq F_{\alpha/2}\}$$

con $F_{\alpha/2}$ e $F_{1-\alpha/2}$ tale che $P_0(F \geq F_{\alpha/2}) = \alpha/2$ e $P_0(F \geq F_{1-\alpha/2}) = 1 - \alpha/2$.

Il **P-value** sarà:

1. $H_1 : \sigma_1^2 > \sigma_2^2 \rightarrow \alpha^{oss} = P_0(F \geq f^{oss}) = 1 - F_F(f^{oss})$
2. $H_1 : \sigma_1^2 < \sigma_2^2 \rightarrow \alpha^{oss} = P_0(F \leq f^{oss}) = F_F(f^{oss})$
3. $H_1 : \sigma_1^2 \neq \sigma_2^2 \rightarrow \alpha^{oss} = 2\min\{F_F(f^{oss}), 1 - F_F(f^{oss})\}$

Dove $F_F(\cdot)$ è la funzione di ripartizione di una $F(n_1 - 1, n_2 - 1)$.

2.3 Test su popolazioni

In molti casi le popolazioni campionarie non sono rappresentabili da modelli gaussiani; di solito le popolazioni da cui provengono i campioni sono descrivibili con modelli bernoulliani (o binomiali).

2.3.1 Test per il confronto tra popolazioni

Date due popolazioni $Ber(p_1)$ e $Ber(p_2)$ **indipendenti**, con p_1, p_2 popolazioni ignote ed estratti due campioni casuali semplici n_1 e n_2 dalle rispettive popolazioni, si vuole vedere se i due campioni vengono dalla stessa popolazione ($H_0 : p_1 = p_2$ ($p_1 - p_2 = 0$)) ad un livello α fissato.

La **statistica test** è la **differenza tra le popolazioni campionarie** $\hat{p}_1 = \bar{X}_1$ e $\hat{p}_2 = \bar{X}_2$ calcolate su campioni standardizzati:

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)}}$$

Lo stimatore combinato ($\hat{p}$) di $p_1 = p_2 = p$ sotto H_0 sarà la proporzione campionaria calcolata considerando insieme i due campioni:

$$\hat{p} = \frac{n_1 \hat{p}_1 + n_2 \hat{p}_2}{n_1 + n_2}$$

Se n_1 e n_2 sono abbastanza alti, la statistica test Z ha distribuzione $N(0, 1)$.

La regione di rifiuto R_α e il P-value definiscono come nel caso del **test z**.

Se le **due popolazioni bernoulliane** sono **dipendenti** e **se n è grande** si può usare il **test di McNemar** che confronta la discordanze osservate e le discordanze attese sotto $H_0 : p_1 = p_2$ con circa distribuzione $N(0, 1)$.

2.3.2 Test chi-quadrato di indipendenza

Se si hanno **due o più campioni multinomiali indipendenti** si può ancora usare il test per il confronto tra popolazioni, infatti il **modello multinomiale** estende il binomiale nel caso in cui si abbiano $n \geq 1$ repliche indipendenti di un esperimento che può assumere due o più esiti.

Si avranno $k \geq 2$ possibili categorie $x_1, \dots, x_k$ e il modello binomiale si ottiene come caso particolare con $k = 2$, $x_1 = 0$, $x_2 = 1$.

	y_1	y_2	$\dots$	y_k	
campione 1	n_{11}	n_{12}	$\dots$	n_{1k}	$n_{1+} = n_1$
campione 2	n_{21}	n_{22}	$\dots$	n_{2k}	$n_{2+} = n_2$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
campione r	n_{r1}	n_{r2}	$\dots$	n_{rk}	$n_{r+} = n_r$
	n_{+1}	n_{+2}	$\dots$	n_{+k}	n

Considerando $r \geq 2$ campioni indipendenti di numerosità fissata $n_1, \dots, n_r$ da un modello multinomiale con $k \geq 2$ categorie $y_1, \dots, y_k$ si possono riassumere così i dati. Si vuole verificare che i campioni vengano dalla stessa popolazione ($H_0 : p_{1j} = p_{2j} = \dots = p_{rj} \forall j = 1, \dots, k$ p_{ij} = probabilità esito y_j nell' i -esima popolazione)

La statistica test sarà l'indice chi-quadrato, il **test chi-quadrato di indipendenza**:

$$K = \sum_{i=1}^r \sum_{j=1}^k \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}, \quad n_{ij}^* = n_{i+} n_{+j} / n, \quad i = 1, \dots, r, \quad j = 1, \dots, k.$$

Se $n_1, \dots, n_r$ sono abbastanza elevati la statistica test sotto H_0 ha circa distribuzione $\chi^2((r-1)(k-1))$.

Se H_0 vera $\rightarrow K \simeq 0$, se H_0 falsa $\rightarrow K > 0$.

La regione di rifiuto per un livello α fissato sarà:

$$R_\alpha = \{k \in R^+ : k > \chi_\alpha^2\}$$

$\alpha^{oss} = 1 - F_K(k^{oss})$ con χ_α^2 il valore critico di livello α e $F_K(\cdot)$ la funzione di ripartizione di una variabile casuale $\chi^2((r-1)(k-1))$; [$k = Z^2 \cong \chi^2(1)$] se si hanno campioni > 2 ed esiti > 2 .

Se si ha un campione piccolo (< 5), è meglio usare un test di Fisher.

2.3.3 Test chi-quadrato di adattamento

Il **test chi-quadrato di adattamento** serve per verificare se una variabile categoriale ha una specifica distribuzione di probabilità.

Data una variabile casuale categoriale X che può avere $k > 1$ modalità distinte e probabilità $p_i > 0$, $i = 1, \dots, k$ e $\sum_{i=1}^k p_i = 1$, si osserva un campione con n osservazioni indipendenti di X e si verifica l'ipotesi nulla ($H_0 : p_1 = p_1^0, \dots, p_k = p_k^0$):

$$K = \sum_{i=1}^k \frac{(n_i - n_i^*)^2}{n_i^*}, \quad n_i^* = \text{frequenza osservata nel campione}, n_i^* = np_i^0 = \text{frequenza attesa sotto } H_0$$

Se il campione è abbastanza elevato, la statistica test K sotto H_0 ha distribuzione $\chi^2(k-1)$.

La regione di rifiuto sarà:

$$R_\alpha = \{k \in R^+ : k > \chi_\alpha^2\}$$

$\alpha^{oss} = 1 - F_K(k^{oss})$ con χ_α^2 il valore critico di livello α e $F_K(\cdot)$ la funzione di ripartizione di una variabile casuale $\chi^2(k-1)$.

Questo test è applicabile a variabili casuali discrete con supporto finito e variabili casuali continue con modalità raggruppate in classi.

3 Modello di regressione lineare

Con il **modello di regressione lineare** si porta l'attenzione in due analisi:

- **correlazione**: si osserva la dipendenza lineare tra le due tra 2 fenomeni aleatori quantitativi (variabili casuali continue).
- **regressione**: si costruisce un modello statistico parametrico opportuno con la variabile casuale d'interesse che dipende da una o più variabili esplicative.

3.1 Analisi di correlazione

Nell'**analisi di correlazione** si osserva la dipendenza lineare tra due fenomeni aleatori di interesse, riferiti alla variabile casuale (X, Y) trattate in modo simmetrico.

Non si cerca di vedere quale delle due spiega l'altra ma solo se c'è dipendenza, un indicatore normalizzato è il **coefficiente di correlazione lineare**:

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \in [0, 1]$$

Con un campione casuale semplice $(X_1, Y_1), \dots, (X_n, Y_n)$ si utilizza lo stimatore per ρ_{XY} , il **coefficiente di correlazione lineare campionario**:

$$\hat{\rho}_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)}{\sqrt{\sum_{i=1}^n (X_i - \bar{X}_n)^2 \sum_{i=1}^n (Y_i - \bar{Y}_n)^2}}$$

$\hat{\rho}_{XY}$ è molto sensibile a valori anomali

3.1.1 Test di correlazione

Date le variabili casuali $(X_1, Y_1), \dots, (X_n, Y_n)$ con distribuzione normale bivariata, si vuole verificare l'ipotesi nulla ($H_0 = \rho_{XY} = 0$) ad un livello α fissato, la statistica test sarà:

$$R = \frac{\hat{\rho}_{XY} \sqrt{n-2}}{\sqrt{1 - \hat{\rho}_{XY}^2}}$$

che sotto H_0 ha distribuzione $t(n-2)$, la **regione di rifiuto** e il **livello di significatività osservato** si calcolano come nel **test t** ma con $n-2$ gradi di libertà.

Questo test si usa nel caso in cui i dati X, Y hanno distribuzione gaussiana (senza dati anomali tipo outliers); di solito insieme ad un'analisi su ρ si fa anche un'analisi con Spireman e Kendall.

3.2 Analisi di regressione

3.2.1 Modello di regressione lineare semplice

Nel **modello di regressione lineare semplice** si ha una **variabile risposta** Y su cui si porta l'attenzione ed una **variabile esplicativa** (o regressore/previsore) x da cui si hanno informazioni che aiutano a spiegare Y . In questo caso si va a vedere anche la direzione della dipendenza.

$$Y_i = \underbrace{a + bx_i}_{\text{parte deterministica}} + \underbrace{\epsilon_i}_{\text{errore}}, \quad Y_i \sim N(a + bx_i, \sigma^2)$$

dove:

- a, b sono i coefficienti di regressione, dei parametri reali ignoti;
- $Y_1, \dots, Y_n$ sono indipendenti e identicamente distribuiti;
- $x_1, \dots, x_n$ sono le corrispondenti osservazioni riferite alla variabile esplicativa;
- $\epsilon_1, \dots, \epsilon_n$ sono i residui (errori), variabili casuali indipendenti con distribuzione $N(0, \sigma^2) \Rightarrow E(\epsilon_i) = 0$;
- le osservazioni $y_1, \dots, y_n$ sono osservazioni di variabili casuali indipendenti ma non sempre identicamente distribuite;
- $E(x_i) = a + bx_i + E(\epsilon_i) = a + bx_i$
- $V(y_i) = V(\epsilon_i) = \sigma^2$

Questo è un modello più flessibile, ammette il cambio della media (è un tentativo di rendere il modello più vicino alla realtà) ma per usarlo servono delle assunzioni:

- x influenza Y in modo lineare (in particolare la media è specificata da $y = a + bx$)
- i dati $Y_1, \dots, Y_n$ sono gaussiani indipendenti
- la varianza è uguale dato per dato

Se $b = 0$ è come togliere la x dalla retta di regressione quindi x non influenza Y .

3.2.2 Inferenza e verifica di ipotesi nel modello regressione lineare

Dalle osservazioni $x_1, \dots, x_n$ e $y_1, \dots, y_n$ si possono stimare i parametri ignoti del modello di regressione lineare semplice: a, b, σ^2

- $a, b \Rightarrow$ **metodo dei minimi quadrati**:

$$\hat{a} = \bar{Y}_n - \hat{b}\bar{x}_n, \quad \hat{b} = \frac{\sum_{i=1}^n (Y_i - \bar{Y}_n)(x_i - \bar{x}_n)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} = \frac{\sum_{i=1}^n Y_i x_i - n\bar{Y}_n \bar{x}_n}{\sum_{i=1}^n x_i^2 - n\bar{x}_n^2} = \frac{\hat{\sigma}_{Yx}}{\hat{\sigma}_x^2}$$

con $\bar{Y}_n$ media campionaria di $Y_1, \dots, Y_n$; $\bar{x}_n$ media dei valori $x_1, \dots, x_n$; $\hat{\sigma}_{Yx}$ covarianza campionaria di $Y_1, \dots, Y_n$ e $x_1, \dots, x_n$; $\hat{\sigma}_x^2$ varianza di $x_1, \dots, x_n$.

$y = \hat{a} + \hat{b}x$ è la **retta di regressione stimata**.

$\hat{a}, \hat{b}$ sono buoni stimatori perché non sono distorti, $E(\hat{a}) = a$, $E(\hat{b}) = b$ e la varianza:

$$V(\hat{a}) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n(\sum_{i=1}^n x_i^2 - n\bar{x}_n^2)}, \quad V(\hat{b}) = \frac{\sigma^2}{\sum_{i=1}^n x_i^2 - n\bar{x}_n^2}$$

quindi $\hat{a}, \hat{b}$ si ottengono da combinazioni lineari tra variabili gaussiane: $\hat{a} \sim N(a, V(\hat{a}))$, $\hat{b} \sim N(b, V(\hat{b}))$.

$$se(\hat{a}) = \sqrt{V(\hat{a})}, \quad se(\hat{b}) = \sqrt{V(\hat{b})}.$$

I **valori stimati** e i **residui stimati** saranno:

$$\hat{y}_i = \hat{a} + \hat{b}x_i = \hat{\mu}_i, \quad \hat{\epsilon}_i = y_i - \hat{a} - \hat{b}x_i = y_i - \hat{y}_i$$

- $\sigma^2 \Rightarrow$ per la **stima della varianza dei residui**:

$$\sigma^2 = V(\epsilon_i), \quad s^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2} = \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{n-2}$$

S^2 è lo stimatore di σ^2 , è consistente e non distorto, si usa $n-2$ perché i dati sono già stati usati 2 volte (per stimare a e b).

Gli **standard error stimati**:

$$\hat{se}(\hat{a}) = \sqrt{\frac{s^2 \sum_{i=1}^n x_i^2}{n(\sum_{i=1}^n x_i^2 - n\bar{x}_n^2)}}, \quad \hat{se}(\hat{b}) = \sqrt{\frac{s^2}{\sum_{i=1}^n x_i^2 - n\bar{x}_n^2}}$$

– studentizzando $\hat{a}$ si ottiene:

$$\frac{\hat{a} - a}{\hat{se}(\hat{a})} \sim t(n-2), \quad \frac{\hat{b} - b}{\hat{se}(\hat{b})} \sim t(n-2)$$

$[\hat{b} - t_{\alpha/2} \hat{se}(\hat{b}), \hat{b} + t_{\alpha/2} \hat{se}(\hat{b})]$ con $t_{\alpha/2}$ valore critico tale che $P(T \geq t_{\alpha/2}) = \alpha/2$ dove $T \sim t(n-2)$

– test di ipotesi:

$$b: \begin{cases} H_0 : b = 0 \Rightarrow \text{verificare che } x \text{ sia inutile a spiegare } Y \\ H_1 : b \neq 0 \Rightarrow \text{verificare che } x \text{ sia utile a spiegare } Y \end{cases}$$

La **statistica test**:

$$T = \frac{\hat{b}}{\hat{se}(\hat{b})}$$

che sotto H_0 ha distribuzione $t(n-2)$, la **regione di rifiuto** e il **livello di significatività osservato** si calcolano come nel **test t** ma con $n-2$ gradi di libertà.

La retta di regressione serve per:

- capire il fenomeno tramite il modello (**interpretazione**)
- finalità predittive per i valori mancanti della Y (in media, mi aspetto un valore sulla retta di regressione), è utile se si rimane nel range dei valori osservati.

3.2.3 Valutazioni sul modello di regressione

Quanto il modello fa capire sui dati Y e quanto spiega il cambiamento dei dati: la bontà del modello tramite l'**indice di determinazione**.

$$R^2 = \frac{\sum_i (\hat{y}_i - \bar{y}_n)^2}{\sum_i (y_i - \bar{y}_n)^2} = \frac{\text{varianza spiegata}}{\text{varianza totale}} = 1 - \frac{\text{varianza residua}}{\text{varianza totale}}$$

$$\underbrace{\frac{\sum_{i=1}^n (y_i - \bar{y}_n)^2}{n}}_{\text{Var. totale}} = \underbrace{\frac{\sum_{i=1}^n (\hat{y}_i - \bar{y}_n)^2}{n}}_{\text{Var. spiegata}} + \underbrace{\frac{\sum_{i=1}^n \overbrace{(y_i - \hat{y}_i)^2}^{\hat{\epsilon}_i}}{n}}_{\text{Var. residua}}$$

R^2 è una percentuale dei dati spiegati dal modello ed è compresa tra 0 e 1:

- 1 = tutti i punti sono sulla retta;
- 0 = il modello non spiega niente.

$R^2 = \hat{\rho}_{Yx}^2$ e nel caso di una sola x , $R^2 = \hat{\rho}^2$

Per migliorare l'adattamento del modello ai dati si possono trasformare (logaritmo o l'elevamento a potenza) i valori della variabile esplicativa x e/o della variabile risposta Y .

R^2 può essere usato per confrontare modelli alternativi sullo stesso dataset; se il valore ottenuto è basso non vuol dire che ci sono errori ma che i dati hanno un alta variabilità; non va bene per dati temporali perché solitamente sono dipendenti.

3.3 Diagnostiche

Per verificare l'ipotesi di linearità e le ipotesi sui residui ci sono altri metodi (grafici):

- **grafici:**
 - valori stimati con errori stimati: costanza nelle varianze
 - valori di x con errori stimati
 - residui stimati (per capire se sono gaussiani)
- **outliers:** controllo se sono dati genuini e non errori:
 - analisi con outliers: è interessante in certi casi analizzare le anomalie
 - analisi senza outliers: una visione normale
 - distanza di Cook: quanto quegli outliers influiscono sull'analisi (valori critici 0,5)