

Terminologia

Dati Osservazionali: dati esistenti in natura che vengono rilevati direttamente [censimenti, sondaggi d'opinione]

Dati Sperimentali: dati ottenuti da esperimenti controllati / laboratorio, (creati in circostanze controllate)

Variabilità: differenze tra osservazioni

Unità Statistiche: oggetto sul quale si raccolgono dati. Ognuna fornisce osservazioni per una o più variabili di interesse {Rows}

Popolazione: insieme per intero delle unità statistiche sulle quali si cerca l'informazione

→ **Reale:** costituite da unità con esistenza fisica. n° finito [censimento (100%), campionamento (%)]

→ **Virtuale:** esistenza concettuale, potenzialmente infinite (replicabilità) [campionamento (n° ripetizioni finito)]

Censimento: si esaminano tutte le unità di una popolazione reale

Campionamento: si esamina un sottoinsieme finito di unità statistiche appartenenti ad una popolazione reale o virtuale [estrazione casuale]

→ **Descrittiva:** individuazione della struttura essenziale tramite descrizione, presentazione e sintesi dei dati

Statistica

→ **Inferenziale:** previsioni / inferenze riguardo popolazione più ampia tramite tecniche come stima, test e ipotesi

→ **Univariata:** relativa ad una singola variabile [caratteristica] di interesse

Analisi

→ **Multivariata:** relativa a due o più variabili [caratteristiche] di interesse

Supporto: insieme delle modalità di una variabile effettivamente misurate (senza ripetizioni) e solitamente ordinate

Variabili: caratteristiche osservate / misurate nelle unità statistiche (lettera Maiuscola)

→ **Modalità:** valori che una variabile può assumere

→ **Qualitative:** modalità concettuale [serie statistica = tabella di frequenza di una variabile statistica qualitativa]

→ **Sconnesse:** prive di ordinamento naturale delle modalità

→ **Ordinali:** con modalità ordinabili in maniera naturale
a) possono essere considerate sconnesse

→ **Quantitative:** modalità numeriche (non codifiche numeriche) [scala] $\left\{ \begin{array}{l} \text{intervalli: } \neq 0 \text{ naturale \& non arbitrario} \\ \text{rapporti: } = 0 \text{ naturale \& non arbitrario} \end{array} \right.$

→ **Discrete:** se l'insieme delle modalità è finito (o numerabile)
a) possono essere tradotte in variabili qualitative ordinali.

→ **Continue:** se l'insieme delle modalità è continuo [potenziale continuità / riferimento semplificativo]
a) possono essere discretizzate

→ **Variabile Statistica:** rilevazione (come array) di una certa variabile su una popolazione (campione) {Cols}
a) stessa variabile ma con diverso campione → variabile statistiche differenti

→ **Variabile Statistica Degenera:** variabile che assume lo stesso valore per tutte le osservazioni di un dataset.

Frequenza: numero di volte in cui un certo valore o categoria di variabile si verifica in un dataset.

→ **Absoluta:** numero di osservazioni di modalità o classi di modalità. [f]

→ **Distribuzione di f:** lista delle modalità osservate accompagnate dalle relative frequenze
→ Modalità + Frequenza = DISTRIBUZIONE DI FREQUENZA ASSOLUTA

→ **Relativa:** proporzione delle osservazioni di modalità o classi di modalità. [p] $\left(\frac{\text{Assolute}}{\text{Totali}} \right) \sim \text{intervallo } (0, 1)$

→ **Cumulate:** somma progressiva delle osservazioni precedenti di modalità o classi di modalità [F(ass), P(rel)]

Serie storica: misura del fenomeno in riferimento al tempo (Temporizzate)

Serie spaziale: misura del fenomeno in riferimento allo spazio (Geotipizzate)

Classi di modalità: intervalli / gruppi di valori che raggruppano le modalità di una variabile quantitativa continua

→ **Regole** $\left\{ \begin{array}{l} \text{N° adeguato} \\ \text{Disgiunte} \\ \text{Contenenti TUTTE le modalità} \\ \text{Possono avere ampiezze diverse} \end{array} \right\} \rightarrow \text{norma} = \sqrt{n}$

→ **Seriazione Statistica:** tabella di frequenza assoluta con modalità raggruppate in classi $\left[\frac{\text{Classi}}{\text{Frequenza}} \right]$

Rappresentazioni Grafiche (Diagrammi Statici)

Dati Categoriali

- **Diagrammi Circolari**: utili per rappresentare serie statistiche sconnesse [nominali/ordinali]
l'area del settore circolare deve essere proporzionale alla frequenza della modalità.
- **Diagrammi a Barre**: utili per rappresentare serie statistiche sconnesse [nominali/ordinali]
l'altezza dei rettangoli è proporzionale alla frequenza della modalità
le barre sono separate tra loro per non implicare alcuna continuità e hanno la stessa base
- **Diagrammi a Barre Multipli**: si usano nel caso in cui la distribuzione di frequenza risulta suddivisa secondo un criterio
si usano frequenze relative affinché il confronto abbia senso
i rettangoli sono raggruppati tenendo conto del criterio di classificazione

Dati Numerici

- **Diagramma a Bastoncini**: utili per rappresentare distribuzioni di frequenza [assoluta/relativa] riferite a dati qualitativi discreti.
l'altezza dei bastoncini è proporzionale o pari alla frequenza della modalità.
- **Istogramma**: utili per rappresentare distribuzioni di frequenza [assoluta/relativa] con modalità raggruppate in classi (continui)
si può anche usare per descrivere distribuzioni di frequenza di variabili statistiche quantitative discrete (modalità distinte)
- **Formule**:
 - **Base**: ampiezza della classe → intervallo $[y_{j-1}, y_j]$
 - **Altezza**: si hanno due casi. Se i rettangoli hanno la stessa base → altezza proporzionale a f_j o p_j
 - **Freq. Ass.**: proporzionale o pari a → $\frac{f_j}{(y_j - y_{j-1})}$
 - **Freq. Rel.**: proporzionale o pari a → $\frac{p_j}{(y_j - y_{j-1})}$

} basi diverse
- **Poligoni di Frequenza**: smussamento locale dell'istogramma.
il poligono si ottiene unendo i punti di mezzo dei lati superiori dei rettangoli
- **Stima della densità**: stima della distribuzione delle frequenze tramite una curva smussata
 - **Formula**: stima con il metodo del nucleo → $f_n(y) = \frac{1}{n \cdot b} \cdot \sum_{i=1}^n K\left(\frac{y - y_i}{b}\right)$, $y \in \mathbb{R}$
 - $K(\cdot)$ = nucleo
 - $b > 0$ = banda
 - $\mathbb{R}$ = insieme numeri reali
 - **Nucleo**: si possono scegliere diversi nuclei ma secondo le seguenti proprietà $[K(u) \geq 0]$ & $[\int_{-\infty}^{\infty} K(u) du = 1]$
 - **Banda**: va scelta in maniera opportuna per avere un risultato ottimale e comprensibile
- **Funzione di Ripartizione Empirica**: Funzione il cui valore nel punto $y \in \mathbb{R}$ corrisponde al rapporto tra il numero di osservazioni $\leq y$ e il totale.
 - a) fornisce la proporzione cumulata di unità statistiche che presentano modalità $\leq y$ [Funzione a gradini]
 - b) si usa per variabili quantitative discrete
- **Formula**: $F_n(y) = \frac{n^{\circ} \text{oss.} \leq y}{n^{\circ} \text{tot. oss.}}$, $y \in \mathbb{R}$
- **Diagrammi di dispersione**: si usano nel caso di due variabili quantitative (per una prima analisi)
- **Boxplot**: fornisce una sintesi grafica efficace dell'insieme dell'insieme di dati basata sui quantili.
 - **Elementi**:
 - **Scatola**: contiene il 50% centrale ($y_{0.25} \sim y_{0.75}$) della distribuzione di frequenza (traccia una linea su $y_{0.5}$)
 - **Baffi**: linee che si prolungano fino al valore massimo e minimo (o $y_{0.05}$ e $y_{0.95}$)
 - a) si possono specificare diversamente per far emergere valori anomali (outliers)

Indici Sintetici

Strumento per descrivere alcuni aspetti rilevanti dell'insieme dei dati e della associata distribuzione di frequenza.

Aspetti d'interesse:

→ **Posizione:** centro dei dati. (espresso nell'ordine di grandezza di Y)

→ **Media Aritmetica:** si può calcolare per una variabile quantitativa Y $[E(Y)]$ (non è un indice robusto)
(sensibile ai valori anomali)

→ **Formule:**

→ dai dati grezzi: $E(Y) = \frac{1}{n} \cdot \sum_{i=1}^n y_i$

→ dalla tabella di Frequenza

→ frequenza assoluta: $E(Y) = \frac{1}{n} \cdot \sum_{j=1}^J y_j \cdot f_j$
→ frequenza relativa: $E(Y) = \sum_{j=1}^J y_j \cdot p_j$ } sono uguali

→ dalla tabella di Frequenza con modalità raggruppate in classi

→ frequenza assoluta: $E(Y) = \frac{1}{n} \cdot \sum_{j=1}^J y_j^c \cdot f_j$
→ frequenza relativa: $E(Y) = \sum_{j=1}^J y_j^c \cdot p_j$ } sono uguali

→ nel caso di classi aperte: si individua il punto centrale solo dopo aver "chiuso la classe"
basta un requisito: { a) le osservazioni che cadono in una classe coincidono col punto centrale
b) le osservazioni sono distribuite uniformemente nella classe

→ **Proprietà:**

→ **Cauchy:** sia $S_Y = \{y_1, \dots, y_J\}$ con $y_1 \leq \dots \leq y_J \rightarrow y_1 \leq E(Y) \leq y_J$

→ **Baricentro:** sia $Y - E(Y)$ la variabile di scarto di Y da $E(Y) \rightarrow E(Y - E(Y)) = 0$

→ **Linearità:** sia $aY + b$, $a, b \in \mathbb{R}$ una trasformata lineare di $Y \rightarrow E(aY + b) = aE(Y) + b$

→ **Mediana:** si può calcolare per una variabile qualitativa ordinale / quantitativa Y $[y_{0.5}]$ (è un indice robusto rispetto alle anomalie)

→ **Definizione:** il valore che rispetto all'ordinamento non decrescente delle osservazioni, le divide in due parti uguali

→ mediana = ogni valore $y_{0.5}$ tale che: { (almeno) 50% delle unità statistiche ha modalità $\leq y_{0.5}$
(almeno) 50% delle unità statistiche ha modalità $\geq y_{0.5}$
→ quantile di livello α con $\alpha = 0.5$

→ **Formule:**

→ dai dati grezzi (ordinati non decrescenti):

→ n dispari: modalità in posizione $\frac{n+1}{2} \rightarrow y_{0.5} = y_{(n+1)/2}$

→ n pari: modalità in posizione $\frac{n}{2}$ & $\frac{n}{2} + 1 \rightarrow y_{0.5} = y_{n/2}$ & $y_{0.5} = y_{(n/2)+1}$ mediana convenzionale
a) se $y_{n/2}$ e $y_{(n/2)+1}$ non coincidono la mediana può non essere unica (usa il valore di mezzo)

→ dalla tabella di Frequenza assoluta/relativa (ordinato crescente)

→ frequenze assolute: $f_j, j = 1, \dots, J$ (si conosce n)

→ n dispari: $y_{0.5} = y_j \rightarrow f_j$ più piccola tale che $\rightarrow f_j \geq \frac{n+1}{2}$

→ n pari: $y_{0.5} = y_j \rightarrow f_j$ più piccola tale che $f_j \geq \frac{n}{2}$ & $y_j \rightarrow f_j$ più piccola tale che $\rightarrow f_j \geq \frac{n}{2} + 1$

→ frequenze relative: $y_{0.5} = y_j \rightarrow p_j$ più piccola tale che $p_j \geq 0.5 \rightarrow$ se esiste $y_{0.5} = y_j$ & $y_{0.5} = y_{j+1}$

→ con classi di modalità: si opera nella stessa maniera ma si individuerà una classe mediana

→ **Quantili:** valore che divide un insieme di dati ordinati in intervalli uguali. (la mediana è un quantile di livello)

→ variabile qual. ordinale/quant. $[Y]$: $y_\alpha \rightarrow$ valore preceduto da $\alpha 100\%$ osservazioni e seguito da $(1-\alpha) 100\%$ osservazioni.
a) il quantile di livello α , con $\alpha \in (0, 1)$ di una variabile statistica Y corrisponde a y_α tale che:
d) almeno $\alpha 100\%$ unità statistiche presenta modalità $\leq y_\alpha$
2) almeno $(1-\alpha) 100\%$ unità statistiche presenta modalità $\geq y_\alpha$

→ **Moda:** si calcola per variabile qualitative/quantitative $[y_m]$ e corrisponde alla modalità con maggior frequenza
a) nel caso si abbiano classi di modalità si individuano classi modali se e solo se le classi hanno la stessa ampiezza

→ Variabilità: dispersione dei dati (diversificazione delle modalità osservate)

→ Quantitative: si intende come diversità di valori osservati e distanza tra essi

→ Campo di Variazione: (range) differenza tra osservazione più grande e la più piccola

Formula: sia Y una variabile statistica, $R_Y = y_{(n)} - y_{(1)}$ (con Y crescente)

→ Scarto interquartile: differenza tra terzo e primo quartile (ampiezza boxplot) (può essere nullo)

Formula: sia Y una variabile statistica, $SI_Y = y_{0.75} - y_{0.25}$

→ Varianza: misura la dispersione dei dati attorno alla media {unità di misura = (misura dei dati)²} [$V(Y)$, σ_y^2]

→ Formule: $\{V(Y) = E(Y^2) - (E(Y))^2\}$

→ data la variabile statistica: 1) $V(Y) = E[(Y - E(Y))^2]$
2) $\sigma_y = \sqrt{V(Y)}$

→ dai dati grezzi: $Y = (y_1, \dots, y_n)$ e si è calcolata $E(Y) \rightarrow V(Y) = \frac{1}{n} \sum_{i=1}^n (y_i - E(Y))^2$

→ dalla distribuzione di Frequenza:

→ assoluta: $V(Y) = \frac{1}{n} \sum_{j=1}^J (y_j^* - E(Y))^2 \cdot f_j$

→ relativa: $V(Y) = \sum_{j=1}^J (y_j^* - E(Y))^2 \cdot p_j$

→ dalle distribuzioni di frequenza in classi: è necessario calcolare il punto centrale $\{y_j^* = \frac{y_{j-1} + y_j}{2}\}$

→ assoluta: $V(Y) = \frac{1}{n} \sum_{j=1}^J (y_j^* - E(Y))^2 \cdot f_j$

→ relativa: $V(Y) = \sum_{j=1}^J (y_j^* - E(Y))^2 \cdot p_j$

→ Proprietà:

→ non negatività: $V(Y) \geq 0$, con $V(Y) = 0$ se e solo se Y è degenera $\leadsto$ se $E(Y) = 0$ allora $V(Y) = E(Y^2)$

→ invarianza per traslazioni: $V(Y+b) = V(Y)$, $b \in \mathbb{R}$

→ omogeneità di secondo grado: $V(aY) = a^2 \cdot V(Y)$, $a \in \mathbb{R}$

$$\left. \begin{array}{l} V(Y+b) = V(Y) \\ V(aY) = a^2 \cdot V(Y) \end{array} \right\} V(aY+b) = a^2 \cdot V(Y)$$

→ Coefficiente di Variazione: misura la variabilità dei dati tenendo conto dell'ordine di grandezza del fenomeno (relativo)

a) Una variabile statistica con media nulla e varianza unitaria $\rightarrow$ standardizzata

→ Formule: $CV_Y = \frac{\sigma_Y}{E(Y)} \leadsto \frac{\text{Varianza}}{\text{Media Ar.}}$

→ data variabile Y : $Z = \frac{Y - E(Y)}{\sigma_Y} \leadsto Z$ è standardizzata

→ data var. standardizzata Z : $Y = \sigma_Y + E(Z)$ $\leadsto E(Y) = E(Z)$ & $V(Y) = \sigma^2$

→ standardizzazione dei dati: $z_i = \frac{y_i - E(Y)}{\sigma_Y}$

→ Forma della distribuzione

→ Indice di Simmetria:

→ Simmetria: distribuzione $\leadsto$ simmetrica se la metà dx si sovrappone sulla metà sx (la mediana fonde da metà)

→ Assimetria: se dx è più lunga $\rightarrow$ asimmetria positiva

→ Si noti che: 1) asimmetria positiva $\leadsto$ media > mediana ($r_Y > 0$)
2) simmetria $\leadsto$ media $\approx$ mediana ($r_Y \approx 0$)
3) asimmetria negativa $\leadsto$ media < mediana ($r_Y < 0$)

→ Formule: data variabile statistica Y , media $E(Y) \rightarrow r_Y = \frac{E[(Y - E(Y))^3]}{\sigma_Y^3}$ con $\sigma_Y = \sqrt{V(Y)}$ (scarto quadratico medio di Y)

→ dati grezzi: $Y = (y_1, \dots, y_n)$, $E(Y)$, σ_Y conosciuti $\leadsto r_Y = \frac{\frac{1}{n} \sum_{i=1}^n (y_i - E(Y))^3}{\sigma_Y^3}$

→ Indice di Curtosi:

→ Curtosi: allontanamento dalla distribuzione di frequenza normale (gaussiana)

a) platicurtica (iponormale) = + appiattito, code leggere $\leadsto \beta_Y < 3$

b) leptocurtica (ipernormale) = + allungato, code pesanti $\leadsto \beta_Y > 3$

c) normocurtica $\leadsto \beta_Y \approx 3$

→ Formule: $\beta_Y = \frac{E[(Y - E(Y))^4]}{\sigma_Y^4} \leadsto \sigma_Y = \sqrt{V(Y)}$ = scarto quadratico medio di Y

→ dai dati grezzi: $\beta_Y = \frac{\frac{1}{n} \sum_{i=1}^n (y_i - E(Y))^4}{\sigma_Y^4}$

Analisi Multivariate

Distribuzioni di Frequenza:

- **Coniunta**: si considera la distribuzione di due o più variabili casuali contemporaneamente
- **Marginale**: si considera la distribuzione di frequenza relativa ad una singola variabile
- **Condizionata**: si considera la distribuzione di frequenza relativa ad una variabile considerando le un.stat. che assumono una modalità dell'altra

Rappresentazioni Grafiche

- dai dati grezzi: grafico di dispersione (scatterplot)
- dalla distribuzione di frequenza:
 - **coniunta (quant)**:
 - istogrammi
 - diagrammi a bastoncini } spazio 3D
 - **marginale/condizionata**: tutte quelle viste per analisi univariate

Tabella di contingenza: descrive la frequenza con la quale le modalità di due variabili vengono congiuntamente osservate

	y_1	y_2	...	y_K	
x_1	n_{11}	n_{12}	...	n_{1K}	n_{1+}
x_2	n_{21}	n_{22}	...	n_{2K}	n_{2+}
...	...	...	...	...	...
x_m	n_{m1}	n_{m2}	...	n_{mK}	n_{m+}
	n_{+1}	n_{+2}	...	n_{+K}	n

$X = (x_1, \dots, x_m)$ n_{rs} = freq. ass. ($m \cdot K$ possibili coppie $[x_r, y_s]$)
 $Y = (y_1, \dots, y_K)$ n_{r+} = totale di riga n_{+s} = totale di colonna n = totale osservazioni

- **distribuzioni di frequenza assoluta ricavate**: $[r = 1, \dots, m], [s = 1, \dots, K]$
 - **coniunta**: $(x_r, y_s); n_{rs}$
 - **marginale di X**: $x_r; n_{r+}$
 - **marginale di Y**: $y_s; n_{+s}$
 - **condizionata di X dato Y**: $y_s: x_r, n_{rs} \text{ (con } r = 1, \dots, m)$
 - **condizionata di Y dato X**: $x_r: y_s, n_{rs} \text{ (con } s = 1, \dots, K)$ } corrispondono ai totali di riga e colonna
} corrispondono ai valori di riga e colonna per $Y = y_s$ & $X = x_r$
- **distribuzioni di frequenza relativa**: si ottengono dividendo i parametri per i rispettivi totali

Indipendenza statistica: quando tutte le distribuzioni condizionate di Y dato X sono uguali (quindi uguali alla marginale di Y) [anche per X dato Y]

→ **Formula**: $\frac{n_{rs}}{n_{+s}} = \frac{n_{r+}}{n} \Rightarrow n_{rs} = \frac{n_{r+} \cdot n_{+s}}{n}$

Studio della dipendenza: X e Y possono essere trattate in modo non simmetrico: - var. dipendente (risposta)
- var. indipendente (esplicativa)

→ **analisi di dipendenza (connessione)**: 2 variabili qualitative

→ **indice di connessione**: indice che misura la distanza fra le frequenze osservate e le frequenze attese in caso di indipendenza $[\chi^2]$

→ **formule**: 1) $\chi^2 = \sum_{r=1}^m \sum_{s=1}^K \frac{(n_{rs} - n_{rs}^*)^2}{n_{rs}^*}$ - dove $n_{rs}^* = \frac{n_{r+} \cdot n_{+s}}{n}$ = frequenza attesa nel caso di indipendenza
- $\chi^2 = 0$ in caso di indipendenza
- $\max(\chi^2) = n \cdot \min(m-1, K-1)$

2) **indice normalizzato** = $\frac{\chi^2}{\max(\chi^2)}$ → indica la forza dell'eventuale dipendenza

→ **analisi di dipendenza in media**: una qualitativa e una quantitativa

→ **indipendenti in media**: due variabili X e Y lo sono se la media condizionata di Y dato X è la stessa per ogni valore assunto da X

→ **formula**: $E(Y|X = x_r) = E(Y) \quad \forall x_r, r = 1, \dots, m$

→ **analisi di correlazione**: 2 variabili quantitative

→ **covarianza**: si usa per misurare l'intensità del legame lineare tra due variabili quantitative e la direzione della relazione $[s_{xy}]$

→ **formula**: 1) $\text{Cov}(X, Y) = E[(X - E(X)) \cdot (Y - E(Y))] = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - E(X))(y_i - E(Y))$
2) $\text{Cov}(X, Y) = E(XY) - E(X) \cdot E(Y) = \frac{1}{n} \cdot \sum_{i=1}^n x_i \cdot y_i - E(X) \cdot E(Y)$

→ disuguaglianza Cauchy-Schwartz: $-\sigma_x \cdot \sigma_y \leq \sigma_{xy} \leq \sigma_x \cdot \sigma_y$

→ coefficiente correlazione lineare: $\rho_{xy} = \text{Cor}(X, Y) = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y}$ (compreso tra -1 e +1)

→ $\rho_{xy} > 0$: relazione lineare crescente $\leadsto = 1 \rightarrow$ allineati su retta pendenza positiva

→ $\rho_{xy} < 0$: relazione lineare decrescente $\leadsto = -1 \rightarrow$ allineati su retta pendenza negativa

→ $\rho_{xy} = 0$: assenza del legame $\rightarrow$ incorrelate ($\neq$ indipendenti)

→ $|\rho_{xy}|$: forza del legame lineare

→ qualitative ordinali: si può definire un indice che misura l'intensità ed il verso associando dei ranghi ai dati

→ indice di correlazione tra ranghi di Spearman: alternativa robusta a ρ_{xy} [ρ_{xy}^s (compreso tra -1 e +1)]

→ $\rho_{xy}^s = 1$: perfetta concordanza tra i ranghi X e Y

→ $\rho_{xy}^s = -1$: perfetta discordanza tra i ranghi X e Y

→ $\rho_{xy}^s = 0$: X e Y privi di associazione

→ analisi di regressione: 2 variabili quantitative.

→ scopo: analisi della media condizionata di una variabile risposta Y in funzione di una o più variabili esplicative $X_1, \dots, X_p$, $p \geq 1$

→ regressione lineare semplice: ipotesi di relazione lineare tra Y (risposta) e X (esplicativa)

→ equazione modello lineare: $y_i = a + bx_i + \epsilon_i$ $\rightarrow$ 1) ϵ_i = errore
2) a = intercetta
3) b = coefficiente angolare della retta di regressione ($y = a + bx$)
su a & b

→ metodo dei minimi quadrati:

→ residui di regressione: si ottengono con la seguente formula $\leadsto \epsilon_i = y_i - (a + bx_i)$

→ stima dei coefficienti di regressione: $Q(a, b) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (y_i - a - bx_i)^2$

→ stime dei minimi quadrati: 1) $\hat{a} = E(y) - \hat{b} \cdot E(x)$
2) $\hat{b} = \frac{\text{Cov}(X, Y)}{V(X)} = \rho_{xy} \frac{\sigma_y}{\sigma_x}$ } $y = \hat{a} + \hat{b}x \rightarrow$ retta di regressione stimata

→ valori stimati dal modello: $\hat{y}_i = \hat{a} + \hat{b}x_i$

→ residui stimati: $\hat{\epsilon}_i = y_i - \hat{a} - \hat{b}x_i = y_i - \hat{y}_i$

→ coefficiente di determinazione: indice di bontà di adattamento del modello lineare (proporzione di varianza di Y) [R^2]

→ formule: 1) $R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - E(\hat{y}))^2}{\sum_{i=1}^n (y_i - E(y))^2} \leadsto \frac{\text{varianza spiegata}}{\text{varianza totale}}$
2) $R^2 = 1 - \frac{\sum_{i=1}^n (\hat{\epsilon}_i - E(\hat{\epsilon}))^2}{\sum_{i=1}^n (y_i - E(y))^2} \leadsto 1 - \frac{\text{varianza residua}}{\text{varianza totale}}$
dove: 1) $E(\hat{y}) = E(y)$
2) $E(\hat{\epsilon}) = 0$
 $0 \leq R^2 \leq 1$

2) $R^2 = \rho_{xy}^2$

→ cambiamento di scala: si usa per migliorare un adattamento della retta di regressione. Le trasformazioni più comuni sono: $\rightarrow \log(y)$
 $\rightarrow \sqrt{y}$
 $\rightarrow \frac{1}{y}$