



Riassunto dell'intero corso

Social Computing (Università degli Studi di Udine)



Scan to open on Studocu


2. SOCIAL MEDIA

Nei social media il comportamento sociale viene mediato dai sistemi computazionali.
Nel Crowdsourcing i sistemi computazionali vengono supportati dal comportamento sociale.

Due dimensioni di partecipazione sui social network:

- Social presence : quanto sembra che uno sia effettivamente lì
- Self presentation : quanto si rivela di se stessi

		Social presence/ Media richness		
		Low	Medium	High
Self-presentation/ Self-disclosure	High	Blogs	Social networking sites (e.g., Facebook)	Virtual social worlds (e.g., Second Life)
	Low	Collaborative projects (e.g., Wikipedia)	Content communities (e.g., YouTube)	Virtual game worlds (e.g., World of Warcraft)



Modello ad alveare di Kietzmann.

3. GRAFI E RETI

I grafi sono nodi connessi da archi. Si indicano con $G(V,E)$
In un grafo sociale i nodi sono le persone e gli archi sono le amicizie.
Archi diretti si rappresentano con gli estremi (nodo1,nodo2)
Archi indiretti si rappresentano con (nodo1,nodo2) e (nodo2,nodo1)

Vicinato di un nodo v è rappresentato da $N(v)$:

- Nei grafi diretti si ha:
 - vicini in ingresso $N_{in}(v)$ (in-degree)
 - vicini in uscita $N_{out}(v)$ (out-degree)
- Nei grafi indiretti, per ogni nodo v , è l'insieme dei nodi collegati con un arco a v .

Il grado (d_v) di un nodo v è la grandezza dell'insieme del vicinato di quel nodo.

Degree distribution: per ogni grado, quanti nodi hanno quel grado. (Distribuzione di frequenza dei gradi).
frequenza relativa di nodi con grado d = numero di nodi con grado d / numero totale di nodi


Teorema 1: La sommatoria dei gradi in un grafo indiretto è due volte il numero degli archi.

Lemma 1: il numero di nodi con grado dispari è pari.

Lemma 2: In ogni grafo diretto, la sommatoria degli in-degree è uguale alla somma degli out-degree.

Possibili alternative per la rappresentazione dei grafi:

- Matrice di adiacenza, dove c' è 1 se esiste un arco tra v_i e v_j , altrimenti 0
E' simmetrica per grafi indiretti.
Per le reti sociali, queste hanno molti zeri.
- Liste di adiacenza, dove per ogni nodo c' è la lista di tutte le sue connessioni
- Lista di archi, dove ogni elemento della lista è un arco.



Nei grafi pesati $G(V,E,W)$ a ogni arco è associato un peso.

Nella matrice di adiacenza c' è il peso dell'arco se due nodi sono collegati, zero altrimenti.

Un nodo v_i è connesso al nodo v_j se esiste un cammino tra loro.

Un grafo è connesso se esiste un cammino fra ogni coppia di nodi, altrimenti si dice disconnesso.

Un grafo diretto si dice:

- fortemente connesso se esiste un cammino diretto fra ogni coppia di nodi
- debolmente connesso se esiste un cammino indiretto fra ogni coppia di nodi

Una componente in un grafo indiretto è un sotto grafo connesso.

Nei grafi diretti si ha:

- una componente fortemente connessa quando per ogni coppia di nodi u e v della CFC, c'è un cammino diretto da u a v e uno da v a u .
- una componente debolmente connessa se rimpiazzando gli archi diretti con indiretti si ottiene una componente.

Una rete è un grande grafo nel mondo reale, dove sono presenti gli attori(individui) e legami(conessioni).

4. Misure sulle reti 1

La centralità è una misura che indica quanto un nodo è centrale.

Centralità di grado (Degree centrality).

Più alto è il grado di un nodo, più è centrale. $C(v_i)=d_i$.

Nei grafi diretti possiamo usare l'in-degree che è più significativo per confrontare grafi tra loro.

Ci sono 3 possibilità per trovare la centralità di grado normalizzata:

- Normalizzazione per grado massimo possibile. $d_i/(n-1)$
- Normalizzazione per grado massimo effettivo. $d_i/(\max_j d_j)$
- Normalizzazione per somma dei gradi. $d_i/(\text{somma dei } d_j)$

Betweenness Centrality.

Quanto uno è in mezzo ai piedi. Quanto un nodo è importante nel connettere gli altri nodi.

$$C_b(v_i) = \sum \frac{\text{numero dei cammini più corti da } s \text{ a } t \text{ che passano per } v_i}{\text{numero di cammini più corti dal nodo } s \text{ al nodo } t}$$

Nei grafi indiretti il risultato è moltiplicato per due.

Nel caso il nodo v_i sia il tramite tra tutti avrà la frazione uguale a uno e valore massimo $(n-1)(n-2)$.

Centralità di vicinanza (Closeness centrality)

I nodi influenti/centrali possono raggiungere velocemente gli altri nodi.

$$C_c(v_i) = \frac{1}{\frac{1}{n-1} * \sum \text{lunghezza del cammino più breve da } v_i \text{ a } v_j}$$

	Low Degree	Low Closeness	Low Betweenness
High Degree		Node is embedded in a community that is far from the rest of the network	Ego's connections are redundant - communication bypasses the node
High Closeness	Key node connected to important/active alters		Probably multiple paths in the network, ego is near many people, but so are many others
High Betweenness	Ego's few ties are crucial for network flow	Very rare! Ego monopolizes the ties from a small number of people to many others	

PageRank

Associabile al grafo, dove Page $\rightarrow$ nodo e Link $\rightarrow$ arco diretto.

Il PageRank di una pagina u è alto se u è linkata:

- da molte pagine
- da pagine con alto PageRank
- da molte pagine con alto PageRank

Ogni pagina web ha il suo punteggio di qualità.

$$\forall v, r(v) = c \cdot \sum_{u \in I(v)} \frac{r(u)}{|O(u)|}$$


$r(v)$ è il pagerank della pagina v . $r(u)$ è il pagerank delle pagine che linkano v .
 $O(u)$ è il numero di archi uscenti da u .

Per ogni pagina u che linka v , si somma la frazione tra il pagerank di u e il numero di archi uscenti da u .

Random walks: immaginiamo che un utente cammini in modo random tra le pagine web, comincia da una pagina random e ad ogni passo segue un link random, tutti i link hanno la stessa probabilità.

Il pagerank di una pagina è la probabilità che durante un percorso random l'utente sia su quella pagina. Questo si rappresenta con le Markov chain, modo per modellare i percorsi random nel web.

Rappresentate dalla matrice P ($n \times n$) dove ogni cella è uno stato da 0 (se non c'è l'arco) a 1 (anche frazioni). Per ogni stato i , P ci dice la probabilità che nel prossimo stato ci sarà j .



Calcolo della convergenza: $x_{i+1} = x_i * P$

Ergodic Markov chain: è possibile essere in ogni stato in ogni passo con probabilità maggiore di 0.

Teletrasporto: spostamento dalla pagina corrente ad un'altra pagina casuale.

$p(\text{follow link}) + p(\text{teleport}) = 1$ con $p(\text{teleport})$ una costante.

Formula: $r_{i+1} = (1-d) * r_i * P + d * r_i * \text{matrice di trasporto}(\text{all'interno } 1/N)$

Con $d = p(\text{teleport}) = 0.1$, moltiplico la matrice P per 0.9 e la sommo alla matrice di teletrasporto ($0.1/\text{numero nodi}$), ottenendo una matrice ergodic.

HITS.

Due tipologie di pagine:

-gli Hub (outlinks): pagine che contengono molti link ad altre pagine

-le Authority pages (inlinks): pagine di persone/entità ben conosciute, sono pagine linkate molto da altre pagine.

Buoni Hubs linkano buone Authority; Buone Authority sono linkate da buoni Hubs.


L'algoritmo per il calcolo consiste in: (v è una pagina composta da più link)

- Partire dal RootSet(RS), un'insieme di pagine
- Si espande RS con:
 - $I(v)$ che sono le in-pages (tutte le pagine che linkano v)
 - $O(v)$ che sono le out-pages (tutte le pagine che linka v)
- Otteniamo il BaseSet(BS), composto da buone pagine H/A candidate
- Per ogni pagina x in BS si calcola usando le pagine H/A:
 - $h(x)$, hubness value, $h(x) = \sum_{x \rightarrow y} a(y)$ (sommo tutte le authority) ($h = Aa$)
 - $a(x)$, authority value, $a(x) = \sum_{y \rightarrow x} h(y)$ (l'autority di una pagina x sarà la somma delle hubness di y) ($a = A^T h$)
- Si assegnano valori iniziali ad ogni pagina, $h(x) = a(x) = 1$
- Si aggiornano i valori usando le formule
- Ci si ferma alla convergenza

Equivalentemente alle formule con la somma, avendo un vettore per i valori di h e uno per i valori di a possiamo concludere che moltiplicando l' i -esima riga di a con la matrice di adiacenza otteniamo l' i -esima componente di h ($h=Aa$).

Con sostituzione algebrica (usando h e a) troviamo:

- AA^T . Il primo conta il numero di nodi che sono co-linkati da i e j .
Rappresenta quanto i e j citano gli stessi documenti.
- $A^T A[i, j]$. Il secondo conta il numero di nodi che co-linkano la coppia (i, j) .
Rappresenta quanto i e j sono citati negli stessi documenti.



Pagerank

Pro: non spamabile, indice di qualità per il web.

Contro: non per specifiche query, computazione complessa

HITS

Pro: per query specifiche, lavora in grafi piccoli

Contro: facilmente spamabile (negli hubs), computazione complessa in grandi grafi

5-6. Misure sulle reti II

Social Network Analysis (SNA)

Ponte locale: arco tra due nodi che sarebbero distanti senza di esso, la distanza senza arco è il grado di quell'arco.

Ponte globale: arco che se rimosso disconnette la rete

Triangolo: sottoinsieme di 3 nodi

Legame debole: arco che appartiene a pochi o un solo triangolo

Legame forte: arco che compare in più triangoli

Geodesic: percorso minimo tra due nodi

Diametro: percorso minimo più lungo tra due nodi

Grado di un nodo: numero di archi (entranti e uscenti)

Distribuzione dei gradi: per ogni grado, il numero di nodi che hanno quel grado.

Densità: numero di archi del grafo / numero massimo possibile di archi ($N*(N-1)/2$)

Coefficiente di clustering: numero di archi che collegano i suoi vicini / numero massimo ($N*(N-1)/2$)

Transitività: a segue b, b segue c $\rightarrow$ a segue c

Due indici di transitività:

- Coefficiente di clustering globale: misura la transitività in grafi indiretti.

$$C = \frac{\text{numero di triangoli} * 6}{\text{percorsi di lunghezza 2}}$$

- Coefficiente di clustering locale: misura quanto i vicini di un nodo v sono a loro volta connessi. Nelle reti sociali le amicizie sono molto transitive. In media il coefficiente è alto.

$$C(v_i) = \frac{\text{numero di coppie dei vicini di } v_i \text{ connesse}}{\text{numero di coppie dei vicini di } v_i}$$

Reciprocità: conto il numero di coppie reciproche nel grafo

$$R = \frac{1}{\text{numero archi}} * Tr(A^2)$$

Bilanciamento sociale: modella la coerenza nelle relazioni amico/nemico. Si modella con grafi in cui gli archi assumono +1(amici) o -(nemici). Un triangolo è (socialmente) bilanciato se il prodotto dei segni degli archi è ≥ 0 .

Status sociale: quanto un individuo è prestigioso all'interno della società, modellato con i segni.


Power law: legge di potenza.

$$f(k) = C/k^\alpha \text{ con } \alpha = [2,3]$$

$$\log(f(k)) = \log C - \alpha * \log k$$

Valori piccoli sono comuni, valori grandi sono estremamente rari.

La frequenza di un evento cambia in funzione della potenza di un attributo.



Reti con una distribuzione dei gradi power law si chiamano anche Scale-free (a invarianza di scala).

Una power law è caratterizzata da una coda lunga.

- Distribuzione dei gradi : Spesso power law.
- Coefficiente di clustering : in media alto.
- Distanza media : (Esperimento delle lettere, Milgram) Spesso bassa, piccolo mondo, persone molto connesse anche con chi non conoscono.

Numero di Erdos: numero indicante la distanza tra uno scienziato ed Erdos sulla base delle co-pubblicazioni di articoli scientifici.

7-8. Modelli delle reti


Sono modelli matematici che permettono di generare dei grafi simili alle reti reali, ma più semplici e analizzabili.

Vediamo 4 reti:

- Regolari
- Casuali
- Small world
- Scale free

Regolari: reti con una topologia regolare, costruite a tavolino. Esempi: a stella, ad anello, completa.

- Media della lunghezza dei percorsi e diametro spesso grandi.
- Coefficiente di clustering spesso alto
- Distribuzione dei gradi spesso con un picco
- Spesso completamente connesse



Le reti del mondo reale raramente sono così.

Reti casuali:

Nei grafi casuali gli archi vengono creati a caso. Corrisponde ad assumere che le amicizie (i legami in una rete sociale) nascano a caso.

Modello $G(n,m)$

Il grafo ha n nodi e m archi messi a caso.

Si studia il caso medio: quello che succede in media su un insieme di tanti grafi casuali. Dall'insieme si analizzano le proprietà tipiche/medie (diametro di G = diametro di tutti i grafi G).

Modello $G(n,p)$

Al posto di fissare il numero di archi, si fissa la probabilità di esistenza archi.


Il numero di archi è in media $m = p * (n * (n-1) / 2)$. $G(3, 2/3)$ ha in media 2 archi, non sempre è connesso.

Il grado medio è $(n-1) * p$, denotato con c .


La distribuzione di $G(n,p)$ e $G(n,m)$ è una Poisson, grafico a campana, dove il grado tipico è nel picco e la curva che si avvicina presto allo zero indica che non ci sono gradi lontani dalla media.

Coefficiente di clustering $C = c / (n-1)$.

La componente connessa gigante è una componente che contiene la maggiorparte dei nodi. La



dimensione in $G(n,p)$, se $p=0$ è uno (grafo disconnesso), se $p=1$ è n (grafo completo)
 Una componente connessa gigante cresce per $n \rightarrow \infty$ se $c > 1$. Se c (media dei gradi dei nodi) è uguale a 1 si forma la componente gigante. Se $c > 1$ cresce velocemente e quasi tutti i nodi sono connessi. Se c è minore di 1 non si forma, l'insieme muore esponenzialmente in cluster piccoli.
 Il diametro $\ln(n)/\ln(c)$ è sorprendentemente piccolo, effetto piccolo mondo.



Le reti casuali modellano bene la lunghezza dei cammini minimi, sottostimano il coefficiente di clustering e hanno una distribuzione Poisson (non power-law).

Reti reali: diametro basso e C alto

Reti regolari: diametro alto e C alto

Grafi casuali: Diametro basso e C basso


Reti piccolo mondo (Small-world):

Piccolo mondo = distanza piccola fra i nodi, cioè diametro basso.

Caratterizzate da coefficiente di clustering alto.

Procedura per la loro creazione:

- parto dalla rete regolare
- con probabilità p ogni arco viene ricollegato casualmente
- con $p=0$ si ha la rete regolare di partenza
- con $p=1$ si ha una nuova rete casuale
- (non si creano auto-archi, non ci sono archi multipli tra nodi)



Caratteristiche delle reti che ci interessano:

$n(\text{numero nodi}) \gg c(\text{numero medio di archi per vertice}) \gg \log(n) \gg 1$

$n \gg 1$: grafo molto grande

$n \gg c$ e $n \gg \log(n)$: reti sparse ma non così sparse da essere disconnesse

Due misure:

L : lunghezza media del cammino (numero archi) minimo fra due nodi della rete

E' la lunghezza media tra tutte le coppie u e v nella rete.

C : coefficiente di clustering locale

Se v è un vertice e k_v i suoi vicini:

- al massimo ci sono $k_v(k_v-1)/2$ archi
- C_v è la frazione degli archi che effettivamente esiste: $n^\circ \text{archi} / [k_v(k_v-1)/2]$

C è la media di C_v su tutti i vertici della rete.

In una rete sociale di amicizia dove i nodi sono le persone e gli archi sono le relazioni di amicizia, L misura per quanti amici devo passare per raggiungere una persona e C misura quanto gli amici di una persona sono amici fra di loro.

$L(p)$ cala al crescere di $p \rightarrow$ piccolo mondo


(Più aumenta p e più si creano scorciatoie per i percorsi tra nodi, diminuisce la distanza dei cammini minimi tra nodi)

$C(p)$ cala al crescere di p


(Più archi sono rediretti casualmente vuol dire che rompe le cricche esistenti)

Con p piccolo, una scorciatoia ha effetto più che lineare (avvicina due nodi ma anche i loro vicini), un taglio ha un effetto lineare (taglia al massimo una cricca).

Basta poca casualità per avere piccolo mondo.



La distribuzione dei gradi nelle reti piccolo mondo è strana e diversa dalle reti reali. C'è un picco e una soglia inferiore. Molti nodi hanno grado simile.



Le reti piccolo mondo spiegano l'effetto piccolo mondo (ereditato da $G(n,p)$), spiegano il coefficiente di clustering alto (ereditato dalle reti regolari). Hanno una distribuzione dei gradi che è circa una Poisson, diversa dalle reti regolari. Sono un mix tra le reti regolari e casuali.

	Lunghezza media cammini minimi (geodesiche)	C	Degree distribution
1. Regolari	KO	OK	KO
2. Casuali	OK	KO	KO
3. WSSW	OK	OK	KO

Nessun modello di reti visto fino ad adesso riesce a creare reti uguali a quelle del mondo reale.

Reti Scale-free: distribuzione dei gradi è power-law

Barabasi e Albert verificarono le distribuzioni dei gradi in-degree e out-degree per una pagina web, scoprendo che sono due power-law, dove aumentando di molto il numero di nodi la distanza media rimane bassa, trovando quindi che il web è una rete piccolo mondo.


Quale modello può generare una rete con distribuzione dei gradi power-law?

Viene proposto un nuovo modello "Preferential attachment". Due nuovi aspetti in questo modello:

- La crescita della rete, dove ad ogni passo viene aggiunto un nuovo nodo e un arco che collega il nuovo nodo ad uno preesistente (scelto a caso ma con probabilità non uniforme)
- La probabilità non uniforme consiste nella probabilità di connettersi a un nodo esistente in proporzione al grado del nodo esistente.

Generazione di grafi con attaccamento preferenziale:

All'aggiunta di un nuovo nodo al grafo, si deve determinare per ogni nodo i già esistente il suo in-degree e per trovare la probabilità che il nuovo nodo si attacchi ad un nodo i si divide il grado del nodo i con la somma dei gradi di tutti i nodi. $P(v_i) = \frac{d_i}{\sum_j d_j}$



Matthew effect: i nodi più vecchi hanno più tempo per accumulare archi.

• **Degree Distribution:**

- Power law
- OK

$$P(d) = \frac{2m^2}{d^3}$$

• **Lunghezza media geodesiche:**

- Bassa
- OK

$$l \sim \frac{\ln |V|}{\ln(\ln |V|)}$$

• **Clustering Coefficient:**

- Basso
- KO

$$C = \frac{m_0 - 1}{8} \frac{(\ln t)^2}{t}$$

Le reti scale-free hanno una distribuzione power-law.

Caratterizzata da una coda lunga, la maggioranza dei nodi ha grado basso.

Ci sono pochi nodi che hanno grado molto alto → HUB.

C'è l'effetto piccolo mondo grazie agli HUB (nodi con grado elevato che con i loro collegamenti permettono cammini più brevi).

	Lunghezza media cammini minimi (geodesiche)	C	Degree distribution
1. Regolari	KO	OK	KO
2. Random Graphs	OK	KO	KO
3. WSSW	OK	OK	KO
4. Scale free	OK	KO	OK

Esistono **varianti dell'attaccamento preferenziale** che usano lo stesso processo ma cambiando il calcolo della probabilità.

- **Non lineare:** viene aggiunto nella formula un termine non lineare α che regola il vantaggio di avere un grado alto. $P(v_i) = \frac{d_i^\alpha}{\sum_j d_j^\alpha}$.

Con $\alpha=1$ si ha l'attaccamento preferenziale originale.

Con $\alpha < 1$ il grado conta meno e non si hanno coda lunga e hubs.

Con $\alpha > 1$ il grado conta di più e si ha un nodo connesso a tutti.

- **Attrattività:** viene aggiunta una costante A . $P(v_i) = \frac{A + d_i}{\sum_j (A + d_j)}$.

$A=0$, attaccamento preferenziale originale.

Con valori maggiori di 1, evita che i nodi con grado zero non ricevano link.

La pendenza della power-law varia in base ad A .

- **Fitness:** Adattività.

Per ottenere l'attaccamento un nodo i deve avere alta fitness (η_i) e alto grado. $P(v_i) = \frac{\eta_i d_i}{\sum_j (\eta_j d_j)}$.

Se i valori di fitness sono in un intervallo limitato si ha una rete con hub multipli e si elimina la dipendenza da rich-get-richer dei nodi più vecchi.

- **Random Walk:**


Si parte da una piccola rete, ad ogni passo si aggiunge un nuovo nodo i con $m > 1$ archi collegati.

Il primo degli m archi è collegato ad un vecchio nodo j scelto a caso.

Ogni altro arco degli $m-1$ viene collegato:

- con probabilità p a un vicino di j scelto a caso
- con probabilità $1-p$ a un nodo vecchio scelto a caso

p è la probabilità che si formi un triangolo (aumenta il coefficiente di clustering)




Per quest'ultimo, la distribuzione dei gradi è power-law, formato da cammini brevi e C alto. Nessuno dei quattro modelli spiega completamente le reti reali.

DIFFUSIONE DELLE INFORMAZIONI

Intervento/intromissione/manomissione: processo che interferisce con la diffusione di informazioni, accelerando, rallentando o fermando la diffusione.

4 modelli.



Herd Behavior (Comportamento di gregge): descrive quando un gruppo di individui eseguono un'azione che è altamente correlata senza nessun piano.


Esempi:

- in un asta, la fiducia delle persone negli altri (che potrebbero essere più esperti di loro), porta gli individui a considerare l'alto numero di offerte su un oggetto come un forte segnale del suo valore. → Herd Behavior.
- si pianifica di andare a cenare e cercando si trova il ristorante A con eccellenti recensioni online. Quando ci si trova davanti ad A si nota che è vuoto e il ristorante B, accanto ad A, è quasi pieno. Si decide di andare da B, basando l'idea che anche altri commensali hanno avuto la chance di andare da A.

Gli individui prendono decisioni osservando le decisioni di tutti gli altri individui.

La rete, che assume una forma simile ad un grafo completo, è osservabile. Informazioni globali disponibili, nessuna informazione privata.


Formula di Bayes per il calcolo delle probabilità: $P(C|I) = \frac{P(C) * P(I|C)}{P(I)}$.



Può succedere un intervento nel gregge con il rilascio di informazioni private. In questo caso, ogni persona del gregge rivaluta la sua intuizione e può cambiare decisione, portando ad un altro risultato.

Information Cascade : informazione propagata tramite persone, dove queste sono connesse da una rete e osservano solo le decisioni prese dagli immediati vicini.

Gli utenti del gregge hanno tutte le informazioni, gli utenti dell'information cascade hanno meno informazioni disponibili.




Si può associare a un grafo diretto, dove i nodi sono gli attori e gli archi sono i canali di comunicazione tra di essi. I nodi possono essere attivi, se hanno già adottato il sistema, inattivi, se non l'hanno ancora adottato. Lo stato dei nodi può cambiare da inattivo a attivo.

Un nodo può influenzare solo i nodi a cui è connesso.

Independent Cascade Model (ICM)

Il mittente è il centro del modello.

Ogni nodo ha una possibilità di attivare i suoi vicini. Al tempo t si attiva il nodo v , al tempo $t+1$ il nodo v ha probabilità p_{vw} (soglia uguale o diversa per ogni coppia (v,w)) di attivare ognuno dei nodi vicini. Nell'algoritmo, la probabilità di attivazione è casuale e viene confrontata con la soglia e, se è minore la prima, il nodo viene attivato.



I nodi attivi sono i mittenti, i nodi che sono stati attivati sono i destinatari.

Problema del massimizzare la diffusione della cascata: trovare un piccolo insieme di nodi in un social network in modo che la loro diffusione nella rete sia massimizzata.


Se S è il set di nodi attivi all'inizio, $f(S)$ è il numero di nodi attivati alla fine della cascata di S .

Problema deterministico: Generare i numeri della probabilità random per gli archi all'inizio

Le proprietà di f sono: non negativa, monotona $f(S+v) \geq f(S)$, submodulare (il guadagno dei sottoinsiemi è maggiore).

Possiamo usare l'algoritmo di greedy:

- parto con il set S vuoto
- per k iterazioni:
 - aggiungo il nodo v a S che massimizza $f(S \cup \{v\}) - f(S)$
 - (scelgo il nodo v che massimizza l'attivazione)



Il set S risultante attiva almeno $(1-1/e)$ il 63% del numero di nodi che ogni set S di dimensione k potrebbe attivare.

Intervento (limitare/espandere la cascata):

- limitare/aumentare il numero di out-links, i nodi disconnessi non possono attivare nessuno
- limitare/aumentare il numero di in-links, riduce la probabilità di essere attivati da altri
- diminuire/aumentare la probabilità di attivazione p_{vw} , riduce la probabilità di attivare altri

Epidemie

Le epidemie descrivono il processo di diffusione delle malattie.

Il processo consiste in:

- un patogeno, la malattia che viene diffusa
- una popolazione
- il meccanismo di diffusione

Il modello Epidemic assume che la rete sia implicita e la connessione tra utenti è sconosciuta.

Il modello è da adottare quando vogliamo sapere di più sui pattern globali, come i trends o la percentuale di persone infettate.

Analizzare le epidemie usando la Rete dei Contatti, dove:


- si guarda come le persone sono in contatto e escogitano metodi che descrivono come avvengono le epidemie nelle reti
- reti di contatto: i nodi sono le persone e gli archi sono le interazioni

4 modelli base.

SI: un individuo suscettibile viene infettato, una volta infetto non può più guarire.

Due tipi di utenti:

- suscettibili (S): quando un utente è in questo stato può essere infettato
- infetti (I): un individuo infetto ha la possibilità di infettare individui suscettibili



N : dimensione della popolazione

$S(t)$: numero di individui suscettibili al tempo t

$I(t)$: numero di individui infetti al tempo t


β : probabilità di contatto, $=1$ tutti in contatto con tutti, $=0$ nessuno incontra nessuno

$N = S(t) + I(t)$

Ad ogni tempo, un individuo infetto incontrerà $\beta \cdot N$ persone in media e infetterà $\beta \cdot S$ di loro.

Nel prossimo tempo, $\beta \cdot I \cdot S$ saranno infettati.

Curva di crescita logistica per I .



SIR

In aggiunta a S e I , è presente lo stato di recupero R .

Gli individui vengono infettati e certi di loro recuperati. Una volta che un individuo ha recuperato, non può più essere infettato (non suscettibile).

$S + I + R = N$

γ indica la probabilità che un individuo infetto venga recuperato.

S decresce monotonicamente e R cresce monotonicamente.

I inizialmente cresce, poi decresce man a mano che gli individui guariscono.



S non va a zero, resta una (piccola) frazione: sopravvivono abbastanza da non essere contagiati o spariscono tutti gli infetti.

R_0 : basic reproduction number, numero medio di individui che un I contagia prima di guarire/morire, rappresenta un indice che calcola come

un'epidemia si comporta. $R_0 = \frac{\beta}{\gamma}$.

Se $R_0 > 1$, il numero di contagiati tende ad aumentare, se < 1 , col passare del tempo il numero di contagiati diminuisce. La soglia epidemica per dire se l'epidemia è in corso è $R_0 > 1$.

Formula transizione epidemica.



$$r(t) = 1 - e^{-\beta r(t)/\gamma}$$



SIS

Come SI, ma con l'aggiunta che gli infetti recuperano e diventano nuovamente suscettibili.

$$\frac{dS}{dt} = \gamma I - \beta I S, \quad \frac{dI}{dt} = I(\beta N - \gamma) - \beta I^2.$$

Se $\beta N \leq \gamma$, (il primo termine) la formula diventa zero o negativa. Nel limite $I(t)$ decresce esponenzialmente a zero $\rightarrow$ "Si guarisce più in fretta di quanto ci si ammali".

Se $\beta N > \gamma$, c'è una funzione di crescita logistica come in SI (immagina $S=99$, $I=1$, $\beta=0.01$, $\gamma=0.1$).




SIRS (malattie con modalità temporanea)

Gli individui che sono stati ricoverati, perdono l'immunità (presente nel modello SIR) e dopo un certo periodo di tempo tornano suscettibili.

$$\frac{dS}{dt} = \lambda R - \beta IS, \frac{dI}{dt} = \beta IS - \gamma I, \frac{dR}{dt} = \gamma I - \lambda R.$$

Le curve del grafico oscillano all'aumentare di t . (fuori dal grafico)

S scende a causa dell'infezione e I sale fino ad un certo punto, fino al punto che ci sono molti I e questi (con molta probabilità) guariscono. Le curve poi oscillano perché gli individui che diventano nuovamente suscettibili possono infettarsi altre volte.



Epidemic Intervention

Interventi per bloccare l'epidemia e quindi assestare l'indice R_0 sotto 1.

Come trovare individui vulnerabili? Scegliere a caso qualche nodo e chiedere chi sono i più vulnerabili dal loro punto di vista, vaccinare la risposta.

Modello collegato alle epidemie è il contagio sociale (per la diffusione di informazioni)

Se un individuo vede un comportamento in un altro individuo lo imita.

Informazione: pettegolezzo, barzelletta, indovinello. Qualcuno mi dice un'informazione, io comincio a riportarlo in giro, smetto di farlo quando continuo a trovare solo gente che lo sa.

Come per le epidemie:

- Susceptible $\rightarrow$ Ignorant
Individuo che non ha ancora ricevuto l'info
- Infected $\rightarrow$ Spreader
individuo che ha ricevuto l'info e la diffonde
- Recovered $\rightarrow$ Stifler
ha ricevuto l'info ma non la diffonde più



- Passaggio $S \rightarrow R$ per mode è non spontaneo e dipende sia dal # S sia dal # R oltre che dal parametro α

$$\frac{di(t)}{dt} = -\lambda i(t)s(t)$$

$$\frac{ds(t)}{dt} = \lambda i(t)s(t) - \alpha s(t)[s(t) + r(t)]$$

$$\frac{dr(t)}{dt} = \alpha s(t)[s(t) + r(t)]$$

$$i(t) + s(t) + r(t) = 1$$



(oppure: $S + S \xrightarrow{\alpha} 2R$)

Allo stato stazionario per $t \rightarrow \infty$ non ci saranno più Spreader ($s_{\infty} \rightarrow 0$).

Gli ignoranti saranno tanti di meno quanti di più saranno gli Stiflers.

r_{∞} rappresenta il numero di Stiflers. E' una misura della diffusione (di una barzelletta) (chiamata anche reliability)

Nel contagio sociale si può dire che c'è epidemia se $1 + \frac{\lambda}{\alpha f_a} > 1$ ossia la frazione maggiore di 1, il che è sempre vero. Non c'è più una soglia epidemica, qualsiasi siano i valori dei parametri c'è sempre un'epidemia sociale. Diverso da malattie.

Questi modelli si basano sull'idea che tutti sono in contatto con tutti, non sempre vero.

In una rete omogenea, dove tutti i nodi hanno grado simile k (ogni individuo viene in contatto con circa lo stesso numero di individui), l' R_0 si può definire come $k * \frac{\beta}{\gamma}$. Per diminuire R_0 (intervention):

- Diminuire la contagiosità (mascherine, vaccino, ...)
- Aumentare il grado di guarigione (cure, ...)
- Diminuire il grado medio (lockdown, quarantene, ...)

Nel mondo reale le reti sono eterogenee, i nodi sono di natura diversa ed hanno pochi collegamenti.

Ci sono nodi con grado molto alto (hub) dove non c'è soglia, c'è sempre epidemia.

Gli hub si contagiano e contagiano velocemente → Intervention: Strategie di vaccinazione mirate.

Nelle reti piccolo mondo, con $\alpha = \lambda$ e la rete non è completa, con p basso si ha una rete molto clusterizzata (C alto) con molti triangoli e quindi gli spreader diffondono sempre agli stessi e passano in fretta fra gli stiflers, poca diffusione.

Con p alti, la rete ha delle scorciatoie e gli spreader diffondono in parti più lontane, maggior diffusione.

Su reti eterogenee la varianza dei gradi è alta, gli hub dovrebbero essere efficientissimi per diffondere il più possibile le malattie (una volta raggiunto la diffusione è immediata).

Però dati sperimentali mostrano come r_{∞} (diffusione di informazioni) è più alto su reti omogenee che su reti eterogenee.

Situazione diversa degli hub tra diffusione di malattie e diffusione di informazioni.

Se gli hub diventano spreader, allora ci saranno subito molte interazioni spreader-spreader e spreader-stifler, che porteranno l'hub a stifler, fermano la sua diffusione ai nodi collegati e isolando dei nodi della rete ancora non raggiunti.

Rumor vs Malattia: uguale sotto il profilo del contagio sociale, entrambe si diffondono da persona a persona su reti simili (rete dei contatti).

Però il contagio sociale (processo attivo: cerco l'informazione) è diverso dal contagio fisiologico (processo passivo: vengo contagiato).

Differiscono anche per la transizione da S a R in seguito all'interazione S+R o S+S, contro la transizione spontanea da I a R.

Modello dei benefici diretti (Morris)

Basato sull'influenza di persone su certe persone, sulla base di: Informazioni (faccio X perché vedo molti che lo fanno); Benefici diretti (faccio X perché mi conviene rispetto a non farlo).

Per un nodo, il beneficio di adottare un comportamento cresce al crescere del numero di vicini che lo adottano. Ogni nodo sceglie fra due possibili comportamenti A e B. Se due nodi sono collegati con un arco sono incentivati ad adottare comportamenti uguali.

Matrice dei payoff

Payoff di v è la somma di tutti i payoff.

v sceglierà il comportamento che massimizza la somma.

La scelta di quale comportamento adottare dipende da:

- $p(1-p)$ è la percentuale di vicini che adottano A (B)
- d è il numero di vicini

		w	
		A	B
v	A	a	0
	B	0	b

Regola di decisione: v adotta A se $pda \geq (1-p)db$, cioè $p \geq \frac{b}{a+b}$.

- Se la frazione è piccola (circa 0) → $a \gg b$ → payoff di A >> payoff di B → A è più attraente e bastano pochi amici che adottano A per farmi adottare A.

- Se la frazione è grande (circa 1) $\rightarrow a < b \rightarrow$ payoff di A $<$ payoff di B $\rightarrow$ B è più attraente e servono un sacco di amici che adottano A per convincermi a adottare A.

Cambio di comportamento

Tutti adottano un comportamento di default B e per qualche ragione (extra-payoff) alcuni nodi (initial adopters) passano ad A.

Ad ogni passo ogni nodo usa la regola di decisione per decidere se cambiare da B ad A (monotono verso A). Il processo si ferma quando tutti i nodi sono passati ad A o nessun nodo vuole più cambiare.

Cascata completa se tutti i nodi passano ad A. Se la cascata è parziale posso operare una Intervention per farla ripartire sui nodi che influenzano maggiormente gli altri nodi.

Differenze dall'Independent Cascade Model, qui è l'insieme di vicini che cerca di convincere, nell'ICM era ogni nodo che provava indipendentemente a convincere i suoi vicini.

Strategie che possono essere usate per far passare ad A: Migliorare il payoff di A; Convincere alcuni nodi chiave.

Cos'è che ferma le cascate? Secondo Morris i cluster (sottografi quasi completi e con pochi legami verso l'esterno) fermano le cascate.

Un insieme di nodi è un cluster di densità p se ogni nodo che vi appartiene ha almeno una frazione p dei suoi vicini nel cluster.

Se il resto della rete contiene un cluster di densità $> 1-q$, allora non ci sarà una cascata completa.

Per far ripartire una cascade bloccata posso: Aggiungere archi fra cluster diversi; Togliere archi all'interno di un cluster.

Per bloccare una cascade posso: Togliere archi fra cluster diversi; Aggiungere archi all'interno del cluster.

Il modello di Morris è quindi basato su il beneficio diretto, un nodo decide di adottare un comportamento perché gli conviene. Diverso da malattie e modelli di contagio (sociale).

- | | |
|--|---|
| <ul style="list-style-type: none"> Diffusione delle informazioni <ul style="list-style-type: none"> Tema variegato, multi/interdisciplinare Ho cercato di "campionare" 5 modelli $\rightarrow$ Ognuno si basa su assunzioni diverse, modella aspetti diversi, porta a risultati diversi: <ul style="list-style-type: none"> Spesso fully mixed Poco sulle reti Non semplice capire quale modello è più aderente alla realtà in casi concreti <ul style="list-style-type: none"> (non ne parliamo) | <ul style="list-style-type: none"> 1. Herd behavior <ul style="list-style-type: none"> "Copio quello che fa il resto del gregge" 2. Information cascade <ul style="list-style-type: none"> "Copio quello che fa chi è vicino a me (ha fatto l'ultimo individuo)" 3. Epidemics <ul style="list-style-type: none"> Modelli classici: SI, SIR, SIS, SIRS 4. Contagio sociale <ul style="list-style-type: none"> "IRS" "Non scelgo di ammalarmi..." 5. Benefici diretti <ul style="list-style-type: none"> Teoria dei giochi Morris, Legame cluster – cascade complete |
|--|---|

CROWDSOURCING

La tesi di Surowiecki: A volte decisioni prese da una folla/gruppo sono più corrette ("sagge") di quelle di singoli esperti. Esempio il peso del bue alla fiera di bestiame oppure la ricerca del sottomarino Scorpion.

I principi di Surowiecki: • Diversità di opinioni • Indipendenza • Decentralizzazione • Aggregazione
Principi per cui non può funzionare: Omogeneità, Centralizzazione, Divisione, Imitazione, Emotività.

Outsourcing to the crowd: Esternalizzare un compito, che tradizionalmente viene eseguito da uno, a un gruppo di persone indefinito e ampio in forma di una chiamata aperta.

Crowdsourcing è un caso particolare di Human computation (ESP game, Duolingo, recaptcha).

Requester: individuo o organizzazione che ha un lavoro da far svolgere

Worker: Persona che vuole fare il lavoro

- HIT (Human Intelligence Task): unità di lavoro da svolgere

Batch: insieme di HIT caricato da un Requester.

La matrice (sparsa) worker/task è il risultato di un compito di crowdsourcing.

Critiche al crowdsourcing: qualità (the cult of amateur→persone non esperte eseguono i compiti di esperti, affidabilità delle risposte), etica (lavoratori sottopagati, cloudworkers).

Tipi di task (Demartini - 4 categorizzazioni) (tempo impiegato decrescente):

- Compito Complesso: costruire un sito web, sviluppare un sistema software.
- Progetto Semplice: disegnare un logo.
- Macro Task: scrivere una recensione, testare una funzionalità di un sito.
- Micro Task: categorizzare un'immagine, verificare un indirizzo.

Tipi (Brabham):

- Knowledge discovery and management: Scoprire e organizzare / gestire conoscenze già disponibili "là fuori" ma disorganizzate;
- Broadcast search: trovare uno specialista che svolga il compito, trovi la risposta e dia la soluzione. Spesso al di fuori del settore.
- Peer-vetted creative production: Crowd produce e seleziona idee creative.
- Distributed human-intelligence task: I problemi di elaborazione dei dati di grandi dimensioni vengono scomposti in piccoli compiti che richiedono intelligenza umana.

Tipologie di categorie (Grier):

- Crowdcontest: si dà in outsourcing un compito tutto intero. Si seleziona e si paga la risposta migliore (gara).
- Macrotasking: dare in outsourcing a un consulente, libero professionista.
- Microtasking: Compito suddiviso in piccole parti, poi aggregate.
- Self-organised crowds: chiedo che venga svolto un lavoro, ma gli individui del crowd cooperano, interagiscono, si organizzano.
- Crowdfunding: Non si vuole lavoro ma soldi, tante piccole donazioni.

	Crowd indipendenti	Crowd collaborative
Pay-one	Crowdcontests	Self-organized crowds
Pay-all	Microtasking	Macrotasking

Dimensioni (Grier):

- Due tipi di pagamento:
 - Pay-all: Tutti i worker che hanno svolto il lavoro vengono pagati.
 - Pay-one: pagamento solo ad uno.
- Due tipi di mercato:
 - Indipendenti: ognuno lavora per sé e viene pagato individualmente
 - Collaborativi: c'è cooperazione tra i worker, a volte si dividono la paga.

Motivazioni dei worker nello svolgere il lavoro:

- ricompense estrinseche: soldi, fama, reputazione
- ricompense intrinseche: lo svolgere il compito stesso per interesse

Classifica bidimensionale di Li et al.:

- granularità dei task:
 - micro: secondi, minuti
 - macro: ore, giorni
- incentivo/motivazione:
 - denaro
 - divertimento
 - volontariato

- **Tipi di task (5 categorizzazioni)**
 - Demartini 1
 - Granularità del task
 - Demartini 2
 - Aree scientifiche
 - Brabham
 - Tipi di problema risolto
 - Grier
 - Tipi di task, organizzata
 - Li et al.
 - Bidimensionale, granularità del task e tipi di incentivi
- **Classificazioni differenti ma compatibili, utili**
- **Tipi di motivazioni dei worker, Tipi di risposte**

Secondo Li et al, i **tipi di risposte** sono:

- Domanda a scelta singola: Una singola risposta fra alcune opzioni
- Domanda a scelta multipla: Una o più risposte fra alcune opzioni
- Fill-in-the-blank: campo dove si inserisce un numero o testo
- Collection: raccolta di dati

Teoria della misurazione: Indica quali operazioni è lecito fare sui dati.


Relevant assessment:

- binaria
- categoriale
- categoriale per web page
- confronti fra coppie

Design di un (micro)task

Fasi (in qualsiasi momento si può ritornare alle precedenti):

- 1. Definire/Capire il problema
- 2. Idea di soluzione, pensare come risolvere il problema. Si crea il progetto vero e proprio. Istruzioni chiare.
- 3. Prototipo di HIT, implementare le domande da porre ai worker, anche diverse versioni.
- 4. Rilascio in laboratorio, far svolgere il compito ad alcuni amici per capire se ci sono bug. Cominciare l'analisi dei dati.
- 5. Test pilota: far svolgere il compito sulla piattaforma con worker veri per testare ulteriormente
- 6. In produzione: lancio esperimento finale.



Qualità in un task

Con tutti gli accorgimenti possibili è difficile avere risposte perfette ed esatte. La qualità perfetta nei dati non esiste, ci sono sempre errori, incongruenze. Una scelta ragionevole è fare il meglio che si può con i dati che si hanno e usare tutti gli accorgimenti possibili per diminuire effetti degli errori.

Cosa non fare: non elencare le cose da non fare nel task, non incaricare di troppo lavoro.

Cosa fare: formattazione task semplice chiara e ben separata tra testo fornito e risposte da inserire.

Design del task

Scelta delle risposte: tra due opzioni (pairwise) o su singolo oggetto.

Modalità di presentazione: come presentare ai worker, scelta testi e formattazione (colori e paginazione)

Test di qualificazione

Controllo preliminare al task, dove si verifichi che il worker superi certi standard.

Obiettivo: selezionare worker competenti.

Controlli sintattici

Controllo dell'input durante il test, per evitare risposte non date o campi vuoti, conteggi di parole, controllo copia e incolla.

Test nascosti (Gold question)

Domande facili di cui si sa già la risposta, confronto di cui si sa la risposta, domande ripetute per verificare la coerenza.

Con lo scopo di misurare la qualità dei worker. Se la qualità è troppo bassa il worker viene scartato (bloccato, non pagato).

Monitoraggio del tempo.

Verifica del tempo necessario per ogni sezione e sul totale, worker scartato se troppo veloce.

Monitoraggio azioni. Spostamenti col mouse, click su pulsanti.

Controlli ex-post.

Decisione in un secondo momento sulla qualità dei dati forniti dal worker.

Controlli più approfonditi di quelli fatti online durante il task.

Qualità individuale della risposta di un singolo worker è la similitudine della risposta col valore corretto.

Qualità del worker è la qualità media delle sue risposte.

Qualità aggregata delle risposte a un task è la similitudine tra la risposta aggregata e il valore corretto.

Per ottenere la risposta aggregata, si prendono tutte le risposte ad un task, si aggregano in un valore unico (media, mediana, moda).

Congettura del crowdsourcing → Qualità aggregata > Qualità individuale.

La similitudine(distanza) media con la ground truth dei valori individuali è minore di quella dei valori aggregati.

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

Teoria della misurazione

Non tutti i modi di ordinare e contare possono essere confrontati.

$$\forall x, y \in \mathcal{D} (R_{\mathcal{D}}(x, y) \implies R_{\mathbb{R}}(\psi(x), \psi(y)))$$

Ogni due oggetti appartenenti allo stesso dominio, con una relazione nel dominio (A pesa più di B) → la loro misurazione ha la stessa relazione.

Scale di misurazione:

- Nominale: dati qualitativi e categoriali. I numeri identificano le classi, 1=rosso 2=blu 3=verde.
- Ordinale: Una misura non è una quantità ma una classifica. Ad esempio, linee classificate in base alla loro lunghezza, non si possono fare paragoni tra le singole o intervalli (la prima è il doppio più lunga della seconda, ...).
- Intervallo: Differenza (-) tra intervalli. (2019-2017=2006-2004=2 anni)
- Rapporto: Si può dire "sono alto il doppio di lui, lui è ricco il doppio di me", altezza e ricchezza partono da zero. Invece "oggi è il doppio caldo di ieri?" non si può dire.

Operazioni e statistiche possibili

		$=, \neq$	$>, <$	$+, -$	$\times, \div$
DUE PALLINE	Nominal	✓	✗	✗	✗
1° 2°	Ordinal	✓	✓	✗	✗
ANNO 1000 ANNO 2000	Interval	✓	✓	✓	✗
MISURAZIONI	Ratio	✓	✓	✓	✓

	Mode	Median	Mean	
			Arithmetic	Geometric, Harmonic
Nominal	✓	✗	✗	✗
Ordinal	✓	✓	✗	✗
Interval	✓	✓	✓	✗
Ratio	✓	✓	✓	✓

Aggregazione

	t_1	t_2	t_3	...	t_n
w_1	1	0	1	...	1
w_2	1	...	0	...	0
w_3	1	0	...	...	0
...	...	...	...	...	...
w_m	...	0	1	...	...

	t_1	t_2	t_3	...	t_n
w_1	P	P	P	...	F
w_2	P	...	P	...	F
w_3	P	P	...	...	F
...	...	...	...	...	...
w_m	...	F	T	...	...

Aggr	t_1	t_2	t_3	...	t_n
	1	0	1	...	0

Aggr	t_1	t_2	t_3	...	t_n
	P	P	P	...	F

Truth	t_1	t_2	t_3	...	t_n
	1	0	1	...	0

Truth	t_1	t_2	t_3	...	t_n
	P	P	P	...	P


Perdita di informazioni, non uguaglianza fra i singoli valori poi aggregati ($t_2 \neq t_3$).

Scala ordinale etichettata. Non tutti i confronti tra intervalli hanno senso.

Pants On Fire --> 0
 False --> 1
 Barely True --> 2
 Half True --> 3
 Mostly True --> 4
 True --> 5

Funzioni di aggregazione: Moda, Mediana, Media aritmetica, Media geometrica (radice n della produttoria di tutti gli x), Media armonica (reciproco della media aritmetica dei reciproci).

Esempio su scala [0,1]



Miglioramento da 0.1 a 0.2 e da 0.8 a 0.9

La media aritmetica li considera uguali, la media geometrica considera maggiore il primo (incremento doppio) → utile per i problemi difficili, task complicati.

La media geometrica pesa di più nella zona bassa.

Un incremento del valore massimo muove di poco la media armonica, il valore minimo influenza di più.

Ponderare la scelta della funzione di aggregazione a seconda dei casi (verificare il dominio)

Accordo: Se i worker sono in accordo, la qualità è alta. Accordo come approssimazione della qualità.

Metodologie di misurazione dell'accordo:

- 1. Guardare quanto i worker che hanno svolto lo stesso task sono in accordo fra di loro.
- 2. Guardare quanto il singolo worker è in accordo con gli altri worker che hanno svolto lo stesso task.

1.

Confronto tra due worker.

	t_1	t_2	t_3	...	t_n
w_1	Y	Y	Y	Y	N
w_2	N	Y	Y	N	N

	w_2
w_1	Y N
	Y 2 2
	N 0 1

Percent agreement: Accordo percentuale.

Percentuale di quanto due worker sono d'accordo = Accuratezza

Scala nominale binaria e matrice completa. Rappresentazione alternativa la matrice di confusione.

$$p = \frac{a+d}{a+b+c+d}$$

	Y	N
Y	a	b
N	c	d

Contro: Accordo casuale (sensibili alle scelte casuali dei worker), Categorie sbilanciate.

Con accordo casuale le categorie sono equidistribuite.

Cohen's kappa: migliora il percent agreement tenendo conto dell'accordo casuale

$$k = \frac{p_o - p_e}{1 - p_e} \cdot p_o \text{ è il percent agreement osservato, } p_e \text{ è il percent agreement by chance}$$

$$(\text{atteso}), \text{calcolato } p_e = \left(\frac{(a+b) \cdot (a+c)}{a+b+c+d} \right) + \left(\frac{(c+d) \cdot (b+d)}{a+b+c+d} \right)$$

		w ₂		
		Y	N	
w ₁	Y	a	b	a + b
	N	c	d	c + d
		a + c	b + d	a + b + c + d

Confronto fra più worker

Pairwise agreement: quanto accordo c'è tra le coppie.

Si confrontano le coppie di valori provenienti da $\frac{m(m-1)}{2}$ coppie di worker.

$$\text{Media} = 18/(6 \cdot 5) = 0.6$$

	t ₁	t ₂	t ₃	t ₄	t ₅
w ₁	A	A	A	A	B
w ₂	A	A	A	A	B
w ₃	A	A	B	B	B
w ₄	A	B	B	C	B

	t ₁	t ₂	t ₃	t ₄	t ₅
Pairwise agreement	6/6	3/6	2/6	1/6	6/6

Fleiss kappa. Come Cohen's kappa ma corretto per accordo casuale.

$$\kappa = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

Valori sottozero indicano pessimo accordo, valori da 0.8 a 1 indicano ottimo accordo.

P: pairwise agreement osservato, P_e: pairwise agreement atteso, casuale.

p_j: calcolato a partire dalla matrice categoria/task, sommando i valori nella riga della categoria j e dividendo per il totale degli assegnamenti.

$$p_j = \frac{1}{nm} \sum_{i=1}^n n_{ij}$$

$$\bar{P}_e = \sum_{j=1}^k p_j^2$$

P_e ci dice quanto sono distribuiti gli assegnamenti ad ogni categoria. Valore vicino a uno vuol dire tutti gli assegnamenti ad una categoria, valore minimo assegnamenti equidistribuiti.

P_i somma degli assegnamenti in colonna i e divisione col numero totale degli assegnamenti.

	i ₁	i ₂	i ₃	i ₄	i ₅	i ₆	i ₇	i ₈	i ₉	i ₁₀	Tot	p _j
A	0	0	0	0	2	7	3	2	6	0	20	.143
B	0	2	0	3	2	7	2	5	5	2	28	.200
C	0	6	3	9	8	0	6	3	2	2	39	.279
D	0	4	5	2	1	0	3	2	1	3	21	.150
E	14	2	6	0	1	0	0	2	0	7	32	.229
P _i	1.00	.253	.308	.440	.330	.462	.242	.176	.286	.286	140	

$$= \frac{1}{m(m-1)} [(\sum_{j=1}^k n_{ij}^2) - n] \quad \bar{P} = \frac{1}{n} \sum_{i=1}^n P_i$$

2.

Misurazione dell'accordo fra w1 e la media degli altri worker. Aggrego tutti tranne w1 e misuro l'agreement fra i valori di w1 e le aggregazioni.

Sfrutto l'accordo per: escludere i worker che hanno accordo basso (bassa qualità); pensarli di meno nell'aggregazione.

L'accordo non funziona nel caso soggettivo, dove non esiste una verità.