

Riassunto Social Computing

Trentin Tommaso

January 20, 2026

Contents

1	Social media	2
1.1	Classificazione	2
2	Grafi e Reti	2
2.1	Nodi vs. Attori (dipende dal contesto)	2
2.2	Archivi	2
2.3	Grafi	3
2.3.1	Proprietà	3
2.4	Gradi	3
2.5	Densità	4
2.6	Rappresentazioni	4
2.6.1	Lista degli archivi	4
2.6.2	Lista di adiacenza	4
2.6.3	Matrice di adiacenza	4
2.7	Reti	5
2.7.1	Reti sociali	5
2.7.2	Analisi delle reti sociali (Social Network Analysis - SNA)	5
3	Reti e Misure	5
3.1	Centralità	5
3.1.1	Centralità di grado	5
3.1.2	Centralità di grado normalizzata	6
3.1.3	Betweenness centrality	6
3.1.4	Betweenness centrality normalizzata	6
3.1.5	Centralità di vicinanza (Closeness centrality)	7
3.1.6	Confronti	7
3.2	PageRank	7
3.2.1	PageRank - vettori e matrici	8
3.2.2	Markov chain	8
3.2.3	Markov chain - autovettore	8
3.2.4	Teleporting	8
3.2.5	PageRank - implementazione	9
3.3	HITS	9

1 Social media

Tecnologie che facilitano **creazione** e **condivisione** di informazioni, idee, interessi e altre forme di espressione mediante **community visuali** e **network**.


- Applicazioni internet-based **Web 2.0**;
- Sviluppate avendo come scopo principale la gestione di **User-generated content**;
- Utenti creano **profili** e identità service-specific che vengono mantenuti dalla social media organization;
- Facilitano lo sviluppo di **social network online** connettendo il profilo di un utente con quello di altri individui / organizzazioni.

1.1 Classificazione

2 dimensioni principali: **Social presence** / **Media richness** (quanto sembra di essere "lì") e **Self presentation** / **Self disclosure** (quanto si rivela di sé).

		Social presence/ Media richness		
		Low	Medium	High
Self-presentation/ Self-disclosure	High	Blogs	Social networking sites (e.g., Facebook)	Virtual social worlds (e.g., Second Life)
	Low	Collaborative projects (e.g., Wikipedia)	Content communities (e.g., YouTube)	Virtual game worlds (e.g., World of Warcraft)

Visione articolata:



2 Grafi e Reti

2.1 Nodi vs. Attori (dipende dal contesto)

$$V = v_1, v_2, \dots, v_n$$

- Grafo del Web:
 - Nodi = pagine/siti web;
 - Archi = link ipertestuali.
- Grafo sociale di amicizie:
 - Nodi = persone;
 - Archi = amicizie, conoscenze...

Grandezza del grafo (size): $|V| = n$

2.2 Archi

$$E = e_1, e_2, \dots, e_m$$

Gli archi (edges) connettono nodi (ties / relationships). In un settng sociale:

- Nodi = entità sociali (persone);
- Archi = relazioni fra persone;

Grandezza dell'insieme degli archi: $|E| = m$

2.3 Grafi

Un grafo G si può rappresentare come coppia dell'insieme di nodi V e archi E :

$$G(V, E)$$

2.3.1 Proprietà

- Archi possono avere direzioni ($e(v_1, v_2) \neq e(v_2, v_1)$);
- **Grafo pesato:** ad ogni arco è associato un peso ($G(V, E, W)$);
- Grafo $G'(V', E')$ è **sottografo** di $G(V, E)$ se $(V' \subseteq V)$ e $(E' \subseteq (V' \times V') \cap E)$;
- **Vicinato** di un nodo: tutti i nodi ad esso collegati mediante archi (incoming / outgoing neighbors);
- **Cammino:** sequenza di archi t.c. ogni arco è incidente allo stesso nodo del successivo;
- **Connessione:**
 - Un **nodo** v_i è connesso al nodo v_j se esiste cammino da v_i a v_j (e viceversa);
 - Un **grafo** è connesso se esiste un cammino fra ogni coppia di nodi (*fortemente* se il cammino è diretto, *debolmente* altrimenti)
- **Componenti:**
 - **Componente in un grafo indiretto:** è un sottografo massimale connesso.
 - * Esiste un cammino indiretto fra ogni coppia di nodi nella componente.
 - * "Massimale" significa che se si aggiungono altri nodi del grafo originale, il sottografo non è più connesso.
 - **Componente Fortemente Connessa** (Strongly Connected Component, **SCC**): In un grafo diretto, si ha una SCC quando per ogni coppia di nodi $u, v \in SCC$ esiste un cammino *diretto* da u a v e uno da v a u .
 - **Componente Debolmente Connessa** (Weakly Connected Component, **WCC**): In un grafo diretto, si ha una WCC quando per ogni coppia di nodi $u, v \in WCC$ esiste un cammino *indiretto* da u a v .
 - Un grafo può avere diverse componenti (ne ha solo 1 se l'intero grafo è connesso).
 - **Giant Connected Component:** è la componente più grande del grafo e contiene "quasi tutto" il grafo (la maggior parte dei nodi).

2.4 Gradi

$\pi(d) = d_1, d_2, \dots, d_n$ **Grado di un nodo i d_i :** numero di archi collegati a quel nodo (entranti = **in-degree** d_i^{in} , uscenti = **out-degree** d_i^{out}).

Degree distribution: per ogni nodo, quanti nodi hanno quel grado:

$$p_{grado} = \frac{numNodi_{grado}}{numNodi}, \sum_{d=0}^{\infty} p_{grado} = 1$$

Teorema: sommatoria dei gradi di un grafo indiretto è 2 volte il numero degli archi

$$\sum_i d_i = 2|E|$$


Corollari:

1. numero di nodi con grado dispari è pari;
2. in ogni grafo diretto la sommatoria degli in-degree è uguale alla somma degli out-degree

$$\sum_i d_i^{out} = \sum_j d_j^{in}$$

Grafico della degree distribution

- L'asse delle x rappresenta il grado
- L'asse delle y rappresenta la frazione (relativa) o il numero (assoluta) dei nodi che hanno quel grado
- Idem per in- e out-degree
- Spesso su scala log-log
- Sui social media, di solito decrescente:
 - Tanti utenti/profili con poche connessioni
 - Alcuni utenti con un numero di amici molto alto
 - (Spesso Power-law degree distribution, non qui)



2.5 Densità


Quanti archi ci sono rispetto a tutti gli archi possibili:

- Grafi **indiretti** - $D = \frac{2|E|}{|V|(|V|-1)}$
- Grafi **diretti** - $D = \frac{|E|}{|V|(|V|-1)}$

2.6 Rappresentazioni


2.6.1 Lista degli archi

- Ogni elemento della lista è un arco da un nodo u a un nodo v (u, v);
- Ok anche per grafi diretti;
- Non ok per nodi isolati: non vengono rappresentati.



2.6.2 Lista di adiacenza

- Per ogni nodo, lista di tutti i nodi a cui è connesso;
- Solitamente ordinata;
- Ok anche per grafi diretti.




Node	Connected To
v_1	v_2
v_2	v_1, v_3, v_4
v_3	v_2, v_4
v_4	v_2, v_3, v_5, v_6
v_5	v_4
v_6	v_4

2.6.3 Matrice di adiacenza

- Quadrata (1 se c'è un arco fra v_i e v_j , 0 altrimenti);

- Simmetrica per grafi indiretti;
- Ok per grafi diretti (generalmente non simmetrica);
- Auto-archi (self-link) sulla diagonale;
- Per reti sociali le matrici di adiacenza sono sparse (quasi tutti 0);
- Ok per grafi pesati ()
- Quadrata (w_{ij} se c'è un arco fra v_i e v_j , 0 altrimenti);



2.7 Reti

Una rete (**network**) è un grafo (solitamente grande) con nodi e archi che esistono nel mondo reale, solitamente per rappresentare problemi su una rete si usano grafi e risultati della teoria dei grafi.

2.7.1 Reti sociali

Reti i cui elementi hanno una struttura sociale:

- Insieme di **attori** = individui / organizzazioni;
- Insieme di **legami** = connessioni fra attori.

Esempi: rete di familiari / amici / colleghi.

2.7.2 Analisi delle reti sociali (Social Network Analysis - SNA)

Settore interdisciplinare (scienze sociali + statistica + teoria dei grafi + reti complesse + informatica) che studia queste reti.

3 Reti e Misure

3.1 Centralità

Misura che indica quanto un nodo è centrale, basandosi su definizioni / assunzioni.


3.1.1 Centralità di grado

Più è alto il grado di un nodo, più è centrale.

$$C_d(v_i) = d_i$$

Es.:

- Degree centrality di v_1 è $d_1=8$
- Per gli altri $d_j = 1, j \neq 1$



In grafi diretti si possono usare in-degree, out-degree o combinazione dei due:


- $C_d(v_i) = d_i^{in}$ (prestige);
- $C_d(v_i) = d_i^{out}$ (gregariousness);
- $C_d(v_i) = d_i^{in} + d_i^{out}$.

In pratica in-degree è il più usato / interessante.

3.1.2 Centralità di grado normalizzata

Utile per confrontare grafi differenti:

- Normalizzazione per grado massimo possibile - $C_d^{norm}(v_i) = \frac{d_i}{n-1}$;
- Normalizzazione per grado massimo effettivo - $C_d^{max}(v_i) = \frac{d_i}{\max_j d_j}$;
- Normalizzazione per somma dei gradi - $C_d^{sum}(v_i) = \frac{d_i}{\sum_j d_j} = \frac{d_i}{2|E|} = \frac{d_i}{2m}$.




3.1.3 Betweenness centrality

Misura quanto un nodo è importante nel connettere altri nodi tramite cammini (si guardano solo shortest paths).

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}}$$

- $\sigma_{st}(v_i)$: numero di shortest paths da s a t che passano per v_i ;
- σ_{st} : numero di shortest paths da s a t .



3.1.4 Betweenness centrality normalizzata

Nel caso migliore il nodo v_i è su tutti gli shortest paths da s a t , quindi $\frac{\sigma_{st}(v_i)}{\sigma_{st}} = 1, \forall s, t$

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}} = \sum_{s \neq t \neq v_i} 1 = 2 \binom{n-1}{2} = (n-1)(n-2)$$

Quindi il valore massimo è $(n-1)(n-2)$, per normalizzarlo: $C_b^{norm}(v_i) = \frac{C_b(v_i)}{2 \binom{n-1}{2}}$


3.1.5 Centralità di vicinanza (Closeness centrality)

$$C_c(v_i) = \frac{1}{\bar{l}_{v_i}}$$

I nodi influenti / centrali possono raggiungere velocemente gli altri nodi (considero gli shortest path verso tutti gli altri nodi).

$$\bar{l}_{v_i} = \frac{1}{n-1} \sum_{v_j \neq v_i} l_{i,j}$$

- $l_{i,j}$: lunghezza cammino più breve da v_i a v_j ;
- $\bar{l}_{v_i}$: lunghezza media dei cammini più brevi più brevi da v_i .




3.1.6 Confronti

	Low Degree	Low Closeness	Low Betweenness
High Degree		Node is embedded in a community that is far from the rest of the network	Ego's connections are redundant - communication bypasses the node
High Closeness	Key node connected to important/active alters		Probably multiple paths in the network, ego is near many people, but so are many others
High Betweenness	Ego's few ties are crucial for network flow	Very rare! Ego monopolizes the ties from a small number of people to many others	

3.2 PageRank

Archì che vengono da **nodì importanti** (più centrali) dovrebbero **aumentare di più la centralità** rispetto a archì che vengono da nodi meno centrali.



Notazione:


- $r(v)$ PageRank della pagina v ;
- $I(v)$ set di pagine che citano v ;

- $O(v)$ set di pagine citate da v .

Ogni pagina u ha il suo valore PageRank $r(u)$, la pagina v riceve dalla pagina u una porzione del suo PageRank uguale alla porzione ricevuta da tutte le altre pagine citate da u : $\frac{r(u)}{|O(u)|}$

3.2.1 PageRank - vettori e matrici

Si possono collezionare tutti i valori PageRank di tutte le pagine u_i in un vettore $r = [r(u_0), r(u_1), \dots, r(u_n)]$




Si costruiscono i vettori r **iterativamente, tutti assieme**. Per andare da r_0 iniziale a r_1 mediante una matrice P tale che $r_{i+1} = r_i \times P$

3.2.2 Markov chain

Dato un grafo / matrice di adiacenza con n stati si ha una matrice $n \times n$ P con le probabilità di transizione. A ciascun istante di tempo la catena di Markov è in uno degli n stati.

$\forall$ stato corrente $i \in [1..n]$, la catena di Markov (P) dice la probabilità che il prossimo stato sia j , $\forall j \in [1..n]$.



Si può rappresentare la posizione corrente in uno stato i con un vettore $x = (x_1, \dots, x_n)$ dove tutti i componenti hanno valore 0 tranne l' i -esimo che ha valore 1 e rappresenta la posizione nello stato i .

Il vettore di probabilità nel prossimo step si può trovare guardando la matrice P alla i -esima riga, in modo da controllare le probabilità per procedere al prossimo stato partendo da i .


3.2.3 Markov chain - autovettore

Quindi, per ogni step $x_{i+1} = x_i \times P$ ma stiamo cercando una distribuzione stabile $x_{i+1} = x_i$, cerchiamo quindi x tale che $x = x \times P$ (x autovettore di P).

Per ogni catena **ergodica (fortemente connessa e in cui in ogni step si può essere in ogni stato con probabilità > 0)** ogni stato ha un rate di visite a lungo termine per cui viene visitato proporzionalmente.

3.2.4 Teleporting

Nella pratica (Web) non sempre si hanno situazioni ergodiche, ma navigando si potrebbe "saltare" ad un'altra pagina random: "ciascuna pagina è collegata con qualsiasi altra pagina" (con basse probabilità).



3.2.5 PageRank - implementazione

Catena di Markov, ogni pagina ha una propria probabilità per cui, durante il percorso random tra le pagine, l'utente si trovi lì

Formula

- Power iteration
 - $\mathbf{r}_{i+1} = \mathbf{r}_i \cdot \mathbf{P}'$

$$\mathbf{r}_{i+1} = (1-d) \cdot \mathbf{r}_i \cdot \mathbf{P} + d \cdot \mathbf{r}_i \cdot \begin{pmatrix} 1/N & \dots & 1/N \\ \vdots & \ddots & \vdots \\ 1/N & \dots & 1/N \end{pmatrix}$$

- d : probability of teleporting (for ex., 0.1)
- N : # of nodes/pages
- (here
 - $\mathbf{P}$ is the adjacency matrix without teleporting,
 - $\mathbf{P}'$ is the adjacency matrix with teleporting)

1. Costruzione matrice P' (matrice di adiacenza P + teleporting (ergodic));
2. Inizio da vettore di probabilità r_0 ;
3. $r_{i+1} = r_i \times P$;
4. Se $|r_{i+1} - r_i| < \epsilon$ stoppa, altrimenti ripeti;
5. Il vettore r trovato ($r = r \times P'$, o $r \times P'$) è il PageRank di tutte le pagine, e l'autovettore di P' .

3.3 HITS

Idea: costruire 2 set di pagine collegati:

- **Hub pages (H)** contenenti (buoni) link ad altre pagine (yahoo, buoni bookmark,...);
- **Authority pages (A)** con persone / entità ben organizzate nel web (w3c, Knuth's homepage,...).

L'algoritmo lavora su un set ristretto di pagine Root Set (RS), che si espande con:

- $I(v)$ in-pages (tutte le pagine u tali che $\exists v \in RS, u \rightarrow v$);
- $O(v)$ out-pages (tutte le pagine u tali che $\exists v \in RS, v \rightarrow u$).

Si ottiene così il Base Set (BS) con buone pagine candidate Hub / Authority e su cui l'algoritmo poi lavora, selezionando H e A mediante un controllo su ogni pagina x in BS per i valori di **hubness** ($h(x)$) e **authority** ($a(x)$).

