

# Riassunto Social Computing

Trentin Tommaso

January 23, 2026

## Contents

|          |                                                                      |           |
|----------|----------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Social media</b>                                                  | <b>4</b>  |
| 1.1      | Classificazione . . . . .                                            | 4         |
| <b>2</b> | <b>Grafi e Reti</b>                                                  | <b>4</b>  |
| 2.1      | Nodi vs. Attori (dipende dal contesto) . . . . .                     | 4         |
| 2.2      | Archì . . . . .                                                      | 4         |
| 2.3      | Grafi . . . . .                                                      | 5         |
| 2.3.1    | Proprietà . . . . .                                                  | 5         |
| 2.4      | Gradi . . . . .                                                      | 5         |
| 2.5      | Densità . . . . .                                                    | 6         |
| 2.6      | Rappresentazioni . . . . .                                           | 6         |
| 2.6.1    | Lista degli archi . . . . .                                          | 6         |
| 2.6.2    | Lista di adiacenza . . . . .                                         | 6         |
| 2.6.3    | Matrice di adiacenza . . . . .                                       | 6         |
| 2.7      | Reti . . . . .                                                       | 7         |
| 2.7.1    | Reti sociali . . . . .                                               | 7         |
| 2.7.2    | Analisi delle reti sociali (Social Network Analysis - SNA) . . . . . | 7         |
| <b>3</b> | <b>Reti e Misure</b>                                                 | <b>7</b>  |
| 3.1      | Centralità . . . . .                                                 | 7         |
| 3.1.1    | Centralità di grado . . . . .                                        | 7         |
| 3.1.2    | Centralità di grado normalizzata . . . . .                           | 8         |
| 3.1.3    | Betweenness centrality . . . . .                                     | 8         |
| 3.1.4    | Betweenness centrality normalizzata . . . . .                        | 8         |
| 3.1.5    | Centralità di vicinanza (Closeness centrality) . . . . .             | 9         |
| 3.1.6    | Confronti . . . . .                                                  | 9         |
| 3.2      | PageRank . . . . .                                                   | 9         |
| 3.2.1    | PageRank - vettori e matrici . . . . .                               | 10        |
| 3.2.2    | Markov chain . . . . .                                               | 10        |
| 3.2.3    | Markov chain - autovettore . . . . .                                 | 10        |
| 3.2.4    | Teleporting . . . . .                                                | 10        |
| 3.2.5    | PageRank - implementazione . . . . .                                 | 11        |
| 3.3      | HITS . . . . .                                                       | 11        |
| 3.3.1    | Procedimento - "Algoritmo" . . . . .                                 | 12        |
| 3.3.2    | HITS - vettori e matrici . . . . .                                   | 12        |
| 3.3.3    | HITS - autovettori . . . . .                                         | 12        |
| 3.3.4    | HITS - $MM^T$ . . . . .                                              | 13        |
| 3.3.5    | HITS - $M^T M$ . . . . .                                             | 13        |
| 3.4      | PageRank / HITS - confronto . . . . .                                | 14        |
| <b>4</b> | <b>Social Network Analysis - terminologia</b>                        | <b>14</b> |
| <b>5</b> | <b>Transitività</b>                                                  | <b>15</b> |
| 5.1      | Coefficiente di clustering locale . . . . .                          | 15        |
| 5.2      | Coefficiente di clustering globale . . . . .                         | 16        |
| <b>6</b> | <b>Reciprocità</b>                                                   | <b>17</b> |
| 6.1      | Calcolo . . . . .                                                    | 17        |
| <b>7</b> | <b>Bilanciamento</b>                                                 | <b>17</b> |

|           |                                                  |           |
|-----------|--------------------------------------------------|-----------|
| 7.1       | Bilanciamento Sociale . . . . .                  | 17        |
| 7.2       | Status sociale . . . . .                         | 18        |
| <b>8</b>  | <b>Degree distributions reali</b>                | <b>18</b> |
| <b>9</b>  | <b>La Legge di Potenza (Power Law)</b>           | <b>19</b> |
| 9.1       | Che cos'è (In parole povere) . . . . .           | 19        |
| 9.2       | Il trucco del Grafico Log-Log . . . . .          | 19        |
| 9.3       | Esempi Reali (Dalle Slide) . . . . .             | 19        |
| 9.4       | Nota: Differenza con Zipf . . . . .              | 19        |
| 9.5       | Test . . . . .                                   | 19        |
| 9.6       | Coefficiente di clustering . . . . .             | 20        |
| <b>10</b> | <b>Diffusione informazioni</b>                   | <b>20</b> |
| 10.1      | Milgram . . . . .                                | 20        |
| 10.2      | Dodds . . . . .                                  | 20        |
| 10.3      | Erdos . . . . .                                  | 20        |
| 10.4      | Proprietà reti reali . . . . .                   | 20        |
| <b>11</b> | <b>Modelli delle reti</b>                        | <b>20</b> |
| 11.1      | Reti regolari . . . . .                          | 20        |
| 11.2      | Reti casuali . . . . .                           | 21        |
| 11.2.1    | Modello $G(n,m)$ . . . . .                       | 21        |
| 11.2.2    | Modello $G(n,p)$ . . . . .                       | 21        |
| 11.2.3    | Differenza . . . . .                             | 22        |
| 11.2.4    | $G(n,p)$ connesso? . . . . .                     | 22        |
| 11.2.5    | Recap . . . . .                                  | 22        |
| 11.3      | Reti small-world . . . . .                       | 22        |
| 11.3.1    | Procedura . . . . .                              | 23        |
| 11.3.2    | Reti che ci interessano . . . . .                | 23        |
| 11.3.3    | Distribuzione dei gradi . . . . .                | 23        |
| 11.3.4    | Recap . . . . .                                  | 23        |
| 11.4      | Reti scale free . . . . .                        | 23        |
| 11.4.1    | Diametro . . . . .                               | 23        |
| 11.5      | Reti con attaccamento preferenziale . . . . .    | 24        |
| 11.5.1    | Sul modello scale-free . . . . .                 | 24        |
| 11.6      | Sunto . . . . .                                  | 24        |
| 11.7      | Attaccamento preferenziale non lineare . . . . . | 24        |
| 11.8      | Attrattività . . . . .                           | 24        |
| 11.9      | Fitness . . . . .                                | 24        |
| 11.10     | Random Walk . . . . .                            | 25        |
| 11.10.1   | FUNZIONA . . . . .                               | 25        |
| <b>12</b> | <b>Comunità</b>                                  | <b>25</b> |
| 12.1      | Definizione "ideale" . . . . .                   | 25        |
| 12.2      | Definizione "realistica" . . . . .               | 25        |
| 12.3      | Algoritmi per riconoscere comunità . . . . .     | 26        |
| 12.3.1    | Edge betweenness centrality . . . . .            | 26        |
| 12.3.2    | Algoritmo di Givran-Newman . . . . .             | 26        |
| 12.4      | Gerarchia . . . . .                              | 26        |
| <b>13</b> | <b>Diffusione informazioni</b>                   | <b>26</b> |
| 13.1      | Herd behavior . . . . .                          | 27        |
| 13.1.1    | Grafo completo . . . . .                         | 27        |
| 13.1.2    | Esempio . . . . .                                | 27        |
| 13.1.3    | Intervention . . . . .                           | 27        |
| 13.2      | Information cascade . . . . .                    | 27        |
| 13.2.1    | Independent Cascade Model (ICM) . . . . .        | 27        |
| 13.2.2    | Massimizzare spread di cascade . . . . .         | 28        |
| 13.2.3    | Problemi . . . . .                               | 28        |
| 13.3      | Epidemics . . . . .                              | 28        |
| 13.3.1    | SI model . . . . .                               | 28        |
| 13.4      | SIR model . . . . .                              | 29        |
| 13.4.1    | Transizione epidemica . . . . .                  | 29        |

|           |                            |           |
|-----------|----------------------------|-----------|
| 13.5      | SIS model . . . . .        | 30        |
| 13.6      | SIRS model . . . . .       | 30        |
| 13.7      | Contagio sociale . . . . . | 30        |
| 13.7.1    | Cosa succede . . . . .     | 31        |
| 13.7.2    | Condizione . . . . .       | 31        |
| <b>14</b> | <b>Epidemie su reti</b>    | <b>31</b> |

# 1 Social media

Tecnologie che facilitano **creazione** e **condivisione** di informazioni, idee, interessi e altre forme di espressione mediante **community visuali** e **network**.


- Applicazioni internet-based **Web 2.0**;
- Sviluppate avendo come scopo principale la gestione di **User-generated content**;
- Utenti creano **profili** e identità service-specific che vengono mantenuti dalla social media organization;
- Facilitano lo sviluppo di **social network online** connettendo il profilo di un utente con quello di altri individui / organizzazioni.

## 1.1 Classificazione

2 dimensioni principali: **Social presence** / **Media richness** (quanto sembra di essere "lì") e **Self presentation** / **Self disclosure** (quanto si rivela di sé).

|                                       |      | Social presence/ Media richness             |                                             |                                                  |
|---------------------------------------|------|---------------------------------------------|---------------------------------------------|--------------------------------------------------|
|                                       |      | Low                                         | Medium                                      | High                                             |
| Self-presentation/<br>Self-disclosure | High | Blogs                                       | Social networking sites<br>(e.g., Facebook) | Virtual social worlds<br>(e.g., Second Life)     |
|                                       | Low  | Collaborative projects<br>(e.g., Wikipedia) | Content communities<br>(e.g., YouTube)      | Virtual game worlds<br>(e.g., World of Warcraft) |

Visione articolata:



# 2 Grafi e Reti

## 2.1 Nodi vs. Attori (dipende dal contesto)

$$V = v_1, v_2, \dots, v_n$$

- Grafo del Web:
  - Nodi = pagine/siti web;
  - Archi = link ipertestuali.
- Grafo sociale di amicizie:
  - Nodi = persone;
  - Archi = amicizie, conoscenze...

**Grandezza del grafo** (size):  $|V| = n$

## 2.2 Archi

$$E = e_1, e_2, \dots, e_m$$

Gli archi (edges) connettono nodi (ties / relationships). In un settng sociale:

- Nodi = entità sociali (persone);
- Archi = relazioni fra persone;

**Grandezza dell'insieme degli archi:**  $|E| = m$

## 2.3 Grafi

Un grafo  $G$  si può rappresentare come coppia dell'insieme di nodi  $V$  e archi  $E$ :

$$G(V, E)$$

### 2.3.1 Proprietà

- Archi possono avere direzioni ( $e(v_1, v_2) \neq e(v_2, v_1)$ );
- **Grafo pesato**: ad ogni arco è associato un peso ( $G(V, E, W)$ );
- Grafo  $G'(V', E')$  è **sottografo** di  $G(V, E)$  se  $(V' \subseteq V)$  e  $(E' \subseteq (V' \times V') \cap E)$ ;
- **Vicinato** di un nodo: tutti i nodi ad esso collegati mediante archi (incoming / outgoing neighbors);
- **Cammino**: sequenza di archi t.c. ogni arco è incidente allo stesso nodo del successivo;
- **Connessione**:
  - Un **nodo**  $v_i$  è connesso al nodo  $v_j$  se esiste cammino da  $v_i$  a  $v_j$  (e viceversa);
  - Un **grafo** è connesso se esiste un cammino fra ogni coppia di nodi (*fortemente* se il cammino è diretto, *debolmente* altrimenti)
- **Componenti**:
  - **Componente in un grafo indiretto**: è un sottografo massimale connesso.
    - \* Esiste un cammino indiretto fra ogni coppia di nodi nella componente.
    - \* "*Massimale*" significa che se si aggiungono altri nodi del grafo originale, il sottografo non è più connesso.
  - **Componente Fortemente Connessa** (Strongly Connected Component, **SCC**): In un grafo diretto, si ha una SCC quando per ogni coppia di nodi  $u, v \in SCC$  esiste un cammino *diretto* da  $u$  a  $v$  e uno da  $v$  a  $u$ .
  - **Componente Debolmente Connessa** (Weakly Connected Component, **WCC**): In un grafo diretto, si ha una WCC quando per ogni coppia di nodi  $u, v \in WCC$  esiste un cammino *indiretto* da  $u$  a  $v$ .
  - Un grafo può avere diverse componenti (ne ha solo 1 se l'intero grafo è connesso).
  - **Giant Connected Component**: è la componente più grande del grafo e contiene "quasi tutto" il grafo (la maggior parte dei nodi).

## 2.4 Gradi

$\pi(d) = d_1, d_2, \dots, d_n$  **Grado di un nodo  $i$   $d_i$** : numero di archi collegati a quel nodo (entranti = **in-degree**  $d_i^{in}$ , uscenti = **out-degree**  $d_i^{out}$ ).

**Degree distribution**: per ogni nodo, quanti nodi hanno quel grado:

$$p_{grado} = \frac{\text{numNodi}_{grado}}{\text{numNodi}}, \sum_{d=0}^{\infty} p_{grado} = 1$$

**Teorema**: sommatoria dei gradi di un grafo indiretto è 2 volte il numero degli archi

$$\sum_i d_i = 2|E|$$


**Corollari**:

1. numero di nodi con grado dispari è pari;
2. in ogni grafo diretto la sommatoria degli in-degree è uguale alla somma degli out-degree

$$\sum_i d_i^{out} = \sum_j d_j^{in}$$

## Grafico della degree distribution

- L'asse delle  $x$  rappresenta il grado
- L'asse delle  $y$  rappresenta la frazione (relativa) o il numero (assoluta) dei nodi che hanno quel grado
- Idem per in- e out-degree
- Spesso su scala log-log
- Sui social media, di solito decrescente:
  - Tanti utenti/profili con poche connessioni
  - Alcuni utenti con un numero di amici molto alto
  - (Spesso Power-law degree distribution, non qui)



## 2.5 Densità


Quanti archi ci sono rispetto a tutti gli archi possibili:

- Grafi **indiretti** -  $D = \frac{2|E|}{|V|(|V|-1)}$
- Grafi **diretti** -  $D = \frac{|E|}{|V|(|V|-1)}$

## 2.6 Rappresentazioni


### 2.6.1 Lista degli archi

- Ogni elemento della lista è un arco da un nodo  $u$  a un nodo  $v$  ( $u, v$ );
- Ok anche per grafi diretti;
- Non ok per nodi isolati: non vengono rappresentati.



### 2.6.2 Lista di adiacenza

- Per ogni nodo, lista di tutti i nodi a cui è connesso;
- Solitamente ordinata;
- Ok anche per grafi diretti.




| Node  | Connected To         |
|-------|----------------------|
| $v_1$ | $v_2$                |
| $v_2$ | $v_1, v_3, v_4$      |
| $v_3$ | $v_2, v_4$           |
| $v_4$ | $v_2, v_3, v_5, v_6$ |
| $v_5$ | $v_4$                |
| $v_6$ | $v_4$                |

### 2.6.3 Matrice di adiacenza

- Quadrata (1 se c'è un arco fra  $v_i$  e  $v_j$ , 0 altrimenti);

- Simmetrica per grafi indiretti;
- Ok per grafi diretti (generalmente non simmetrica);
- Auto-archi (self-link) sulla diagonale;
- Per reti sociali le matrici di adiacenza sono sparse (quasi tutti 0);
- Ok per grafi pesati ()
- Quadrata ( $w_{ij}$  se c'è un arco fra  $v_i$  e  $v_j$ , 0 altrimenti);



## 2.7 Reti

Una rete (**network**) è un grafo (solitamente grande) con nodi e archi che esistono nel mondo reale, solitamente per rappresentare problemi su una rete si usano grafi e risultati della teoria dei grafi.

### 2.7.1 Reti sociali

Reti i cui elementi hanno una struttura sociale:

- Insieme di **attori** = individui / organizzazioni;
- Insieme di **legami** = connessioni fra attori.

Esempi: rete di familiari / amici / colleghi.

### 2.7.2 Analisi delle reti sociali (Social Network Analysis - SNA)

Settore interdisciplinare (scienze sociali + statistica + teoria dei grafi + reti complesse + informatica) che studia queste reti.

## 3 Reti e Misure

### 3.1 Centralità

**Misura** che indica quanto un nodo è centrale, basandosi su definizioni / assunzioni.


#### 3.1.1 Centralità di grado

Più è alto il grado di un nodo, più è centrale.

$$C_d(v_i) = d_i$$

Es.:

- Degree centrality di  $v_1$  è  $d_1=8$
- Per gli altri  $d_j = 1, j \neq 1$



In grafi diretti si possono usare in-degree, out-degree o combinazione dei due:


- $C_d(v_i) = d_i^{in}$  (prestige);
- $C_d(v_i) = d_i^{out}$  (gregariousness);
- $C_d(v_i) = d_i^{in} + d_i^{out}$ .

In pratica in-degree è il più usato / interessante.

### 3.1.2 Centralità di grado normalizzata

Utile per confrontare grafi differenti:

- Normalizzazione per grado massimo possibile -  $C_d^{norm}(v_i) = \frac{d_i}{n-1}$ ;
- Normalizzazione per grado massimo effettivo -  $C_d^{max}(v_i) = \frac{d_i}{\max_j d_j}$ ;
- Normalizzazione per somma dei gradi -  $C_d^{sum}(v_i) = \frac{d_i}{\sum_j d_j} = \frac{d_i}{2|E|} = \frac{d_i}{2m}$ .




### 3.1.3 Betweenness centrality

Misura quanto un nodo è importante nel connettere altri nodi tramite cammini (si guardano solo shortest paths).

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}}$$

- $\sigma_{st}(v_i)$ : numero di shortest paths da  $s$  a  $t$  che passano per  $v_i$ ;
- $\sigma_{st}$ : numero di shortest paths da  $s$  a  $t$ .



### 3.1.4 Betweenness centrality normalizzata

Nel caso migliore il nodo  $v_i$  è su tutti gli shortest paths da  $s$  a  $t$ , quindi  $\frac{\sigma_{st}(v_i)}{\sigma_{st}} = 1, \forall s, t$

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}} = \sum_{s \neq t \neq v_i} 1 = 2 \binom{n-1}{2} = (n-1)(n-2)$$

Quindi il valore massimo è  $(n-1)(n-2)$ , per normalizzarlo:  $C_b^{norm}(v_i) = \frac{C_b(v_i)}{2 \binom{n-1}{2}}$


### 3.1.5 Centralità di vicinanza (Closeness centrality)

$$C_c(v_i) = \frac{1}{\bar{l}_{v_i}}$$

I nodi influenti / centrali possono raggiungere velocemente gli altri nodi (considero gli shortest path verso tutti gli altri nodi).

$$\bar{l}_{v_i} = \frac{1}{n-1} \sum_{v_j \neq v_i} l_{i,j}$$

- $l_{i,j}$ : lunghezza cammino più breve da  $v_i$  a  $v_j$ ;
- $\bar{l}_{v_i}$ : lunghezza media dei cammini più brevi più brevi da  $v_i$ .




### 3.1.6 Confronti

|                  | Low Degree                                         | Low Closeness                                                                           | Low Betweenness                                                                                |
|------------------|----------------------------------------------------|-----------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
| High Degree      |                                                    | Node is embedded in a <b>community</b> that is far from the rest of the network         | Ego's connections are <b>redundant</b> - communication bypasses the node                       |
| High Closeness   | Key node connected to important/active alters      |                                                                                         | Probably <b>multiple paths</b> in the network, ego is near many people, but so are many others |
| High Betweenness | Ego's few ties are <b>crucial</b> for network flow | Very rare! Ego <b>monopolizes the ties</b> from a small number of people to many others |                                                                                                |

## 3.2 PageRank

Archì che vengono da **nodì importanti** (più centrali) dovrebbero **aumentare di più la centralità** rispetto a archì che vengono da nodi meno centrali.



Notazione:


- $r(v)$  PageRank della pagina  $v$ ;
- $I(v)$  set di pagine che citano  $v$ ;

- $O(v)$  set di pagine citate da  $v$ .

Ogni pagina  $u$  ha il suo valore PageRank  $r(u)$ , la pagina  $v$  riceve dalla pagina  $u$  una porzione del suo PageRank uguale alla porzione ricevuta da tutte le altre pagine citate da  $u$ :  $\frac{r(u)}{|O(u)|}$

### 3.2.1 PageRank - vettori e matrici

Si possono collezionare tutti i valori PageRank di tutte le pagine  $u_i$  in un vettore  $r = [r(u_0), r(u_1), \dots, r(u_n)]$




Si costruiscono i vettori  $r$  **iterativamente, tutti assieme**. Per andare da  $r_0$  iniziale a  $r_1$  mediante una matrice  $P$  tale che  $r_{i+1} = r_i \times P$ .

### 3.2.2 Markov chain

Dato un grafo / matrice di adiacenza con  $n$  stati si ha una matrice  $n \times n$   $P$  con le probabilità di transizione. A ciascun istante di tempo la catena di Markov è in uno degli  $n$  stati.

$\forall$  stato corrente  $i \in [1..n]$ , la catena di Markov ( $P$ ) dice la probabilità che il prossimo stato sia  $j$ ,  $\forall j \in [1..n]$ .



Si può rappresentare la posizione corrente in uno stato  $i$  con un vettore  $x = (x_1, \dots, x_n)$  dove tutti i componenti hanno valore 0 tranne l' $i$ -esimo che ha valore 1 e rappresenta la posizione nello stato  $i$ .

Il vettore di probabilità nel prossimo step si può trovare guardando la matrice  $P$  alla  $i$ -esima riga, in modo da controllare le probabilità per procedere al prossimo stato partendo da  $i$ .


### 3.2.3 Markov chain - autovettore

Quindi, per ogni step  $x_{i+1} = x_i \times P$  ma stiamo cercando una distribuzione stabile  $x_{i+1} = x_i$ , cerchiamo quindi  $x$  tale che  $x = x \times P$  ( $x$  autovettore di  $P$ ).

Per ogni catena **ergodica (fortemente connessa e in cui in ogni step si può essere in ogni stato con probabilità  $> 0$ )** ogni stato ha un rate di visite a lungo termine per cui viene visitato proporzionalmente.

### 3.2.4 Teleporting

Nella pratica (Web) non sempre si hanno situazioni ergodiche, ma navigando si potrebbe "saltare" ad un'altra pagina random: "ciascuna pagina è collegata con qualsiasi altra pagina" (con basse probabilità).



### 3.2.5 PageRank - implementazione

Catena di Markov, ogni pagina ha una propria probabilità per cui, durante il percorso random tra le pagine, l'utente si trovi lì

**Formula**

- Power iteration
  - $\mathbf{r}_{i+1} = \mathbf{r}_i \cdot \mathbf{P}'$

$$\mathbf{r}_{i+1} = (1-d) \cdot \mathbf{r}_i \cdot \mathbf{P} + d \cdot \mathbf{r}_i \cdot \begin{pmatrix} 1/N & \dots & 1/N \\ \vdots & \ddots & \vdots \\ 1/N & \dots & 1/N \end{pmatrix}$$

- $d$ : probability of teleporting (for ex., 0.1)
- $N$ : # of nodes/pages
- (here
  - $\mathbf{P}$  is the adjacency matrix without teleporting,
  - $\mathbf{P}'$  is the adjacency matrix with teleporting)

1. Costruzione matrice  $P'$  (matrice di adiacenza  $P$  + teleporting (ergodic));
2. Inizio da vettore di probabilità  $r_0$ ;
3.  $r_{i+1} = r_i \times P$ ;
4. Se  $|r_{i+1} - r_i| < \epsilon$  stoppa, altrimenti ripeti;
5. Il vettore  $r$  trovato ( $r = r \times P'$ , o  $r \times P'$ ) è il PageRank di tutte le pagine, e l'autovettore di  $P'$ .

### 3.3 HITS


Idea: costruire 2 set di pagine collegati:


- **Hub pages (H)** contenenti (buoni) link ad altre pagine (yahoo, buoni bookmark,...);
- **Authority pages (A)** con persone / entità ben organizzate nel web (w3c, Knuth's homepage,...).

L'algoritmo lavora su un set ristretto di pagine Root Set ( $RS$ ), che si espande con:

- $I(v)$  in-pages (tutte le pagine  $u$  tali che  $\exists v \in RS, u \rightarrow v$ );
- $O(v)$  out-pages (tutte le pagine  $u$  tali che  $\exists v \in RS, v \rightarrow u$ ).

Si ottiene così il Base Set ( $BS$ ) con buone pagine candidate Hub / Authority e su cui l'algoritmo poi lavora, selezionando  $H$  e  $A$  mediante un controllo su ogni pagina  $x$  in  $BS$  per i valori di **hubness** ( $h(x)$ ) e **authority** ( $a(x)$ ).





### 3.3.1 Procedimento - "Algoritmo"

1. Assegnazione valori iniziali di  $h(x)$  e  $a(x)$  a ogni pagina  $x$  del  $BS$  (inizialmente  $h(x) = a(x) = 1$ );
2. Aggiornamento iterativo, con la precedente formula, di  $h(x)$  e  $a(x)$ ;
3. Stop quando converge ( $h(x)$  e  $a(x)$  non variano più);
4. Alla fine si riconoscono pagine "top hub" e "top authority".

### 3.3.2 HITS - vettori e matrici

Formalizzazione in vettori / matrici come PageRank.

• Let us build 2 (column!) vectors, for  $\mathbf{h}$  and  $\mathbf{a}$ :

•  $\mathbf{h} =$ 


|                   |     |                   |     |                   |
|-------------------|-----|-------------------|-----|-------------------|
| $\mathbf{h}(u_0)$ | ... | $\mathbf{h}(u_i)$ | ... | $\mathbf{h}(u_n)$ |
|-------------------|-----|-------------------|-----|-------------------|

•  $\mathbf{a} =$ 

|                   |     |                   |     |                   |
|-------------------|-----|-------------------|-----|-------------------|
| $\mathbf{a}(u_0)$ | ... | $\mathbf{a}(u_i)$ | ... | $\mathbf{a}(u_n)$ |
|-------------------|-----|-------------------|-----|-------------------|

$\mathbf{h}(x) = \sum_{x \rightarrow y} \mathbf{a}(y)$

Per calcolare  $h$  dell' $i$ -esimo componente si sommano tutti i componenti corrispondenti alle out-pages di  $u_i$  e si sommano, moltiplicando quindi  $a$  per  $l'i$ -esima riga della matrice di adiacenza.



Quindi, moltiplicando l' $i$ -esima riga di  $M$  per  $a$  si ottiene l' $i$ -esimo componente di  $h$ , e moltiplicando tutta  $M$  per  $a$  si ottiene tutto  $h$ .

$$h = Ma$$

e, di conseguenza:

$$a = M^T h$$

### 3.3.3 HITS - autovettori

Se abbiamo


- $h = Ma$
- $a = M^T h$

per sostituzione otteniamo

- $h = Ma = MM^T h$
- $a = M^T h = M^T Ma$

$h$  è quindi l'autovettore di  $MM^T$  e  $a$  è l'autovettore di  $M^T M$ .

### 3.3.4 HITS - $MM^T$



Questa matrice rappresenta l'**Accoppiamento Bibliografico** (Bibliographic Coupling). Ci dice quanto due nodi sono simili basandosi su "chi citano" (o chi linkano).


- **Definizione:** Il valore nella cella  $MM^T[i, j]$  conta il numero di nodi che sono **co-linkati** da  $i$  e da  $j$ . In altre parole, conta quante destinazioni hanno in comune.
- **La Logica Matematica:** Il valore aumenta di 1 quando esiste un nodo  $k$  che funge da "ponte comune", tale che:

$$M[i, k] = 1 \quad \text{e} \quad M[j, k] = 1$$

(Ovvero:  $i$  linka  $k$  E  $j$  linka  $k$ ).

- **Esempio (dalla figura):** Consideriamo  $MM^T[4, 2]$  (incrocio tra nodo 4 e nodo 2). Il risultato è **2**.
  - Il nodo 4 punta verso: **2, 3, 5**.
  - Il nodo 2 punta verso: **3, 5**.
  - Hanno in comune i nodi **3** e **5** → Totale: 2 destinazioni comuni.
- **Proprietà:**
  - La matrice è sempre **simmetrica** ( $MM^T[i, j] = MM^T[j, i]$ ).
  - Sulla diagonale principale ( $MM^T[i, i]$ ) troviamo il grado di uscita (out-degree) del nodo  $i$ , cioè quanti link totali partono da quel nodo.

### 3.3.5 HITS - $M^T M$




Questa matrice rappresenta la **Co-citazione** (Co-citation). È il concetto duale rispetto al precedente: misura la similarità tra due nodi basandosi su "chi li linka" (chi punta a loro).

- **Definizione:** Il valore nella cella  $M^T M[i, j]$  conta quanti nodi esterni puntano SIA al nodo  $i$  CHE al nodo  $j$ .
- **La Logica Matematica:** Il valore aumenta di 1 quando esiste un nodo  $k$  (una fonte comune) tale che:

$$M[k, i] = 1 \quad \text{e} \quad M[k, j] = 1$$

(Ovvero:  $k$  linka  $i$  E  $k$  linka  $j$ ).


- **Esempio (dalla figura):** Consideriamo  $M^T M[3, 5]$  (incrocio tra nodo 3 e nodo 5). Il risultato è **2**.
  - Chi punta al nodo 3? I nodi **2** e **4**.
  - Chi punta al nodo 5? I nodi **2** e **4**.
  - I "cittadini" in comune sono il **2** e il **4** → Totale: 2 fonti comuni.
- **Proprietà:**
  - Anche questa matrice è sempre **simmetrica** ( $M^T M[i, j] = M^T M[j, i]$ ).
  - Sulla diagonale principale ( $M^T M[i, i]$ ) troviamo il **grado di ingresso** (in-degree) del nodo  $i$ , cioè quanti link totali arrivano a quel nodo.



### 3.4 PageRank / HITS - confronto

- **PageRank** (Google)
  - **PRO:** Robusto contro lo spam (è difficile farsi linkare da siti autorevoli), indice di qualità valido per l'intero Web.
  - **CONTRO:** Non è specifico per la query (è un valore statico calcolato "offline"), calcolo complesso su grafi immensi.
- **HITS** (Kleinberg)
  - **PRO:** Specifico per la query (viene calcolato sul sottografo dei risultati), distingue tra *Hubs* e *Authorities*.
  - **CONTRO:** Facilmente spamabile (basta creare falsi Hub), problemi di convergenza, costo computazionale alto.



## 4 Social Network Analysis - terminologia



- **Local bridge:** arco tra due nodi che sarebbero altrimenti "lontani", ha un **grado  $k$**  (NON IL GRADO DEL NODO) che rappresenta la distanza che ci sarebbe senza quell'arco (Tamara - Boris ha grado 3);
- **Global bridge:** arco che, se rimosso, disconetterebbe la rete (Trevor - Tom, Alex - Roger);
- **Triangle:** sottografo completo di 3 nodi (Trevor - George - Keith);
- **Weak tie:** arco che appartiene a qualche triangolo (Mike - Peter);

- **Strong tie**: arco che appartiene a molti triangoli (Trevor - George);
- **Geodensic** (tra due nodi): cammino più corto tra di loro, distanza = n° archi (geodensico tra Tom e Mike = Tom - Trevor - Mike);
- **Diametro** di una rete: geodensico più lungo della rete (Steve - Nigel: 6);
- **Grado** di un nodo: n° di archi (differenza in in-degree e out-degree su reti con direzioni);
- **Distribuzione di grado**: per ogni grado, il numero di nodi aventi quel grado;
- **Densità**: proporzione di archi che ha la rete (n° archi / n° massimo possibile nella rete);
- **Coefficiente di clustering** (C) di un nodo: n° archi con i suoi vicini / n° massimo possibile con i vicini ( $n(n-1)/2$ ) ( $C(Keith) = 1/(3*2/2) = 1/3$ ), il C della rete è pari alla media su tutti i nodi.

| Node | Name   | Degr | PR    | HITS  | Closeness | Betweenness |
|------|--------|------|-------|-------|-----------|-------------|
| 1    | Steve  | 1    | 0.036 | 0.026 | 0.29      | 0.00        |
| 2    | Trevor | 5    | 0.14  | 0.15  | 0.55      | 0.32        |
| 3    | Boris  | 2    | 0.057 | 0.074 | 0.41      | 0.030       |
| 4    | Roger  | 2    | 0.074 | 0.021 | 0.34      | 0.17        |
| 5    | Mike   | 6    | 0.16  | 0.16  | 0.60      | 0.63        |
| 6    | George | 4    | 0.11  | 0.14  | 0.52      | 0.15        |
| 7    | Keith  | 3    | 0.087 | 0.092 | 0.40      | 0.17        |
| 8    | Nigel  | 1    | 0.043 | 0.006 | 0.26      | 0.00        |
| 9    | Tamara | 3    | 0.081 | 0.11  | 0.40      | 0.038       |
| 10   | Alex   | 3    | 0.091 | 0.068 | 0.46      | 0.030       |
| 11   | Dan    | 1    | 0.035 | 0.044 | 0.39      | 0.00        |
| 12   | Tom    | 1    | 0.034 | 0.044 | 0.36      | 0.00        |
| 13   | Peter  | 2    | 0.060 | 0.064 | 0.43      | 0.00        |



## 5 Transitività


In una rete sociale si ha **transitività** quando "un amico di un mio amico è mio amico", ha come indici *coefficiente di clustering locale* (relativo a singolo punto) e *coefficiente di clustering globale* (relativo alla rete, media degli altri), questi sono correlati ma  $\neq$ .

### 5.1 Coefficiente di clustering locale

Misura la transitività a livello dei singoli nodi, controllando quanto i vicini di un nodo  $v_i$  sono a loro volta connessi.

$$C(v_i) = \frac{\text{Number of Pairs of Neighbors of } v_i \text{ That Are Connected}}{\text{Number of Pairs of Neighbors of } v_i}.$$

In un grafo indiretto il denominatore è  $\binom{d_i}{2} = d_i(d_i - 1)/2$ .





- Linee sottili: connessioni ai vicini;
- Linee tratteggiate: archi mancanti fra vicini;
- Linee spesse: vicini connessi (quando nessun vicino è connesso  $C = 0$ , quando tutti sono connessi  $C = 1$ ).


## 5.2 Coefficiente di clustering globale

Misura transittività in grafi indiretti in 3 modi equivalenti:

- **1. Conto i cammini di lunghezza 2 e controllo se esiste il terzo arco (ossia, il cammino è chiuso)**

$$C = \frac{|\text{Closed Paths of Length 2}|}{|\text{Paths of Length 2}|}$$

- **2. Oppure, conto i triangoli (e mi riconduco a 1.)**
  - Siccome ogni triangolo ha 6 cammini chiusi di lunghezza 2 (triangolo abc --> cammini ab, bc, ca, ac, cb, ba):
$$C = \frac{(\text{Number of Triangles}) \times 6}{|\text{Paths of Length 2}|}$$


- **3. Oppure, conto le triple**
- **Triple:** un insieme ordinato di tre nodi, connesso
  - da due archi (tripla aperta), o
  - da tre archi (tripla chiusa)



$v_i v_j v_k$  e  $v_j v_k v_i$  sono triple differenti

- Gli stessi elementi
- Nella prima manca l'arco  $e(v_k, v_i)$
- Nella seconda manca  $e(v_i, v_j)$

Un triangolo ha 3 triple


Quindi:

$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$

$v_i v_j v_k$  e  $v_k v_j v_i$  sono la stessa tripla

- "Di tutte le triple di nodi connessi, prendo quelle chiuse, ossia i triangoli \* 3"

## Esempio



$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$

$$= \frac{2 \times 3}{2 \times 3 + \underbrace{2}_{v_2 v_1 v_4, v_2 v_3 v_4}} = 0.75.$$

## 6 Reciprocità

”Se tu mi diventi amico, anche io divento amico tuo”, se nodo  $v$  è connesso a nodo  $u$ ,  $u$  connettendosi a  $v$  manifesta reciprocità.


### 6.1 Calcolo

Conto numero di **coppie reciproche** nel grafo:

- Uso matrice di adiacenza  $A$ ;
- La sommatoria aggiunge 1 per ogni coppia reciproca ( $A_{i,j} = A_{j,i} = 1$ );
- Divido per il numero massimo possibile di coppie reciproche dati gli archi in  $E$ :  $|E|/2$ .

$$R = \frac{\sum_{i,j,i < j} A_{i,j} A_{j,i}}{|E|/2} = \frac{2}{|E|} \sum_{i,j,i < j} A_{i,j} A_{j,i} = \frac{2}{|E|} \times \frac{1}{2} \text{Tr}(A^2) = \frac{1}{|E| \text{Tr}(A^2) = \frac{1}{m} \text{Tr}(A^2)}$$

$$\text{Tr}(A) = A_{1,1} + A_{2,2} + \dots + A_{n,n} = \sum_{i=1}^n A_{i,i}$$



## 7 Bilanciamento


### 7.1 Bilanciamento Sociale

Modella la **coerenza** nelle relazioni amico / nemico, formalmente si ha bilanciamento quando:

- amico di amico è amico;


- amico di nemico è nemico;
- nemico di nemico è amico;
- nemico di amico è nemico.

Si modella con reti / grafi di '+' e '-' (signed graph), in cui archi positivi hanno valore +1 e archi negativi hanno valore -1. Un triangolo di nodi  $i, j, k$  è bilanciato se  $w_{ij}w_{jk}w_{ki} \geq 0$



## 7.2 Status sociale

Quando un individuo è prestigioso all'interno della società: se  $X$  ha status più alto di  $Y$  e  $Y$  più alto di  $Z$  allora  $X$  dovrebbe avere status più alto di  $Z$ ... questi **cicli** sono problematici.



## 8 Degree distributions reali

- Popolarità siti web:
  - Tanti siti sono visitati  $\sim 1000$  volte / mese (poco popolari);
  - Pochi siti sono visitati  $\sim 1M$  volte / giorno (molto popolari).
- Attività utenti:
  - Utenti di SM sono spesso attivi su pochi siti;
  - Alcuni (pochi) individui sono attivi su tanti siti.
- Prezzi dei prodotti:
  - Tantissimi prodotti a prezzo basso;
  - Pochi prodotti costosi.
- Amicizia:

- Tanti individui con pochi amici;
- Pochi individui con migliaia di amici.
- Distribuzioni dei gradi:
  - Tanti nodi con grado basso;
  - Pochi nodi con grado alto.

## 9 La Legge di Potenza (Power Law)

### 9.1 Che cos'è (In parole povere)

La **Power Law** è una relazione matematica che descrive fenomeni dove eventi "piccoli" sono comunissimi, mentre eventi "giganti" sono rari ma esistono.

- **Formula base:**  $f(k) \sim \frac{1}{k^\alpha}$
- **Significato:** La frequenza decresce molto velocemente man mano che cresce la grandezza ( $k$ ).
- **Esempio intuitivo:** Pensa ai follower su Instagram.
  - Miliardi di persone hanno pochi follower (la "coda" lunga del grafico).
  - Pochissimi influencer (la "testa") ne hanno milioni.

### 9.2 Il trucco del Grafico Log-Log

Se disegni una Power Law su un grafico normale, ottieni un'**iperbole** (una curva a forma di "L") difficile da analizzare. Per capire se una rete segue davvero questa legge, si usa la scala logaritmica su entrambi gli assi.

- **La Magia:** Se applichi il logaritmo alla formula  $f(k) = C/k^\alpha$ , trasformi le moltiplicazioni in addizioni:

$$\log(f(k)) = \log(C) - \alpha \log(k)$$

- **Risultato:** Questa è l'equazione di una **retta** ( $y = q - mx$ ).
- **Regola d'oro:** Se metti i dati su un grafico log-log e vedi una linea dritta che scende, allora sei davanti a una Power Law. La pendenza della retta è l'esponente  $\alpha$ .

### 9.3 Esempi Reali (Dalle Slide)

- **Telefonate** ( $1/k^2$ ): Pochissimi numeri ricevono milioni di chiamate, la maggioranza ne riceve poche.
- **Libri** ( $1/k^3$ ): Pochi best-seller vendono milioni di copie, la maggioranza dei libri vende quasi zero.
- **Citazioni Scientifiche** ( $1/k^3$ ): Pochi paper (tipo quelli di Einstein) sono citati da tutti, la maggior parte dei paper non li legge nessuno.
- **Social Network** ( $1/k^2$ ): La distribuzione dei follower (in-degree).

### 9.4 Nota: Differenza con Zipf

- **Power Law:** Sull'asse X metti il **valore** (es. "Quanti hanno 100 amici?").
- **Zipf:** Sull'asse X metti la **classifica/rank** (es. "Chi è il 1°, il 2°, il 3° più ricco?").

### 9.5 Test

Per capire se rete ha degree distribution power law:

1. Calcolare grado  $k$  di ogni nodo;
2. Calcolare  $p_k$ , la frazione di nodi con grado  $k$ ;
3. Disegnare grafico su scala log-log con  $k$  su asse X e  $p_k$  su asse Y;
4. Se è power law, linea retta.

NON è un approccio sistematico! Altre distribuzioni potrebbero avere lo stesso pattern.

## 9.6 Coefficiente di clustering


Nelle reti sociali reali connessioni sono **molto transitive** (amici di un utente sono amici tra di loro, dormando **triangoli** con alto clustering).

## 10 Diffusione informazioni

Un rumor si diffonde su una rete sociale, tutti gli utenti lo passano immediatamente a tutti gli amici. Quanti hop servono per raggiungere tutti i nodi?

### 10.1 Milgram

Partendo da 296 persone a caso (196 Nebraska / 100 Boston) gli viene chiesto di spedire una lettera via intermediari a un agente di borsa a Boston, potendo spedire solo a persone che conoscevano personalmente. Fra tutte le (64) lettere che arrivarono a destinazione il n° medio di passaggi fu circa 6.



### 10.2 Dodds

Esperimento di Milgram mandato per email, confermato tasso di risposta e sei gradi di separazione.

### 10.3 Erdos

Ricerca n° di link per connettere uno scienziato / studioso mediante co-authorship di articoli scientifici, lunghezza dei cammini fra matematici: **media** 4.65, **massima** 13.


### 10.4 Proprietà reti reali

- Solitamente hanno struttura core-periferia: core denso con tanti archi, nodi della periferia con archi verso il core ma non fra di loro,
- Paradosso degli amici: grado dei vicini di un nodo  $v$  è più alto del grado di  $v$ .

## 11 Modelli delle reti

**Reti reali** sono troppo grandi per valutarle univocamente, si usano quindi processi stocastici che generano / producono grafi per poterle valutare su una scala inferiore, rendendole più controllabili / analizzabili rispetto alla visione reale.

### 11.1 Reti regolari




- **Distanze** (Average path length / Diametro): spesso **grandi**;
- Coefficiente di **Clustering**: spesso **alto**;
- **Distribuzione dei gradi**: spesso con un **picco**, e spesso 0 altrove;
- **Connettività**: spesso **completamente connesse**;
- Le reti al mondo raramente sono così, nemmeno quelle artificiali se grandi / complesse.

## 11.2 Reti casuali

Grafo con  $n$  nodi e archi casuali, studiando tutte le proprietà dei grafi e, nei grafi **grandi**, il **limite termodinamico** per  $n \rightarrow \infty$ . Reti interessanti se suppongo che le amicizie possano scaturire in modo casuale.

### 11.2.1 Modello $G(n,m)$

Grafo con  **$n$  nodi** fissati e  **$m$  archi** piazzati a caso fra gli  $n$  nodi (solitamente indiretto, senza multi e auto archi).



Si studia il caso  $n \rightarrow \infty$ , valutando il **caso medio**: ciò che succede in media su un insieme di tanti grafi casuali (diametro di  $G(n,m)$  = diametro medio di tutti i grafi  $G(n,m)$ ). Comodo analiticamente per  $n$  molto grandi, si valutano proprietà **tipiche** (più interessanti) e non casi speciali / particolari (meno interessanti).

### 11.2.2 Modello $G(n,p)$

Introdotta per determinate misure altrimenti non facilmente calcolabili, invece di fissare il # di archi, si fissa la **probabilità  $p$**  (indipendente) **di esistenza archi**

- N° archi (medio):  $\langle m \rangle = \frac{n(n-1)}{2}p = \binom{n}{2}p$ ;
- Grado medio (tutte le estremità di archi / n° nodi):  $\langle k \rangle = \frac{2\langle m \rangle}{n} = (n-1)p$ , di solito denotato con  $c = (n-1)p$  e approssimato con  $c = np$ , per  $n$  grande cambia poco;
- **Coefficiente di Clustering**:  $C = \frac{c}{n-1}$ , valore molto basso ( $\rightarrow 0$  per  $n \rightarrow \infty$ );
- **Diametro** (geodensica più lunga):  $l = \frac{\ln n}{\ln c}$ , cresce con  $n$  e cala con crescere di  $c$  (sorprendentemente piccolo, **small world effect**)

Da degree distribution e  $C$  si evince che non è un modello adeguato a modellazione reti reali.



### 11.2.3 Differenza

Si assomigliano ma  $G(n, m) \neq G(n, p)$ , nel primo il n° di archi è **esattamente**  $m$ , nell'altro è **in media**  $m = p \times n(n-1)/2$ .

• Es.:

- Un grafo casuale in  $G(n, m) = G(3, 2)$  ha **sempre** 2 archi, è sempre connesso, non è mai completo, ...
- Un grafo casuale in  $G(n, p) = G(3, 2/3)$  ha **in media** 2 archi, non è sempre connesso, può essere completo, ...



Entrambi hanno distribuzione dei gradi di **Poisson** / **Bernoulli** (= per  $n = \infty$ ), non proprio simmetrica ma quasi.

### 11.2.4 $G(n, p)$ connesso?

In generale no (basta un singolo nodo isolato), ma dato che  $n \rightarrow \infty$ , che ci sia un singolo nodo (o piccole componenti) isolato o meno non importa, basta aggiungere / togliere un arco (nodo) e si sistema. Si valuta invece esistenza "giant component", connessa e che contiene quasi tutti i nodi, e se ne valuta la dimensione:

- $p = 0$ : grafo disconnesso - dimensione = 1 - costante a aumentare di  $n$ ;
- $p = 1$ : grafo completo - dimensione =  $n$  - aumenta con  $n$ .



|                             |     |       |             |         |
|-----------------------------|-----|-------|-------------|---------|
| Probability ( $p$ )         | 0.0 | 0.055 | 0.11        | 1.0     |
| Average Node Degree ( $c$ ) | 0.0 | 0.8   | $\approx 1$ | $n-1=9$ |
| Diameter                    | 0   | 2     | 6           | 1       |
| Giant Component Size        | 0   | 4     | 7           | 10      |
| Average Path Length         | 0.0 | 1.5   | 2.66        | 1.0     |

Con aumentare di  $p$  aumenterà la probabilità di avere una GC?

Siano un grafo casuale con grado medio  $c$ , un insieme di nodi connesso  $S$  e  $S' = V - S$  l'insieme complementare (assumiamo  $|S| \ll |S'|$ ). Per ogni nodo  $v \in S$  con un hop da  $v$  visitiamo  $c$  nodi (con un hop da un qualsiasi nodo di  $S$  visito  $|S|c$  nodi). Se  $S$  è piccolo, da  $S \rightarrow S'$  con un hop l'insieme dei nodi connessi diventa più grande di un fattore di  $c$ .

Se è la componente connessa più grande, la sua grandezza aumenta sempre e dopo  $n$  hop:  $c^n \geq 1$ , se invece  $c < 1$  il numero di nodi visitati muore.

### 11.2.5 Recap

Riguardo a reti reali il modello casuale:

- Modella **bene** lunghezza media dei cammini (bassa, small world);
- **Sottostima** drasticamente coefficiente di clustering;
- Non hanno distribuzione Power-law, ma **Poisson**.

Utile per spiegare alcuni fenomeni (small world) ma non tutti.

## 11.3 Reti small-world

Distanza piccola fra nodi, diametro basso e coefficiente di clustering alto.

### 11.3.1 Procedura

1. Parto da rete regolare;
2. Considero ogni singolo arco;
3. Con probabilità  $p$  lo ricollego casualmente (con  $p=0$  ho rete regolare, con  $p=1$  ho rete casuale).

### 11.3.2 Reti che ci interessano

Dati  $n$  nodi e  $c$  n° (medio) di archi per vertice ( $\frac{nc}{2}$  archi totali) avremo  $n \geq c \geq \log(n) \geq 1$ :

- Con  $n \geq 1$  reti grandi con  $n$  grande;
- Con  $n \geq c$  reti sparse;
- Con  $c \geq \log(n) \geq 1$  *non così sparse* da rischiare di diventare sconnesse.

Si valutano 2 misure:

- **L**: lunghezza media del cammino (numero di archi) minimo fra 2 nodi della rete. Misura per quanti amici devo passare per raggiungere una persona (globale);
- **C** coefficiente di Clustering: dato un vertice  $v$  considero i suoi  $k_v$  vicini e controllo quanti archi trovo fra i vicini (al massimo  $k_v(k_v-1)/2$ ). Sia  $C_v = \frac{\text{narchi}}{k_v(k_v-1)/2}$  la frazione degli archi effettivamente esistente, quindi **C** = media di  $C_v$  su tutti i vertici della rete. Misura quanto gli amici di una persona sono amici fra di loro (locale).

Casi limite

- $p=0$  (regolare):
  - $L(0)$ :  $\frac{n}{2c} \gg 1$  distanze grandi;
  - $C(0)$ :  $\frac{3}{4}$  "criccoso".
- $p=1$  (random):
  - $L(1)$ :  $\frac{\log(n)}{\log(c)}$  distanze basse (small world);
  - $C(1)$ :  $\frac{c}{n} \ll 1$  poco "criccoso".

### 11.3.3 Distribuzione dei gradi

Distribuzione strana con picco e soglia (cutoff) inferiore  $p_k = e^{-cp} \frac{(cp)^{k-c}}{(k-c)!}$ .

### 11.3.4 Recap

Reti small-world:

- Spiegano effetto small world (non spiegato da reti regolari, "ereditato" da  $G(n,p)$ );
- Spiega coefficiente di clustering alto (non spiegato da  $G(n,p)$ , "ereditato" da reti regolari);
- Non spiega distribuzione dei gradi che si trova "in natura" (**no power-law**, no coda lunga, no hub).

## 11.4 Reti scale free

Studio delle distribuzioni di:

- **Outdegree**:  $P_{out}(k)$  probabilità che una pagina abbia  $k$  outlink;
- **Indegree**:  $P_{in}(k)$  probabilità che una pagina abbia  $k$  inlink (più interessante).

Sono entrambe **power-law**, non poisson.


### 11.4.1 Diametro

Distanza **media** fra nodi (lunghezza media del cammino minimo fra 2 nodi della rete), sperimentalmente  $\langle d \rangle = 0.35 + 2.06 \times \log(N)$  (anche aumentando molto n° nodi, diametro rimane basso  $\rightarrow$  **power law** e **small-world**).

## 11.5 Reti con attaccamento preferenziale

*Nuovo modello stocastico*, ad ogni passo aggiungo nuovo nodo e un arco che lo collega ad un nodo preesistente scelto a caso ma con probabilità non uniforme (proporzionale al **grado** del nodo esistente  $P(v_i) = \frac{d_i}{\sum_j d_j}$ ).

Come per gradi casuali si possono simulare reti del mondo reale generando un grafo con attaccamento preferenziale (lavorando su grafi indiretti) con un grado atteso  $m$  (invece di attaccare nuovo nodo a un unico altro nodo, ne scelgo  $m$ ).



### 11.5.1 Sul modello scale-free

**Lunghezze medie** basse, ma **clustering** basso. Le scale-free hanno distribuzioni **power law**, in log-log è una retta  $f(k) = \frac{C}{k^\alpha}$ , ha **code lunghe** con molti nodi con  $k$  basso, ci sono però pochi nodi con grado molto alto (**hub**).

## 11.6 Sunto

|                  | Lunghezza media cammini minimi (geodesiche) | C  | Degree distribution |
|------------------|---------------------------------------------|----|---------------------|
| 1. Regolari      | KO                                          | OK | KO                  |
| 2. Random Graphs | OK                                          | KO | KO                  |
| 3. WSSW          | OK                                          | OK | KO                  |
| 4. Scale free    | OK                                          | KO | OK                  |

Insomma nessun modello "funziona", ossia crea reti uguali a quelle del mondo reale...

## 11.7 Attaccamento preferenziale non lineare

$$P(v_i) = \frac{d_i^\alpha}{\sum_j d_j^\alpha}$$

- Se  $\alpha = 1$  è l'attaccamento preferenziale originale;
- Se  $\alpha < 1$  vantaggio di avere grado alto è inferiore, no long tail, no hub;
- Se  $\alpha > 1$  vantaggio di avere grado alto è superiore, winner-takes-all (un singolo nodo connesso a tutti).

## 11.8 Attrattività

$$P(v_i) = \frac{A + d_i}{\sum_j (A + d_j)}$$

- Se  $A = 0$  è l'attaccamento preferenziale originale;
- Altrimenti evita che nodi con grado 0 non ricevano link, si ottiene sempre una **power law** con pendenza che varia con  $A$ .

## 11.9 Fitness

$$P(v_i) = \frac{\eta_i d_i}{\sum_j (\eta_j d_j)}$$


$\eta_i$  rappresenta la fitness del nodo  $i$ , se  $\forall i, j (\eta_i = \eta_j)$  è l'attaccamento preferenziale originale, se i valori di fitness sono in un intervallo limitato: rete con + hub, si elimina dipendenza dal rich-get-richer dei nodi più vecchi, anche i nodi giovani con alta fitness competono. Si ottiene **sempre** una **power law**.

## 11.10 Random Walk

Parte da una piccola rete qualsiasi, ad ogni passo si aggiunge un nuovo nodo  $i$ , con  $m > 1$  archi attaccati di cui il primo è collegato con un nodo vecchio  $j$  scelto a caso (probabilità **uniforme**), ogni arco degli  $m - 1$  restanti viene collegato:

- Con probabilità  $p$  a un **vicino** di  $j$  scelto a caso;
- Con probabilità  $1 - p$  a un nodo vecchio qualsiasi scelto a caso;

Con  $p$  probabilità che si formi un triangolo.




### 11.10.1 FUNZIONA

- **Degree distribution power law**: quando scelgo un vicino ( $p$ ) tendo a scegliere nodi con grado alto (in quanto attaccamento preferenziale), si formano hub;
- **Cammini brevi**;
- **Clustering alto**: presenza di triangoli.

## 12 Comunità

Comunità (**community**) di utenti = gruppo fornito / gestito dalla piattaforma, modellato mediante gruppo di nodi "connessi fra loro e non connessi con gli altri" (homophilia: tendenza ad associarsi con persone simili a loro).



### 12.1 Definizione "ideale"

Sottografo connesso e senza archi con altri nodi: dato un grafo  $G$ , una comunità  $C$  è un sottografo di  $G$  tale che  $C$  è connesso (o addirittura completo) e  $\forall$  nodo  $v \notin C$ ,  $v$  è sconnesso da  $C$  ( $\nexists$  cammino fra  $v$  e nodi di  $C$ ).


### 12.2 Definizione "realistica"

Sottografo connesso e senza archi con altri nodi: dato un grafo  $G$ , una comunità  $C$  è un sottografo di  $G$  tale che  $C$  è connesso e  $\forall$  nodo  $v \notin C$ ,  $v$  è **poco connesso** a  $C$ .

## 12.3 Algoritmi per riconoscere comunità

### 12.3.1 Edge betweenness centrality


Anche gli archi possono essere più o meno centrali (si applica centralità di betweenness sugli archi), quantifica quanti shortest path passano per un arco anziché per un vertice (*quanto un arco è importante nel connettere i nodi*). Gli archi con alta betweenness centrality sono i **weak ties**.



Idea: rimuovere ricorsivamente legami deboli rimuovendo gli archi con alta betweenness centrality (**disconnettendo la rete**), rendendo le comunità componenti connesse.

### 12.3.2 Algoritmo di Givran-Newman

1. Calcolare edge betweenness per tutti gli archi del grafo;
2. Rimuovere arco con betweenness più alta;
3. Ricalcolare edge betweenness per tutti gli archi del grafo (basta per quelli la cui betweenness è cambiata);
4. Ripetere fino alla rimozione di tutti gli archi.



## 12.4 Gerarchia

Viene prodotto un albero (*dendrogramma*) del quale ogni livello corrisponde ad un valore di edge betweenness (decrescente da radice a foglie - sopracomunità → comunità → sottocomunità).

## 13 Diffusione informazioni

Processo per cui un'informazione (video, meme), o anche **comportamento** (adozione di una tecnologia) si diffonde e raggiunge altri individui. È un fenomeno **dinamico** sulle reti, dove i player principali sono:

- **Mittente (sender)**: uno o più mittenti che iniziano il processo;
- **Destinatari (receivers)**: uno o più destinatari che ricevono l'informazione (insieme solitamente molto più grande di quello dei sender);
- **Mezzo (medium)**: mezzo tramite il quale la diffusione avviene.
- **Intervention**: mezzo di intervento / **intromissione** fino al blocco completo della diffusione (nel caso di fake news), al contrario possono anche "far ripartire" / velocizzare la condivisione (messaggi pubblicitari).


## 13.1 Herd behavior

Network **completamente osservabile** e ho informazioni **globali**, questo comportamento descrive quando un **gruppo di individui** esegue azioni **altamente correlate** senza piani (tendenza naturale a imitare). Dev'esserci una **connessione** fra individui e un **metodo di condivisione** informazioni oppure un modo di osservare individui.

### 13.1.1 Grafo completo

Rappresentazione di reti herd dove nodi possono osservare almeno maggior parte degli altri nodi e possono osservare informazioni pubbliche.

### 13.1.2 Esempio



Due possibili configurazioni (B/B/R - majority blue o R/R/B - majority red), ogni studente cerca di stimare la **conditional probability** che sia maj. blue / red data una sua estrazione e la lista delle votazioni degli altri.

- $P[\text{majority-blue}] = P[\text{majority-red}] = 1/2$ ;
- $P[\text{blue} \mid \text{majority-blue}] = P[\text{red} \mid \text{majority-red}] = 2/3$ ;
- $P[\text{blue} \mid \text{majority-red}] = P[\text{red} \mid \text{majority-blue}] = 1/3$ .

**Bayes's rule:**  $p(C|I) = \frac{p(C) \times p(I|C)}{p(I)}$ , per cui  $P[\text{majority-blue} \mid \text{blue}] = P[\text{blue} \mid \text{majority-blue}] \times P[\text{majority-blue}] / P[\text{blue}]$ .

Sapendo che  $P[\text{blue}] = P[\text{blue} \mid \text{majority-blue}] \times P[\text{majority-blue}] + P[\text{blue} \mid \text{majority-red}] \times P[\text{majority-red}] = 2/3 \times 1/2 + 1/3 \times 1/2 = 1/2$  possiamo vedere  **$P[\text{majority-blue} \mid \text{blue}] = (2/3 \times 1/2) / (1/2) = 2/3 > 1/2$** . Se le osservazioni sono *blue, blue*, anche se il terzo studente osserva *red* sarà portato a votare *blue*.

### 13.1.3 Intervention

Quando una nuova **informazione privata** viene rilasciata la herd rivaluta le scelte, il che potrebbe portare a risultati completamente diversi.

## 13.2 Information cascade

Utenti condividono contenuti di altri utenti presenti nella rete, quindi le info si propagano tra vicini:

- individui devono essere **connessi a una rete**;
- individui **osservano** solo **decisioni** dei **vicini immediati**.

La rete è un **grafo diretto** (nodi sono attori e archi appresentano canali di comunicazione tra loro), un nodo può solo influenzare nodi **a cui è connesso**. Le decisioni sono binarie (Y/N) ed i nodi possono essere **attivi** (adottano comportamento / decisione del precedente) o **inattivi** (non hanno ancora adottato). Un nodo attivo può **attivare** i nodi vicini (si può passare solo da non attivo ad attivo, non viceversa).

### 13.2.1 Independent Cascade Model (ICM)

Modello cascade **sender-centric** dove **ogni** nodo ha la possibilità di attivare i suoi vicini subito dopo la sua attivazione (nodi che attivano sono sender e nodi che vengono attivati sono receivers).

- Nodo attivato all'istante  $t$ ;
- All'istante  $t + 1$  può attivare i suoi vicini;
- Assumiamo che  $v$  sia attivato all'istante  $t$ :

- Per ogni vicino  $w$  di  $v$  c'è probabilità  $p_{vw}$  che quel nodo venga attivato all'istante  $t + 1$ ;
- $p_{vw}$  può differire per diverse coppie di nodi.
- Ogni nodo  $v$  attivato all'istante  $t$  ha una **singola** possibilità di attivare i suoi vicini (può solo accadere a  $t + 1$ ).

### 13.2.2 Massimizzare spread di cascade

Trovare il **più piccolo** set di nodi di una rete tale il loro spread aggregato nella rete sia massimizzato: dato un **budget**  $k$  si deve trovare un **initial set**  $S, |S| = k$  che massimizzi  $f(S)$ . Sappiamo che le activations sono **random**: si generano i numeri random per tutti gli archi all'inizio del processo.  $f(S)$  è:

- **non negativa**;
- **monotona** -  $f(S + v) \geq f(S)$ ;
- **submodulare** - sia  $N$  un set finito, un set è submodulare se e solo se:
  - $f : 2^N \rightarrow R$ ;
  - $\forall S \subset T \subset N, \forall v \in N \setminus T$ ;
  - $f(S + v) - f(S) \geq f(T + v) - f(T)$ ;

Ovvero sottoinsiemi più piccoli ci guadagnano di più.

### 13.2.3 Problemi


Trovare un element set  $S$  per il quale  $f(S)$  è massimizzato è **NP-hard**. Posso usare un **greedy algorithm** che partendo da un empty set  $S$  per  $k$  iterazioni ad ogni passo aggiunge as  $S$  un nodo  $v$  che massimizza  $f(S \cup v) - f(S)$

## 13.3 Epidemics

Assumono **rete implicita** e delle **connessioni sconosciute** tra gli user, vengono utilizzati quando si è interessati a **pattern globali** (trend, pattern d'infezione), si possono analizzare con due metodi:

- **Fully-mixed**: valuta le proporzioni d'infezione / recover, evitando di considerare le informazioni di rete;
- **Contact network**: controlla come gli host comunicano tra loro, valutando come le epidemie avvengono in una rete (*contact network* = grafo in cui nodi rappresentano host e archi rappresentano interazioni tra questi host).

### 13.3.1 SI model



Gli individui **suscettibili (S)** possono venire infetti, se **infetti (I)** non possono essere curati e possono infettare altri utenti. Sia  $N$  la dimensione della **crowd**, costante:

- $S(t)$ : numero di individui suscettibili all'istante  $t$  -  $s(t) = \frac{S(t)}{N}$ ;
- $I(t)$ : numero di individui infetti all'istante  $t$  -  $\frac{I(t)}{N}$ ;
- $\beta$ : probabilità di contatto - per  $\beta = 1$  tutti entrano in contatto con tutti, per  $\beta = 0$  nessuno entra in contatto con nessuno.

Dimensione della crowd è  $N = S(t) + I(t)$ , per ogni istante un individuo infetto può **incontrare**  $\beta N$  individui e può **infettarne**  $\beta S$ , per gli altri  $\beta I$  non succede niente,  $\beta IS$  saranno infettati al prossimo istante.


- Ad ogni time step la variazione del numero di individui in S e I è di  $\beta IS$ :  
 – (S e I sarebbero  $S(t)$  e  $I(t)$ )

$$\frac{dS}{dt} = -\beta IS, \quad \frac{dI}{dt} = \beta IS.$$


- Si risolve analiticamente:

$$(S + I = N) \Rightarrow \frac{dI}{dt} = \beta I(N - I) \Rightarrow I(t) = \frac{NI_0 e^{\beta t N}}{N + I_0(e^{\beta t N} - 1)}$$

$I_0$  is the number of individuals infected at time 0  
 This is the logistic growth curve



## 13.4 SIR model



Introduce (in aggiunta a **I** e **S**) lo stato di **recovery R**: determinati individui possono "curarsi" (o essere rimossi / morire), una volta arrivato a stato **R** non può più tornare **I**.

$$S + I + R = N$$

$\gamma$  invece definisce la probabilità di recover di un individuo infetto ad un dato istante.


- S decrescono monotonamente;
- R crescono monotonamente;
- I crescono inizialmente e poi decrescono man mano che individui guariscono / muoiono e vanno a 0 per  $t \rightarrow \infty$ ;
- S **non vanno** a 0: ne resta una generalmente piccola frazione (quando non ci sono più I non c'è nessuno per contagiare i pochi S che si salvano).

$R_0$  **Basic reproduction number** (calcolato con  $\beta/\gamma$ ) numero medio di individui che un individuo infetta prima di guarire / morire.  $R_0 = 1$  indica la **soglia epidemica**, quindi c'è epidemia se  $R_0 \geq 1$ , se  $R_0 \leq 1$  non c'è epidemia perché gli infetti guariscono più in fretta di quanto gli S si ammalino.

### 13.4.1 Transizione epidemica

Transizione di fase fra regime epidemia e regime non-epidemia: brusca, improvvisa.

## 13.5 SIS model




Uguale a modello SI, ma soggetti infetti possono tornare sani e venire ri-infettati di nuovo.

$$I(\beta N - \gamma) - \beta I^2$$

- Se  $\beta N \leq \gamma$ : gli infetti diminuiranno esponenzialmente;
- Se  $\beta N > \gamma$ : crescita logistica simile al modello SI.

## 13.6 SIRS model




Individui che sono in stato R perdono l'immunità dopo un certo periodo di tempo e diventano suscettibili di nuovo

## 13.7 Contagio sociale

Se un individuo vede un comportamento in un altro individuo, lo **imita** (adotta lo stesso comportamento), rappresentabile come **modifica di SIR**:

- Suscettibile - **Ignorant (I)**: individuo che non ha ancora ricevuto l'info;
- Infetto - **Spreader (S)**: individuo che ha ricevuto l'info e la diffonde;
- Recovered/Removed - **Stifler (R)**: ha ricevuto l'info ma non la diffonde (più).

A differenza di SIR (patologia **negativa**), il contagio sociale (ISR) è un atto intenzionale, vantaggioso ed attivo.



- Passaggio  $I \rightarrow R$  in SIR è spontaneo e dipende solo da n° di I e dal parametro  $\gamma$ ;
- Passaggio  $S \rightarrow R$  in "ISR" non è spontaneo e dipende da n° di S, parametro  $\alpha$  e dal n° di R.

### 13.7.1 Cosa succede

- Allo **stato stazionario** ( $t \rightarrow \infty$ ) non ci saranno più **spreaders** -  $s_\infty = \lim_{t \rightarrow \infty} s(t) = 0$ ;
- Gli ignoranti saranno tanti di meno quanti di più saranno gli stiflers -  $i_\infty = e^{-(1+\lambda/\alpha)r_\infty}$ ;
- Gli stiflers saranno tutti gli altri,  $i_\infty + r_\infty = 1$ ,  $r_\infty = 1 - i_\infty$  -  $r_\infty = 1 - e^{-(1+\lambda/\alpha)r_\infty}$ .

### 13.7.2 Condizione

Per avere contagio sociale la condizione diventa  $1 + \frac{\lambda}{\alpha}$ . **Non c'è più soglia epidemica**, qualsiasi siano i valori dei parametri c'è **sempre** epidemia sociale.

## 14 Epidemie su reti

Supponiamo di avere una **rete omogenea**, tutti i nodi hanno un grado simile.