

Riassunto Social Computing

Trentin Tommaso

January 25, 2026

Contents

1 Social media

Tecnologie che facilitano **creazione** e **condivisione** di informazioni, idee, interessi e altre forme di espressione mediante **community visuali** e **network**.


- Applicazioni internet-based **Web 2.0**;
- Sviluppate avendo come scopo principale la gestione di **User-generated content**;
- Utenti creano **profili** e identità service-specific che vengono mantenuti dalla social media organization;
- Facilitano lo sviluppo di **social network online** connettendo il profilo di un utente con quello di altri individui / organizzazioni.

1.1 Classificazione

2 dimensioni principali: **Social presence** / **Media richness** (quanto sembra di essere "lì") e **Self presentation** / **Self disclosure** (quanto si rivela di sé).

		Social presence/ Media richness		
		Low	Medium	High
Self-presentation/ Self-disclosure	High	Blogs	Social networking sites (e.g., Facebook)	Virtual social worlds (e.g., Second Life)
	Low	Collaborative projects (e.g., Wikipedia)	Content communities (e.g., YouTube)	Virtual game worlds (e.g., World of Warcraft)

Visione articolata:



2 Grafi e Reti

2.1 Nodi vs. Attori (dipende dal contesto)

$$V = v_1, v_2, \dots, v_n$$

- Grafo del Web:
 - Nodi = pagine/siti web;
 - Archi = link ipertestuali.
- Grafo sociale di amicizie:
 - Nodi = persone;
 - Archi = amicizie, conoscenze...

Grandezza del grafo (size): $|V| = n$

2.2 Archi

$$E = e_1, e_2, \dots, e_m$$

Gli archi (edges) connettono nodi (ties / relationships). In un settng sociale:

- Nodi = entità sociali (persone);
- Archi = relazioni fra persone;

Grandezza dell'insieme degli archi: $|E| = m$

2.3 Grafi

Un grafo G si può rappresentare come coppia dell'insieme di nodi V e archi E :

$$G(V, E)$$

2.3.1 Proprietà

- Archi possono avere direzioni ($e(v_1, v_2) \neq e(v_2, v_1)$);
- **Grafo pesato:** ad ogni arco è associato un peso ($G(V, E, W)$);
- Grafo $G'(V', E')$ è **sottografo** di $G(V, E)$ se $(V' \subseteq V)$ e $(E' \subseteq (V' \times V') \cap E)$;
- **Vicinato** di un nodo: tutti i nodi ad esso collegati mediante archi (incoming / outgoing neighbors);
- **Cammino:** sequenza di archi t.c. ogni arco è incidente allo stesso nodo del successivo;
- **Connessione:**
 - Un **nodo** v_i è connesso al nodo v_j se esiste cammino da v_i a v_j (e viceversa);
 - Un **grafo** è connesso se esiste un cammino fra ogni coppia di nodi (*fortemente* se il cammino è diretto, *debolmente* altrimenti)
- **Componenti:**
 - **Componente in un grafo indiretto:** è un sottografo massimale connesso.
 - * Esiste un cammino indiretto fra ogni coppia di nodi nella componente.
 - * "Massimale" significa che se si aggiungono altri nodi del grafo originale, il sottografo non è più connesso.
 - **Componente Fortemente Connessa** (Strongly Connected Component, **SCC**): In un grafo diretto, si ha una SCC quando per ogni coppia di nodi $u, v \in SCC$ esiste un cammino *diretto* da u a v e uno da v a u .
 - **Componente Debolmente Connessa** (Weakly Connected Component, **WCC**): In un grafo diretto, si ha una WCC quando per ogni coppia di nodi $u, v \in WCC$ esiste un cammino *indiretto* da u a v .
 - Un grafo può avere diverse componenti (ne ha solo 1 se l'intero grafo è connesso).
 - **Giant Connected Component:** è la componente più grande del grafo e contiene "quasi tutto" il grafo (la maggior parte dei nodi).

2.4 Gradi

$\pi(d) = d_1, d_2, \dots, d_n$ **Grado di un nodo i d_i :** numero di archi collegati a quel nodo (entranti = **in-degree** d_i^{in} , uscenti = **out-degree** d_i^{out}).

Degree distribution: per ogni nodo, quanti nodi hanno quel grado:

$$p_{grado} = \frac{\text{numNodi}_{grado}}{\text{numNodi}}, \sum_{d=0}^{\infty} p_{grado} = 1$$

Teorema: sommatoria dei gradi di un grafo indiretto è 2 volte il numero degli archi

$$\sum_i d_i = 2|E|$$


Corollari:

1. numero di nodi con grado dispari è pari;
2. in ogni grafo diretto la sommatoria degli in-degree è uguale alla somma degli out-degree

$$\sum_i d_i^{out} = \sum_j d_j^{in}$$

Grafico della degree distribution

- L'asse delle x rappresenta il grado
- L'asse delle y rappresenta la frazione (relativa) o il numero (assoluta) dei nodi che hanno quel grado
- Idem per in- e out-degree
- Spesso su scala log-log
- Sui social media, di solito decrescente:
 - Tanti utenti/profili con poche connessioni
 - Alcuni utenti con un numero di amici molto alto
 - (Spesso Power-law degree distribution, non qui)



2.5 Densità


Quanti archi ci sono rispetto a tutti gli archi possibili:

- Grafi **indiretti** - $D = \frac{2|E|}{|V|(|V|-1)}$
- Grafi **diretti** - $D = \frac{|E|}{|V|(|V|-1)}$

2.6 Rappresentazioni


2.6.1 Lista degli archi

- Ogni elemento della lista è un arco da un nodo u a un nodo v (u, v);
- Ok anche per grafi diretti;
- Non ok per nodi isolati: non vengono rappresentati.



2.6.2 Lista di adiacenza

- Per ogni nodo, lista di tutti i nodi a cui è connesso;
- Solitamente ordinata;
- Ok anche per grafi diretti.




Node	Connected To
v_1	v_2
v_2	v_1, v_3, v_4
v_3	v_2, v_4
v_4	v_2, v_3, v_5, v_6
v_5	v_4
v_6	v_4

2.6.3 Matrice di adiacenza

- Quadrata (1 se c'è un arco fra v_i e v_j , 0 altrimenti);

- Simmetrica per grafi indiretti;
- Ok per grafi diretti (generalmente non simmetrica);
- Auto-archi (self-link) sulla diagonale;
- Per reti sociali le matrici di adiacenza sono sparse (quasi tutti 0);
- Ok per grafi pesati ()
- Quadrata (w_{ij} se c'è un arco fra v_i e v_j , 0 altrimenti);



2.7 Reti

Una rete (**network**) è un grafo (solitamente grande) con nodi e archi che esistono nel mondo reale, solitamente per rappresentare problemi su una rete si usano grafi e risultati della teoria dei grafi.

2.7.1 Reti sociali

Reti i cui elementi hanno una struttura sociale:

- Insieme di **attori** = individui / organizzazioni;
- Insieme di **legami** = connessioni fra attori.

Esempi: rete di familiari / amici / colleghi.

2.7.2 Analisi delle reti sociali (Social Network Analysis - SNA)

Settore interdisciplinare (scienze sociali + statistica + teoria dei grafi + reti complesse + informatica) che studia queste reti.

3 Reti e Misure

3.1 Centralità

Misura che indica quanto un nodo è centrale, basandosi su definizioni / assunzioni.


3.1.1 Centralità di grado

Più è alto il grado di un nodo, più è centrale.

$$C_d(v_i) = d_i$$

Es.:

- Degree centrality di v_1 è $d_1=8$
- Per gli altri $d_j = 1, j \neq 1$



In grafi diretti si possono usare in-degree, out-degree o combinazione dei due:


- $C_d(v_i) = d_i^{in}$ (prestige);
- $C_d(v_i) = d_i^{out}$ (gregariousness);
- $C_d(v_i) = d_i^{in} + d_i^{out}$.

In pratica in-degree è il più usato / interessante.

3.1.2 Centralità di grado normalizzata

Utile per confrontare grafi differenti:

- Normalizzazione per grado massimo possibile - $C_d^{norm}(v_i) = \frac{d_i}{n-1}$;
- Normalizzazione per grado massimo effettivo - $C_d^{max}(v_i) = \frac{d_i}{\max_j d_j}$;
- Normalizzazione per somma dei gradi - $C_d^{sum}(v_i) = \frac{d_i}{\sum_j d_j} = \frac{d_i}{2|E|} = \frac{d_i}{2m}$.




3.1.3 Betweenness centrality

Misura quanto un nodo è importante nel connettere altri nodi tramite cammini (si guardano solo shortest paths).

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}}$$

- $\sigma_{st}(v_i)$: numero di shortest paths da s a t che passano per v_i ;
- σ_{st} : numero di shortest paths da s a t .



3.1.4 Betweenness centrality normalizzata

Nel caso migliore il nodo v_i è su tutti gli shortest paths da s a t , quindi $\frac{\sigma_{st}(v_i)}{\sigma_{st}} = 1, \forall s, t$

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}} = \sum_{s \neq t \neq v_i} 1 = 2 \binom{n-1}{2} = (n-1)(n-2)$$

Quindi il valore massimo è $(n-1)(n-2)$, per normalizzarlo: $C_b^{norm}(v_i) = \frac{C_b(v_i)}{2 \binom{n-1}{2}}$


3.1.5 Centralità di vicinanza (Closeness centrality)

$$C_c(v_i) = \frac{1}{\bar{l}_{v_i}}$$

I nodi influenti / centrali possono raggiungere velocemente gli altri nodi (considero gli shortest path verso tutti gli altri nodi).

$$\bar{l}_{v_i} = \frac{1}{n-1} \sum_{v_j \neq v_i} l_{i,j}$$

- $l_{i,j}$: lunghezza cammino più breve da v_i a v_j ;
- $\bar{l}_{v_i}$: lunghezza media dei cammini più brevi più brevi da v_i .




3.1.6 Confronti

	Low Degree	Low Closeness	Low Betweenness
High Degree		Node is embedded in a community that is far from the rest of the network	Ego's connections are redundant - communication bypasses the node
High Closeness	Key node connected to important/active alters		Probably multiple paths in the network, ego is near many people, but so are many others
High Betweenness	Ego's few ties are crucial for network flow	Very rare! Ego monopolizes the ties from a small number of people to many others	

3.2 PageRank

Archì che vengono da **nodì importanti** (più centrali) dovrebbero **aumentare di più la centralità** rispetto a archì che vengono da nodi meno centrali.



Notazione:


- $r(v)$ PageRank della pagina v ;
- $I(v)$ set di pagine che citano v ;

- $O(v)$ set di pagine citate da v .

Ogni pagina u ha il suo valore PageRank $r(u)$, la pagina v riceve dalla pagina u una porzione del suo PageRank uguale alla porzione ricevuta da tutte le altre pagine citate da u : $\frac{r(u)}{|O(u)|}$

3.2.1 PageRank - vettori e matrici

Si possono collezionare tutti i valori PageRank di tutte le pagine u_i in un vettore $r = [r(u_0), r(u_1), \dots, r(u_n)]$




Si costruiscono i vettori r **iterativamente, tutti assieme**. Per andare da r_0 iniziale a r_1 mediante una matrice P tale che $r_{i+1} = r_i \times P$.

3.2.2 Markov chain

Dato un grafo / matrice di adiacenza con n stati si ha una matrice $n \times n$ P con le probabilità di transizione. A ciascun istante di tempo la catena di Markov è in uno degli n stati.

$\forall$ stato corrente $i \in [1..n]$, la catena di Markov (P) dice la probabilità che il prossimo stato sia j , $\forall j \in [1..n]$.



Si può rappresentare la posizione corrente in uno stato i con un vettore $x = (x_1, \dots, x_n)$ dove tutti i componenti hanno valore 0 tranne l' i -esimo che ha valore 1 e rappresenta la posizione nello stato i .

Il vettore di probabilità nel prossimo step si può trovare guardando la matrice P alla i -esima riga, in modo da controllare le probabilità per procedere al prossimo stato partendo da i .


3.2.3 Markov chain - autovettore

Quindi, per ogni step $x_{i+1} = x_i \times P$ ma stiamo cercando una distribuzione stabile $x_{i+1} = x_i$, cerchiamo quindi x tale che $x = x \times P$ (x autovettore di P).

Per ogni catena **ergodica (fortemente connessa e in cui in ogni step si può essere in ogni stato con probabilità > 0)** ogni stato ha un rate di visite a lungo termine per cui viene visitato proporzionalmente.

3.2.4 Teleporting

Nella pratica (Web) non sempre si hanno situazioni ergodiche, ma navigando si potrebbe "saltare" ad un'altra pagina random: "ciascuna pagina è collegata con qualsiasi altra pagina" (con basse probabilità).



3.2.5 PageRank - implementazione

Catena di Markov, ogni pagina ha una propria probabilità per cui, durante il percorso random tra le pagine, l'utente si trovi lì

Formula

- Power iteration
 - $\mathbf{r}_{i+1} = \mathbf{r}_i \cdot \mathbf{P}'$

$$\mathbf{r}_{i+1} = (1-d) \cdot \mathbf{r}_i \cdot \mathbf{P} + d \cdot \mathbf{r}_i \cdot \begin{pmatrix} 1/N & \dots & 1/N \\ \vdots & \ddots & \vdots \\ 1/N & \dots & 1/N \end{pmatrix}$$

- d : probability of teleporting (for ex., 0.1)
- N : # of nodes/pages
- (here
 - $\mathbf{P}$ is the adjacency matrix without teleporting,
 - $\mathbf{P}'$ is the adjacency matrix with teleporting)

1. Costruzione matrice P' (matrice di adiacenza P + teleporting (ergodic));
2. Inizio da vettore di probabilità r_0 ;
3. $r_{i+1} = r_i \times P$;
4. Se $|r_{i+1} - r_i| < \epsilon$ stoppa, altrimenti ripeti;
5. Il vettore r trovato ($r = r \times P'$, o $r \times P'$) è il PageRank di tutte le pagine, e l'autovettore di P' .

3.3 HITS


Idea: costruire 2 set di pagine collegati:


- **Hub pages (H)** contenenti (buoni) link ad altre pagine (yahoo, buoni bookmark,...);
- **Authority pages (A)** con persone / entità ben organizzate nel web (w3c, Knuth's homepage,...).

L'algoritmo lavora su un set ristretto di pagine Root Set (RS), che si espande con:

- $I(v)$ in-pages (tutte le pagine u tali che $\exists v \in RS, u \rightarrow v$);
- $O(v)$ out-pages (tutte le pagine u tali che $\exists v \in RS, v \rightarrow u$).

Si ottiene così il Base Set (BS) con buone pagine candidate Hub / Authority e su cui l'algoritmo poi lavora, selezionando H e A mediante un controllo su ogni pagina x in BS per i valori di **hubness** ($h(x)$) e **authority** ($a(x)$).





3.3.1 Procedimento - "Algoritmo"

1. Assegnazione valori iniziali di $h(x)$ e $a(x)$ a ogni pagina x del BS (inizialmente $h(x) = a(x) = 1$);
2. Aggiornamento iterativo, con la precedente formula, di $h(x)$ e $a(x)$;
3. Stop quando converge ($h(x)$ e $a(x)$ non variano più);
4. Alla fine si riconoscono pagine "top hub" e "top authority".

3.3.2 HITS - vettori e matrici

Formalizzazione in vettori / matrici come PageRank.

• Let us build 2 (column!) vectors, for $\mathbf{h}$ and $\mathbf{a}$:

• $\mathbf{h} =$


$\mathbf{h}(u_0)$	...	$\mathbf{h}(u_i)$	...	$\mathbf{h}(u_n)$
-------------------	-----	-------------------	-----	-------------------

• $\mathbf{a} =$

$\mathbf{a}(u_0)$	...	$\mathbf{a}(u_i)$	...	$\mathbf{a}(u_n)$
-------------------	-----	-------------------	-----	-------------------

$\mathbf{h}(x) = \sum_{x \rightarrow y} \mathbf{a}(y)$

Per calcolare h dell' i -esimo componente si sommano tutti i componenti corrispondenti alle out-pages di u_i e si sommano, moltiplicando quindi a per l' i -esima riga della matrice di adiacenza.



Quindi, moltiplicando l' i -esima riga di M per a si ottiene l' i -esimo componente di h , e moltiplicando tutta M per a si ottiene tutto h .

$$h = Ma$$

e, di conseguenza:

$$a = M^T h$$

3.3.3 HITS - autovettori

Se abbiamo


- $h = Ma$
- $a = M^T h$

per sostituzione otteniamo

- $h = Ma = MM^T h$
- $a = M^T h = M^T Ma$

h è quindi l'autovettore di MM^T e a è l'autovettore di $M^T M$.

3.3.4 HITS - MM^T



Questa matrice rappresenta l'**Accoppiamento Bibliografico** (Bibliographic Coupling). Ci dice quanto due nodi sono simili basandosi su "chi citano" (o chi linkano).


- **Definizione:** Il valore nella cella $MM^T[i, j]$ conta il numero di nodi che sono **co-linkati** da i e da j . In altre parole, conta quante destinazioni hanno in comune.
- **La Logica Matematica:** Il valore aumenta di 1 quando esiste un nodo k che funge da "ponte comune", tale che:

$$M[i, k] = 1 \quad \text{e} \quad M[j, k] = 1$$

(Ovvero: i linka k E j linka k).

- **Esempio (dalla figura):** Consideriamo $MM^T[4, 2]$ (incrocio tra nodo 4 e nodo 2). Il risultato è **2**.
 - Il nodo 4 punta verso: **2, 3, 5**.
 - Il nodo 2 punta verso: **3, 5**.
 - Hanno in comune i nodi **3** e **5** → Totale: 2 destinazioni comuni.
- **Proprietà:**
 - La matrice è sempre **simmetrica** ($MM^T[i, j] = MM^T[j, i]$).
 - Sulla diagonale principale ($MM^T[i, i]$) troviamo il grado di uscita (out-degree) del nodo i , cioè quanti link totali partono da quel nodo.

3.3.5 HITS - $M^T M$




Questa matrice rappresenta la **Co-citazione** (Co-citation). È il concetto duale rispetto al precedente: misura la similarità tra due nodi basandosi su "chi li linka" (chi punta a loro).

- **Definizione:** Il valore nella cella $M^T M[i, j]$ conta quanti nodi esterni puntano SIA al nodo i CHE al nodo j .
- **La Logica Matematica:** Il valore aumenta di 1 quando esiste un nodo k (una fonte comune) tale che:

$$M[k, i] = 1 \quad \text{e} \quad M[k, j] = 1$$

(Ovvero: k linka i E k linka j).


- **Esempio (dalla figura):** Consideriamo $M^T M[3, 5]$ (incrocio tra nodo 3 e nodo 5). Il risultato è **2**.
 - Chi punta al nodo 3? I nodi **2** e **4**.
 - Chi punta al nodo 5? I nodi **2** e **4**.
 - I "cittadini" in comune sono il **2** e il **4** → Totale: 2 fonti comuni.
- **Proprietà:**
 - Anche questa matrice è sempre **simmetrica** ($M^T M[i, j] = M^T M[j, i]$).
 - Sulla diagonale principale ($M^T M[i, i]$) troviamo il **grado di ingresso** (in-degree) del nodo i , cioè quanti link totali arrivano a quel nodo.



3.4 PageRank / HITS - confronto

- **PageRank** (Google)
 - **PRO:** Robusto contro lo spam (è difficile farsi linkare da siti autorevoli), indice di qualità valido per l'intero Web.
 - **CONTRO:** Non è specifico per la query (è un valore statico calcolato "offline"), calcolo complesso su grafi immensi.
- **HITS** (Kleinberg)
 - **PRO:** Specifico per la query (viene calcolato sul sottografo dei risultati), distingue tra *Hubs* e *Authorities*.
 - **CONTRO:** Facilmente spamabile (basta creare falsi Hub), problemi di convergenza, costo computazionale alto.



4 Social Network Analysis - terminologia



- **Local bridge:** arco tra due nodi che sarebbero altrimenti "lontani", ha un **grado k** (NON IL GRADO DEL NODO) che rappresenta la distanza che ci sarebbe senza quell'arco (Tamara - Boris ha grado 3);
- **Global bridge:** arco che, se rimosso, disconetterebbe la rete (Trevor - Tom, Alex - Roger);
- **Triangle:** sottografo completo di 3 nodi (Trevor - George - Keith);
- **Weak tie:** arco che appartiene a qualche triangolo (Mike - Peter);

- **Strong tie**: arco che appartiene a molti triangoli (Trevor - George);
- **Geodensic** (tra due nodi): cammino più corto tra di loro, distanza = n° archi (geodensico tra Tom e Mike = Tom - Trevor - Mike);
- **Diametro** di una rete: geodensico più lungo della rete (Steve - Nigel: 6);
- **Grado** di un nodo: n° di archi (differenza in in-degree e out-degree su reti con direzioni);
- **Distribuzione di grado**: per ogni grado, il numero di nodi aventi quel grado;
- **Densità**: proporzione di archi che ha la rete (n° archi / n° massimo possibile nella rete);
- **Coefficiente di clustering** (C) di un nodo: n° archi con i suoi vicini / n° massimo possibile con i vicini ($n(n-1)/2$) ($C(Keith) = 1/(3*2/2) = 1/3$), il C della rete è pari alla media su tutti i nodi.

Node	Name	Degr	PR	HITS	Closeness	Betweenness
1	Steve	1	0.036	0.026	0.29	0.00
2	Trevor	5	0.14	0.15	0.55	0.32
3	Boris	2	0.057	0.074	0.41	0.030
4	Roger	2	0.074	0.021	0.34	0.17
5	Mike	6	0.16	0.16	0.60	0.63
6	George	4	0.11	0.14	0.52	0.15
7	Keith	3	0.087	0.092	0.40	0.17
8	Nigel	1	0.043	0.006	0.26	0.00
9	Tamara	3	0.081	0.11	0.40	0.038
10	Alex	3	0.091	0.068	0.46	0.030
11	Dan	1	0.035	0.044	0.39	0.00
12	Tom	1	0.034	0.044	0.36	0.00
13	Peter	2	0.060	0.064	0.43	0.00



5 Transitività


In una rete sociale si ha **transitività** quando "un amico di un mio amico è mio amico", ha come indici *coefficiente di clustering locale* (relativo a singolo punto) e *coefficiente di clustering globale* (relativo alla rete, media degli altri), questi sono correlati ma $\neq$.

5.1 Coefficiente di clustering locale

Misura la transitività a livello dei singoli nodi, controllando quanto i vicini di un nodo v_i sono a loro volta connessi.

$$C(v_i) = \frac{\text{Number of Pairs of Neighbors of } v_i \text{ That Are Connected}}{\text{Number of Pairs of Neighbors of } v_i}.$$

In un grafo indiretto il denominatore è $\binom{d_i}{2} = d_i(d_i - 1)/2$.



- Linee sottili: connessioni ai vicini;
- Linee tratteggiate: archi mancanti fra vicini;
- Linee spesse: vicini connessi (quando nessun vicino è connesso $C = 0$, quando tutti sono connessi $C = 1$).

5.2 Coefficiente di clustering globale

Misura transittività in grafi indiretti in 3 modi equivalenti:

• **1. Conto i cammini di lunghezza 2 e controllo se esiste il terzo arco (ossia, il cammino è chiuso)**

$$C = \frac{|\text{Closed Paths of Length 2}|}{|\text{Paths of Length 2}|}$$

• **2. Oppure, conto i triangoli (e mi riconduco a 1.)**

- Siccome ogni triangolo ha 6 cammini chiusi di lunghezza 2 (triangolo abc --> cammini ab, bc, ca, ac, cb, ba):

$$C = \frac{(\text{Number of Triangles}) \times 6}{|\text{Paths of Length 2}|}$$

• **3. Oppure, conto le triple**

• **Triple:** un insieme ordinato di tre nodi, connesso

- da due archi (tripla aperta), o
- da tre archi (tripla chiusa)

• Un triangolo ha 3 triple

• Quindi:

$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$


• "Di tutte le triple di nodi connessi, prendo quelle chiuse, ossia i triangoli * 3"

$v_i v_j v_k$ e $v_j v_k v_i$ sono triple differenti

- Gli stessi elementi
- Nella prima manca l'arco $e(v_k, v_i)$
- Nella seconda manca $e(v_i, v_j)$

$v_i v_j v_k$ e $v_k v_j v_i$ sono la stessa tripla

Esempio



$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$

$$= \frac{2 \times 3}{2 \times 3 + \underbrace{2}_{v_2 v_1 v_4, v_2 v_3 v_4}} = 0.75.$$

6 Reciprocità

”Se tu mi diventi amico, anche io divento amico tuo”, se nodo v è connesso a nodo u , u connettendosi a v manifesta reciprocità.


6.1 Calcolo

Conto numero di **coppie reciproche** nel grafo:

- Uso matrice di adiacenza A ;
- La sommatoria aggiunge 1 per ogni coppia reciproca ($A_{i,j} = A_{j,i} = 1$);
- Divido per il numero massimo possibile di coppie reciproche dati gli archi in E : $|E|/2$.

$$R = \frac{\sum_{i,j,i < j} A_{i,j} A_{j,i}}{|E|/2} = \frac{2}{|E|} \sum_{i,j,i < j} A_{i,j} A_{j,i} = \frac{2}{|E|} \times \frac{1}{2} \text{Tr}(A^2) = \frac{1}{|E| \text{Tr}(A^2) = \frac{1}{m} \text{Tr}(A^2)}$$

$$\text{Tr}(A) = A_{1,1} + A_{2,2} + \dots + A_{n,n} = \sum_{i=1}^n A_{i,i}$$



$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$



- Nodi reciproci: v_1, v_2
- 4 archi

$$R = \frac{1}{m} \text{Tr}(A^2) = \frac{1}{4} \text{Tr} \left(\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 0 \end{bmatrix} \right) = \frac{2}{4} = \frac{1}{2}.$$

7 Bilanciamento


7.1 Bilanciamento Sociale

Modella la **coerenza** nelle relazioni amico / nemico, formalmente si ha bilanciamento quando:

- amico di amico è amico;


- amico di nemico è nemico;
- nemico di nemico è amico;
- nemico di amico è nemico.

Si modella con reti / grafi di '+' e '-' (signed graph), in cui archi positivi hanno valore +1 e archi negativi hanno valore -1. Un triangolo di nodi i, j, k è bilanciato se $w_{ij}w_{jk}w_{ki} \geq 0$



7.2 Status sociale

Quando un individuo è prestigioso all'interno della società: se X ha status più alto di Y e Y più alto di Z allora X dovrebbe avere status più alto di Z ... questi **cicli** sono problematici.



8 Degree distributions reali

- Popolarità siti web:
 - Tanti siti sono visitati ~ 1000 volte / mese (poco popolari);
 - Pochi siti sono visitati $\sim 1M$ volte / giorno (molto popolari).
- Attività utenti:
 - Utenti di SM sono spesso attivi su pochi siti;
 - Alcuni (pochi) individui sono attivi su tanti siti.
- Prezzi dei prodotti:
 - Tantissimi prodotti a prezzo basso;
 - Pochi prodotti costosi.
- Amicizia:

- Tanti individui con pochi amici;
- Pochi individui con migliaia di amici.
- Distribuzioni dei gradi:
 - Tanti nodi con grado basso;
 - Pochi nodi con grado alto.

9 La Legge di Potenza (Power Law)

9.1 Che cos'è (In parole povere)

La **Power Law** è una relazione matematica che descrive fenomeni dove eventi "piccoli" sono comunissimi, mentre eventi "giganti" sono rari ma esistono.

- **Formula base:** $f(k) \sim \frac{1}{k^\alpha}$
- **Significato:** La frequenza decresce molto velocemente man mano che cresce la grandezza (k).
- **Esempio intuitivo:** Pensa ai follower su Instagram.
 - Miliardi di persone hanno pochi follower (la "coda" lunga del grafico).
 - Pochissimi influencer (la "testa") ne hanno milioni.

9.2 Il trucco del Grafico Log-Log

Se disegni una Power Law su un grafico normale, ottieni un'**iperbole** (una curva a forma di "L") difficile da analizzare. Per capire se una rete segue davvero questa legge, si usa la scala logaritmica su entrambi gli assi.

- **La Magia:** Se applichi il logaritmo alla formula $f(k) = C/k^\alpha$, trasformi le moltiplicazioni in addizioni:

$$\log(f(k)) = \log(C) - \alpha \log(k)$$

- **Risultato:** Questa è l'equazione di una **retta** ($y = q - mx$).
- **Regola d'oro:** Se metti i dati su un grafico log-log e vedi una linea dritta che scende, allora sei davanti a una Power Law. La pendenza della retta è l'esponente α .

9.3 Esempi Reali (Dalle Slide)

- **Telefonate** ($1/k^2$): Pochissimi numeri ricevono milioni di chiamate, la maggioranza ne riceve poche.
- **Libri** ($1/k^3$): Pochi best-seller vendono milioni di copie, la maggioranza dei libri vende quasi zero.
- **Citazioni Scientifiche** ($1/k^3$): Pochi paper (tipo quelli di Einstein) sono citati da tutti, la maggior parte dei paper non li legge nessuno.
- **Social Network** ($1/k^2$): La distribuzione dei follower (in-degree).

9.4 Nota: Differenza con Zipf

- **Power Law:** Sull'asse X metti il **valore** (es. "Quanti hanno 100 amici?").
- **Zipf:** Sull'asse X metti la **classifica/rank** (es. "Chi è il 1°, il 2°, il 3° più ricco?").

9.5 Test

Per capire se rete ha degree distribution power law:

1. Calcolare grado k di ogni nodo;
2. Calcolare p_k , la frazione di nodi con grado k ;
3. Disegnare grafico su scala log-log con k su asse X e p_k su asse Y;
4. Se è power law, linea retta.

NON è un approccio sistematico! Altre distribuzioni potrebbero avere lo stesso pattern.

9.6 Coefficiente di clustering


Nelle reti sociali reali connessioni sono **molto transitive** (amici di un utente sono amici tra di loro, dormando **triangoli** con alto clustering).

10 Diffusione informazioni

Un rumor si diffonde su una rete sociale, tutti gli utenti lo passano immediatamente a tutti gli amici. Quanti hop servono per raggiungere tutti i nodi?

10.1 Milgram

Partendo da 296 persone a caso (196 Nebraska / 100 Boston) gli viene chiesto di spedire una lettera via intermediari a un agente di borsa a Boston, potendo spedire solo a persone che conoscevano personalmente. Fra tutte le (64) lettere che arrivarono a destinazione il n° medio di passaggi fu circa 6.



10.2 Dodds

Esperimento di Milgram mandato per email, confermato tasso di risposta e sei gradi di separazione.

10.3 Erdos

Ricerca n° di link per connettere uno scienziato / studioso mediante co-authorship di articoli scientifici, lunghezza dei cammini fra matematici: **media** 4.65, **massima** 13.


10.4 Proprietà reti reali

- Solitamente hanno struttura core-periferia: core denso con tanti archi, nodi della periferia con archi verso il core ma non fra di loro,
- Paradosso degli amici: grado dei vicini di un nodo v è più alto del grado di v .

11 Modelli delle reti

Reti reali sono troppo grandi per valutarle univocamente, si usano quindi processi stocastici che generano / producono grafi per poterle valutare su una scala inferiore, rendendole più controllabili / analizzabili rispetto alla visione reale.

11.1 Reti regolari




- **Distanze** (Average path length / Diametro): spesso **grandi**;
- Coefficiente di **Clustering**: spesso **alto**;
- **Distribuzione dei gradi**: spesso con un **picco**, e spesso 0 altrove;
- **Connettività**: spesso **completamente connesse**;
- Le reti al mondo raramente sono così, nemmeno quelle artificiali se grandi / complesse.

11.2 Reti casuali

Grafo con n nodi e archi casuali, studiando tutte le proprietà dei grafi e, nei grafi **grandi**, il **limite termodinamico** per $n \rightarrow \infty$. Reti interessanti se suppongo che le amicizie possano scaturire in modo casuale.

11.2.1 Modello $G(n,m)$

Grafo con n **nodi** fissati e m **archi** piazzati a caso fra gli n nodi (solitamente indiretto, senza multi e auto archi).



Si studia il caso $n \rightarrow \infty$, valutando il **caso medio**: ciò che succede in media su un insieme di tanti grafi casuali (diametro di $G(n,m)$ = diametro medio di tutti i grafi $G(n,m)$). Comodo analiticamente per n molto grandi, si valutano proprietà **tipiche** (più interessanti) e non casi speciali / particolari (meno interessanti).

11.2.2 Modello $G(n,p)$

Introdotta per determinate misure altrimenti non facilmente calcolabili, invece di fissare il # di archi, si fissa la **probabilità p** (indipendente) **di esistenza archi**

- N° archi (medio): $\langle m \rangle = \frac{n(n-1)}{2}p = \binom{n}{2}p$;
- Grado medio (tutte le estremità di archi / n° nodi): $\langle k \rangle = \frac{2\langle m \rangle}{n} = (n-1)p$, di solito denotato con $c = (n-1)p$ e approssimato con $c = np$, per n grande cambia poco;
- **Coefficiente di Clustering**: $C = \frac{c}{n-1}$, valore molto basso ($\rightarrow 0$ per $n \rightarrow \infty$);
- **Diametro** (geodensica più lunga): $l = \frac{\ln n}{\ln c}$, cresce con n e cala con crescere di c (sorprendentemente piccolo, **small world effect**)

Da degree distribution e C si evince che non è un modello adeguato a modellazione reti reali.



11.2.3 Differenza

Si assomigliano ma $G(n, m) \neq G(n, p)$, nel primo il n° di archi è **esattamente** m , nell'altro è **in media** $m = p \times n(n-1)/2$.

• Es.:

- Un grafo casuale in $G(n, m) = G(3, 2)$ ha **sempre** 2 archi, è sempre connesso, non è mai completo, ...
- Un grafo casuale in $G(n, p) = G(3, 2/3)$ ha **in media** 2 archi, non è sempre connesso, può essere completo, ...



Entrambi hanno distribuzione dei gradi di **Poisson** / **Bernoulli** (= per $n = \infty$), non proprio simmetrica ma quasi.

11.2.4 $G(n, p)$ connesso?

In generale no (basta un singolo nodo isolato), ma dato che $n \rightarrow \infty$, che ci sia un singolo nodo (o piccole componenti) isolato o meno non importa, basta aggiungere / togliere un arco (nodo) e si sistema. Si valuta invece esistenza "giant component", connessa e che contiene quasi tutti i nodi, e se ne valuta la dimensione:

- $p = 0$: grafo disconnesso - dimensione = 1 - costante a aumentare di n ;
- $p = 1$: grafo completo - dimensione = n - aumenta con n .

Probability (p)	0.0	0.055	0.11	1.0
Average Node Degree (c)	0.0	0.8	≈ 1	$n-1=9$
Diameter	0	2	6	1
Giant Component Size	0	4	7	10
Average Path Length	0.0	1.5	2.66	1.0

Con aumentare di p aumenterà la probabilità di avere una GC?

Siano un grafo casuale con grado medio c , un insieme di nodi connesso S e $S' = V - S$ l'insieme complementare (assumiamo $|S| \ll |S'|$). Per ogni nodo $v \in S$ con un hop da v visitiamo c nodi (con un hop da un qualsiasi nodo di S visito $|S|c$ nodi). Se S è piccolo, da $S \rightarrow S'$ con un hop l'insieme dei nodi connessi diventa più grande di un fattore di c .

Se è la componente connessa più grande, la sua grandezza aumenta sempre e dopo n hop: $c^n \geq 1$, se invece $c < 1$ il numero di nodi visitati muore.

11.2.5 Recap

Riguardo a reti reali il modello casuale:

- Modella **bene** lunghezza media dei cammini (bassa, small world);
- **Sottostima** drasticamente coefficiente di clustering;
- Non hanno distribuzione Power-law, ma **Poisson**.

Utile per spiegare alcuni fenomeni (small world) ma non tutti.

11.3 Reti small-world

Distanza piccola fra nodi, diametro basso e coefficiente di clustering alto.

11.3.1 Procedura

1. Parto da rete regolare;
2. Considero ogni singolo arco;
3. Con probabilità p lo ricollego casualmente (con $p=0$ ho rete regolare, con $p=1$ ho rete casuale).

11.3.2 Reti che ci interessano

Dati n nodi e c n° (medio) di archi per vertice ($\frac{nc}{2}$ archi totali) avremo $n \geq c \geq \log(n) \geq 1$:

- Con $n \geq 1$ reti grandi con n grande;
- Con $n \geq c$ reti sparse;
- Con $c \geq \log(n) \geq 1$ *non così sparse* da rischiare di diventare sconnesse.

Si valutano 2 misure:

- **L**: lunghezza media del cammino (numero di archi) minimo fra 2 nodi della rete. Misura per quanti amici devo passare per raggiungere una persona (globale);
- **C** coefficiente di Clustering: dato un vertice v considero i suoi k_v vicini e controllo quanti archi trovo fra i vicini (al massimo $k_v(k_v-1)/2$). Sia $C_v = \frac{\text{narchi}}{k_v(k_v-1)/2}$ la frazione degli archi effettivamente esistente, quindi **C** = media di C_v su tutti i vertici della rete. Misura quanto gli amici di una persona sono amici fra di loro (locale).

Casi limite

- $p=0$ (regolare):
 - $L(0)$: $\frac{n}{2c} \gg 1$ distanze grandi;
 - $C(0)$: $\frac{3}{4}$ "criccoso".
- $p=1$ (random):
 - $L(1)$: $\frac{\log(n)}{\log(c)}$ distanze basse (small world);
 - $C(1)$: $\frac{c}{n} \ll 1$ poco "criccoso".

11.3.3 Distribuzione dei gradi

Distribuzione strana con picco e soglia (cutoff) inferiore $p_k = e^{-cp} \frac{(cp)^{k-c}}{(k-c)!}$.

11.3.4 Recap

Reti small-world:

- Spiegano effetto small world (non spiegato da reti regolari, "ereditato" da $G(n,p)$);
- Spiega coefficiente di clustering alto (non spiegato da $G(n,p)$, "ereditato" da reti regolari);
- Non spiega distribuzione dei gradi che si trova "in natura" (**no power-law**, no coda lunga, no hub).

11.4 Reti scale free

Studio delle distribuzioni di:

- **Outdegree**: $P_{out}(k)$ probabilità che una pagina abbia k outlink;
- **Indegree**: $P_{in}(k)$ probabilità che una pagina abbia k inlink (più interessante).

Sono entrambe **power-law**, non poisson.


11.4.1 Diametro

Distanza **media** fra nodi (lunghezza media del cammino minimo fra 2 nodi della rete), sperimentalmente $\langle d \rangle = 0.35 + 2.06 \times \log(N)$ (anche aumentando molto n° nodi, diametro rimane basso $\rightarrow$ **power law** e **small-world**).

11.5 Reti con attaccamento preferenziale

Nuovo modello stocastico, ad ogni passo aggiungo nuovo nodo e un arco che lo collega ad un nodo preesistente scelto a caso ma con probabilità non uniforme (proporzionale al **grado** del nodo esistente $P(v_i) = \frac{d_i}{\sum_j d_j}$).

Come per gradi casuali si possono simulare reti del mondo reale generando un grafo con attaccamento preferenziale (lavorando su grafi indiretti) con un grado atteso m (invece di attaccare nuovo nodo a un unico altro nodo, ne scelgo m).



11.5.1 Sul modello scale-free

Lunghezze medie basse, ma **clustering** basso. Le scale-free hanno distribuzioni **power law**, in log-log è una retta $f(k) = \frac{C}{k^\alpha}$, ha **code lunghe** con molti nodi con k basso, ci sono però pochi nodi con grado molto alto (**hub**).

11.6 Sunto

	Lunghezza media cammini minimi (geodesiche)	C	Degree distribution
1. Regolari	KO	OK	KO
2. Random Graphs	OK	KO	KO
3. WSSW	OK	OK	KO
4. Scale free	OK	KO	OK

Insomma nessun modello "funziona", ossia crea reti uguali a quelle del mondo reale...

11.7 Attaccamento preferenziale non lineare

$$P(v_i) = \frac{d_i^\alpha}{\sum_j d_j^\alpha}$$

- Se $\alpha = 1$ è l'attaccamento preferenziale originale;
- Se $\alpha < 1$ vantaggio di avere grado alto è inferiore, no long tail, no hub;
- Se $\alpha > 1$ vantaggio di avere grado alto è superiore, winner-takes-all (un singolo nodo connesso a tutti).

11.8 Attrattività

$$P(v_i) = \frac{A + d_i}{\sum_j (A + d_j)}$$

- Se $A = 0$ è l'attaccamento preferenziale originale;
- Altrimenti evita che nodi con grado 0 non ricevano link, si ottiene sempre una **power law** con pendenza che varia con A .

11.9 Fitness

$$P(v_i) = \frac{\eta_i d_i}{\sum_j (\eta_j d_j)}$$


η_i rappresenta la fitness del nodo i , se $\forall i, j (\eta_i = \eta_j)$ è l'attaccamento preferenziale originale, se i valori di fitness sono in un intervallo limitato: rete con + hub, si elimina dipendenza dal rich-get-richer dei nodi più vecchi, anche i nodi giovani con alta fitness competono. Si ottiene **sempre** una **power law**.

11.10 Random Walk

Parte da una piccola rete qualsiasi, ad ogni passo si aggiunge un nuovo nodo i , con $m > 1$ archi attaccati di cui il primo è collegato con un nodo vecchio j scelto a caso (probabilità **uniforme**), ogni arco degli $m - 1$ restanti viene collegato:

- Con probabilità p a un **vicino** di j scelto a caso;
- Con probabilità $1 - p$ a un nodo vecchio qualsiasi scelto a caso;

Con p probabilità che si formi un triangolo.




11.10.1 FUNZIONA

- **Degree distribution power law**: quando scelgo un vicino (p) tendo a scegliere nodi con grado alto (in quanto attaccamento preferenziale), si formano hub;
- **Cammini brevi**;
- **Clustering alto**: presenza di triangoli.

12 Comunità

Comunità (**community**) di utenti = gruppo fornito / gestito dalla piattaforma, modellato mediante gruppo di nodi "connessi fra loro e non connessi con gli altri" (homophilia: tendenza ad associarsi con persone simili a loro).



12.1 Definizione "ideale"

Sottografo connesso e senza archi con altri nodi: dato un grafo G , una comunità C è un sottografo di G tale che C è connesso (o addirittura completo) e $\forall$ nodo $v \notin C$, v è sconnesso da C ($\nexists$ cammino fra v e nodi di C).


12.2 Definizione "realistica"

Sottografo connesso e senza archi con altri nodi: dato un grafo G , una comunità C è un sottografo di G tale che C è connesso e $\forall$ nodo $v \notin C$, v è **poco connesso** a C .

12.3 Algoritmi per riconoscere comunità

12.3.1 Edge betweenness centrality


Anche gli archi possono essere più o meno centrali (si applica centralità di betweenness sugli archi), quantifica quanti shortest path passano per un arco anziché per un vertice (*quanto un arco è importante nel connettere i nodi*). Gli archi con alta betweenness centrality sono i **weak ties**.



Idea: rimuovere ricorsivamente legami deboli rimuovendo gli archi con alta betweenness centrality (**disconnettendo la rete**), rendendo le comunità componenti connesse.

12.3.2 Algoritmo di Givran-Newman

1. Calcolare edge betweenness per tutti gli archi del grafo;
2. Rimuovere arco con betweenness più alta;
3. Ricalcolare edge betweenness per tutti gli archi del grafo (basta per quelli la cui betweenness è cambiata);
4. Ripetere fino alla rimozione di tutti gli archi.



12.4 Gerarchia

Viene prodotto un albero (*dendrogramma*) del quale ogni livello corrisponde ad un valore di edge betweenness (decrescente da radice a foglie - sopracomunità → comunità → sottocomunità).

13 Diffusione informazioni

Processo per cui un'informazione (video, meme), o anche **comportamento** (adozione di una tecnologia) si diffonde e raggiunge altri individui. È un fenomeno **dinamico** sulle reti, dove i player principali sono:

- **Mittente (sender)**: uno o più mittenti che iniziano il processo;
- **Destinatari (receivers)**: uno o più destinatari che ricevono l'informazione (insieme solitamente molto più grande di quello dei sender);
- **Mezzo (medium)**: mezzo tramite il quale la diffusione avviene.
- **Intervention**: mezzo di intervento / **intromissione** fino al blocco completo della diffusione (nel caso di fake news), al contrario possono anche "far ripartire" / velocizzare la condivisione (messaggi pubblicitari).


13.1 Herd behavior

Network **completamente osservabile** e ho informazioni **globali**, questo comportamento descrive quando un **gruppo di individui** esegue azioni **altamente correlate** senza piani (tendenza naturale a imitare). Dev'esserci una **connessione** fra individui e un **metodo di condivisione** informazioni oppure un modo di osservare individui.

13.1.1 Grafo completo

Rappresentazione di reti herd dove nodi possono osservare almeno maggior parte degli altri nodi e possono osservare informazioni pubbliche.

13.1.2 Esempio



Due possibili configurazioni (B/B/R - majority blue o R/R/B - majority red), ogni studente cerca di stimare la **conditional probability** che sia maj. blue / red data una sua estrazione e la lista delle votazioni degli altri.

- $P[\text{majority-blue}] = P[\text{majority-red}] = 1/2$;
- $P[\text{blue} \mid \text{majority-blue}] = P[\text{red} \mid \text{majority-red}] = 2/3$;
- $P[\text{blue} \mid \text{majority-red}] = P[\text{red} \mid \text{majority-blue}] = 1/3$.

Bayes's rule: $p(C|I) = \frac{p(C) \times p(I|C)}{p(I)}$, per cui $P[\text{majority-blue} \mid \text{blue}] = P[\text{blue} \mid \text{majority-blue}] \times P[\text{majority-blue}] / P[\text{blue}]$.

Sapendo che $P[\text{blue}] = P[\text{blue} \mid \text{majority-blue}] \times P[\text{majority-blue}] + P[\text{blue} \mid \text{majority-red}] \times P[\text{majority-red}] = 2/3 \times 1/2 + 1/3 \times 1/2 = 1/2$ possiamo vedere **$P[\text{majority-blue} \mid \text{blue}] = (2/3 \times 1/2) / (1/2) = 2/3 > 1/2$** . Se le osservazioni sono *blue, blue*, anche se il terzo studente osserva *red* sarà portato a votare *blue*.

13.1.3 Intervention

Quando una nuova **informazione privata** viene rilasciata la herd rivaluta le scelte, il che potrebbe portare a risultati completamente diversi.

13.2 Information cascade

Utenti condividono contenuti di altri utenti presenti nella rete, quindi le info si propagano tra vicini:

- individui devono essere **connessi a una rete**;
- individui **osservano** solo **decisioni** dei **vicini immediati**.

La rete è un **grafo diretto** (nodi sono attori e archi appresentano canali di comunicazione tra loro), un nodo può solo influenzare nodi **a cui è connesso**. Le decisioni sono binarie (Y/N) ed i nodi possono essere **attivi** (adottano comportamento / decisione del precedente) o **inattivi** (non hanno ancora adottato). Un nodo attivo può **attivare** i nodi vicini (si può passare solo da non attivo ad attivo, non viceversa).

13.2.1 Independent Cascade Model (ICM)

Modello cascade **sender-centric** dove **ogni** nodo ha la possibilità di attivare i suoi vicini subito dopo la sua attivazione (nodi che attivano sono sender e nodi che vengono attivati sono receivers).

- Nodo attivato all'istante t ;
- All'istante $t + 1$ può attivare i suoi vicini;
- Assumiamo che v sia attivato all'istante t ;

- Per ogni vicino w di v c'è probabilità p_{vw} che quel nodo venga attivato all'istante $t + 1$;
- p_{vw} può differire per diverse coppie di nodi.
- Ogni nodo v attivato all'istante t ha una **singola** possibilità di attivare i suoi vicini (può solo accadere a $t + 1$).

13.2.2 Massimizzare spread di cascade

Trovare il **più piccolo** set di nodi di una rete tale il loro spread aggregato nella rete sia massimizzato: dato un **budget** k si deve trovare un **initial set** $S, |S| = k$ che massimizzi $f(S)$. Sappiamo che le activations sono **random**: si generano i numeri random per tutti gli archi all'inizio del processo. $f(S)$ è:

- **non negativa**;
- **monotona** - $f(S + v) \geq f(S)$;
- **submodulare** - sia N un set finito, un set è submodulare se e solo se:
 - $f : 2^N \rightarrow R$;
 - $\forall S \subset T \subset N, \forall v \in N \setminus T$;
 - $f(S + v) - f(S) \geq f(T + v) - f(T)$;

Ovvero sottoinsiemi più piccoli ci guadagnano di più.

13.2.3 Problemi


Trovare un element set S per il quale $f(S)$ è massimizzato e **NP-hard**. Posso usare un **greedy algorithm** che partendo da un empty set S per k iterazioni ad ogni passo aggiunge as S un nodo v che massimizza $f(S \cup v) - f(S)$

13.3 Epidemics

Assumono **rete implicita** e delle **connessioni sconosciute** tra gli user, vengono utilizzati quando si è interessati a **pattern globali** (trend, pattern d'infezione), si possono analizzare con due metodi:

- **Fully-mixed**: valuta le proporzioni d'infezione / recover, evitando di considerare le informazioni di rete;
- **Contact network**: controlla come gli host comunicano tra loro, valutando come le epidemie avvengono in una rete (*contact network* = grafo in cui nodi rappresentano host e archi rappresentano interazioni tra questi host).

13.3.1 SI model



Gli individui **suscettibili (S)** possono venire infetti, se **infetti (I)** non possono essere curati e possono infettare altri utenti. Sia N la dimensione della **crowd**, costante:

- $S(t)$: numero di individui suscettibili all'istante t - $s(t) = \frac{S(t)}{N}$;
- $I(t)$: numero di individui infetti all'istante t - $\frac{I(t)}{N}$;
- β : probabilità di contatto - per $\beta = 1$ tutti entrano in contatto con tutti, per $\beta = 0$ nessuno entra in contatto con nessuno.

Dimensione della crowd è $N = S(t) + I(t)$, per ogni istante un individuo infetto può **incontrare** βN individui e può **infettarne** βS , per gli altri βI non succede niente, βIS saranno infettati al prossimo istante.


- Ad ogni time step la variazione del numero di individui in S e I è di βIS :
 – (S e I sarebbero $S(t)$ e $I(t)$)

$$\frac{dS}{dt} = -\beta IS, \quad \frac{dI}{dt} = \beta IS.$$


- Si risolve analiticamente:

$$(S + I = N) \Rightarrow \frac{dI}{dt} = \beta I(N - I) \Rightarrow I(t) = \frac{NI_0 e^{\beta t N}}{N + I_0(e^{\beta t N} - 1)}$$

I_0 is the number of individuals infected at time 0
 This is the logistic growth curve



13.4 SIR model



Introduce (in aggiunta a **I** e **S**) lo stato di **recovery R**: determinati individui possono "curarsi" (o essere rimossi / morire), una volta arrivato a stato **R** non può più tornare **I**.

$$S + I + R = N$$

γ invece definisce la probabilità di recover di un individuo infetto ad un dato istante.


- S decrescono monotonamente;
- R crescono monotonamente;
- I crescono inizialmente e poi decrescono man mano che individui guariscono / muoiono e vanno a 0 per $t \rightarrow \infty$;
- S **non vanno** a 0: ne resta una generalmente piccola frazione (quando non ci sono più I non c'è nessuno per contagiare i pochi S che si salvano).

R_0 **Basic reproduction number** (calcolato con β/γ) numero medio di individui che un individuo infetta prima di guarire / morire. $R_0 = 1$ indica la **soglia epidemica**, quindi c'è epidemia se $R_0 \geq 1$, se $R_0 \leq 1$ non c'è epidemia perché gli infetti guariscono più in fretta di quanto gli S si ammalino.

13.4.1 Transizione epidemica

Transizione di fase fra regime epidemia e regime non-epidemia: brusca, improvvisa.

13.5 SIS model




Uguale a modello SI, ma soggetti infetti possono tornare sani e venire ri-infettati di nuovo.

$$I(\beta N - \gamma) - \beta I^2$$

- Se $\beta N \leq \gamma$: gli infetti diminuiranno esponenzialmente;
- Se $\beta N > \gamma$: crescita logistica simile al modello SI.

13.6 SIRS model




Individui che sono in stato R perdono l'immunità dopo un certo periodo di tempo e diventano suscettibili di nuovo

13.7 Contagio sociale

Se un individuo vede un comportamento in un altro individuo, lo **imita** (adotta lo stesso comportamento), rappresentabile come **modifica di SIR**:

- Suscettibile - **Ignorant (I)**: individuo che non ha ancora ricevuto l'info;
- Infetto - **Spreader (S)**: individuo che ha ricevuto l'info e la diffonde;
- Recovered/Removed - **Stifler (R)**: ha ricevuto l'info ma non la diffonde (più).

A differenza di SIR (patologia **negativa**), il contagio sociale (ISR) è un atto intenzionale, vantaggioso ed attivo.



- Passaggio $I \rightarrow R$ in SIR è spontaneo e dipende solo da n° di I e dal parametro γ ;
- Passaggio $S \rightarrow R$ in "ISR" non è spontaneo e dipende da n° di S, parametro α e dal n° di R.

13.7.1 Cosa succede

- Allo **stato stazionario** ($t \rightarrow \infty$) non ci saranno più **spreaders** - $s_\infty = \lim_{t \rightarrow \infty} s(t) = 0$;
- Gli ignoranti saranno tanti di meno quanti di più saranno gli stiflers - $i_\infty = e^{-(1+\lambda/\alpha)r_\infty}$;
- Gli stiflers saranno tutti gli altri, $i_\infty + r_\infty = 1$, $r_\infty = 1 - i_\infty$ - $r_\infty = 1 - e^{-(1+\lambda/\alpha)r_\infty}$.

13.7.2 Condizione

Per avere contagio sociale la condizione diventa $1 + \frac{\lambda}{\alpha}$. **Non c'è più soglia epidemica**, qualsiasi siano i valori dei parametri c'è **sempre** epidemia sociale.

14 Epidemie su reti

Supponiamo di avere una **rete omogenea**, tutti i nodi hanno un grado simile e ogni individuo viene a contatto con lo stesso numero di individui. Si può ridefinire il **basic reproduction number** (n° di individui che un infected contagia prima di guarire / morire).

- **Rete omogenea**: tutti i nodi hanno grado simile alla media $\langle k \rangle$;
- Ogni I infetta un vicino S con probabilità β ;
- Ad inizio epidemia sono quasi tutti S , anche i vicini di un I ;
- N° medio di infezioni causate da un I : $\beta \langle k \rangle$;
- Ad ogni istante t , ogni I può transitare in R con probabilità γ .

Quindi:

- $\Delta I_{t+1} = \beta \langle k \rangle I_t$;
- $\Delta R_{t+1} = \gamma I_t$.

Per avere epidemia deve essere $\Delta I_{t+1} > \Delta R_{t+1}$, ossia $\beta \langle k \rangle I_t > \gamma I_t$. **Quindi** $R_0 = \langle k \rangle \beta / \gamma$.

14.1 Intervention

Per diminuire R_0 :

- Diminuire **contagiosità** β ;
- Aumentare **velocità di guarigione** γ ;
- Diminuire il **grado medio** $\langle k \rangle$.

Nel **mondo reale** reti sono eterogenee (power law, hub), se ci sono nodi con grado alto non c'è soglia e c'è comunue un'epidemia (hub si contagiano facilmente e contagiano molti altri).

14.2 Epidemic intervention

Scelgo nodi randomici e gli chiedo di selezionare gli altri individui più suscettibili, studio sperimentale su **rete WSSW**:

- $\lambda = \alpha = 1$;
- non fully mixed (**non completa**);
- variazione rispetto a probabilità p :
 - per p **bassi** - rete molto clusterizzata, alto C e molti triangoli, spreaders diffondono sempre agli stessi e quindi passano velocemente fra stiflers (poca diffusione);
 - per p **alti** - rete con shortcut, spreaders diffondono anche in parti lontane e quindi rumor si diffonde.

14.3 Su reti eterogenee

Power law, scale-free, con hub e **varianza alta** sui gradi. Hub dovrebbero essere spreader efficientissimi, tuttavia r_∞ è più alto su reti omogenee... infatti hub non aiutano diffusione per i rumor: facile che un rumor raggiunga un hub (rendendo diffusione molto alta), ma se hub diventa spreader allora creerà velocemente molti **molti stifler**.

15 Modello dei benefici diretti (Morris)

Persone sono influenzate da altre persone sulla base di **informazioni** (faccio X perché vedo molti che lo fanno) e **benefici diretti** (faccio X perché mi conviene rispetto a non farlo).

15.1 Modello direct benefit

Comportamento si diffonde sulla rete sulla base di un processo di decision making basato su scelte dei nodi vicini.

15.2 Modello di Morris

Valuto un nodo di partenza e valuto i nodi vicini, per un nodo il **beneficio** di adottare un comportamento cresce al crescere del n° dei vicini che lo adottano. Ogni nodo sceglie fra due possibili comportamenti A e B , se due nodi v e w sono collegati da un arco hanno un incentivo ad **adottare comportamenti uguali**.

15.2.1 Matrice payoff

v e w **giocatori**, A e B **strategie**:

- se v e w adottano entrambi A allora **payoff** $a > 0$;
- se v e w adottano entrambi B allora **payoff** $b > 0$;
- se v e w adottano comportamenti differenti allora **payoff** 0 ;

		w	
		A	B
v	A	a	0
	B	0	b

Ogni nodo seleziona strategia che massimizza la somma di tutti i payoff (trovati creando la matrice con tutti i suoi vicini).

15.2.2 Regola di decisione

Decisione della strategia dipende da:

- payoff a ;
- payoff b ;
- n° vicini che adottano A (basta anche percentuale);
- n° vicini che adottano B (basta anche percentuale);
- p = percentuale vicini che adottano A , $1-p$ = percentuale vicini che adottano B ;
- d = n° vicini.

Se v adotta A payoff = pda , se adotta B payoff = $(1-p)db$. v adotta A **se e solo se** $pda \geq (1-p)db$, ossia se $p \geq \frac{b}{a+b}$.

15.2.3 Equilibri

2 ovvi equilibri (tutti A / tutti B), definendo inizialmente un **comportamento di default**, ci sono poi **early adopters** che vanno contro il comportamento default per ragioni extra-payoff. Ad ogni passo ogni nodo usa la **regola di decisione** per scegliere se cambiare comportamento, si ferma quando tutti sono cambiati / nessuno vuole più cambiare. Si ha quindi una **cascata di adozioni** e, se tutti i nodi passano a un singolo comportamento si ha **cascata completa**.

15.2.4 Intervention

Strategie che possono essere usate per cambiare le decisioni, **migliorando i payoff** o **convincendo** alcuni nodi chiave per far ripartire la reazione a catena.

15.2.5 Risultato di Morris


Se esistono **cluster** (comunità molto legate con sottografi quasi completi e poco legati all'esterno) **fermano le cascate**, in particolare una cascata si ferma **se e solo se** c'è un cluster.

- Dati degli **initial adopters** di A ;

- Si definisce **soglia** q per adottare A ;
- Se il resto della rete contiene un cluster di **densità** $> 1 - q$ allora non ci sarà una cascata completa;
- Se non c'è cascata completa, allora c'è un **cluster** di densità $> 1 - q$.

Dimostrazioni

- Caso 1:
 - Sia un cluster con densità $> 1 - q$, sia v il **primo** nodo nel cluster che adotta A (al tempo t);
 - A $t - 1$ doveva esserci almeno una frazione q di vicini di v adottanti A , nessuno **nel** cluster adottava A ;
 - v aveva almeno una frazione q di vicini fuori dal cluster;
 - Il cluster è di densità $> 1 - q \rightarrow > 1 - q$ vicini di v devono essere nel cluster;
 - Impossibile averne q fuori... **no complete cascade**.
- Caso 2:
 - Sia un qualsiasi nodo w in S ;
 - w non cambia da B ad A , la frazione dei suoi vicini che usano A è $F_W(A) < q$ e la frazione dei suoi vicini che usano B è $F_W(B) > 1 - q$;
 - Soli nodi che usano B sono quelli in S , la frazione dei vicini di w che stanno in S è $> 1 - q$;
 - Questo vale per tutti i nodi w in S , per ognuno di questi la frazione dei vicini che stanno in S è $> 1 - q$ e quindi S è un **cluster** di densità $> 1 - q$.



15.2.6 Awareness, adoption, weak ties

Weak ties sono utili per conoscenze non intime (es. trovare lavoro), utili per diffusione informazioni ma inutili per diffusione mode, innovazione. Ricorsio che **awareness** = semplice consapevolezza e **adoption** = adozione comportamento. Posso estendere il modello di Morris con **payoff eterogenei**:

- Ogni nodo v ha una ricompensa diversa a_v (b_v) per l'adozione del comportamento A (B)
- Modellando così non solo chi è **influyente** ma anche chi è **facilmente influenzabile**.

		w	
		A	B
v	A	a_w	0
	B	0	b_w
		a_v	b_v

16 Fake news

Quando parliamo di **fake news** parliamo di:

- **misinformation** = errori non intenzionali come diffusione di informazioni sbagliate "in buona fede";
- **disinformation** = diffusione di contenuti / informazioni volutamente manipolate;
- **malinformation** = diffusioni di info malevole con intenti diffamatori.

Un'informazione si valuta sotto **7 dimensioni**:

- **correctness** - informazione espressa in maniera accurata senza sbagli;
- **neutrality** - informazione espressa sotto punto di vista oggettivo / neutrale;
- **comprehensibility** - informazione comprensibile / capibile / leggibile facilmente);
- **precision** - informazione è precisa / specifica, non vaga;
- **completeness** - informazione è completa e racconta "tutta la storia";
- **speaker's trustworthiness** - chi trasmette informazione è generalmente affidabile;
- **informativeness** - informazione permette di ricavare dati utili.

16.1 Perché studiarle

Fenomeno in forte crescita e sempre più problematico senza soluzione ovvia, studi hanno evidenziato che notizie false si diffondono quasi allo stesso rateo delle vere, ma con *depth* e *size* maggiore.

- Si è notato come notizie false vengano pubblicate con **più frequenza** delle vere, e come causino paura, disgusto e sorpresa per restare impresse;
- Anche se implementassimo un **bot** per diffonderle non cambierebbe niente in quando vengono diffuse maggiormente da **umani**;
- Due comunità ben distinte (buona parte dei post ha **alta omogeneità**): **cospirazionisti** e **scientifici**, che scaturiscono nelle **echo chambers** ad alta omogeneità (contenuti tendono a circolare solo all'interno della rispettiva comunità);
- Si è riscontrato come attività di **debunking** sembra inutile (se non controproducente) a causa di **pregiudizio di conferma (confirmation bias)**: si crede a quello che si sa già.

17 Crowdsourcing

Sistemi computazionali vengono supportati dal **comportamento sociale**: compiti che i calcolatori non fanno bene svolti da persone ragionate tramite i sistemi computazionali. Si sfruttano quindi le **folle** (possono avere comportamenti positivi / negativi), solitamente decisioni prese da un gruppo sono **più corrette** di quelle dei singoli esperti. Si parla quindi di **decisioni di gruppo**.

17.1 4 elementi perché "funzioni"

- **Diversità di opinioni**: ognuno deve avere le proprie **informazioni private** (al limite un'interpretazione originale dei fatti noti);
- **Indipendenza**: le opinioni personali **non sono determinate** dalle opinioni di chi sta intorno (*no herding behavior, cascade*);
- **Decentralizzazione**: persone sono capaci di **specializzare e basarsi su conoscenze locali**;
- **Aggregazione**: esistono meccanismi per **trasformare giudizi privati in una decisione collettiva**.

17.2 5 motivi per cui non sempre "funziona"

- **Omogeneità**: necessità che ci sia **diversità** in una folla, per avere abbastanza varietà di approcci / ragionamenti / informazioni private;
- **Centralizzazione**: disastro dello shuttle Columbia attribuibile alla **gestione gerarchica / burocratica** della nasa (chiusa rispetto a ingegneri di "basso livello");
- **Divisione**: informazioni **appartenenti a una sottodivisione non accessibili alle altre** (torri gemelle). Folle lavorano meglio se scelgono autonomamente su cosa lavorare e con quali informazioni;

- **Imitazione:** scelte **visibili ed effettuate in sequenza**, si può formare una **information cascade** (*herding behavior*) in cui solo prime scelte vengono fatte in modo genuino e poi si tende a confermare / copiare;
- **Emotività:** fattori **emotivi** possono portare a pressioni, *istinto di gregge* e, in casi estremi, a **isteria collettiva**.

17.3 Definizione

Compito tipicamente svolto da uno / pochi dipendenti esperti viene svolto in **outsourcing** con un **grande** gruppo di persone / community mediante una **chiamata aperta**.

17.4 Human computation

Processo computazionale che da in outsourcing **alcuni passi** ad umani: computer chiede a persona / crowd di risolvere un problema, lo raccoglie, interpreta e integra le soluzioni (reCAPTCHA).

17.5 Esempi reali

- Ricercatore che vuole dati epr esperimenti;
- Azienda che vende beni (indagini di mercato veloci e a basso prezzo);
- Amministrazione comunale che vuole sapere presenza di buche nelle strade.

17.6 Amazon mechanical turk

Mercato che richiede intelligenza umana per del lavoro dove i player sono:

- **requester** - individuo / organizzazione con lavoro da far svolgere;
- **worker** - persona che fa il lavoro;
- **HIT** (Human Intelligence Task) - unità di lavoro da svolgere alla quale è associato un pagamento;
- **batch** - insieme di HIT caricato da un requester.

L'esito di un HIT o di un batch può venire rappresentato mediatnte una **matrice** n **task** / m **worker**, con v_{ij} valori dati in risposta dal worker i per la task j (numero / testo / ...).

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

La matrice è **sparsa**: non tutti i worker fanno tutti i task e non tutti i task sono fatti da tutti i worker.

17.6.1 Principi di Surowiecki

Amazon mechanical turk rispetta i 4 principi di Surowiecki: diversità di opinioni, indipendenza, decentralizzazione e aggregazione.

17.7 Tipi di task

- **Complex task:** creazione website, sviluppo sistema SW;
- **Simple projects:** sviluppare logo / visual identity;
- **Macro tasks:** scrivere recensione, testare una feature nuova;
- **Micro tasks:** labelling di un'immagine, verificare un indirizzo.

17.7.1 Demartini

Classificazione (capitoli) basata sulla **letteratura scientifica** in vari settori di ricerca, **sistemi ibridi** (human + machine) per:

- DB;
- information retrieval;
- processing di linguaggio naturale;
- semantic web;
- machine learning;
- multimedia processing.

17.7.2 Brabham

4 tipi di task sulla base dei problemi risolti:

- **Knowledge discovery and management** - scoprire e organizzare / gestire conoscenze **già disponibili** ma **disorganizzate**, utile per raccolta e organizzazione info, creazione risorse collettive e reporting;
- **Broadcast search** - trovare uno **specialista** (spesso fuori dal settore - "mente fresca") che svolga il compito, trovi la risposta giusta e dia la soluzione, utile per problemi tecnico-scientifici con soluzioni misurabili;
- **Peer-vetted creative production** - produzione creativa riesaminata da pari, **crowd** produce e seleziona idee creative (sensato perché sarà massa ad usarle), utile per problemi la cui soluzione dipende da gusti e/o mercato;
- **Distributed human-intelligence task** - grandi problemi di data processing decomposti in piccoli task che richiedono intelligenza umana (Amazon mechanical turk), utile per analisi dati su larga scala.

17.7.3 Grier

Classificazione più articolata con tipi di pagamento e tipi di mercato:

- **Crowdcontest**: do in **outsourcing** un compito intero (solitamente) senza scomporlo, mediante un **contest** dove si seleziona e si paga **solo** la risposta migliore (es. design di un logo);
- **Macrotasking**: dare in **outsourcing** a un consulente / libero professionista, pagamento orario (es. traduzioni, creazione app);
- **Microtasking**: compito **suddiviso** in piccole parti, poi aggregate (**il vero Crowdsourcing**);
- **Self-organized crowds**: chiedo che venga svolto un lavoro ma gli individui **cooperano** / **interagiscono**.
- **Crowdfunding**: non si vuole lavoro ma soldi, tante piccole donazioni (gofundme).

2 tipi di pagamento:

- **Pay-all**: tutti i worker che hanno svolto il lavoro vengono pagati (tipico);
- **Pay-one**: solo uno viene pagato (contest).

2 tipi di mercato / crowd:

- **Indipendenti**: ognuno lavora per sé e viene pagato individualmente;
- **Collaborative**: cooperazione fra i worker, a volte si dividono la paga.

		Mercato	
		Crowd indipendenti	Crowd collaborative
Pagamento	Pay-one	1. Crowdcontests	4. Self-organized crowds
	Pay-all	3. Microtasking	2. Macrotasking
+ 5. Crowdfunding			


17.8 Come convincere i worker

2 tipi di motivazioni:

- **Estrinseche**: compito considerato noioso, inutile o spiacevole necessita di **ricompensa aggiuntiva** (soldi, fama, reputazione, il mio tesoro, cercatelo, chissà se qualcuno di voi lo troverà);
- **Intrinseche**: attività consegua a interesse / divertimento del compito stesso, la ricompensa è quindi **intrinseca** nello svolgimento del compito (Games With A Purpose).

17.8.1 Li et al

Classificazione **bidimensionale** che mette isieme **granularità** (microtask / macrotask) e **incentivo** / **motivazione** (denaro / divertimento).



17.9 Tipi di risposte

Domande a risposta singola / multipla, risposta aperta numerica / testuale, collection di dati.

17.9.1 Real world tasks


Sempre con associazione **task - tipo di risposta** con:

- **sentiment analysis** - opinione di una review;
- **search relevance** - data un'interrogazione dire se un documento è pertinente con 2 o N valori;
- **moderazione contenuti** - immagini o siti web, risposta singola S/N;
- **raccolta dati** - points of interest / coordinate geografiche;
- **categorizzazione** - ad es. classificare come attore o come cantante;
- **trascrizione di audio / immagini** - digitalizzazione con dati immediatamente usabili.

Esito di un esperimento di crowdsourcing rappresentabile sempre mediante una **matrice worker / task**.

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

18 Progettare microtask



Il workflow per la definizione di una task si suddivide in 6 parti:

1. **Definire il problema:** comprenderlo per bene in modo da non risolvere il problema sbagliato;
2. **Idea di soluzione:** capire che esperimento effettuare con un progetto vero e proprio (cosa mostrare / chiedere su quanti / quali dati, con quanta ridondanza, quanto pagare e quali controlli di qualità effettuare), fornendo **istruzioni chiare** e raccogliendo **feedback**;
3. **Prototipo di HIT:** implemmentazione di tutto, magari non su tutti i dati e non con tutti i controlli (anche versioni alternative);
4. **Rilascio in laboratorio:** far svolgere il compito ad alcuni collaboratori per capire se ci sono **bug** e iniziare a imbastire la fase di analisi dati;
5. **Test pilota:** far svolgere il compito sulla piattaforma con worker e soldi **veri** su un insieme **fittizio / limitato** di dati oer comprendere scalabilità e collaudare GUI, istruzioni...;
6. **In produzione:** lancio esperimento finale con precauzioni, è difficile avere risposte perfette ed esatte.

La qualità perfetta dei dati ottenuti mediante crowdsourcing è un'**utopia**, ci sono errori, incongruenze ecc. **Si fa il meglio che si può con i dati che si ha.**

19 Qualità

19.1 Tecniche per migliorare / ottenere buona qualità

19.1.1 Task design

Scelte progettuali (pairwise vs singolo), modalità di presentazione, worker nelle migliori condizioni possibili ma **controlli costanti**.

19.1.2 Qualification test

Valutazioni prima del task: se un worker vuole svolgere un task deve prima superare un **test esplicito** (worker sa che sta facendo un test). Voglio selezionare worker **qualificati** e motivati a superare il test (magari senza paga). Il test può essereso **piattaforma** o **interno** al task (prime domande).

19.1.3 Controlli sintattici

Parsing dell'input / preprocessing per evitare **campi vuoti** (matrici sparse), ma anche conteggio caratteri / parole e parsing più sofisticati e **controlli anti copiatura**.

19.1.4 Testi nascosti

Nascosti nelle varie parti del task, domande per definire qualità del worker (spesso facili o di cui si sa già la risposta) e spesso **ripetute** per valutare coerenza.

19.1.5 Monitoraggio tempi

Verifica del tempo impiegato per leggere istruzioni e compito, sia su singole parti che su totale: se troppo o troppo poco il worker viene scartato.

19.1.6 Monitoraggio azioni

Valutazione spostamenti mouse, focus, scrolling, click, ordine inserimento dati, pattern di navigazione fra pagine, mediante **behavioral logger**.

19.1.7 Controlli ex post

Il worker ha finito il task e sottomesso il risultato, posso decidere di:

- non usarli (pagandolo);
- non accettarli (non pagarlo - quando non paga cala mia reputazione come requester);
- non pagarlo e bloccarlo (impedendogli di fare altri task dello stesso batch).

19.2 Ridondanza e aggregazione

Raccogliere più volte lo stesso dato dalla stessa domanda e poi aggregare in un unico dato è una tecnica al cuore del crowdsourcing. La misura della qualità si divide quindi in:

- **qualità individuale** della risposta di un singolo worker;
- **qualità aggregata** delle risposte a un task;
- **qualità di un worker**: qualità media delle sue risposte.

19.2.1 Qualità individuale

Si ripende la matrice **workers / tasks** aggiungendoci la **verità**: singola e nota come unico valore corretto.

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}	...	v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

19.2.2 Qualità aggregata

Dopo aver aggregato tutte le risposte a un task in un valore unico (mediante media, mediana, moda...). **Qualità aggregata** e **qualità individuale**, è proprio l'idea del crowdsourcing.

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}	...	v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

19.2.3 Più formalmente

- Document relevance
- Un oracolo ci dice qual è il valore corretto
- Aggreghiamo a maggioranza
 - (MV, Majority Voting)
 - Moda
- Risposte individuali contengono errori
 - Errore medio > 0, qualità individuale non perfetta
- Risposte aggregate sono OK
 - Errore medio = 0, qualità aggregata massima

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...					
w_m		N	R		

Aggr	R	N	R	...	N
Truth	R	N	R	...	N

- $w_i \in W = \{w_i\}_{i=1\dots m}$: i -esimo worker, e l'insieme dei worker;
- $t_j \in T = \{t_j\}_{j=1\dots n}$: j -esimo task, e l'insieme dei task;
- v_{ij} : i valori (le risposte) dati dal worker i al task j . Risposta mancante: $\perp$;
- $W_j = \{w_i \in W \mid v_{ij} \neq \perp\}$: l'insieme dei worker che hanno risposto al task t_j ;
- $T_i = \{t_j \in T \mid v_{ij} \neq \perp\}$: l'insieme dei task a cui ha risposto il worker w_i ;
- $av_j = F_{agg}(\{v_{ij} \mid w_i \in W_j\})$: i valori aggregati per il task t_j ;
- cv_j : i valori corretti (*correct values*) per il task t_j .

Similitudine media con ground truth dei valori indivisuali è **minore** di quella dei valori aggregati:

$$\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{m} \sum_{j=1}^m \text{sim}(v_{ij}, cv_j) \right) < \frac{1}{n} \sum_{j=1}^n \text{sim}(av_j, cv_j)$$

$$\frac{1}{n} \sum_{j=1}^n \left(\frac{1}{|W_j|} \sum_{i \mid w_i \in W_j} \text{sim}(v_{ij}, cv_j) \right) < \frac{1}{n} \sum_{j=1}^n \text{sim}(av_j, cv_j)$$

19.2.4 Funzioni di aggregazione

$$av_j = F_{aggr}(v_{ij} \mid w_j \in W_j) = F_{aggr}(v_{ij} \mid v_{ij} \neq \perp)$$

Possibili funzioni di aggregazione:

- Moda a maggioranza;
- Media aritmetica;
- Media geometrica;
- Media armonica;
- Mediana.

19.2.5 Esempio aggregazione

- v_{ij} è
 - o Relevant (1)
 - o Not relevant (0)
- Idem per cv_j
- E av_j ?

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...					
w_m		0	1		

Aggr	av_1	av_2	av_3	...	av_n
Truth	1	0	1	...	0

- Moda (MV);
- + valori ammissibili;
- - perso informazioni.

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...				...	
w_m		0	1		

Aggr	1	0	1	...	0
------	---	---	---	-----	---

Truth	1	0	1	...	0
-------	---	---	---	-----	---

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...				...	
w_m		0	1		

Aggr	1	0	2/3	...	1/3
------	---	---	-----	-----	-----

Truth	1	0	1	...	0
-------	---	---	---	-----	---

- Media aritmetica;
- - valori non ammissibili;
- + perdo meno informazioni.

20 Misurazione

Determinare una relazione fra una quantità ed un'unità di misura (**assegnare numeri a oggetti / eventi**), studiato nella **Measurement theory**.

20.1 Definizione 1



Assegnamento $w \in \Omega$ (Ω denota il set di tutti i possibili assegnamenti) è una funzione che assegna valori a oggetti in un set di oggetti D : $w : D \rightarrow \mathbb{R}$ Posso avere diverse misure per la stessa cosa (metri vs pollici), posso cassificare **in colori** (non funziona benissimo), posso fare **aggregazioni** (temp media ultimi x gg).

20.2 Definizione 2

Assegnamento deve essere **omomorfo**: sia $\langle D, R_D \rangle$ una struttura relazionale empirica e $\langle \mathbb{R}, R_{\mathbb{R}} \rangle$ una struttura relazionale numerale, una misurazione $\psi \in \Psi$ è un assegnamento di oggetti in un set D (si denota con $\Psi \subset \Omega$ il set di tutti i misuramenti possibili):

$$\psi : D \rightarrow \mathbb{R}$$

$$\forall x, y \in D (R_D(x, y) \implies R_{\mathbb{R}}(\psi(x), \psi(y)))$$



20.3 Scale di misura

20.3.1 Ratio scale

Scala a **rapporti** "sono il doppio più alto di lui", poco efficiente per le date.

$$y = f(x), f(x) = a * x, a > 0$$

20.3.2 Interval scale

Scala a **intervalli** "negli ultimi 2 giorni c'è stato un aumento di 5°C della temperatura", funziona per le date.

$$y = f(x), f(x) = ax + b, a > 0$$

20.3.3 Ordinal scale

Una misurazione non è un valore ma un **rango** (funziona a classifica), $y = f(x)$ con f monotona crescente.

20.3.4 Nominal scale

Quantitativa e relativa a categorie, può essere **dicotomica** o no, non ci sono valutazioni su ratei, distanze, ranghi, $y = f(x)$ con f iniettiva.

20.3.5 Recap

	(increasing)		(a > 0)	
	1-to-1	Monotonic	$a \cdot x + b$	$a \cdot x$
Nominal	✓	✓	✓	✓
Ordinal	✗	✓	✓	✓
Interval	✗	✗	✓	✓
Ratio	✗	✗	✗	✓

20.3.6 Operazioni ammissibili

Data una scala, solo alcune operazioni hanno senso (sono **legittime**):

- Relazionali: =, ≠, <, >;
- Aritmetiche: +, -, ×, /;
- Statistiche: media, mediana, moda.

	=, ≠	>, <	+, -	×, ÷
Nominal	✓	✗	✗	✗
Ordinal	✓	✓	✗	✗
Interval	✓	✓	✓	✗
Ratio	✓	✓	✓	✓

	Mode	Median	Mean	
			Arithmetic	Geometric, Harmonic
Nominal	✓	✗	✗	✗
Ordinal	✓	✓	✗	✗
Interval	✓	✓	✓	✗
Ratio	✓	✓	✓	✓

Legit, but info loss!

20.4 Aggregazione Reloaded

Quando si aggregano giudizi su scale complesse (non binarie), sorgono problemi legati alla perdita di informazione e alla scelta della funzione corretta.

20.4.1 Il problema delle Scale Ordinali

Se abbiamo giudizi su scala ordinale (es. scala Likert a 6 valori: *Pants on Fire ... True*), l'approccio standard prevede l'uso della **Moda** o del **Majority Vote**. Tuttavia:

- **Perdita di informazione:** Una situazione con 51% *True* e 49% *Mostly True* viene trattata come 51% *True* e 49% *False*. La moda ignora la distribuzione dei voti "perdenti".
- **Magnitudine dell'errore:** Errori piccoli dovrebbero pesare meno di errori grandi, ma la moda non distingue la "distanza" tra le categorie.

Per ovviare a questo, spesso si mappano le categorie su numeri (es. 0..5). Sebbene teoricamente rischioso (non è garantito che la distanza tra 1 e 2 sia uguale a quella tra 4 e 5), permette di usare:

- **Mediana:** Robusta rispetto agli outlier.
- **Media:** Più sensibile, ma richiede cautela nell'interpretazione.

20.4.2 Le diverse funzioni di Media

La scelta della funzione di aggregazione "deforma" lo spazio di valutazione in modo diverso. Date le osservazioni x , valgono le disuguaglianze: $HM \leq GM \leq AM$.

- **Media Aritmetica (AM):** $AM = \frac{1}{n} \sum x_i$.
 - Considera uguali un miglioramento da 0.1 a 0.2 e uno da 0.8 a 0.9 (incremento lineare).
 - Molto sensibile agli outlier alti.
- **Media Geometrica (GM):** $GM = \sqrt[n]{\prod x_i} = e^{\frac{1}{n} \sum \ln x_i}$.
 - "Stira" lo spazio verso i valori alti: è più difficile migliorare quando si è già vicini alla perfezione (1.0).
 - Premia il miglioramento su task "difficili" (es. passare da 0.8 a 0.9 vale più che passare da 0.1 a 0.2).
 - Utile in contesti come i Motori di Ricerca (meglio gestire bene le query difficili).
- **Media Armonica (HM):** $HM = \frac{n}{\sum \frac{1}{x_i}}$.
 - Tende a essere vicina al valore **minimo** della distribuzione.
 - Molto penalizzante per i valori bassi (usata nella F-Measure).

20.4.3 Outlier e Robustezza

- **AM:** Un singolo errore enorme (outlier) "sporca" significativamente il risultato (es. un worker che inserisce 1000 in una scala 0-10).
- **Mediana:** È la misura più robusta. Se un worker sbaglia completamente (outlier), la mediana spesso non cambia.

20.4.4 Recap

Non esiste una funzione "giusta" a priori. Bisogna scegliere la funzione di aggregazione in base al dominio applicativo (es. voglio premiare l'eccellenza? Voglio penalizzare i fallimenti gravi? Voglio ignorare gli outlier?).

21 Accordo

Assunzione, congettura che viene sfruttata come **proxy** / **approssimazione** della realtà. se non so il valore corretto di una risposta posso comunque:

- **Accordo globale** - guardare quanto worker sono **in accordo tra loro** come insieme di tutti i worker che hanno svolto lo stesso task: se sono d'accordo allora **dati affidabili**, altrimenti no (magari ne vanno raccolti di più / bisogna cambiare).
- **Accordo individuale** - guardare quanto il singolo worker è **in accordo con gli altri worker** che hanno svolto lo stesso task: se è d'accordo con gli altri si *ipotizza* che la **qualità del worker sia alta**, altrimenti si assume come bassa (solitamente worker con qualità bassa vengono scartati).

21.1 Percent(age) agreement

Partiamo da solita matrice **workers** / **tasks** e la trasformiamo in una **scala nominale binaria non sparsa**.

• Matrice workers / task → "Confusion matrix"

	t_1	t_2	t_3	...	t_n
w_1	Y	Y	Y	Y	N
w_2	N	Y	Y	N	N

		w_2	
		Y	N
w_1	Y	2	2
	N	0	1

La percentuale di accordo tra due worker è semplice da calcolare con la matrice d confusione: $p = \frac{a+d}{a+b+c+d}$

		w_2	
		Y	N
w_1	Y	a	b
	N	c	d

Pro:

- Facile da calcolare;
- Intuitivo;
- Consente confronti;
- Facilmente estendibile a **più categorie** (finché si resta in scala nominale).

Contro

- Agreement by chance, accordo casuale tra gli worker (2 cat: 50%, 3 cat: 33%);
- Categorie sbilanciate (se worker sanno che 90% di risposte sono N diranno a loro volta N al 90-100%).

21.2 Cohen's kappa (K)

Idea: **migliorare / correggere percent agreement** tenendo conto dell'**agreement by chance**:

- sempre 2 worker;
- sempre scala nominale $K = \frac{p_o - p_e}{1 - p_e}$;
- p_o è percent agreement osservato;
- p_e è percent agreement by chance atteso (calcolato usando dati per stimare probabilità che ogni worker scelga una data categoria).

21.2.1 Esempio

- 50 task
 - Ad es., dire per 50 foto se contengono un'auto o no
- 2 worker
 - Ogni foto viene giudicata da entrambi (no sparsità)

	t_1	t_2	t_3	...	t_{50}
w_1	Y	Y	Y	...	N
w_2	N	Y	Y	...	N

		w_2	
		Y	N
w_1	Y	20	5
	N	10	15

• $p_o = \frac{20+15}{20+5+10+15} = \frac{35}{50} = 0.7$ (come prima)

w_1 ha detto 25 volte Y (e 25 volte N) $\rightarrow w_1$ ha detto 50% di volte Y (e 50% di volte N)

w_2 ha detto 30 volte Y (e 20 volte N) $\rightarrow w_2$ ha detto 60% di volte Y (e 40% di volte N)

Probabilità che entrambi dicano Y: $p_Y = \frac{a+b}{a+b+c+d} \cdot \frac{a+c}{a+b+c+d} = 0.5 \times 0.6 = 0.3$

Probabilità che entrambi dicano N: $p_N = \frac{c+d}{a+b+c+d} \cdot \frac{b+d}{a+b+c+d} = 0.5 \times 0.4 = 0.2$

$p_e = p_Y + p_N = 0.3 + 0.2 = 0.5$

Quindi $K = \frac{p_o - p_e}{1 - p_e} = \frac{0.7 - 0.5}{1 - 0.5} = 0.4$ (notare che K può essere < 0).

21.2.2 Scott's pi

Stessa idea di Cohen's kappa, correggendo / normalizzando sulla base dell'accordo casuale. **ENTRAMBI LIMITATI, SOLO 2 WORKER.**

21.3 Fleiss kappa (K)

Estende Scott's pi con m worker, scala nominale e un n° di categorie a piacere. Per misurare accordo tra i worker si ricorre a **pairwise agreement**, considerando tutte le coppie di worker e vedendo quale frazione di coppie è in accordo.

21.3.1 Definizione

Definizione generale: $K = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$, come Cohen's kappa ma con pairwise agreement invece di percent agreement.

- m : numero di worker;
- n : numero di task;
- k : numero di categorie;
- n_{ij} : numero di worker che hanno assegnato task i alla categoria j ;
- Proporzione di assegnamenti a categoria j : $p_j = \frac{1}{nm} \sum_{i=1}^n n_{ij}$;
- Somma dei loro quadrati: $\bar{P}_e = \sum_{j=1}^k p_j^2$;
- Coppie worker-worker in accordo rispetto a tutte le coppie possibili: $P_i = \frac{2}{m(m-1)} \sum_{j=1}^k \frac{n_{ij}(n_{ij}-1)}{2}$;
- Media su tutti gli item: $\bar{P} = \frac{1}{n} \sum_{i=1}^n P_i$.

21.4 Sfruttare l'accordo

Escludendo i worker che hanno agreement con l'aggregazione inferiore (magari iterativamente), pesarli di meno nell'aggregazione (in caso di media pesata) o utilizzando un modello più sofisticato.

		w_2		
		Y	N	
w_1	Y	a	b	$a + b$
	N	c	d	$c + d$
		$a + c$	$b + d$	$a + b + c + d$

		w_2		
		Y	N	
w_1	Y	20	5	25
	N	10	15	25
		30	20	50