

Riassunto Social Computing

Trentin Tommaso

January 22, 2026

Contents

1	Social media	3
1.1	Classificazione	3
2	Grafi e Reti	3
2.1	Nodi vs. Attori (dipende dal contesto)	3
2.2	Archi	3
2.3	Grafi	4
2.3.1	Proprietà	4
2.4	Gradi	4
2.5	Densità	5
2.6	Rappresentazioni	5
2.6.1	Lista degli archi	5
2.6.2	Lista di adiacenza	5
2.6.3	Matrice di adiacenza	5
2.7	Reti	6
2.7.1	Reti sociali	6
2.7.2	Analisi delle reti sociali (Social Network Analysis - SNA)	6
3	Reti e Misure	6
3.1	Centralità	6
3.1.1	Centralità di grado	6
3.1.2	Centralità di grado normalizzata	7
3.1.3	Betweenness centrality	7
3.1.4	Betweenness centrality normalizzata	7
3.1.5	Centralità di vicinanza (Closeness centrality)	8
3.1.6	Confronti	8
3.2	PageRank	8
3.2.1	PageRank - vettori e matrici	9
3.2.2	Markov chain	9
3.2.3	Markov chain - autovettore	9
3.2.4	Teleporting	9
3.2.5	PageRank - implementazione	10
3.3	HITS	10
3.3.1	Procedimento - "Algoritmo"	11
3.3.2	HITS - vettori e matrici	11
3.3.3	HITS - autovettori	11
3.3.4	HITS - MM^T	12
3.3.5	HITS - $M^T M$	12
3.4	PageRank / HITS - confronto	13
4	Social Network Analysis - terminologia	13
5	Transitività	14
5.1	Coefficiente di clustering locale	14
5.2	Coefficiente di clustering globale	15
6	Reciprocità	16
6.1	Calcolo	16
7	Bilanciamento	16

7.1	Bilanciamento Sociale	16
7.2	Status sociale	17
8	Degree distributions reali	17
9	La Legge di Potenza (Power Law)	18
9.1	Che cos'è (In parole povere)	18
9.2	Il trucco del Grafico Log-Log	18
9.3	Esempi Reali (Dalle Slide)	18
9.4	Nota: Differenza con Zipf	18
9.5	Test	18
9.6	Coefficiente di clustering	19
10	Diffusione informazioni	19
10.1	Milgram	19
10.2	Dodds	19
10.3	Erdos	19
10.4	Proprietà reti reali	19
11	Modelli delle reti	19
11.1	Reti regolari	19
11.2	Reti casuali	20
11.2.1	Modello $G(n,m)$	20
11.2.2	Modello $G(n,p)$	20
11.2.3	Differenza	21
11.2.4	$G(n,p)$ connesso?	21
11.2.5	Recap	21
11.3	Reti small-world	21
11.3.1	Procedura	22
11.3.2	Reti che ci interessano	22
11.3.3	Distribuzione dei gradi	22
11.3.4	Recap	22
11.4	Reti scale free	22
11.4.1	Diametro	22
11.5	Reti con attaccamento preferenziale	23
11.5.1	Sul modello scale-free	23
11.6	Sunto	23
11.7	Attaccamento preferenziale non lineare	23
11.8	Attrattività	23
11.9	Fitness	23
11.10	Random Walk	24
11.10.1	FUNZIONA	24

1 Social media

Tecnologie che facilitano **creazione** e **condivisione** di informazioni, idee, interessi e altre forme di espressione mediante **community visuali** e **network**.


- Applicazioni internet-based **Web 2.0**;
- Sviluppate avendo come scopo principale la gestione di **User-generated content**;
- Utenti creano **profili** e identità service-specific che vengono mantenuti dalla social media organization;
- Facilitano lo sviluppo di **social network online** connettendo il profilo di un utente con quello di altri individui / organizzazioni.

1.1 Classificazione

2 dimensioni principali: **Social presence** / **Media richness** (quanto sembra di essere "lì") e **Self presentation** / **Self disclosure** (quanto si rivela di sé).

		Social presence/ Media richness		
		Low	Medium	High
Self- presentation/ Self- disclosure	High	Blogs	Social networking sites (e.g., Facebook)	Virtual social worlds (e.g., Second Life)
	Low	Collaborative projects (e.g., Wikipedia)	Content communities (e.g., YouTube)	Virtual game worlds (e.g., World of Warcraft)

Visione articolata:



2 Grafi e Reti

2.1 Nodi vs. Attori (dipende dal contesto)

$$V = v_1, v_2, \dots, v_n$$

- Grafo del Web:
 - Nodi = pagine/siti web;
 - Archi = link ipertestuali.
- Grafo sociale di amicizie:
 - Nodi = persone;
 - Archi = amicizie, conoscenze...

Grandezza del grafo (size): $|V| = n$

2.2 Archi

$$E = e_1, e_2, \dots, e_m$$

Gli archi (edges) connettono nodi (ties / relationships). In un settng sociale:

- Nodi = entità sociali (persone);
- Archi = relazioni fra persone;

Grandezza dell'insieme degli archi: $|E| = m$

2.3 Grafi

Un grafo G si può rappresentare come coppia dell'insieme di nodi V e archi E :

$$G(V, E)$$

2.3.1 Proprietà

- Archi possono avere direzioni ($e(v_1, v_2) \neq e(v_2, v_1)$);
- **Grafo pesato:** ad ogni arco è associato un peso ($G(V, E, W)$);
- Grafo $G'(V', E')$ è **sottografo** di $G(V, E)$ se $(V' \subseteq V)$ e $(E' \subseteq (V' \times V') \cap E)$;
- **Vicinato** di un nodo: tutti i nodi ad esso collegati mediante archi (incoming / outgoing neighbors);
- **Cammino:** sequenza di archi t.c. ogni arco è incidente allo stesso nodo del successivo;
- **Connessione:**
 - Un **nodo** v_i è connesso al nodo v_j se esiste cammino da v_i a v_j (e viceversa);
 - Un **grafo** è connesso se esiste un cammino fra ogni coppia di nodi (*fortemente* se il cammino è diretto, *debolmente* altrimenti)
- **Componenti:**
 - **Componente in un grafo indiretto:** è un sottografo massimale connesso.
 - * Esiste un cammino indiretto fra ogni coppia di nodi nella componente.
 - * "*Massimale*" significa che se si aggiungono altri nodi del grafo originale, il sottografo non è più connesso.
 - **Componente Fortemente Connessa** (Strongly Connected Component, **SCC**): In un grafo diretto, si ha una SCC quando per ogni coppia di nodi $u, v \in SCC$ esiste un cammino *diretto* da u a v e uno da v a u .
 - **Componente Debolmente Connessa** (Weakly Connected Component, **WCC**): In un grafo diretto, si ha una WCC quando per ogni coppia di nodi $u, v \in WCC$ esiste un cammino *indiretto* da u a v .
 - Un grafo può avere diverse componenti (ne ha solo 1 se l'intero grafo è connesso).
 - **Giant Connected Component:** è la componente più grande del grafo e contiene "quasi tutto" il grafo (la maggior parte dei nodi).

2.4 Gradi

$\pi(d) = d_1, d_2, \dots, d_n$ **Grado di un nodo i d_i :** numero di archi collegati a quel nodo (entranti = **in-degree** d_i^{in} , uscenti = **out-degree** d_i^{out}).

Degree distribution: per ogni nodo, quanti nodi hanno quel grado:

$$p_{grado} = \frac{numNodi_{grado}}{numNodi}, \sum_{d=0}^{\infty} p_{grado} = 1$$

Teorema: sommatoria dei gradi di un grafo indiretto è 2 volte il numero degli archi

$$\sum_i d_i = 2|E|$$


Corollari:

1. numero di nodi con grado dispari è pari;
2. in ogni grafo diretto la sommatoria degli in-degree è uguale alla somma degli out-degree

$$\sum_i d_i^{out} = \sum_j d_j^{in}$$

Grafico della degree distribution

- L'asse delle x rappresenta il grado
- L'asse delle y rappresenta la frazione (relativa) o il numero (assoluta) dei nodi che hanno quel grado
- Idem per in- e out-degree
- Spesso su scala log-log
- Sui social media, di solito decrescente:
 - Tanti utenti/profili con poche connessioni
 - Alcuni utenti con un numero di amici molto alto
 - (Spesso Power-law degree distribution, non qui)



2.5 Densità


Quanti archi ci sono rispetto a tutti gli archi possibili:

- Grafi **indiretti** - $D = \frac{2|E|}{|V|(|V|-1)}$
- Grafi **diretti** - $D = \frac{|E|}{|V|(|V|-1)}$

2.6 Rappresentazioni


2.6.1 Lista degli archi

- Ogni elemento della lista è un arco da un nodo u a un nodo v (u, v);
- Ok anche per grafi diretti;
- Non ok per nodi isolati: non vengono rappresentati.



2.6.2 Lista di adiacenza

- Per ogni nodo, lista di tutti i nodi a cui è connesso;
- Solitamente ordinata;
- Ok anche per grafi diretti.




Node	Connected To
v_1	v_2
v_2	v_1, v_3, v_4
v_3	v_2, v_4
v_4	v_2, v_3, v_5, v_6
v_5	v_4
v_6	v_4

2.6.3 Matrice di adiacenza

- Quadrata (1 se c'è un arco fra v_i e v_j , 0 altrimenti);

- Simmetrica per grafi indiretti;
- Ok per grafi diretti (generalmente non simmetrica);
- Auto-archi (self-link) sulla diagonale;
- Per reti sociali le matrici di adiacenza sono sparse (quasi tutti 0);
- Ok per grafi pesati ()
- Quadrata (w_{ij} se c'è un arco fra v_i e v_j , 0 altrimenti);



2.7 Reti

Una rete (**network**) è un grafo (solitamente grande) con nodi e archi che esistono nel mondo reale, solitamente per rappresentare problemi su una rete si usano grafi e risultati della teoria dei grafi.

2.7.1 Reti sociali

Reti i cui elementi hanno una struttura sociale:

- Insieme di **attori** = individui / organizzazioni;
- Insieme di **legami** = connessioni fra attori.

Esempi: rete di familiari / amici / colleghi.

2.7.2 Analisi delle reti sociali (Social Network Analysis - SNA)

Settore interdisciplinare (scienze sociali + statistica + teoria dei grafi + reti complesse + informatica) che studia queste reti.

3 Reti e Misure

3.1 Centralità

Misura che indica quanto un nodo è centrale, basandosi su definizioni / assunzioni.


3.1.1 Centralità di grado

Più è alto il grado di un nodo, più è centrale.

$$C_d(v_i) = d_i$$

Es.:

- Degree centrality di v_1 è $d_1=8$
- Per gli altri $d_j = 1, j \neq 1$



In grafi diretti si possono usare in-degree, out-degree o combinazione dei due:


- $C_d(v_i) = d_i^{in}$ (prestige);
- $C_d(v_i) = d_i^{out}$ (gregariousness);
- $C_d(v_i) = d_i^{in} + d_i^{out}$.

In pratica in-degree è il più usato / interessante.

3.1.2 Centralità di grado normalizzata

Utile per confrontare grafi differenti:

- Normalizzazione per grado massimo possibile - $C_d^{norm}(v_i) = \frac{d_i}{n-1}$;
- Normalizzazione per grado massimo effettivo - $C_d^{max}(v_i) = \frac{d_i}{\max_j d_j}$;
- Normalizzazione per somma dei gradi - $C_d^{sum}(v_i) = \frac{d_i}{\sum_j d_j} = \frac{d_i}{2|E|} = \frac{d_i}{2m}$.




3.1.3 Betweenness centrality

Misura quanto un nodo è importante nel connettere altri nodi tramite cammini (si guardano solo shortest paths).

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}}$$

- $\sigma_{st}(v_i)$: numero di shortest paths da s a t che passano per v_i ;
- σ_{st} : numero di shortest paths da s a t .



3.1.4 Betweenness centrality normalizzata

Nel caso migliore il nodo v_i è su tutti gli shortest paths da s a t , quindi $\frac{\sigma_{st}(v_i)}{\sigma_{st}} = 1, \forall s, t$

$$C_b(v_i) = \sum_{s \neq t \neq v_i} \frac{\sigma_{st}(v_i)}{\sigma_{st}} = \sum_{s \neq t \neq v_i} 1 = 2 \binom{n-1}{2} = (n-1)(n-2)$$

Quindi il valore massimo è $(n-1)(n-2)$, per normalizzarlo: $C_b^{norm}(v_i) = \frac{C_b(v_i)}{2 \binom{n-1}{2}}$


3.1.5 Centralità di vicinanza (Closeness centrality)

$$C_c(v_i) = \frac{1}{\bar{l}_{v_i}}$$

I nodi influenti / centrali possono raggiungere velocemente gli altri nodi (considero gli shortest path verso tutti gli altri nodi).

$$\bar{l}_{v_i} = \frac{1}{n-1} \sum_{v_j \neq v_i} l_{i,j}$$

- $l_{i,j}$: lunghezza cammino più breve da v_i a v_j ;
- $\bar{l}_{v_i}$: lunghezza media dei cammini più brevi più brevi da v_i .




3.1.6 Confronti

	Low Degree	Low Closeness	Low Betweenness
High Degree		Node is embedded in a community that is far from the rest of the network	Ego's connections are redundant - communication bypasses the node
High Closeness	Key node connected to important/active alters		Probably multiple paths in the network, ego is near many people, but so are many others
High Betweenness	Ego's few ties are crucial for network flow	Very rare! Ego monopolizes the ties from a small number of people to many others	

3.2 PageRank

Archì che vengono da **nodì importanti** (più centrali) dovrebbero **aumentare di più la centralità** rispetto a archì che vengono da nodi meno centrali.



Notazione:


- $r(v)$ PageRank della pagina v ;
- $I(v)$ set di pagine che citano v ;

- $O(v)$ set di pagine citate da v .

Ogni pagina u ha il suo valore PageRank $r(u)$, la pagina v riceve dalla pagina u una porzione del suo PageRank uguale alla porzione ricevuta da tutte le altre pagine citate da u : $\frac{r(u)}{|O(u)|}$

3.2.1 PageRank - vettori e matrici

Si possono collezionare tutti i valori PageRank di tutte le pagine u_i in un vettore $r = [r(u_0), r(u_1), \dots, r(u_n)]$




Si costruiscono i vettori r **iterativamente, tutti assieme**. Per andare da r_0 iniziale a r_1 mediante una matrice P tale che $r_{i+1} = r_i \times P$.

3.2.2 Markov chain

Dato un grafo / matrice di adiacenza con n stati si ha una matrice $n \times n$ P con le probabilità di transizione. A ciascun istante di tempo la catena di Markov è in uno degli n stati.

$\forall$ stato corrente $i \in [1..n]$, la catena di Markov (P) dice la probabilità che il prossimo stato sia j , $\forall j \in [1..n]$.



Si può rappresentare la posizione corrente in uno stato i con un vettore $x = (x_1, \dots, x_n)$ dove tutti i componenti hanno valore 0 tranne l' i -esimo che ha valore 1 e rappresenta la posizione nello stato i .

Il vettore di probabilità nel prossimo step si può trovare guardando la matrice P alla i -esima riga, in modo da controllare le probabilità per procedere al prossimo stato partendo da i .


3.2.3 Markov chain - autovettore

Quindi, per ogni step $x_{i+1} = x_i \times P$ ma stiamo cercando una distribuzione stabile $x_{i+1} = x_i$, cerchiamo quindi x tale che $x = x \times P$ (x autovettore di P).

Per ogni catena **ergodica (fortemente connessa e in cui in ogni step si può essere in ogni stato con probabilità > 0)** ogni stato ha un rate di visite a lungo termine per cui viene visitato proporzionalmente.

3.2.4 Teleporting

Nella pratica (Web) non sempre si hanno situazioni ergodiche, ma navigando si potrebbe "saltare" ad un'altra pagina random: "ciascuna pagina è collegata con qualsiasi altra pagina" (con basse probabilità).



3.2.5 PageRank - implementazione

Catena di Markov, ogni pagina ha una propria probabilità per cui, durante il percorso random tra le pagine, l'utente si trovi lì

Formula

- Power iteration
 - $\mathbf{r}_{i+1} = \mathbf{r}_i \cdot \mathbf{P}'$

$$\mathbf{r}_{i+1} = (1-d) \cdot \mathbf{r}_i \cdot \mathbf{P} + d \cdot \mathbf{r}_i \cdot \begin{pmatrix} 1/N & \dots & 1/N \\ \vdots & \ddots & \vdots \\ 1/N & \dots & 1/N \end{pmatrix}$$

- d : probability of teleporting (for ex., 0.1)
- N : # of nodes/pages
- (here
 - $\mathbf{P}$ is the adjacency matrix without teleporting,
 - $\mathbf{P}'$ is the adjacency matrix with teleporting)

1. Costruzione matrice P' (matrice di adiacenza P + teleporting (ergodic));
2. Inizio da vettore di probabilità r_0 ;
3. $r_{i+1} = r_i \times P$;
4. Se $|r_{i+1} - r_i| < \epsilon$ stoppa, altrimenti ripeti;
5. Il vettore r trovato ($r = r \times P'$, o $r \times P'$) è il PageRank di tutte le pagine, e l'autovettore di P' .

3.3 HITS


Idea: costruire 2 set di pagine collegati:


- **Hub pages (H)** contenenti (buoni) link ad altre pagine (yahoo, buoni bookmark,...);
- **Authority pages (A)** con persone / entità ben organizzate nel web (w3c, Knuth's homepage,...).

L'algoritmo lavora su un set ristretto di pagine Root Set (RS), che si espande con:

- $I(v)$ in-pages (tutte le pagine u tali che $\exists v \in RS, u \rightarrow v$);
- $O(v)$ out-pages (tutte le pagine u tali che $\exists v \in RS, v \rightarrow u$).

Si ottiene così il Base Set (BS) con buone pagine candidate Hub / Authority e su cui l'algoritmo poi lavora, selezionando H e A mediante un controllo su ogni pagina x in BS per i valori di **hubness** ($h(x)$) e **authority** ($a(x)$).





3.3.1 Procedimento - "Algoritmo"

1. Assegnazione valori iniziali di $h(x)$ e $a(x)$ a ogni pagina x del BS (inizialmente $h(x) = a(x) = 1$);
2. Aggiornamento iterativo, con la precedente formula, di $h(x)$ e $a(x)$;
3. Stop quando converge ($h(x)$ e $a(x)$ non variano più);
4. Alla fine si riconoscono pagine "top hub" e "top authority".

3.3.2 HITS - vettori e matrici

Formalizzazione in vettori / matrici come PageRank.

• Let us build 2 (column!) vectors, for $\mathbf{h}$ and $\mathbf{a}$:

• $\mathbf{h} =$


$\mathbf{h}(u_0)$	...	$\mathbf{h}(u_i)$	...	$\mathbf{h}(u_n)$
-------------------	-----	-------------------	-----	-------------------

• $\mathbf{a} =$

$\mathbf{a}(u_0)$	...	$\mathbf{a}(u_i)$	...	$\mathbf{a}(u_n)$
-------------------	-----	-------------------	-----	-------------------

$\mathbf{h}(x) = \sum_{x \rightarrow y} \mathbf{a}(y)$

Per calcolare h dell' i -esimo componente si sommano tutti i componenti corrispondenti alle out-pages di u_i e si sommano, moltiplicando quindi a per $l'i$ -esima riga della matrice di adiacenza.



Quindi, moltiplicando l' i -esima riga di M per a si ottiene l' i -esimo componente di h , e moltiplicando tutta M per a si ottiene tutto h .

$$h = Ma$$

e, di conseguenza:

$$a = M^T h$$

3.3.3 HITS - autovettori

Se abbiamo


- $h = Ma$
- $a = M^T h$

per sostituzione otteniamo

- $h = Ma = MM^T h$
- $a = M^T h = M^T Ma$

h è quindi l'autovettore di MM^T e a è l'autovettore di $M^T M$.

3.3.4 HITS - MM^T



Questa matrice rappresenta l'**Accoppiamento Bibliografico** (Bibliographic Coupling). Ci dice quanto due nodi sono simili basandosi su "chi citano" (o chi linkano).


- **Definizione:** Il valore nella cella $MM^T[i, j]$ conta il numero di nodi che sono **co-linkati** da i e da j . In altre parole, conta quante destinazioni hanno in comune.
- **La Logica Matematica:** Il valore aumenta di 1 quando esiste un nodo k che funge da "ponte comune", tale che:

$$M[i, k] = 1 \quad \text{e} \quad M[j, k] = 1$$

(Ovvero: i linka k E j linka k).

- **Esempio (dalla figura):** Consideriamo $MM^T[4, 2]$ (incrocio tra nodo 4 e nodo 2). Il risultato è **2**.
 - Il nodo 4 punta verso: **2, 3, 5**.
 - Il nodo 2 punta verso: **3, 5**.
 - Hanno in comune i nodi **3** e **5** → Totale: 2 destinazioni comuni.
- **Proprietà:**
 - La matrice è sempre **simmetrica** ($MM^T[i, j] = MM^T[j, i]$).
 - Sulla diagonale principale ($MM^T[i, i]$) troviamo il grado di uscita (out-degree) del nodo i , cioè quanti link totali partono da quel nodo.

3.3.5 HITS - $M^T M$




Questa matrice rappresenta la **Co-citazione** (Co-citation). È il concetto duale rispetto al precedente: misura la similarità tra due nodi basandosi su "chi li linka" (chi punta a loro).

- **Definizione:** Il valore nella cella $M^T M[i, j]$ conta quanti nodi esterni puntano SIA al nodo i CHE al nodo j .
- **La Logica Matematica:** Il valore aumenta di 1 quando esiste un nodo k (una fonte comune) tale che:

$$M[k, i] = 1 \quad \text{e} \quad M[k, j] = 1$$

(Ovvero: k linka i E k linka j).


- **Esempio (dalla figura):** Consideriamo $M^T M[3, 5]$ (incrocio tra nodo 3 e nodo 5). Il risultato è **2**.
 - Chi punta al nodo 3? I nodi **2** e **4**.
 - Chi punta al nodo 5? I nodi **2** e **4**.
 - I "cittadini" in comune sono il **2** e il **4** → Totale: 2 fonti comuni.
- **Proprietà:**
 - Anche questa matrice è sempre **simmetrica** ($M^T M[i, j] = M^T M[j, i]$).
 - Sulla diagonale principale ($M^T M[i, i]$) troviamo il **grado di ingresso** (in-degree) del nodo i , cioè quanti link totali arrivano a quel nodo.



3.4 PageRank / HITS - confronto

- **PageRank** (Google)
 - **PRO:** Robusto contro lo spam (è difficile farsi linkare da siti autorevoli), indice di qualità valido per l'intero Web.
 - **CONTRO:** Non è specifico per la query (è un valore statico calcolato "offline"), calcolo complesso su grafi immensi.
- **HITS** (Kleinberg)
 - **PRO:** Specifico per la query (viene calcolato sul sottografo dei risultati), distingue tra *Hubs* e *Authorities*.
 - **CONTRO:** Facilmente spamabile (basta creare falsi Hub), problemi di convergenza, costo computazionale alto.



4 Social Network Analysis - terminologia



- **Local bridge:** arco tra due nodi che sarebbero altrimenti "lontani", ha un **grado k** (NON IL GRADO DEL NODO) che rappresenta la distanza che ci sarebbe senza quell'arco (Tamara - Boris ha grado 3);
- **Global bridge:** arco che, se rimosso, disconetterebbe la rete (Trevor - Tom, Alex - Roger);
- **Triangle:** sottografo completo di 3 nodi (Trevor - George - Keith);
- **Weak tie:** arco che appartiene a qualche triangolo (Mike - Peter);

- **Strong tie**: arco che appartiene a molti triangoli (Trevor - George);
- **Geodensic** (tra due nodi): cammino più corto tra di loro, distanza = n° archi (geodensico tra Tom e Mike = Tom - Trevor - Mike);
- **Diametro** di una rete: geodensico più lungo della rete (Steve - Nigel: 6);
- **Grado** di un nodo: n° di archi (differenza in in-degree e out-degree su reti con direzioni);
- **Distribuzione di grado**: per ogni grado, il numero di nodi aventi quel grado;
- **Densità**: proporzione di archi che ha la rete (n° archi / n° massimo possibile nella rete);
- **Coefficiente di clustering** (C) di un nodo: n° archi con i suoi vicini / n° massimo possibile con i vicini ($n(n-1)/2$) ($C(Keith) = 1/(3*2/2) = 1/3$), il C della rete è pari alla media su tutti i nodi.

Node	Name	Degr	PR	HITS	Closeness	Betweenness
1	Steve	1	0.036	0.026	0.29	0.00
2	Trevor	5	0.14	0.15	0.55	0.32
3	Boris	2	0.057	0.074	0.41	0.030
4	Roger	2	0.074	0.021	0.34	0.17
5	Mike	6	0.16	0.16	0.60	0.63
6	George	4	0.11	0.14	0.52	0.15
7	Keith	3	0.087	0.092	0.40	0.17
8	Nigel	1	0.043	0.006	0.26	0.00
9	Tamara	3	0.081	0.11	0.40	0.038
10	Alex	3	0.091	0.068	0.46	0.030
11	Dan	1	0.035	0.044	0.39	0.00
12	Tom	1	0.034	0.044	0.36	0.00
13	Peter	2	0.060	0.064	0.43	0.00



5 Transitività


In una rete sociale si ha **transitività** quando "un amico di un mio amico è mio amico", ha come indici *coefficiente di clustering locale* (relativo a singolo punto) e *coefficiente di clustering globale* (relativo alla rete, media degli altri), questi sono correlati ma $\neq$.

5.1 Coefficiente di clustering locale

Misura la transitività a livello dei singoli nodi, controllando quanto i vicini di un nodo v_i sono a loro volta connessi.

$$C(v_i) = \frac{\text{Number of Pairs of Neighbors of } v_i \text{ That Are Connected}}{\text{Number of Pairs of Neighbors of } v_i}.$$

In un grafo indiretto il denominatore è $\binom{d_i}{2} = d_i(d_i - 1)/2$.





- Linee sottili: connessioni ai vicini;
- Linee tratteggiate: archi mancanti fra vicini;
- Linee spesse: vicini connessi (quando nessun vicino è connesso $C = 0$, quando tutti sono connessi $C = 1$).


5.2 Coefficiente di clustering globale

Misura transittività in grafi indiretti in 3 modi equivalenti:

- **1. Conto i cammini di lunghezza 2 e controllo se esiste il terzo arco (ossia, il cammino è chiuso)**

$$C = \frac{|\text{Closed Paths of Length 2}|}{|\text{Paths of Length 2}|}$$

- **2. Oppure, conto i triangoli (e mi riconduco a 1.)**
 - Siccome ogni triangolo ha 6 cammini chiusi di lunghezza 2 (triangolo abc --> cammini ab, bc, ca, ac, cb, ba):
$$C = \frac{(\text{Number of Triangles}) \times 6}{|\text{Paths of Length 2}|}$$


- **3. Oppure, conto le triple**
- **Triple:** un insieme ordinato di tre nodi, connesso
 - da due archi (tripla aperta), o
 - da tre archi (tripla chiusa)



$v_i v_j v_k$ e $v_j v_k v_i$ sono triple differenti

- Gli stessi elementi
- Nella prima manca l'arco $e(v_k, v_i)$
- Nella seconda manca $e(v_i, v_j)$

Un triangolo ha 3 triple


Quindi:

$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$

$v_i v_j v_k$ e $v_k v_j v_i$ sono la stessa tripla

- "Di tutte le triple di nodi connessi, prendo quelle chiuse, ossia i triangoli * 3"

Esempio



$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$

$$= \frac{2 \times 3}{2 \times 3 + \underbrace{2}_{v_2 v_1 v_4, v_2 v_3 v_4}} = 0.75.$$

6 Reciprocità

”Se tu mi diventi amico, anche io divento amico tuo”, se nodo v è connesso a nodo u , u connettendosi a v manifesta reciprocità.


6.1 Calcolo

Conto numero di **coppie reciproche** nel grafo:

- Uso matrice di adiacenza A ;
- La sommatoria aggiunge 1 per ogni coppia reciproca ($A_{i,j} = A_{j,i} = 1$);
- Divido per il numero massimo possibile di coppie reciproche dati gli archi in E : $|E|/2$.

$$R = \frac{\sum_{i,j,i < j} A_{i,j} A_{j,i}}{|E|/2} = \frac{2}{|E|} \sum_{i,j,i < j} A_{i,j} A_{j,i} = \frac{2}{|E|} \times \frac{1}{2} \text{Tr}(A^2) = \frac{1}{|E| \text{Tr}(A^2) = \frac{1}{m} \text{Tr}(A^2)}$$

$$\text{Tr}(A) = A_{1,1} + A_{2,2} + \dots + A_{n,n} = \sum_{i=1}^n A_{i,i}$$



$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$



- Nodi reciproci: v_1, v_2
- 4 archi

$$R = \frac{1}{m} \text{Tr}(A^2) = \frac{1}{4} \text{Tr} \left(\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 0 \end{bmatrix} \right) = \frac{2}{4} = \frac{1}{2}.$$

7 Bilanciamento


7.1 Bilanciamento Sociale

Modella la **coerenza** nelle relazioni amico / nemico, formalmente si ha bilanciamento quando:

- amico di amico è amico;


- amico di nemico è nemico;
- nemico di nemico è amico;
- nemico di amico è nemico.

Si modella con reti / grafi di '+' e '-' (signed graph), in cui archi positivi hanno valore +1 e archi negativi hanno valore -1. Un triangolo di nodi i, j, k è bilanciato se $w_{ij}w_{jk}w_{ki} \geq 0$



7.2 Status sociale

Quando un individuo è prestigioso all'interno della società: se X ha status più alto di Y e Y più alto di Z allora X dovrebbe avere status più alto di Z ... questi **cicli** sono problematici.



8 Degree distributions reali

- Popolarità siti web:
 - Tanti siti sono visitati ~ 1000 volte / mese (poco popolari);
 - Pochi siti sono visitati $\sim 1M$ volte / giorno (molto popolari).
- Attività utenti:
 - Utenti di SM sono spesso attivi su pochi siti;
 - Alcuni (pochi) individui sono attivi su tanti siti.
- Prezzi dei prodotti:
 - Tantissimi prodotti a prezzo basso;
 - Pochi prodotti costosi.
- Amicizia:

- Tanti individui con pochi amici;
- Pochi individui con migliaia di amici.
- Distribuzioni dei gradi:
 - Tanti nodi con grado basso;
 - Pochi nodi con grado alto.

9 La Legge di Potenza (Power Law)

9.1 Che cos'è (In parole povere)

La **Power Law** è una relazione matematica che descrive fenomeni dove eventi "piccoli" sono comunissimi, mentre eventi "giganti" sono rari ma esistono.

- **Formula base:** $f(k) \sim \frac{1}{k^\alpha}$
- **Significato:** La frequenza decresce molto velocemente man mano che cresce la grandezza (k).
- **Esempio intuitivo:** Pensa ai follower su Instagram.
 - Miliardi di persone hanno pochi follower (la "coda" lunga del grafico).
 - Pochissimi influencer (la "testa") ne hanno milioni.

9.2 Il trucco del Grafico Log-Log

Se disegni una Power Law su un grafico normale, ottieni un'**iperbole** (una curva a forma di "L") difficile da analizzare. Per capire se una rete segue davvero questa legge, si usa la scala logaritmica su entrambi gli assi.

- **La Magia:** Se applichi il logaritmo alla formula $f(k) = C/k^\alpha$, trasformi le moltiplicazioni in addizioni:

$$\log(f(k)) = \log(C) - \alpha \log(k)$$

- **Risultato:** Questa è l'equazione di una **retta** ($y = q - mx$).
- **Regola d'oro:** Se metti i dati su un grafico log-log e vedi una linea dritta che scende, allora sei davanti a una Power Law. La pendenza della retta è l'esponente α .

9.3 Esempi Reali (Dalle Slide)

- **Telefonate** ($1/k^2$): Pochissimi numeri ricevono milioni di chiamate, la maggioranza ne riceve poche.
- **Libri** ($1/k^3$): Pochi best-seller vendono milioni di copie, la maggioranza dei libri vende quasi zero.
- **Citazioni Scientifiche** ($1/k^3$): Pochi paper (tipo quelli di Einstein) sono citati da tutti, la maggior parte dei paper non li legge nessuno.
- **Social Network** ($1/k^2$): La distribuzione dei follower (in-degree).

9.4 Nota: Differenza con Zipf

- **Power Law:** Sull'asse X metti il **valore** (es. "Quanti hanno 100 amici?").
- **Zipf:** Sull'asse X metti la **classifica/rank** (es. "Chi è il 1°, il 2°, il 3° più ricco?").

9.5 Test

Per capire se rete ha degree distribution power law:

1. Calcolare grado k di ogni nodo;
2. Calcolare p_k , la frazione di nodi con grado k ;
3. Disegnare grafico su scala log-log con k su asse X e p_k su asse Y;
4. Se è power law, linea retta.

NON è un approccio sistematico! Altre distribuzioni potrebbero avere lo stesso pattern.

9.6 Coefficiente di clustering


Nelle reti sociali reali connessioni sono **molto transitive** (amici di un utente sono amici tra di loro, dormando **triangoli** con alto clustering).

10 Diffusione informazioni

Un rumor si diffonde su una rete sociale, tutti gli utenti lo passano immediatamente a tutti gli amici. Quanti hop servono per raggiungere tutti i nodi?

10.1 Milgram

Partendo da 296 persone a caso (196 Nebraska / 100 Boston) gli viene chiesto di spedire una lettera via intermediari a un agente di borsa a Boston, potendo spedire solo a persone che conoscevano personalmente. Fra tutte le (64) lettere che arrivarono a destinazione il n° medio di passaggi fu circa 6.



10.2 Dodds

Esperimento di Milgram mandato per email, confermato tasso di risposta e sei gradi di separazione.

10.3 Erdos

Ricerca n° di link per connettere uno scienziato / studioso mediante co-authorship di articoli scientifici, lunghezza dei cammini fra matematici: **media** 4.65, **massima** 13.


10.4 Proprietà reti reali

- Solitamente hanno struttura core-periferia: core denso con tanti archi, nodi della periferia con archi verso il core ma non fra di loro,
- Paradosso degli amici: grado dei vicini di un nodo v è più alto del grado di v .

11 Modelli delle reti

Reti reali sono troppo grandi per valutarle univocamente, si usano quindi processi stocastici che generano / producono grafi per poterle valutare su una scala inferiore, rendendole più controllabili / analizzabili rispetto alla visione reale.

11.1 Reti regolari




- **Distanze** (Average path length / Diametro): spesso **grandi**;
- Coefficiente di **Clustering**: spesso **alto**;
- **Distribuzione dei gradi**: spesso con un **picco**, e spesso 0 altrove;
- **Connettività**: spesso **completamente connesse**;
- Le reti al mondo raramente sono così, nemmeno quelle artificiali se grandi / complesse.

11.2 Reti casuali

Grafo con n nodi e archi casuali, studiando tutte le proprietà dei grafi e, nei grafi **grandi**, il **limite termodinamico** per $n \rightarrow \infty$. Reti interessanti se suppongo che le amicizie possano scaturire in modo casuale.

11.2.1 Modello $G(n,m)$

Grafo con n **nodi** fissati e m **archi** piazzati a caso fra gli n nodi (solitamente indiretto, senza multi e auto archi).



Si studia il caso $n \rightarrow \infty$, valutando il **caso medio**: ciò che succede in media su un insieme di tanti grafi casuali (diametro di $G(n,m)$ = diametro medio di tutti i grafi $G(n,m)$). Comodo analiticamente per n molto grandi, si valutano proprietà **tipiche** (più interessanti) e non casi speciali / particolari (meno interessanti).

11.2.2 Modello $G(n,p)$

Introdotta per determinate misure altrimenti non facilmente calcolabili, invece di fissare il # di archi, si fissa la **probabilità p** (indipendente) **di esistenza archi**

- N° archi (medio): $\langle m \rangle = \frac{n(n-1)}{2}p = \binom{n}{2}p$;
- Grado medio (tutte le estremità di archi / n° nodi): $\langle k \rangle = \frac{2\langle m \rangle}{n} = (n-1)p$, di solito denotato con $c = (n-1)p$ e approssimato con $c = np$, per n grande cambia poco;
- **Coefficiente di Clustering**: $C = \frac{c}{n-1}$, valore molto basso ($\rightarrow 0$ per $n \rightarrow \infty$);
- **Diametro** (geodensica più lunga): $l = \frac{\ln n}{\ln c}$, cresce con n e cala con crescere di c (sorprendentemente piccolo, **small world effect**)

Da degree distribution e C si evince che non è un modello adeguato a modellazione reti reali.



11.2.3 Differenza

Si assomigliano ma $G(n, m) \neq G(n, p)$, nel primo il n° di archi è **esattamente** m , nell'altro è **in media** $m = p \times n(n-1)/2$.

• Es.:

- Un grafo casuale in $G(n, m) = G(3, 2)$ ha **sempre** 2 archi, è sempre connesso, non è mai completo, ...
- Un grafo casuale in $G(n, p) = G(3, 2/3)$ ha **in media** 2 archi, non è sempre connesso, può essere completo, ...



Entrambi hanno distribuzione dei gradi di **Poisson** / **Bernoulli** (= per $n = \infty$), non proprio simmetrica ma quasi.

11.2.4 $G(n, p)$ connesso?

In generale no (basta un singolo nodo isolato), ma dato che $n \rightarrow \infty$, che ci sia un singolo nodo (o piccole componenti) isolato o meno non importa, basta aggiungere / togliere un arco (nodo) e si sistema. Si valuta invece esistenza "giant component", connessa e che contiene quasi tutti i nodi, e se ne valuta la dimensione:

- $p = 0$: grafo disconnesso - dimensione = 1 - costante a aumentare di n ;
- $p = 1$: grafo completo - dimensione = n - aumenta con n .

Probability (p)	0.0	0.055	0.11	1.0
Average Node Degree (c)	0.0	0.8	≈ 1	$n-1=9$
Diameter	0	2	6	1
Giant Component Size	0	4	7	10
Average Path Length	0.0	1.5	2.66	1.0

Con aumentare di p aumenterà la probabilità di avere una GC?

Siano un grafo casuale con grado medio c , un insieme di nodi connesso S e $S' = V - S$ l'insieme complementare (assumiamo $|S| \ll |S'|$). Per ogni nodo $v \in S$ con un hop da v visitiamo c nodi (con un hop da un qualsiasi nodo di S visito $|S|c$ nodi). Se S è piccolo, da $S \rightarrow S'$ con un hop l'insieme dei nodi connessi diventa più grande di un fattore di c .

Se è la componente connessa più grande, la sua grandezza aumenta sempre e dopo n hop: $c^n \geq 1$, se invece $c < 1$ il numero di nodi visitati muore.

11.2.5 Recap

Riguardo a reti reali il modello casuale:

- Modella **bene** lunghezza media dei cammini (bassa, small world);
- **Sottostima** drasticamente coefficiente di clustering;
- Non hanno distribuzione Power-law, ma **Poisson**.

Utile per spiegare alcuni fenomeni (small world) ma non tutti.

11.3 Reti small-world

Distanza piccola fra nodi, diametro basso e coefficiente di clustering alto.

11.3.1 Procedura

1. Parto da rete regolare;
2. Considero ogni singolo arco;
3. Con probabilità p lo ricollego casualmente (con $p=0$ ho rete regolare, con $p=1$ ho rete casuale).

11.3.2 Reti che ci interessano

Dati n nodi e c n° (medio) di archi per vertice ($\frac{nc}{2}$ archi totali) avremo $n \geq c \geq \log(n) \geq 1$:

- Con $n \geq 1$ reti grandi con n grande;
- Con $n \geq c$ reti sparse;
- Con $c \geq \log(n) \geq 1$ *non così sparse* da rischiare di diventare sconnesse.

Si valutano 2 misure:

- **L**: lunghezza media del cammino (numero di archi) minimo fra 2 nodi della rete. Misura per quanti amici devo passare per raggiungere una persona (globale);
- **C** coefficiente di Clustering: dato un vertice v considero i suoi k_v vicini e controllo quanti archi trovo fra i vicini (al massimo $k_v(k_v-1)/2$). Sia $C_v = \frac{\text{narchi}}{k_v(k_v-1)}$ la frazione degli archi effettivamente esistente, quindi **C** = media di C_v su tutti i vertici della rete. Misura quanto gli amici di una persona sono amici fra di loro (locale).

Casi limite

- $p=0$ (regolare):
 - $L(0)$: $\frac{n}{2c} \gg 1$ distanze grandi;
 - $C(0)$: $\frac{3}{4}$ "criccoso".
- $p=1$ (random):
 - $L(1)$: $\frac{\log(n)}{\log(c)}$ distanze basse (small world);
 - $C(1)$: $\frac{c}{n} \ll 1$ poco "criccoso".

11.3.3 Distribuzione dei gradi

Distribuzione strana con picco e soglia (cutoff) inferiore $p_k = e^{-cp} \frac{(cp)^{k-c}}{(k-c)!}$.

11.3.4 Recap

Reti small-world:

- Spiegano effetto small world (non spiegato da reti regolari, "ereditato" da $G(n,p)$);
- Spiega coefficiente di clustering alto (non spiegato da $G(n,p)$, "ereditato" da reti regolari);
- Non spiega distribuzione dei gradi che si trova "in natura" (**no power-law**, no coda lunga, no hub).

11.4 Reti scale free

Studio delle distribuzioni di:

- **Outdegree**: $P_{out}(k)$ probabilità che una pagina abbia k outlink;
- **Indegree**: $P_{in}(k)$ probabilità che una pagina abbia k inlink (più interessante).

Sono entrambe **power-law**, non poisson.


11.4.1 Diametro

Distanza **media** fra nodi (lunghezza media del cammino minimo fra 2 nodi della rete), sperimentalmente $\langle d \rangle = 0.35 + 2.06 \times \log(N)$ (anche aumentando molto n° nodi, diametro rimane basso $\rightarrow$ **power law** e **small-world**).

11.5 Reti con attaccamento preferenziale

Nuovo modello stocastico, ad ogni passo aggiungo nuovo nodo e un arco che lo collega ad un nodo preesistente scelto a caso ma con probabilità non uniforme (proporzionale al **grado** del nodo esistente $P(v_i) = \frac{d_i}{\sum_j d_j}$).

Come per gradi casuali si possono simulare reti del mondo reale generando un grafo con attaccamento preferenziale (lavorando su grafi indiretti) con un grado atteso m (invece di attaccare nuovo nodo a un unico altro nodo, ne scelgo m).



11.5.1 Sul modello scale-free

Lunghezze medie basse, ma **clustering** basso. Le scale-free hanno distribuzioni **power law**, in log-log è una retta $f(k) = \frac{C}{k^\alpha}$, ha **code lunghe** con molti nodi con k basso, ci sono però pochi nodi con grado molto alto (**hub**).

11.6 Sunto

	Lunghezza media cammini minimi (geodesiche)	C	Degree distribution
1. Regolari	KO	OK	KO
2. Random Graphs	OK	KO	KO
3. WSSW	OK	OK	KO
4. Scale free	OK	KO	OK

Insomma nessun modello "funziona", ossia crea reti uguali a quelle del mondo reale...

11.7 Attaccamento preferenziale non lineare

$$P(v_i) = \frac{d_i^\alpha}{\sum_j d_j^\alpha}$$

- Se $\alpha = 1$ è l'attaccamento preferenziale originale;
- Se $\alpha < 1$ vantaggio di avere grado alto è inferiore, no long tail, no hub;
- Se $\alpha > 1$ vantaggio di avere grado alto è superiore, winner-takes-all (un singolo nodo connesso a tutti).

11.8 Attrattività

$$P(v_i) = \frac{A + d_i}{\sum_j (A + d_j)}$$

- Se $A = 0$ è l'attaccamento preferenziale originale;
- Altrimenti evita che nodi con grado 0 non ricevano link, si ottiene sempre una **power law** con pendenza che varia con A .

11.9 Fitness

$$P(v_i) = \frac{\eta_i d_i}{\sum_j (\eta_j d_j)}$$


η_i rappresenta la fitness del nodo i , se $\forall i, j (\eta_i = \eta_j)$ è l'attaccamento preferenziale originale, se i valori di fitness sono in un intervallo limitato: rete con + hub, si elimina dipendenza dal rich-get-richer dei nodi più vecchi, anche i nodi giovani con alta fitness competono. Si ottiene **sempre** una **power law**.

11.10 Random Walk

Parte da una piccola rete qualsiasi, ad ogni passo si aggiunge un nuovo nodo i , con $m > 1$ archi attaccati di cui il primo è collegato con un nodo vecchio j scelto a caso (probabilità **uniforme**), ogni arco degli $m - 1$ restanti viene collegato:

- Con probabilità p a **un vicino** di j scelto a caso;
- Con probabilità $1 - p$ a un nodo vecchio qualsiasi scelto a caso;

Con p probabilità che si formi un triangolo.



11.10.1 FUNZIONA

- **Degree distribution power law:** quando scelgo un vicino (p) tendo a scegliere nodi con grado alto (in quanto attaccamento preferenziale), si formano hub;
- **Cammini brevi;**
- **Clustering alto:** presenza di triangoli.