

Reti e Misure – II

Stefano Mizzaro

DMIF – UNIUD

mizzaro@uniud.it

Social Computing – Lezioni 6, 7

17, 20 Ottobre 2025

Annuncio

- No lezione Lun 27/10

Riassunto

- 1. Intro a Social Computing
- 2. Intro a Social Media
 - Termini, Definizioni, Esempi, Classificazioni, Storia, Statistiche
- 3. Grafi e Reti
 - Richiami sui grafi
 - Reti = Grafi grandi nel mondo reale
- 4, 5. Misure sulle reti – I
 - Centralità "semplice" (Degree, Betweenness, Closeness)
 - Centralità ricorsiva (PageRank e HITS)

Motivazioni

- Perché misure?
- Voglio sapere, **quantificando**:
 - chi è "importante", "influyente" in una rete sociale
 - Io ho 100 follower, Obama ne ha 100 milioni...
 - Tutto qui?
 - No...
 - quali sono i pattern di interazione più tipici fra "amici"
 - (quali sono gli utenti più simili a me)
 - ...

A quali domande rispondono le misure?

- Chi sono gli individui / attori più importanti in una rete?
 - Centralità
- Quali pattern di interazione sono comuni fra amici?
 - Reciprocità e Transitività
 - Bilanciamento e Status
- Quali individui sono simili e come li trovo?
 - Similitudine
- Per rispondere a queste ed altre domande, si definiscono misure quantitative

Centralità

- "Semplice"
 - Grado, Betweenness, Vicinanza
 - Dall'analisi delle reti sociali ai social media
- Ricorsiva
 - Pagerank, HITS
 - Dal Web ai Social media
- Indici che si possono usare per modellare chi è più centrale/importante in una rete sociale

Le idee del PageRank


- Intuizione
 - "pagine che distribuiscono il loro PageRank"
- Camminata casuale
 - Cammino e distribuisco il PageRank, ma anche
 - Cammino e qual è la probabilità di essere su ogni pagina
- Catene di Markov
 - Vettore di PageRank
 - Camminata come $\mathbf{x}_{i+1} = \mathbf{x}_i \cdot \mathbf{P}$
 - Distribuzione stabile
 - Autovettore $\mathbf{x} = \mathbf{x} \cdot \mathbf{P}$
- Teletrasporto per rendere il Web ergodico

Le idee di HITS

- Due indici (hubness e authority), non solo uno
- Ricorsione mutua, non solo semplice
 - $\mathbf{h} = \mathbf{f}(\mathbf{a})$ ($\mathbf{h} = \mathbf{M}\mathbf{a}$)
 - $\mathbf{a} = \mathbf{f}'(\mathbf{h})$ ($\mathbf{a} = \mathbf{M}^T\mathbf{h}$)
- Autovettori di $\mathbf{M}\mathbf{M}^T$ e $\mathbf{M}^T\mathbf{M}$

Oggi

- Ancora Misure delle reti
 - "Data una rete, che cosa possiamo misurare"
 - "Cassetta degli attrezzi"
- Reza Zafarani, Mohammad Ali Abbasi, Huan Liu. *Social Media Mining - An Introduction*, Cambridge University Press, 2014
- Cap. 3 "Network Measures" e §4.1
- <http://socialmediamining.info/>



Scaletta

- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- Bilanciamento
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi
 - Coefficiente di clustering
 - Distanza media, piccolo mondo

Scaletta


- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- Bilanciamento
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi
 - Coefficiente di clustering
 - Distanza media, piccolo mondo

Social Network Analysis (SNA)

- "Historical" discipline
- 1970s
- Measures relationships among persons
 - Friendship
 - Collaboration
 - Citation (Bibliometrics)
 - ...
- Aims:
 - Short introduction to SNA (terminology)
 - Historical context: SNA Studied many concepts "re-studied" by Web science
 - For example, centrality

An example

- Relationships among persons
- For example, collaboration graph




SNA: ~ Terminology (1/4)


- The real terminology is somehow... "strange"
 - Actor, relation, strength, weight, ties, ...
- I keep most of it
 - But I simplify a bit and adapt to graph terminology
- **Local bridge:**
 - Arc between two nodes that would be "far away" without it
 - **of degree k:** if k would be the distance without that arc
 - Ex.: Tamara – Boris: local bridge of degree 3
 - (it is NOT the degree of a node!!)
- **(Global) bridge:**
 - Arc that, if removed, will disconnect the network
 - Ex.: Trevor – Tom, Alex – Roger, ...

SNA: ~ Terminology (2/4)

- **Triangle:**
 - Complete subgraph of 3 nodes
- **Weak tie**
 - Arc that belongs to few triangles
 - Ex.: Mike – Peter
 - "Acquaintance"
 - Bridge: the weakest tie
- **Strong tie**
 - When it belongs to many triangles
 - Ex.: Trevor – George
 - "Strong friendship" / group / clique ...



SNA: ~ Terminology (3/4)



- **Geodesic** (between 2 nodes)
 - Shortest path between them
 - Distance = # arcs
 - Ex.: geodesic between Tom and Mike: Tom-Trevor-Mike
 - "Geodesic" = "Shortest path"
- **Diameter** of a network
 - Longest geodesic of the network
 - Ex.: 6, Steve – Niegel
- **Degree of a node**
 - # of arcs
 - Indegree and outdegree on directed nets
- **Degree distribution**
 - For each degree, the number of nodes having that degree

Degree	# nodes
1	4
2	3
3	3
4	1
5	1
6	1


SNA: ~ Terminology (4/4)

- **Density:**

- Proportion of arcs it has: $\# \text{ arcs} / \# \text{ max.}$
- Ex.: $17 / ((13 * 12) / 2) = 0.22$

- **Clustering coefficient (C)**

- Of a node: $(\# \text{ arcs among its neighbors}) / \# \text{ max.}$
- $\# \text{ max.}$: if n neighbors $\rightarrow n(n-1)/2$
- Ex.: $C(\text{Keith}) = 1 / (3 * 2 / 2) = 1/3$
- C of the network:
 - average on all the nodes
 - (also other, different, definitions exist. More later)




"The strength of weak ties" [Granovetter, 1973]

- The most cited paper in the Social sciences
- "Strong": closest, intimate friends (groups, etc.)
- "Weak": other friends
- By removing strong ties, distances do not change a lot
- By removing weak ties, the network tends to become disconnected
- Weak ties are shortcuts, they "keep the network connected"
- If you are looking for a job, don't ask your closest friends :-)
 - You'd stay inside a clique


Centrality: 3 measures

- Centrality has been studied in SNA
- How much a node is "in the center" of the network
- **Degree** centrality
 - # link / # max. link ($= |N| - 1$)
 - # neighbors / # max. possible neighbors
 - Ex.: Mike: 6/12; Roger: 2/12; ...
- **Betweenness** centrality
 - How much a node is between other nodes, on the geodesic between them
 - How much you "need to go through it"
 - Ex.: Mike is "very between"
- **Closeness** centrality
 - How much a node is close to the other nodes
 - $1/\sum \text{distances (geodesics lengths)}$
 - Ex.: Mike: $1/(2+3+2+2+1+1+1+1+1+2+3)=1/20$
- Maximum centrality, for all three measures:
 - the central node in a star network



A (toy) experiment


- Relationships between the centrality measures and PageRank, HITS
 - Undirected graph => transformed into directed
 - Hubness = Authority



PageRank, HITS, Centralities


Node	Name	Degr	PR	HITS	Closeness	Betweenness
1	Steve	1	0.036	0.026	0.29	0.00
2	Trevor	5	0.14	0.15	0.55	0.32
3	Boris	2	0.057	0.074	0.41	0.030
4	Roger	2	0.074	0.021	0.34	0.17
5	Mike	6	0.16	0.16	0.60	0.63
6	George	4	0.11	0.14	0.52	0.15
7	Keith	3	0.087	0.092	0.40	0.17
8	Nigel	1	0.043	0.006	0.26	0.00
9	Tamara	3	0.081	0.11	0.40	0.038
10	Alex	3	0.091	0.068	0.46	0.030
11	Dan	1	0.035	0.044	0.39	0.00
12	Tom	1	0.034	0.044	0.36	0.00
13	Peter	2	0.060	0.064	0.43	0.00

PageRank, HITS, Centralities



PageRank, HITS, Centralities

Relationships among centralities (normalized)



SNA summary

- Quite "historical" discipline – not young
 - Results on centrality/prestige are from the 70es
- Sort of "reinvented" by Web search engines ...
- Not only for Web search. Other applications:
 - PageRank, HITS, ...
 - P2P networks
 - Trust networks, FOAF, ...
 - ...
- SNA – Web relationships perhaps not yet completely understood... "science of networks"...

Bibliometrics, Citation analysis

- A rather classic discipline, bibliometrics, study of the scientific/scholarly literature
 - Who cites whom
 - Who is cited a lot
 - Who is cited a lot by who is cited a lot as well
 - Who is co-cited with
 - Who co-cites whom
 - Who works with whom...
- Again, quite old. Main results in the 60es-70es
- Web is slightly different
 - Quality
 - Of pages
 - Of citations
 - Time, modifiability

Centrality ... and spam

- PageRank w.r.t. #inlink
- Very similar
- Also very similar to other centrality indexes
- Just a matter of spam?!
- Anyway, forget "PageRank has been The fortune of Google"...
- Anchor text, social perception ("don't be evil"), usability and simplicity, graphical appearance...

Scaletta


- Social Network Analysis (SNA)
- **Transitività e Reciprocità**
 - E coefficiente di clustering
- Bilanciamento
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi
 - Coefficiente di clustering
 - Distanza media, piccolo mondo

"Pattern" di amicizia

- Situazioni tipiche che si trovano / formano
- Su reti di "amicizia"

- Reciprocità

- Se io sono amico tuo, tu sei amico mio





- Transitività

- Se io sono amico tuo e tu sei amico suo, io sono amico suo

- ...

- Vediamo prima la transitività






Transitività


- Algebra: una relazione R è transitiva sse:

$$aRb \wedge bRc \rightarrow aRc$$




- In una rete sociale, si ha **transitività**
 - quando un amico di un mio amico è mio amico
- Più transitività $\rightarrow$ grafi più densi, più vicini a grafo completo
 - Possiamo stimare quanto un grafo è vicino ad essere completo misurandone la transitività?
 - Hm, grafo completo e alta transitività sono $\neq$: aggiungendo archi a caso non aumento molto transitività

$(aRc \text{ o } cRa)?$




Due indici di transittività

- Coefficiente di clustering locale
 - Relativo a un singolo nodo
 - Anche se poi si può fare la media su tutti i nodi!
- Coefficiente di clustering globale
 - Relativo alla rete
- (useremo di più il primo)
- Correlati ma $\neq$
- Di solito su grafi indiretti




Coefficiente di clustering **locale**

- Misura la transitività a livello dei singoli nodi
 - Misura quanto i vicini di un nodo v_i (i nodi adiacenti a v_i) sono a loro volta connessi




$$C(v_i) = \frac{\text{Number of Pairs of Neighbors of } v_i \text{ That Are Connected}}{\text{Number of Pairs of Neighbors of } v_i}.$$


In un grafo indiretto, il denominatore è: $\binom{d_i}{2} = d_i(d_i - 1)/2$




Esempio



$$C(v_1)=1$$




$$C(v_1)=1/3$$



$$C(v_1)=0$$

- Linee sottili: connessioni ai vicini
- Linee tratteggiate: archi mancanti fra i vicini
- Linee più spesse: vicini connessi
 - Quando nessun vicino è connesso: $C = 0$
 - Quando tutti i vicini sono connessi: $C = 1$


Lo
useremo...



Coefficiente di clustering globale /1


- Misura la transitività in grafi indiretti
- Tre definizioni equivalenti
- **1.** Conto i cammini di lunghezza 2 e controllo se esiste il terzo arco (ossia, il cammino è chiuso)


$$C = \frac{|\text{Closed Paths of Length 2}|}{|\text{Paths of Length 2}|}$$



- **2.** Oppure, conto i triangoli (e mi riconduco a **1.**)
 - Siccome ogni triangolo ha 6 cammini chiusi di lunghezza 2 (triangolo abc --> cammini ab, bc, ca, ac, cb, ba):

$$C = \frac{(\text{Number of Triangles}) \times 6}{|\text{Paths of Length 2}|}$$






Coefficiente di clustering globale /2

- 3. Oppure, conto le triple
- **Triple:** un insieme ordinato di tre nodi, connesso

- da due archi (tripla aperta), o
- da tre archi (tripla chiusa)



$v_i v_j v_k$ e $v_j v_k v_i$ sono triple differenti

- Gli stessi elementi
- Nella prima manca l'arco $e(v_k, v_i)$
- Nella seconda manca $e(v_i, v_j)$


$v_i v_j v_k$ e $v_k v_j v_i$ sono la stessa tripla

- Un triangolo ha 3 triple
- Quindi:


$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$

- "Di tutte le triple di nodi connesse, prendo quelle chiuse, ossia i triangoli * 3"


Esempio




$$C = \frac{(\text{Number of Triangles}) \times 3}{\text{Number of Connected Triples of Nodes}}$$
$$= \frac{2 \times 3}{2 \times 3 + \underbrace{2}_{v_2 v_1 v_4, v_2 v_3 v_4}} = 0.75.$$



Reciprocità




- "Se tu mi diventi amico, anche io divento amico tuo"
- È ""una versione semplificata della transitività""
 - Considera cicli di lunghezza 2
- Se il nodo v è connesso al nodo u ,
 - u , connettendosi a v , manifesta reciprocità



Calcolo della reciprocità ("globale")

- Conto il numero di **coppie reciproche** nel grafo
 - Uso la matrice di adiacenza A
 - (la sommatoria aggiunge 1 per ogni coppia reciproca: $A_{i,j} = A_{j,i} = 1$)
 - (divido per il numero massimo possibile di coppie reciproche dati gli archi in E : $|E|/2$)





$$\begin{aligned} R &= \frac{\sum_{i,j,i < j} A_{i,j} A_{j,i}}{|E|/2}, \\ &= \frac{2}{|E|} \sum_{i,j,i < j} A_{i,j} A_{j,i}, \\ &= \frac{2}{|E|} \times \frac{1}{2} \text{Tr}(A^2), \\ &= \frac{1}{|E|} \text{Tr}(A^2), \\ &= \frac{1}{m} \text{Tr}(A^2). \end{aligned}$$

What
about
 $i = j$?


$$\text{Tr}(A) = A_{1,1} + A_{2,2} + \cdots + A_{n,n} = \sum_{i=1}^n A_{i,i}$$

Tr(A^2)




$$\text{Tr}(A) = A_{1,1} + A_{2,2} + \cdots + A_{n,n} = \sum_{i=1}^n A_{i,i}$$

$$\frac{1}{2} \text{Tr}(A^2)$$




$$\frac{1}{2} \text{Tr}(A^2)$$



(L'1/2 sulla slide precedente è perché ogni coppia reciproca viene "intercettata" e contata 2 volte. Ad es., la prima coppia in alto a sx anche per riga = colonna = 1)

Esempio




$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$



- Nodi reciproci: v_1, v_2
- 4 archi


$$R = \frac{1}{m} \text{Tr}(A^2) = \frac{1}{4} \text{Tr} \left(\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 0 \end{bmatrix} \right) = \frac{2}{4} = \frac{1}{2}.$$



Scaletta

- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- **Bilanciamento**
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi
 - Coefficiente di clustering
 - Distanza media, piccolo mondo

Bilanciamento: Intuizione




- **1. Bilanciamento sociale**

- Se X e Y sono grandi amici/amiche e Y e Z sono grandi amici/amiche
- E X e Z sono grandi nemici/nemiche, prima o poi ci sarà qualche problema...
- (rete indiretta)

- **2. Status sociale**

- Se X è superiore a Y e Y è superiore a Z
- E Z è superiore a X, allora c'è qualche problema
- (rete diretta)

- (In)coerenza nelle relazioni amico/nemico o sottoposto/superiore
→ La rete è "sbilanciata"



- **N.B.**


- in 1., "nemico" ≠ da assenza di link
- "poco implementato" nei social media attuali
 - Blocking ~

1. Teoria del bilanciamento sociale

- Modella la **coerenza** nelle relazioni amico/nemico
- Informalmente, si ha bilanciamento quando:
 - L'amico di un mio amico è mio amico
 - L'amico di un mio nemico è mio nemico
 - Il nemico di un mio nemico è mio amico
 - Il nemico di un mio amico è mio nemico
- Si modella con reti / grafi di '+' e '-' ("signed graph")
 - Amicizia: Archi positivi, amici ($w_{ij} = 1$, '+')
 - Inimicizia: Archi negativi, nemici ($w_{ij} = -1$, '-')
- Un triangolo di nodi i, j, k è bilanciato sse
 - w_{ij} : valore dell'arco fra i nodi i e j

$$w_{ij}w_{jk}w_{ki} \geq 0.$$


Possibili combinazioni




- Per ogni ciclo, se la moltiplicazione dei valori degli archi è positiva, allora il ciclo è socialmente bilanciato
 - (negativa: non bilanciato)

2. Teoria dello status sociale


- **Status:** quanto un individuo è prestigioso all'interno della società
 - "like(X) se penso che X sia più importante di me"
 - "dislike(X) se penso che X sia meno importante di me"
- **Teoria dello status sociale:**
 - Quanto gli individui sono consistenti nell'assegnare lo status ai loro vicini?
 - Informalmente,
 - se
 - X ha uno status più alto di Y e
 - Y più alto di Z,
 - allora
 - X dovrebbe avere uno status più alto di Z
 - Qui i **cicli** sono problematici



Esempio



Configurazione instabile
($v_1 < v_2$, $v_2 < v_3$ e $v_1 > v_3$)



Configurazione stabile
($v_1 > v_2$, $v_2 > v_3$ e $v_1 > v_3$)

- Sempre reti con '+' e '-', ma:
 - Significato $\neq$ da amici/nemici
 - Reti dirette
- Arco diretto '+' dal nodo X al nodo Y :
 - Y ha uno status più alto di X
- Viceversa per '-'
- In realtà '+' e '-' neanche servirebbero, basterebbero gli archi diretti
 - (inverto gli archi etichettati con '-')

Scaletta

- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- Bilanciamento
- **Misure delle reti II (e proprietà)**
 - Distribuzione dei gradi
 - Coefficiente di clustering
 - Distanza media, piccolo mondo

SNA: ~ Terminology (3/4)

- **Geodesic** (between 2 nodes)
 - Shortest path between them
 - Distance = # arcs
 - Ex.: geodesic between Tom and Mike: Tom-Trevor-Mike
 - "Geodesic" = "Shortest path"
- **Diameter**
 - Longest geodesic of the network
 - Ex.: 6, Steve – Niegel
- **Degree of a node**
 - # of arcs
 - Indegree and outdegree on directed nets
- **Degree distribution**
 - For each degree, the number of nodes having that degree

Degree	# nodes
1	4
2	3
3	3
4	1
5	1
6	1


Degree distribution reali

- Reti di tipo diverso hanno distribuzioni diverse
 - Uniforme
 - Con un picco
 - Gaussiana
 - Power law
 - ...

Distribuzioni "reali"

- Ricchezza / Benessere
 - La maggioranza degli individui ha un capitale medio
 - Pochi individui sono ricchi
 - Tanti ("Esponenzialmente") più individui con capitale medio che ricchi
- Popolazione delle città
 - Poche aree metropolitane densamente popolate
 - La maggior parte delle città hanno una grandezza media (in termini di popolazione)
- Social Media
 - Stesso fenomeno quando misuriamo popolarità o interesse per entità

Global Distribution of Wealth



James S. Henry, 2012




Herbert A Simon,
On a Class of Skew Distribution Functions, 1955

The Pareto principle
(80–20 rule): 80% of the effects come
from 20% of the causes


Distribuzioni

- Popolarità dei siti web
 - Tanti siti sono visitati meno di 1000 volte / mese (poco popolari)
 - Pochi siti sono visitati più di 1 milione volte / giorno (molto popolari)
- Attività utenti
 - Gli utenti di social media sono spesso attivi su pochi siti
 - Alcuni (pochi) individui sono attivi su tanti siti
- Prezzi dei prodotti
 - Ci sono tantissimi prodotti a basso prezzo e
 - Pochi prodotti costosi
- Amicizia
 - Tanti individui con pochi amici e
 - Pochi individui con migliaia di amici (→ idem sui social...)
- → Distribuzioni dei gradi
 - Tanti nodi con grado basso
 - Pochi nodi con grado alto



Power law

- Legge della potenza
- “Polinomio inverso”
- $f(k) \sim 1/k^\alpha$ [$\Pr(X = k) \sim 1/k^\alpha$] $\alpha > 1$
- $f(k) = C/k^\alpha$
 - Es.: # di pagine web con k (out/in)link
 - Grafico: ~iperbole
 - Grafico su scala log-log è una retta:



$$\boxed{\log(f(k))} = \log\left(\frac{C}{k^\alpha}\right) = \log C - \log k^\alpha = \log C - \alpha \boxed{\log k}$$

- Power law $\neq$ Zipf
 - Power law: in ascissa ho il valore
 - Zipf: in ascissa ho il rank, la posizione

Power law – Degree distribution


- La frequenza di un evento cambia in funzione della potenza di un attributo
 - La frequenza segue una power law

The diagram shows the equation $p_d = a d^{-b}$ with four arrows pointing to its components from surrounding text:


- An arrow from "Power law intercept" points to the constant a .
- An arrow from "The power law exponent. Its value is typically in the range [2, 3]" points to the exponent $-b$.
- An arrow from "Fraction of users with degree d " points to the variable p_d .
- An arrow from "Node degree" points to the variable d .

$$\ln p_d = -b \ln d + \ln a$$


Grafici



Grafici (log-log)



Esempi



- Rete delle telefonate
 - La frazione di numeri di telefono che ricevono k chiamate al giorno è approssimativamente proporzionale a $1/k^2$
- Acquisti di libri
 - La frazione di libri che sono comprati da k persone è approssimativamente proporzionale a $1/k^3$
- Articoli scientifici
 - La frazione di articoli scientifici che ricevono k citazioni in totale è approssimativamente proporzionale a $1/k^3$
- Reti sociali
 - La frazione di utenti che hanno in-degree k è approssimativamente proporzionale a $1/k^2$

Distribuzione di Internet




Fig. 8.3

Figure 8.3: The degree distribution of the Internet. A histogram of the degree distribution of the vertices of the Internet graph at the level of autonomous systems.

Su scala log-log (Internet)




Fig. 8.5

Figure 8.5: The power-law degree distribution of the Internet. Another histogram of the degree distribution of the Internet graph, plotted this time on logarithmic scales. The approximate straight-line form of the histogram indicates that the degree distribution roughly follows a power law of the form (8.3).

Distribuzioni del Web (in- e out-degree)

Fig. 8.4





Figure 8.4: The degree distributions of the World Wide Web. Histograms of the distributions of in- and out-degrees of pages on the World Wide Web. Data are from the study by Broder *et al.* [56].



Distribuzione power law, riassunto

- Molte reti "reali" (incluse quelle sottostanti i social media) mostrano una distribuzione dei gradi power law
- Le power law occorrono sistematicamente
 - Quando la quantità misurata è una qualche forma di popolarità
- In una distribuzione power law
 - Valori piccoli: comuni
 - Valori grandi: estremamente rari
 - **Ma non impossibili!**
 - Probabilità bassa ma non zero
 - Diverso da distribuzioni esponenziali (es. Gaussiana)

Forma tipica di una distribuzione power law



(a) Power-Law Degree Distribution




(b) Log-Log Plot of Power-Law Degree Distribution


Distribuzione power law: test

- Per capire se una rete ha una degree distribution power law
 - 1. Calcolare il grado di ogni nodo, k
 - 2. Calcolare p_k , la frazione di nodi con grado k
 - 3. Disegnare il grafico su scala log-log, con k sull'asse X e p_k sull'asse Y
 - 4. se è power law, linea retta
- Non è un approccio sistematico!
 - Rumore nella coda (pochi dati) → la distribuzione cumulativa sarebbe meglio
 - Altre distribuzioni (non power law) potrebbero avere lo stesso pattern
 - ...


Power law e Reti reali




(a) Blog Catalog



(b) My Blog Log



(c) Twitter



(d) My Space


Reti con una distribuzione dei gradi power law si chiamano anche reti Scale-free (a invarianza di scala)

Long tail – Coda lunga

- Power law → Coda lunga
 - Maggior parte delle vendite riguardano un piccolo insieme di elementi molto popolari / venduti?
 - Oppure
 - Riguardano un insieme molto più grande di elementi molto meno popolari?

The Looooong Tail

Probabilità bassa, ma non zero!




Il volume totale di vendite di elementi impopolari, se li si mette tutti insieme, diventa importante

- 57% delle vendite di Amazon è dalla coda lunga (di tanti prodotti poco popolari / venduti)

Scaletta

- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- Bilanciamento
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi
 - **Coefficiente di clustering**
 - Distanza media, piccolo mondo

Coefficiente di clustering (locale)



- Nelle reti (sociali) reali, le amicizie sono "molto" transitive
 - Gli amici di un utente sono spesso amici fra di loro
 - Si formano triangoli
 - In media, coefficiente di clustering (locale, ma anche globale) alto:

Web	Facebook	Flickr	LiveJournal	Orkut	YouTube
0.081	0.14 (with 100 friends)	0.31	0.33	0.17	0.13

Coefficiente di clustering di reti reali


	Network	Type	<i>n</i>	<i>m</i>	<i>C</i>
Social	Film actors	Undirected	449 913	25 516 482	0.20
	Company directors	Undirected	7 673	55 392	0.59
	Math coauthorship	Undirected	253 339	496 489	0.15
	Physics coauthorship	Undirected	52 909	245 300	0.45
	Biology coauthorship	Undirected	1 520 251	11 803 064	0.088
	Telephone call graph	Undirected	47 000 000	80 000 000	
	Email messages	Directed	59 812	86 300	
	Email address books	Directed	16 881	57 029	0.17
	Student dating	Undirected	573	477	0.005
	Sexual contacts	Undirected	2 810		
Information	WWW nd . edu	Directed	269 504	1 497 135	0.11
	WWW AltaVista	Directed	203 549 046	1 466 000 000	
	Citation network	Directed	783 339	6 716 198	
	Roget's Thesaurus	Directed	1 022	5 103	0.13
	Word co-occurrence	Undirected	460 902	16 100 000	
Technological	Internet	Undirected	10 697	31 992	0.035
	Power grid	Undirected	4 941	6 594	0.10
	Train routes	Undirected	587	19 603	
	Software packages	Directed	1 439	1 723	0.070
	Software classes	Directed	1 376	2 213	0.033
	Electronic circuits	Undirected	24 097	53 248	0.010
	Peer-to-peer network	Undirected	880	1 296	0.012
Biological	Metabolic network	Undirected	765	3 686	0.090
	Protein interactions	Undirected	2 115	2 240	0.072
	Marine food web	Directed	134	598	0.16
	Freshwater food web	Directed	92	997	0.20
	Neural network	Directed	307	2 359	0.18

Scaletta

- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- Bilanciamento
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi
 - Coefficiente di clustering
 - Distanza media, piccolo mondo

"Il mondo è piccolo". Quanto piccolo?

- Un "rumor" si diffonde su una rete sociale
 - Rumor = pettegolezzo, voce, diceria, barzelletta, notizia, fake news, ...
 - Ipotesi: tutti gli utenti lo passano immediatamente a tutti i loro amici



1. Quanto prima che raggiunga (quasi) tutti i nodi della rete?
2. Tempo massimo? ($\leftrightarrow$ diametro)
3. Tempo medio?

di hops

Il mondo è piccolo?

- Qual è la distanza fra due nodi?
 - Media
 - Massima
- Se bassa → mondo piccolo.

(Aneddoti: Milgram 1)


- Stanley Milgram, psicologo sociale, famoso per 2 esperimenti, anni 60
- (Esperimento 1): Obbedienza all'autorità
 - E mancanza di senso di responsabilità...
 - “Allievo-soggetto” legato su sedia con elettrodi
 - “Aiutante” con l'ordine di dare scariche elettriche di intensità crescente se l'allievo sbaglia risposta
 - In realtà:
 - Allievo: attore
 - Scariche elettriche: finte
 - Aiutante: soggetto (ignaro)
 - Risultato: 26 soggetti su 40 arrivarono a 450 V!



Stanley Milgram
(1933-1984)


Esperimento di Milgram

- 296 persone scelte a caso
 - dal Nebraska (196 persone)
 - da Boston (100 persone)
- Gli viene chiesto di spedire una lettera via intermediari a un agente di borsa a Boston
- Potevano spedire la lettera solo a persone che conoscevano personalmente
 - "a cui davano del tu"
- Fra tutte le (64) lettere che arrivarono a destinazione, il numero medio di passaggi fu ca. 6
 - (sorprendentemente?) basso
 - "Il mondo è piccolo"; fra 2 persone ci sono 6 passaggi...



Risultato: 6 gradi di separazione – "Six degrees"

Travers, Jeffrey, and Stanley Milgram. "An experimental study of the small world problem." *Sociometry* (1969): 425-443.



Numero medio
di persone /
intermediari: 5.2

[Dodds et al. 2003]

- Esperimento di Milgram per email
- Sempre basso tasso di risposta
- Conferma dei sei gradi di separazione
- P. S. Dodds, R. Muhamad, D. J. Watts, An Experimental Study of Search in Global Social Networks, *Science*, 8 August 2003, vol. 301. no. 5634, pp. 827-829, <http://www.sciencemag.org/cgi/content/abstract/301/5634/827>
- E altre conferme successive (ne parleremo) → il mondo delle amicizie è piccolo
- E non è l'unico ad esserlo →

(Aneddoti: Paul Erdős)


- Un matematico “strano”
- Moolto prolifico (1485 articoli)
- Senza fissa dimora
 - "My brain is open"
- Gergo tutto suo
 - The Book, SF (Sommo Fascista)
 - Sposato = captured, Divorziato = liberated
 - ...
- Caffè & Anfetamine...
 - Renyi: "Un matematico è una macchina per trasformare caffè in teoremi"
- Cfr. Wikipedia e libro di Hoffman: *L'uomo che amava solo i numeri*, Mondadori, 2000



Paul Erdős
(1913-1996)

Numero di Erdős


- Numero di link per connettere uno scienziato/studioso tramite co-authorship di articoli scientifici
- Erdős scrisse ~1500 articoli con 507 co-autori
- Erdős Number Project
 - per calcolarsi il proprio numero di Erdős
 - <http://www.oakland.edu/enp/>
 - <https://www.csauthors.net/distance/>
- Lunghezza dei cammini, fra matematici:
 - Media: 4.65 ("mondo piccolo")
 - Massima: 13



Paul Erdős (1913-1996)


Guardate su YouTube
il documentario su
Erdős "*N is a number*"

Einstein: numero di Erdős 2




Paul Erdős (1913-1996)

Erdős, Paul, B. Rothschild, and E. G. Straus. "Polychromatic Euclidean Ramsey theorems." *Journal of Geometry* 20.1 (1983): 28-35.




Ernst Gabor Straus
(1922-1983)

Einstein, Albert, and Ernst Gabor Straus. "A generalization of the relativistic theory of gravitation, II." *Annals of Mathematics* (1946): 731-741.




Albert Einstein (1879-1955)

Distribuzione del numero di Erdős



- Numero di Erdős mediano: 5
- Numero di Erdős medio: 4.65
- Deviazione standard: 1.27



Erdős Number Project: <http://www.oakland.edu/enp/>

Calculator: <https://www.csauthors.net/distance/>

Lunghezza media dei cammini più corti in reti reali

- Nelle reti reali, ogni coppia di nodi è di solito connessa da un cammino **breve**



Facebook

Maggio 2011:

- Lunghezza media del cammino più corto: 4.7
- 4.3 per utenti US

"Quattro gradi di separazione"

La lunghezza media dei cammini più corti (average path length) è piccola

Web	Facebook	Flickr	LiveJournal	Orkut	YouTube
16.12	4.7	5.67	5.88	4.25	5.10


Lunghezza media dei cammini più corti in reti reali

	Network	Type	n	m	ℓ
Social	Film actors	Undirected	449 913	25 516 482	3.48
	Company directors	Undirected	7 673	55 392	4.60
	Math coauthorship	Undirected	253 339	496 489	7.57
	Physics coauthorship	Undirected	52 909	245 300	6.19
	Biology coauthorship	Undirected	1 520 251	11 803 064	4.92
	Telephone call graph	Undirected	47 000 000	80 000 000	
	Email messages	Directed	59 812	86 300	4.95
	Email address books	Directed	16 881	57 029	5.22
	Student dating	Undirected	573	477	16.01
	Sexual contacts	Undirected	2 810		
Information	WWW nd . edu	Directed	269 504	1 497 135	11.27
	WWW AltaVista	Directed	203 549 046	1 466 000 000	16.18
	Citation network	Directed	783 339	6 716 198	
	Roget's Thesaurus	Directed	1 022	5 103	4.87
	Word co-occurrence	Undirected	460 902	16 100 000	
Technological	Internet	Undirected	10 697	31 992	3.31
	Power grid	Undirected	4 941	6 594	18.99
	Train routes	Undirected	587	19 603	2.16
	Software packages	Directed	1 439	1 723	2.42
	Software classes	Directed	1 376	2 213	5.40
	Electronic circuits	Undirected	24 097	53 248	11.05
	Peer-to-peer network	Undirected	880	1 296	4.28
Biological	Metabolic network	Undirected	765	3 686	2.56
	Protein interactions	Undirected	2 115	2 240	6.80
	Marine food web	Directed	134	598	2.05
	Freshwater food web	Directed	92	997	1.90
	Neural network	Directed	307	2 359	3.97

ℓ : average path length.
Piuttosto piccoli!

Altre proprietà delle reti reali

- Di solito hanno una struttura core-periferia
 - Core (nucleo, cuore) più denso con tanti archi
 - Nodi della periferia con archi verso il core ma non fra di loro
 - Struttura a "medusa" o "piovra"
- Paradosso degli amici [Feld 1991]
 - "I tuoi amici hanno più amici di te"
 - In media, il grado dei vicini di un nodo v è più alto del grado di v
 - Sperimentalmente, vero per 98% degli utenti Twitter [Hodas et al. 2013]



Riassunto


- Centralità
 - "semplice" (Degree, Betweenness, Closeness)
 - ricorsiva (PageRank e HITS)
- Social Network Analysis (SNA)
- Transitività e Reciprocità
 - E coefficiente di clustering
- Bilanciamento
- Misure delle reti II (e proprietà)
 - Distribuzione dei gradi → Spesso power law
 - Coefficiente di clustering → Spesso grande
 - Distanza media → Spesso bassa, piccolo mondo
- "Cassetta degli attrezzi" per il prossimo argomento

Prossimamente...

- Useremo un po' tutto, e anche:
 - Centralità
 - Diametro, distanze
 - Coefficiente di Clustering
 - Distribuzione dei gradi (Degree distribution)
 - Connettività
 - ...

Biblio

- Reza Zafarani, Mohammad Ali Abbasi, Huan Liu.
Social Media Mining - An Introduction, Cambridge University Press, 2014
- <http://socialmediamining.info/>
- Cap. 3
- §4.1



Ma anche, per approfondire

- D. Easley and J. Kleinberg. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press, 2010.
- M. Newman. *Networks. Second Edition*. Oxford University Press, 2018. [oggi: Cap. 7]
- F. Menczer, S. Fortunato, C.A. Davis. *A First Course in Network Science*. Cambridge University Press, 2020.
- A.L. Barabási. *Network Science*. Cambridge University Press, 2016
- Stanley Wasserman e Katherine Faust. *Social Network Analysis: Methods and Applications*. Cambridge University Press. 1994
- Articoli scientifici

Dear instructors/users of these slides:

Please feel free to include these slides in your own material, or modify them as you see fit. If you decide to incorporate these slides into your presentations, please include the following note:

R. Zafarani, M. A. Abbasi, and H. Liu, Social Media Mining: An Introduction, Cambridge University Press, 2014.

Free book and slides at <http://socialmediamining.info/>

or include a link to the website:

<http://socialmediamining.info/>