

Qualità - 1: Controlli in itinere, Ridondanza & Aggregazione

Stefano Mizzaro

DMIF – UNIUD

mizzaro@uniud.it

Social Computing - Lezione 21

15 dicembre 2025

(Annuncio)

- La Fondazione ELICSIR organizza Il Futuro Annunciato (FA26), iniziativa rivolta agli studenti e studentesse della Laurea Triennale in discipline STEM.

Attraverso seminari, tavole rotonde e discussioni informali con ricercatori dell'accademia, dell'industria avanzata, dottorandi e fondatori di startup, questo breve workshop vuole offrire uno spaccato delle grandi sfide intellettuali e soprattutto delle incredibili opportunità che l'informatica offre in questo momento storico.

L'evento, che si svolgerà a Venezia, Centro Congressi Isola di San Servolo, dal 30 Gennaio al 2 Febbraio 2026, è descritto sul sito:

<https://www.elicsir.it/eventi/futuro-annunciato-2026>

Grazie al generoso supporto di Schmidt Sciences, la partecipazione è gratuita, inclusi vitto e alloggio. La selezione avviene su base meritocratica e candidarsi è semplice: basta compilare il modulo nella sezione "Iscriversi" del sito (disponibile anche al seguente link: <https://forms.gle/5LMhm425aBEAtiJg6>).

(Iscrizione a mturk)

- A volte viene rifiutata
- Riprovate con un altro indirizzo email
- Rispondete "per bene" alle domande

Riassunto

- 18. Intro Crowdsourcing
 - Def.
 - Es.
- 19. Tipologie di Crowdsourcing
 - Varie classificazioni
- 20. (Micro)task design
 - Come progettare un task, processo, metodologia

Calendario lezioni (?)

«È difficile fare
previsioni, soprattutto
sul futuro» [Bohr ?]

- ✓ 18. Lu 1/12: Intro Crowdsourcing
- ✓ 19. Ve 5/12: Tipologie/classificazione crowdsourcing
- ✓ 20. Ve 12/12: Design
- 21. Lu 15/12 (oggi): Qualità 1
 - Task design, Ridondanza & Aggregazione
- 22. Ve 19/12: Qualità 2
 - Teoria della misurazione
 - Ancora aggregazione
- 23. Lu 22/12: Qualità 3
 - Seminario Michael Soprano su Crowd_Frame
 - Accordo
- 24. Ve 9/1:
 - Di nuovo disinformazione
 - Fine!

Obiettivo della lezione di oggi

- Cominciare a discutere della qualità

Tecniche per avere qualità

- Qualification test, design del task, honey pot, gold question, coerenza, tempo, behavior & logs, accordo, ridondanza e aggregazione, analisi dati, ...
- Tante!
- Facciamo un po' d'ordine

Tecniche per migliorare / ottenere buona qualità

- Metodologiche
 - Design del task (Pairwise, scale, presentazione, ...)
- In itinere
 - Test di qualificazione (Qualification test)
 - Controlli sintattici
 - Test nascosti (Gold questions, honey pots, coerenza)
 - Monitoraggio del comportamento (tempo, azioni, log, ...)
- Ridondanza. Aggregare
- Ex-post
 - Pulizia dati (rimozione outlier, ecc.)
 - Aggregazione sofisticata (co-determination algorithms)
 - Sfruttare l'accordo / agreement

Scaletta

- Design del task
- Controlli in itinere
- Ridondanza & Aggregazione

} Lezione scorsa

- Teoria della misurazione
- Aggregazione reloaded
- Accordo
 - Def.; Varie misure
 - Come sfruttarlo per la qualità
 - Un modello più sofisticato

} Prossime lezioni

Scaletta

- Controlli in itinere
- Ridondanza & Aggregazione

Design del task

- Metodologia di progetto di un (micro)task
 - Lezione scorsa
- Scelte di progetto (ad es., pairwise vs. singolo)
- Modalità di presentazione
 - Scelta testi (istruzioni e compito)
 - Formattazioni
 - Uso colori
 - Paginazione
- Atteggiamento **duplice**:
 - → Mettere il worker nelle migliori condizioni possibili
 - Ma anche controlli, controlli, controlli →

Varie tecniche

- Test di qualificazione (Qualification test)
- Controlli sintattici
- Test nascosti (Gold questions, honey pots, coerenza)
- Monitoraggio del comportamento (tempo, azioni, log, ...)
- (Sono pur sempre design del task)

Test di qualificazione

- Qualification test
- Prima del task
 - Se un worker vuole svolgere il task, deve prima superare un test
- Esplicito, il worker sa che sta facendo un test
- Obiettivo: selezionare worker
 - Competenti, che sperabilmente sanno fare il task
 - Motivati, che sono disposti a provare a superare il qualification test (magari senza paga!)
- 2 possibilità
 - Da piattaforma
 - Interno al task (come prime domande)

Controlli sintattici

- Parsing dell'input
- Evitare risposte non date, campi vuoti
 - Ad es., [InputBox] lasciata vuota,
 - ma anche checkbox con almeno una scelta selezionata...
- Conteggio caratteri / parole / frasi
- Parsing più sofisticati
 - Numeri, date, indirizzi, URL, ...
 - Broken link
 - Spell-check, controllo grammaticale, black-list e white-list di termini
 - ...
- Controllo Copia & Incolla
 - Ad es., se vengono richieste giustificazioni, motivazioni, verificare che non siano sempre le stesse
- Plagio (testi copiati dal web)

Test nascosti

- Nascosti fra le varie parti del task
- Alcune domande servono a misurare la qualità del work(er)
 - "Gold questions", "Honey pots", "Gold nuggets"
 - Domanda (facile) di cui si sa già la risposta
 - Non sempre possibile: task di raccolta opinioni...
 - "Ti piace A?"
 - Confronto di cui si sa la risposta
 - "Quanto è alto il monte Everest?" "Quanto è alto il Monte Bianco?"
 - Anche su task di raccolta opinioni
 - Non so quanto piacciono A e B ma so che A deve piacere più di B
 - Domanda ripetuta dopo un po' (per verificare coerenza)
 - "È più alto il Monte Rosa o il Monte Bianco?" ...
"È più alto il Monte Bianco o il Monte Rosa?"
 - Ma anche "Preferisci A o B?" ... "Preferisci B o A?" (anche su opinioni)

Monitoraggio tempi

- Verifica del tempo impiegato
- Per leggere le istruzioni
- Per leggere il compito
- Sia su singole parti sia sul tempo totale
- Se troppo veloce (inferiore a soglia), worker scartato
- A volte anche se troppo lungo! (probabile worker distratto, magari multitasking)

Monitoraggio azioni

- Verificare spostamenti del mouse
- Focus on / Focus off
- Scrolling
 - (ad es. per vedere se un testo viene letto interamente)
- Click su pulsanti, link, slider, ecc.
 - (ad es. per verificare che lo slider venga mosso dal default)
- Ordine di inserimento dati
 - (se c'è un ordine non sensato...)
- Se le info sono paginate, pattern di navigazione fra le pagine (Next / Previous)
- Behavioral logger integrato in Crowd_Frame
 - [Bombassei De Bona], ottima tesi triennale

Controlli in itinere


- Come usarli?
- Se qualità troppo bassa,
 - Work(er) scartato
 - O "pesato" meno
 - (bloccato, non pagato, dati non usati, usati con meno confidenza,...)
- Sia durante il task sia in fase di analisi dati

Controlli ex post

- Anche se il worker ha finito il lavoro e sottomesso i risultati, posso poi decidere di:
 - Non usarli (magari pagandolo comunque)
 - (quando non pago, cala la mia reputazione come requester)
 - Non accettarli e/o non pagarlo
 - Oltre a non pagarlo, bloccarlo, impedendogli di fare altri task (dello stesso batch o in futuro)
- Magari sulla base di analisi più sofisticate di quelle fatte online durante il task
- Ad es.:
 - O usando le risposte degli altri worker allo stesso task
 - O usando le risposte dello stesso worker a tutti i task
 - O analisi automatica offline dei testi
 - O analisi manuale dei testi e/o delle risposte
 - ...



Attitudine

- La qualità non è binaria
 - (perfetto / sbagliato)
- È da massimizzare
- Ci sarà un "tipping point", "punto di svolta"
 - Una soglia
 - Oltre cui la qualità è "abbastanza"



Tipping point

- Es.
 - Problema di classificazione binaria
 - Se il 50% + 1 dei worker dà la risposta corretta
 - Accuratezza media $\sim 50\%$ (poco di più)
 - Ma aggregando con voto a maggioranza (moda) ho accuratezza perfetta
- Fenomeni "in natura" già visti:
 - Giant component ($c > 1$)
 - Diffusione epidemia ($R_0 = \beta / \gamma > 1$)
 - ...




Scaletta

- Controlli in itinere
- Ridondanza & Aggregazione

Ridondanza e aggregazione

- Raccogliere
 - più risposte alla stessa domanda
 - più volte lo stesso dato
- E poi aggregare le risposte in una unica
- È sempre una tecnica di design del task...
- ... ma è importante...
- ... ed è al cuore del crowdsourcing!
- Vediamolo in modo più preciso

Qualità individuale e aggregata

- Def.: **Qualità individuale** della risposta di un singolo worker
 - Similitudine della risposta individuale con il valore corretto
 - (Def. Qualità di un worker = qualità media delle sue risposte)
 - Def.: **Qualità aggregata** delle risposte a un task
 - Ridondanza, più worker fanno lo stesso task
 - Aggregazione
 - Similitudine della risposta aggregata con il valore corretto
- 

Qualità individuale


- Riprendiamo la matrice workers / tasks
 - (che usiamo parecchio oggi)
- E aggiungiamoci La Verità
 - "ground truth"
 - (assunzioni: c'è una e una sola verità, ed è nota)
 - Es.: peso della mucca
 - cv_i : correct value
- **Qualità individuale** = similitudine fra verità e valore dato dal worker sul task
 - Qualche funzione di similitudine
 - Posso parlare di qualità media di worker / task

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

Aggregazione

- Prendo tutte le risposte a un task
- Le aggrego in un valore unico
 - Con qualche funzione di aggregazione
 - (media, mediana, moda, ...)
- → Valore aggregato
 - av_i : aggregated value



Qualità aggregata

- Qualità aggregata = Similitudine fra dato aggregato e verità

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Aggr	av_1	av_2	av_3	...	av_n
Truth	cv_1	cv_2	cv_3	...	cv_n

Congettura del crowdsourcing

- Qualità aggregata > Qualità individuale
- È proprio l'idea del crowdsourcing! 🙋🙋
- La similitudine media con la ground truth è minore per i valori individuali rispetto ai valori aggregati

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Aggr	av_1	av_2	av_3	...	av_n
Truth	cv_1	cv_2	cv_3	...	cv_n

Esempio

- Document relevance

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...				...	
w_m		N	R		

Document Relevance Evaluation

Instructions

Evaluate the relevance of a document to the space program topic. A document is relevant if it would be useful if you were writing a report on the space program topic. Each document should be judged on its own merits. That is, a document is still relevant even if it is the thirtieth document you have seen with the same information.

Tips

- Payment based on quality of the work completed. Please follow the instructions.
- Be consistent in your judgments.
- A document should not be judged as relevant or irrelevant based only on the title of the document. You must read the document

Task

Please evaluate the relevance of the following document about the space program topic. To be relevant, a document must discuss the goals or plans of a space program or space project and identify the organization(s) sponsoring the program. The space program is a coherent set of initiatives to exploit outer space. The space project is a specific mission to exploit outer space.

\$DOCUMENT\$

Please rate the above document according to its relevance to the space program topic as follows. Note that the task is about how relevant to the topic the document is.

- () Relevant. A relevant document for the topic.
- () Not relevant. The document is not good because it doesn't contain any relevant information.

Esempio

- Document relevance
- Un oracolo ci dice qual è il valore corretto

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...				...	
w_m		N	R		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	R	N	R	...	N
-------	---	---	---	-----	---

Esempio

- Document relevance
- Un oracolo ci dice qual è il valore corretto
- Aggreghiamo a maggioranza
 - (MV, Majority Voting)
 - Moda

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...				...	
w_m		N	R		

Aggr	R	N	R	...	N
------	---	---	---	-----	---

Truth	R	N	R	...	N
-------	---	---	---	-----	---

Esempio

- Document relevance
- Un oracolo ci dice qual è il valore corretto
- Aggreghiamo a maggioranza
 - (MV, Majority Voting)
 - Moda
- Risposte individuali contengono errori
 - Errore medio > 0 , qualità individuale non perfetta

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...				...	
w_m		N	R		

Aggr	R	N	R	...	N
------	---	---	---	-----	---

Truth	R	N	R	...	N
-------	---	---	---	-----	---

Esempio

- Document relevance
- Un oracolo ci dice qual è il valore corretto
- Aggreghiamo a maggioranza
 - (MV, Majority Voting)
 - Moda
- Risposte individuali contengono errori
 - Errore medio > 0 , qualità individuale non perfetta
- Risposte aggregate sono OK
 - Errore medio $= 0$, qualità aggregata massima

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...				...	
w_m		N	R		

Aggr	R	N	R	...	N
------	---	---	---	-----	---

Truth	R	N	R	...	N
-------	---	---	---	-----	---

Più formale

- Come dire che la qualità aggregata è maggiore della qualità individuale?
- La similitudine media con la ground truth dei valori individuali è minore di quella dei valori aggregati

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}		v_{1n}
w_2	v_{21}		v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}		...	v_{3n}
...				...	
w_m		v_{m2}	v_{m3}		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

Notazione

- $w_i \in W = \{w_i | i = 1..m\}$ i worker, e l'insieme dei worker
- $t_j \in T = \{t_j | j = 1..n\}$ i task, e l'insieme dei task
- v_{ij} i valori, le risposte. Risposta mancante: $\perp$
- $W_j = \{w_i \in W | v_{ij} \neq \perp\}$ l'insieme dei worker che hanno risposto al task t_j
- $T_i = \{t_j \in T | v_{ij} \neq \perp\}$ l'insieme dei task a cui ha risposto il worker w_i
- $av_j = F_{aggr}(\{v_{ij} | w_i \in W_j\}) = F_{aggr}(\{v_{ij} | v_{ij} \neq \perp\})$ i valori aggregati per il task t_j
- cv_j i valori corretti per il task t_j

Esempio

- $W = \{w_i | i = 1..m\}$
- $t_j \in T = \{t_j | j = 1..n\}$
- v_{ij} i valori, le risposte
- Risposta mancante: $\perp$
- $W_2 = \{w_1, w_3, w_m\}$ è l'insieme dei worker che hanno fatto il task t_2
- $T_2 = \{t_1, t_3, t_n\}$ è l'insieme dei task a cui ha risposto il worker w_2
- av_j i valori aggregati per il task t_j
- cv_j i valori corretti per il task t_j

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}	$\perp$	v_{1n}
w_2	v_{21}	$\perp$	v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}	$\perp$	...	v_{3n}
...	$\perp$	$\perp$	$\perp$	...	$\perp$
w_m	$\perp$	v_{m2}	v_{m3}	$\perp$	$\perp$

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

Più formale

- Come dire che la qualità aggregata è maggiore della qualità individuale?
- La similitudine media con la ground truth dei valori individuali è minore di quella dei valori aggregati

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}	$\perp$	v_{1n}
w_2	v_{21}	$\perp$	v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}	$\perp$	...	v_{3n}
...	$\perp$	$\perp$	$\perp$	...	$\perp$
w_m	$\perp$	v_{m2}	v_{m3}	$\perp$	$\perp$

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

$$\frac{1}{n} \sum_{j=1}^n \left(\frac{1}{m} \sum_{i=1}^m \text{sim}(v_{ij}, cv_j) \right) < \frac{1}{n} \sum_{j=1}^n \text{sim}(av_j, cv_j) \quad (\text{Ok solo se la matrice è completa})$$

$$\frac{1}{n} \sum_{j=1}^n \left(\frac{1}{|W_j|} \sum_{\{i | w_i \in W_j\}} \text{sim}(v_{ij}, cv_j) \right) < \frac{1}{n} \sum_{j=1}^n \text{sim}(av_j, cv_j)$$

Similitudine?

- Nozione delicata... semplifichiamo
- Una possibilità
- L'opposto della distanza
- La distanza media dalla ground truth dei valori individuali è maggiore di quella dei valori aggregati

	t_1	t_2	t_3	...	t_n
w_1	v_{11}	v_{12}	v_{13}	$\perp$	v_{1n}
w_2	v_{21}	$\perp$	v_{23}	...	v_{2n}
w_3	v_{31}	v_{32}	$\perp$	...	v_{3n}
...	$\perp$	$\perp$	$\perp$	...	$\perp$
w_m	$\perp$	v_{m2}	v_{m3}	$\perp$	$\perp$

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	cv_1	cv_2	cv_3	...	cv_n
-------	--------	--------	--------	-----	--------

$$\frac{1}{n} \sum_{j=1}^n \left(\frac{1}{|W_j|} \sum_{\{i | w_i \in W_j\}} |v_{ij} - cv_j| \right) > \frac{1}{n} \sum_{j=1}^n |av_j - cv_j|$$

Congettura del crowdsourcing: quando non è vera?

- Quando la qualità individuale è così bassa che aggregandola la rinforzo e faccio peggio
- Ad es., classificazione con risposte in $\{0, 1\}$
 - Se la classe corretta è 0 ma maggioranza dice 1...
- Se il 50% + 1 dei worker dà la risposta sbagliata...
- Il tipping point funziona in entrambi i versi!

$$\frac{1}{n} \sum_{j=1}^n \left(\frac{1}{|W_j|} \sum_{\{i | w_i \in W_j\}} |v_{ij} - cv_j| \right) > \frac{1}{n} \sum_{j=1}^n |av_j - cv_j|$$

Funzioni di aggregazione

$$av_j = F_{aggr}(\{v_{ij} | w_i \in W_j\}) = F_{aggr}(\{v_{ij} | v_{ij} \neq \perp\})$$

- Moda, A maggioranza, MV (Majority Voting)
- Mediana
- Media aritmetica
- Media geometrica
- Media armonica
- ...
- ... non sempre è semplice scegliere
 - Accenniamo il perché
 - ($\rightarrow$ prox. lezione)

Esempio

- v_{ij} è
 - o Relevant (R)
 - o Not relevant (N)
- Idem per cv_j

	t_1	t_2	t_3	...	t_n
w_1	R	N	R		R
w_2	R		N	...	N
w_3	R	N		...	N
...				...	
w_m		N	R		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	R	N	R	...	N
-------	---	---	---	-----	---

Esempio

- v_{ij} è
 - o Relevant (**1**)
 - o Not relevant (**0**)
- Idem per cv_j

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...				...	
w_m		0	1		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	1	0	1	...	0
-------	---	---	---	-----	---

Esempio

- v_{ij} è
 - o Relevant (1)
 - o Not relevant (0)
- Idem per cv_j
- E av_j ?

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...				...	
w_m		0	1		

Aggr	av_1	av_2	av_3	...	av_n
------	--------	--------	--------	-----	--------

Truth	1	0	1	...	0
-------	---	---	---	-----	---

Aggregazione con Moda

- Moda (MV)
- + Valori ammissibili
- - Perdo informazioni

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...				...	
w_m		0	1		

Aggr	1	0	1	...	0
------	---	---	---	-----	---

Truth	1	0	1	...	0
-------	---	---	---	-----	---

Aggregazione con Media

- Media aritmetica
- - Valori non ammissibili
- + Perdo meno informazioni
- ($\rightarrow$ prox. lezione)

	t_1	t_2	t_3	...	t_n
w_1	1	0	1		1
w_2	1		0	...	0
w_3	1	0		...	0
...				...	
w_m		0	1		

Aggr	1	0	$2/3$	...	$1/3$
------	---	---	-------	-----	-------

Truth	1	0	1	...	0
-------	---	---	---	-----	---

Riassunto

- Controlli in itinere
- Ridondanza & Aggregazione

Riassunto: Tecniche per qualità


- Metodologiche
 - Design del task (Pairwise, scale, ...)
- In itinere
 - Qualification test
 - Controlli sintattici
 - Test nascosti (Gold questions, honey pots, coerenza)
 - Monitoraggio del comportamento (tempo, azioni, log, ...)
- Ridondanza. Aggregare
- Ex-post
 - Pulizia dati (rimozione outlier, ecc.)
 - Aggregazione sofisticata (co-determination algorithms)
 - Sfruttare l'accordo / agreement

Biblio

- Eh...

[Alonso, cap. 2 (e capp. 1, 6)]

- Omar Alonso, *The practice of Crowdsourcing*, Morgan & Claypool, 2019



[Li et al, cap. 3]

- Guoliang Li, Jiannan Wang, Yudian Zheng, Ju Fan, Michael J. Franklin. *Crowdsourced Data Management – Hybrid Machine-Human Computing*, Springer, 2018

